航 空 学 报
Acta Aeronautica et Astronautica Sinica

Apr. 25 2025 Vol. 46 No. 8
ISSN 1000-6893 CN 11-1929/V

http://hkxb.buaa.edu.cn hkxb@buaa.edu.cn

引用格式：姜凌峰，李新凯，张海，等. 基于改进TD3算法的无人机动态环境无地图导航[J]. 航空学报，2025，46(8)：331035. JIANG L F，LI X K，ZHANG H，et al. Mapless navigation of UAVs in dynamic environments based on an improved TD3 algorithm[J]. Acta Aeronautica et Astronautica Sinica，2025，46(8)：331035 (in Chinese). doi：10.7527/S1000-6893.2024.31035

基于改进TD3算法的无人机动态环境无地图导航

姜凌峰[1]，李新凯[1,*]，张海[2]，李涵玮[1]，张宏立[3]

1．新疆大学 电气工程学院，乌鲁木齐 830017
2．新疆大学 工程训练中心，乌鲁木齐 830017
3．新疆大学 智能科学与技术学院（未来技术学院），乌鲁木齐 830017

摘 要：针对无人机导航系统在未知动态环境中难以进行建图、导航的问题，提出了基于改进双延迟深度确定性策略梯度(TD3)算法的端到端无地图导航方法。为解决无地图环境下无人机感知受限问题将导航模型定义为部分可观马尔科夫决策过程(POMDP)引入门控循环单元(GRU)，使得策略网络能够利用历史状态的时序信息获取最优策略，避免陷入局部最优；基于TD3算法引入softmax算子对值函数进行处理，同时采用双策略网络，以解决TD3算法中存在策略函数不稳定和值函数低估问题；设计非稀疏奖励函数，解决强化学习策略在稀疏奖励条件下难以收敛的问题。最后，在AirSim平台上进行仿真实验，结果表明，相比传统深度强化学习算法，改进算法在无人机无地图避障导航问题上，具有更快的收敛速度和更高的任务成功率。

关键词：无地图导航；深度强化学习；确定策梯度；无人机；动态环境

中图分类号：V279 **文献标识码**：A **文章编号**：1000-6893(2025)08-331035-16

近年来，随着低空经济的不断发展，无人机(Unmanned Aerial Vehicle，UAV)作为一种多用途无人载具，因其具有灵活轻便、结构简单、造价低廉等优势，在物流运输、电力巡检、农业植保等民用领域发挥了重要作用[1-2]。无人机自主导航任务是指在城市、森林等复杂环境中，无人机自主规划从起始位置到目标位置的行驶轨迹以避开障碍物并优化行驶距离。随着无人机的广泛应用，在复杂环境中快速、准确地规划出一条安全便捷的导航路径，是实现各项复杂作业任务的重要前提[3]。

面对无人机自主避障导航问题，现有的研究根据是否具有已知的全局地图分为基于地图的导航和无地图导航。随着同步定位与地图创建(Simultaneous Localization And Mapping，SLAM)技术的快速进步，基于全局地图的导航技术取得了显著的成果[4-5]。SLAM方案的首要工作是使用视觉图像、激光雷达等传感器配合里程计进行定位建图，获取先验地图，再在先验地图的基础上使用全局路径规划器进行全局路径规划，最后使用局部避障规划器应对导航过程中未记录障碍和一些意外情况[6]。但当无人机部署在动态、复杂的场景中时，由于存在大量移动的障碍物，无人机必须实时调整移动路径以避开这些动态障碍物。此外，动态障碍物的频繁变化对机器人平台的计算能力和传感器精度提出了巨大挑战。

收稿日期：2024-08-02；**退修日期**：2024-11-04；**录用日期**：2024-12-06；**网络出版时间**：2024-12-13 13:34
网络出版地址：https://hkxb.buaa.edu.cn/CN/Y2025/V46/I8/331035
基金项目：国家自然科学基金(62263030)；新疆维吾尔自治区自然科学基金(2022D01C86)
*通信作者. E-mail：lxk@xju.edu.cn

基于地图的导航方法难以处理复杂动态障碍物[7],从而影响自主导航的准确性和可靠性,同时建立高精度的全局地图依赖昂贵且复杂的传感器,大大增加任务难度和系统的整体负担[8]。无人机飞行一般采用全球定位系统(Global Positioning System, GPS)结合惯性测量单元(Inertial Measurement Unit, IMU)的定位方式,无人机在飞行时可能会进入GPS信号拒止区域,此时只能依赖惯性导航系统(Inertial Navigation System, INS)进行定位。INS在运行时会有误差的累计,导致定位误差随时间增大,基于学习的导航算法能够从IMU信号中提取空间特征并跟踪其时间特征,以提高导航性能为减少对地图数据的依赖,同时增强无人机适应复杂环境的自主能力。因此,基于深度强化学习的无地图导航问题成为了自主导航领域的一个重要研究方向。

深度强化学习(Deep Reinforcement Learning, DRL)作为机器学习的重要分支之一,被广泛应用于解决复杂决策问题[9-12]。确定性策略梯度(Deterministic Policy Gradient, DPG)解决了强化学习中的连续控制问题[13]。Lillicrap等[14]结合深度神经网络对DPG网络进行了改进,使用了经验回放和目标网络。在此基础上,Silver等[15]提出了基于演员-评论家(Actor-Critic)框架的深度确定性策略梯度(Deep Deterministic Policy Gradient, DDPG),该算法将深度神经网络应用于确定性策略梯度算法中。Fujimoto等[16]在此基础上提出双延迟深度确定性策略梯度(Twin Delayed Deep Deterministic policy gradient, TD3)算法利用双Q学习网络减缓了Q值过估计的问题,同时使用延迟更新策略减小了Q值误差。

深度强化学习因较强的泛化以及对复杂策略的学习能力,在无地图导航问题上展现出显著优势[17-18]。近年来,众多学者都投入到这方面的研究中,提出了各种模型和算法用于解决无人机自主导航问题。Cui等[19]提出了一种基于Q学习的多层路径规划算法,该算法简化了获取最优策略的难度,大大提高了网络收敛速度。然而,该方案使用的深度Q网络(Deep Q Network, DQN)只能处理离散变量,因此需要将无人机的控制信息进行映射,无法直接输出速度和角度控制。Xue等[20]基于演员-评论家框架设计了一种在线求解的快速循环随机梯度算法,所提出的算法能够进行安全导航,但文章仅使用最简单的距离传感器来获取状态量,该方案在实际应用中具有一定的局限性。Everett等[21]提出了一种应用于复杂动态环境的DRL导航方法,但该方法对动态障碍物的处理有严格的要求。要求提前了解动态障碍物的精确位置,以及掌握所有动态障碍物的预期速度,这在有遮挡的动态环境中很难实现。

综上所述,未知动态环境中基于深度强化学习的无人机自主导航应考虑以上问题:由于缺乏全局先验地图以及环境的局部可观性,无人机仅依靠当前时刻的观测信息难以评估环境状态以执行安全合理的导航策略;深度强化学习策略在稀疏奖励条件下难以收敛的问题;在训练过程中,缺乏策略多样性与探索导致无人机的导航算法经常陷入局部最优解,甚至发生碰撞。

为此,本文提出了适用于动态复杂场景的基于TD3的改进算法(GRU Softmax Deep Double Deterministic policy gradients, G-SD3),该算法主要创新点如下。

1) 为解决无人机避障导航中感知受限问题,将无地图无人机导航问题建模为部分可观马尔科夫决策过程(Partially Observable Markov Decision Process, POMDP)。引入GRU网络,使得策略网络能够有效利用历史状态的时序信息。通过对历史记忆信息与当前的观测整合处理,提取观测数据的时序依赖关系,从而避免算法陷入局部最优解,提高了算法优化效果和导航性能。

2) 在TD3网络的基础上使用了双Actor网络进行策略选择,优化了策略获取,同时使用Softmax算子对Q值进行平滑处理,改善了TD3中Q值低估问题,提高了算法收敛速度。

3) 采用双目视觉传感器获取深度图像数据构建无人机无地图导航问题的状态空间,同时重新设计引导完成自主导航任务的非稀疏奖励函数,使无人机能够在复杂动态环境中迅速做出反应高效完成导航任务。

1 问题描述与模型建立

1.1 无人机坐标系及环境感知

假设一架无人机从三维世界中的任意位置(起点)起飞,其飞行任务目标为在复杂环境中避开各类障碍物,成功导航到达目标点(终点)。在这个过程中,可以使用地球坐标系来描述其绝对位置,即$\boldsymbol{\partial}=[x,y,z,\theta_x,\theta_y,\theta_z]$。通过机体坐标系来表征无人机的平移运动和旋转运动,即$\boldsymbol{\mu}=[a,b,c,\theta_a,\theta_b,\theta_c]$。固定的世界坐标系和机体坐标系共同表示无人机的速度、方向和高度。

为了更好地适应实际应用,需要在无人机导航研究中考虑高度变化的因素,以实现更灵活和高效的导航,如图1所示。本文将无人机的飞行高度设置为[0,5] m。进而无人机位置、方向和运动的向量可以简化为$\boldsymbol{\mu}=[x,y,z,\theta]$,则无人机的动力学可以表示为

$$\begin{cases} v_{t+1}=v_t+\rho_t \\ \phi_{t+1}=\phi_t+\varphi_t \\ x_{t+1}=x_t+v_{t+1}\times\cos(\phi_{t+1}) \\ y_{t+1}=y_t+v_{t+1}\times\sin(\phi_{t+1}) \end{cases} \tag{1}$$

式中:v_t和ϕ_t表示无人机在时间步t时的速度和前进方向,ρ_t和φ_t表示无人机速度和角度增量[22]。

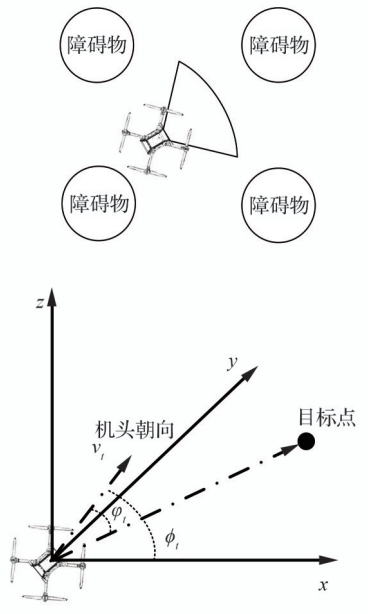
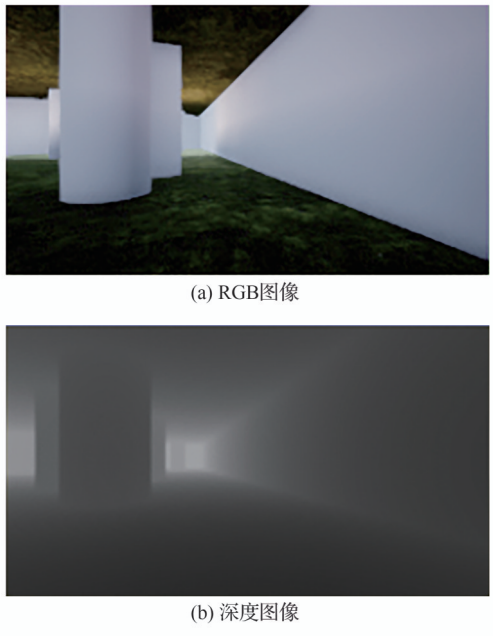


图1 无人机导航示意图

Fig. 1 UAV navigation diagram

本文采用双目深度相机实时获取高分辨率深度图像进行环境感知、获取。视觉传感器具有尺寸小,功耗低等优点,适合与无人机结合用作飞行环境的场景感知,双目视觉传感器获取深度图像如图2所示。



(a) RGB图像

(b) 深度图像

图2 深度图像示意图

Fig. 2 Depth image schematic

深度图像为无人机提供了详细的环境信息,使其能够准确避开障碍物。精准的障碍物识别能力显著提升了避障决策的准确性和导航效率,从而增强了无人机在复杂环境中的自主导航能力。

1.2 未知动态环境下无地图导航任务描述

由于无人机导航问题中的决策过程具有马尔科夫性质,即下一个状态只依赖于当前的状态和动作,而与之前的历史状态无关,因此通常将这类问题建模为马尔科夫决策过程(Markov Decision Process, MDP)。然而,MDP模型理论建立在无人机能够完全捕获当前环境的所有状态信息,这与实际场景并不符合。在真实环境中,由于没有先验地图帮助,无人机仅能通过传感器观测到机身周围的部分环境信息,无法

获取全局地图信息。因此，该决策范式更符合POMDP[23]。POMDP模型去除了环境状态完全可观的假设，由7元组$(S, A, T, O, Z, R, \gamma)$组成，其中，$S$为无人机状态集合；$A$为无人机动作集合；$T$为转移函数，描述给定当前状态$s$和无人机采取动作$a$后，转移到下一个状态的概率分布

$$T(s'|s,a)=P(s'|s,a) \tag{2}$$

式中：s'是下一个状态，s为当前状态，a为无人机选择的动作；O表示无人机获取的观测信息集合。Z为在给定当前状态s和无人机采取动作a后，得到的观测值o的概率分布

$$Z(o|s',a)=P(o|s',a) \tag{3}$$

式中：o是无人机的观测值；R表示在给定当前状态s和无人机采取动作a后获取的奖励总和。POMDP框架允许模型在状态信息不完全的情况下进行决策，同时该框架允许无人机根据实时观测到的环境变化动态调整策略，这与无人机在实际环境中的导航需求相符合。

因此，本文将动态环境下无地图导航任务定义为部分可观测马尔科夫决策过程POMDP，使用环境观测代替环境状态。从而采用强化学习模型框架进行求解，具体任务模型如图3所示。

观测空间基于深度图像和无人机位置信息定义，动作空间根据无人机动力学模型参数设计，并结合非稀疏奖励思想设计奖励函数。为解决无人机在无地图环境中的避障导航问题，采用了改进的DRL算法。通过该算法训练无人机避

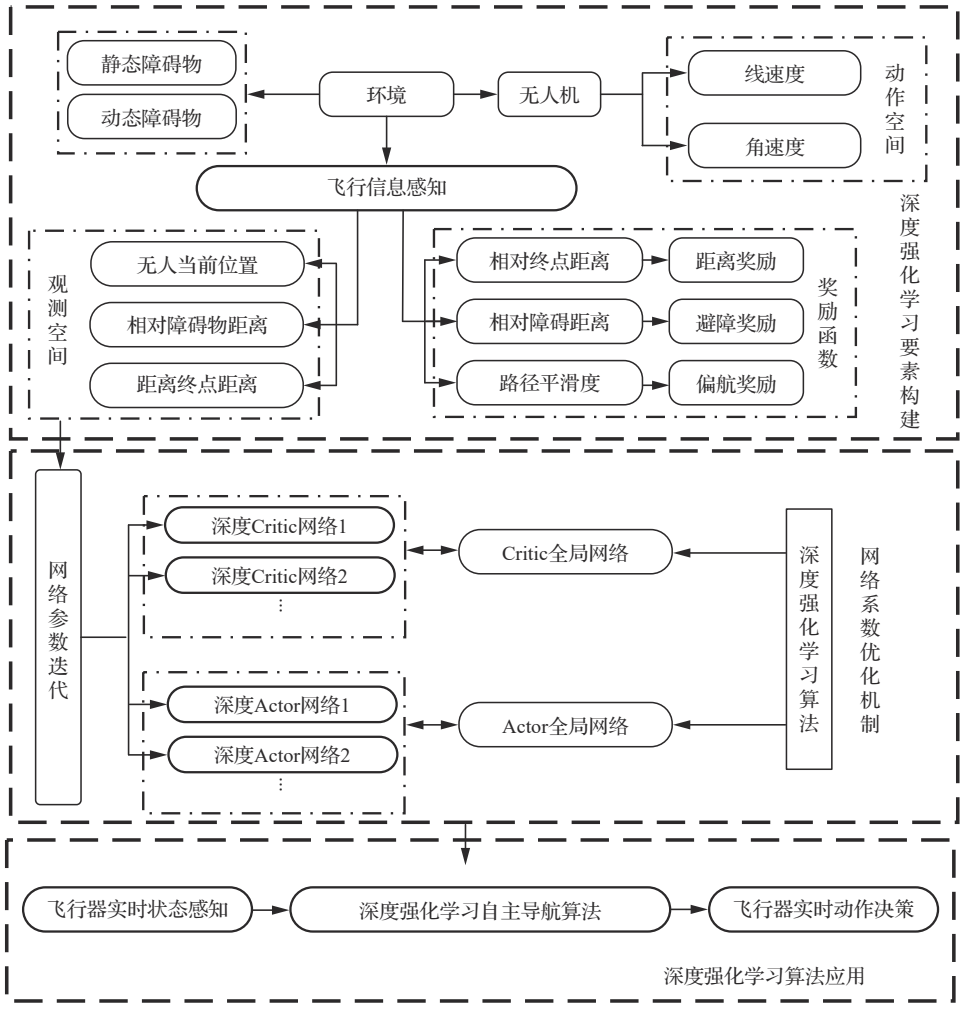


图3 无人机避障导航系统模型

Fig. 3 Model of UAV obstacle avoidance navigation system

障导航系统模型，优化无人机在实时飞行中的决策能力，其在动态环境中自主完成导航任务，并安全准确地到达目标点，该方法能够提升感知和处理动态障碍物的能力。这可以改进障碍物检测和运动预测，优化路径规划和决策策略等方面。

2 系统框架及网络结构

2.1 循环神经网络

循环神经网络（RNN）的主要特点是在一定的时间节点内，神经元的输出可以再次用作神经元的输入[24]。这种序列化的网络结构能够在很大程度上保留数据中的时间依赖关系，因此非常适合处理时间序列数据。门控循环单元[25]（GRU）作为RNN的一种变体，与传统的长短期记忆网络（Long Short-Term Memory，LSTM）相比，GRU将遗忘门和输入门合并为1个单一的更新门，并将细胞状态和隐藏状态混合为1个新的状态，从而减少了神经网络的计算量，加快了网络的训练时间。GUR网络结构图如图4所示。

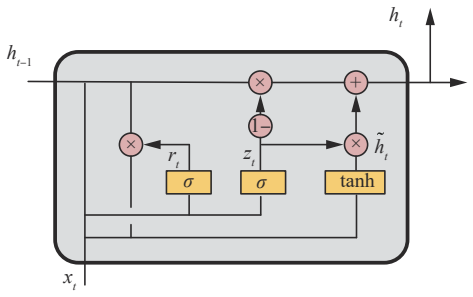


图4 GRU网络结构图

Fig. 4 GRU network structure

无人机自主导航任务中存在的观测问题，具体可以描述为：假设无人机已到达A点，如图5所示，它将向前移动至C点以接近目标点。此时，无人机发现前方有障碍物，应选择向左、向右或向后移动。如果选择到达左侧的D点，因为没有循环神经网络的无人机会忘记C点的环境结构，而是被鼓励接近目标点，从而到达B点或C点。同样，如果无人机选择到达在C点右侧的E点，或者直接选择回到B点，最终都会

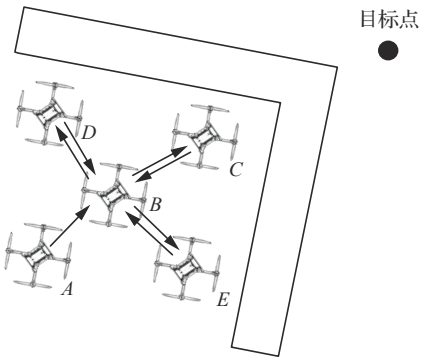


图5 可行进方向示意图

Fig. 5 Feasible direction diagram

陷入B点和C点之间的困境，循环而无法逃脱。造成这种情况的主要原因是由于无人机机载传感器只能感知有限范围内的障碍物。因此，如果无人机无法记住它经历过的环境，就无法理解相似环境并做出决策。

无人机导航问题作为一个典型的顺序决策问题，需要在飞行过程中不断做出路径选择和调整，引入GRU可以较好地处理长序列数据中的长期依赖问题，能更好的解决顺序决策问题。避免在类似图5的环境中陷入循环路径，导致训练失败。具体实现方案为将无人机观测、动作向量优先传入GRU网络拟合时间信息后再传入全连接层网络，进行特征提取。这种结合利用了GRU在处理时间序列数据方面的优势，使无人机能够利用历史信息进行决策，从而在复杂的环境中实现更为有效的避障和导航。结合GRU网络的Actor和Critic网络如图6所示。

2.2 奖励函数设计

奖励函数表征了算法的学习目标，通过奖励的反馈指导智能体在不同行动中做出决策。一个合理设计的奖励函数可以促进策略网络学习，帮助智能体有效地解决问题并达到预期目标。因此，本文根据无人机实际的飞行情况与无地图导航任务相结合，重新设计奖励函数。

为实现无人机根据感知到的环境状态做出最优的决策，须设计适当的奖励函数来控制其运动轨迹。动态环境中无人机自主导航任务为典型的稀疏奖励任务，只有在到达终点时才能获得奖励[26]。虽然奖励简单，但因为初始策略

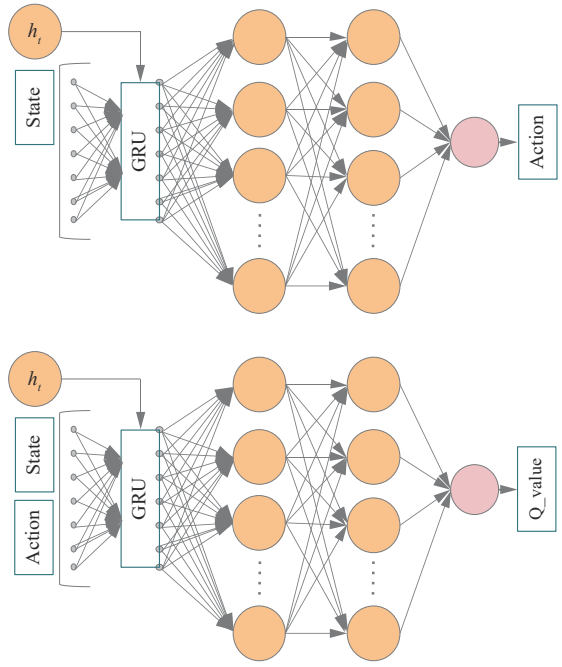


图 6 Actor、Critic网络结构图

Fig. 6 Structure diagram of Actor and Critic network

是随机的，使得无人机在复杂动态环境下完成导航任务的概率较低，进而导致算法收敛非常缓慢。为加快训练速度，现将奖励重新设计为非稀疏奖励。在现有的研究中，为解决稀疏奖励问题，人们提出了许多使用内部奖励的方法来解决智能体探索问题，包括好奇心驱动、基于计数和基于状态的方法[27]。这些方法都重新设计了奖励形式，通过内部激励去完成探索或导航任务，并保证了策略不变性。然而，这些方法的回报的形式取决于状态的潜在变化，在实践中较难应用。

因此，本文为动态环境下无人机导航任务设计了一种非稀疏奖励，无人机做出每个动作后会得到相应的奖励和惩罚，使其能用最优的方式导航到目标点。奖励设计结合无人机导航的领域知识，最终得到了较为满意的奖励函数，该函数由4部分组成：移动奖励、障碍物惩罚、速度惩罚、分段奖励。

首先，将起点到终点的距离均分为 G 份，$\eta_g = D/G$ 当前时刻机器人距离目标点的距离 D_t 小于阈值 η_g 时，计数器 L 增加1位，将整体目标进行拆分为 $g(L)$ 目标位置，当无人机当前位置 d_s 大于等于当前目标位置 $g(L)$ 时，获取对应分段奖励。移动奖励设计为

$$r_{\text{tra}} = \epsilon(d_s - d_{s-1}) \tag{4}$$

式中：ϵ 是比例系数，$d_s - d_{s-1}$ 表示无人机当前位置和上一位置到终点的距离差值。通过该方式，可以有效地激励无人机靠近目的地，同时限制其远离终点。此外，复杂环境下航行最为关键的就是确保无人机的安全，碰撞后获得 -30 奖励，最终非稀疏奖励可以表示为

$$r = \begin{cases} -30 & F = 1 \\ 20 & d \leqslant 1 \\ 10\left(1 + \dfrac{L+1}{n}\right) & l \geqslant g[L] \\ -0.25 & v < v_{\text{lim}} \\ \epsilon(d_s - d_{s-1}) & \theta \leqslant |30| \\ -0.5 & \text{其他} \end{cases} \tag{5}$$

式中：v 为无人机当前时刻速度，设定 v_{lim} 为飞行最慢速度 0.2 m/s，当速度小于 0.2 m/s 时无人机会得到低速惩罚。偏航角 ϕ 为无人机机头位置与目标点之间角度差，当偏角小于30°时认为无人机在面向终点移动时，获取相应距离奖励。

在实际应用过程中，根据各种场景对公式中的数进行微调，以使策略适合导航任务。最终，获取该轮从开始时刻到结束时刻的累积奖励，即

$$R = R_{t+1} + R_{t+2} + \cdots + R_n \tag{6}$$

2.3 TD3算法框架

TD3算法全称为双延迟深度确定性策略梯度，是一种确定性策略的深度强化学习方法，适用于具有连续动作空间的决策任务，TD3算法主要解决了DDPG中存在的 Q 值过估计问题。DDPG算法旨在获得带有参数 θ 的确定性策略 μ^θ，并计算现有策略Q的真实动作值

$$\frac{\partial J(\theta)}{\partial \theta} = \mathbb{E}_{s\sim\rho^\mu}\left(\frac{\partial Q^\mu(s,a)}{\partial a}\Big|_{a=\mu^\theta(s)} \frac{\partial \mu^\theta(s)}{\partial \theta}\right) \tag{7}$$

式中：期望值与当前策略 μ^θ 引起的折扣状态访问分布 ρ^μ 有关。然而，DDPG算法对参数的敏感性较高难以收敛。为了解决上述问题，TD3算法通过引入双Q网络和延迟更新目标网络的策略，提高了 Q 值函数估计的稳定性，同时利用双重噪声

策略进一步增强了策略的探索性。

TD3算法采用延迟学习和梯度截取的方法，评价网络的更新频率高于策略网络。评价网络会先更新多次，之后再更新策略网络。这种方式可以减少策略网络的更新误差，并将策略网络参数的梯度更新限制在合理范围内，采用双评价网络结构，能够有效的解决DDPG算法持续过估计的问题。TD3算法的基本框图如图7所示。

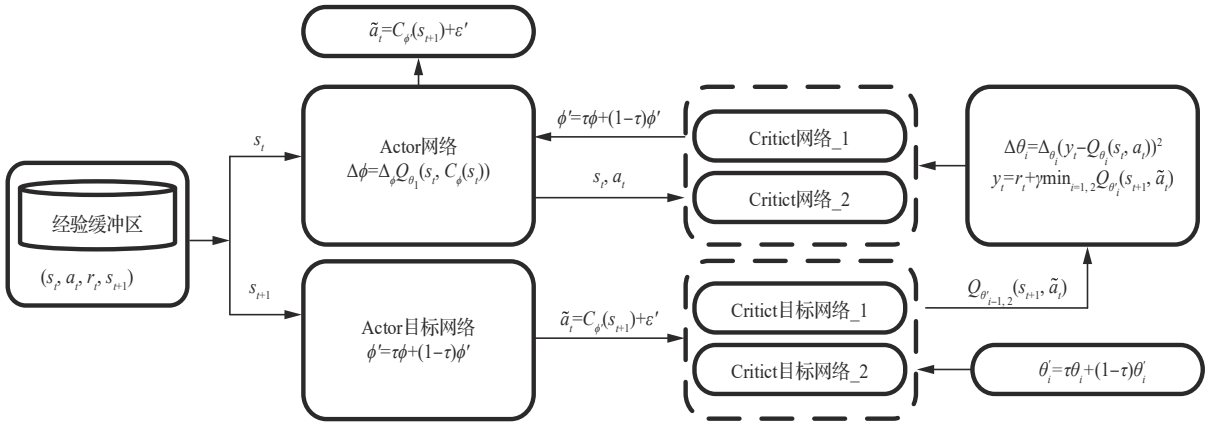


图 7 TD3网络结构图

Fig. 7 TD3 network structure diagram

从图中可以看出，Actor网络C_{ϕ}根据当前状态s_t输出当前动作a_t，Actor目标网络C_{ϕ}根据下一个状态s_{t+1}输出目标动作a_t。Critic网络Q_{θ_i}在状态s_t和动作a_t情况下计算Q值$Q_{\theta_i}(s_t, a_t)$，Critic目标网络$Q_{\theta'_i}$则计算在下1个状态s_{t+1}和目标动作$\tilde{a}_t$情况下的目标Q值$Q_{\theta'_i}(s_{t+1}, \tilde{a}_t)$。$\phi$和$\theta_i$分别是Actor网络和Critic目标网络的参数，$i=1, 2$。当Critic网络更新参数时，选取2个Critic目标网络中更小的Q值作为目标值y_t，即

$$\begin{cases}\Delta\theta_i=\nabla_{\theta_i}\left(y_t-Q_{\theta_i}(s_t, a_t)\right)^2\\ y_t=r_t+\gamma\min_{i=1,2}Q_{\theta_i'}(s_{t+1}, \tilde{a}_t)\\ \tilde{a}_t=C_{\phi'}(s_{t+1})+\varepsilon'\end{cases}\tag{8}$$

式中：ε'是添加的随机噪声，服从截断正态分布$\mathrm{clip}(N(0, \sigma), -c, c)$，$c>0$。Actor网络和4个目标网络的参数按照式(9)更新

$$\begin{cases}\Delta\phi=\nabla_{\phi}Q_{\theta_1}(s_t, C_{\phi}(s_t))\\ \theta_i'\leftarrow\tau\theta_i+(1-\tau)\theta_i'\\ \phi'\leftarrow\tau\phi+(1-\tau)\phi'\end{cases}\tag{9}$$

式中：$\tau\leqslant 1$。

TD3算法通过引入双Q值和延迟更新机制有效缓解了DDPG算法中存在的Q值过估计问题，如下

$$y_t=r_t+\gamma\min_{i=1,2}Q_{\theta_i'}(s_{t+1}, \tilde{a}_t)\tag{10}$$

但是，该方法会导致较大的低估偏差，影响网络的整体性能，导致算法的决策性能下降，收敛速度减慢。

2.4 G-SD3算法框架

TD3算法采用的状态值函数更新策略只是简单选用双Critic网络中较小的Q值作为最终评价Actor网络效果的指标，这种方式会导致网络一味采取低Q值策略，即算法对动作价值的估计低于其真实值[28]，这种低估会长期维持，影响算法性能，SD3算法通过加入Softmax算子将值函数映射为一个概率分布，这个分布反映了在给定状态下选择各个动作的相对概率。具体来说，Softmax算子将Critic网络得到的Q值向量输入并转换为概率向量，其中每个动作的概率与它的Q值成指数关系。Softmax函数的关键在于它只关心Q值之间的相对差异，而不是Q值的绝对差异。这意味着，如果所有Q值都增加或减少相同的量，Softmax输出的概率分布不会改变，因为概率是由Q值之间的相对大小决定的。其次，SD3算法有助于在探索新动作和利用已知最佳动作之间取得平

衡。能够给非最优动作分配一定的概率,鼓励探索,同时保留算法利用已知信息的能力,加快算法收敛速度。这使得SD3算法在解决复杂决策环境中的强化学习问题时表现的更加稳健和高效[29]。

SD3算法在式(8)的基础上通过式(9)更新Critic网络中Q值,并更新目标值

$$y_i = r_t + \gamma T_{\mathrm{SD3}}(s') \tag{11}$$

式中:$T_{\mathrm{SD3}}(s')$可表示为

$$T_{\mathrm{SD3}}(s') = \mathrm{softmax}_{\beta}\left(\hat{Q}_i(s', \cdot)\right) \tag{12}$$

$$\hat{Q}_i(s', a') = \min\left(Q_i(s', a';\ \theta_i'), Q^{-i}(s', a';\ \theta'_{-i})\right) \tag{13}$$

式中:y_i为第i个训练样本的目标Q值;r_i为第i个样本当前时刻奖励值;s'和a'为当前时刻的状态和动作。

本文提出的G-SD3算法是在SD3算法的基础上加入了GRU网络,使无人机能够总结和利用动态障碍物的时序信息,从而更好地完成未知动态环境中的自主导航任务。时序策略网络的核心在于使用历史信息h_t,通过梯度上升的方式更新网络参数。通过式(14)近似求解

$$\frac{1}{NT}\sum_i\sum_t\left[\nabla_{\phi_i}\left(\pi\left(h_t;\ \phi_i\right)\right)\nabla_a Q_i\left(h_t, a_t;\ \theta_i\right)\big|_{a=\pi(s;\,\phi_i)}\right] \tag{14}$$

式中:N表示每轮训练过程中的样本数据。T表示h_i经过GRU处理后的有效关联信息,进而使得期望回报最大化。

G-SD3目标网络通过历史信息h_i和目标策略网络输出目标动作a_{t+1}来估计下一时刻的策略评价值如下

$$y_i \leftarrow r_t + \gamma(1-d)\,\mathrm{softmax}_{\beta}\left(\hat{Q}\left(h_{t+1}, \cdot\right)\right) \tag{15}$$

此外,算法中引入了延时更新策略,并将Actor、Critc网络的激活函数修改为tanh(),以优化网络的整体参数,并采用线性衰减学习率的方式,增强训练后期的平稳性,提高训练的效果。

在对目标网络更新过中,采用与TD3目标网络更新相同方案,使目标Actor、Critic网络整体参数变化不会过于剧烈,提升了算法的稳定性。使无人机能够更全面地探索环境信息,获得更平滑的动作策略。完整的算法步骤如算法1所示。

算法1 G-SD3

1:使用随机参数θ_1、θ_2、ϕ_1、ϕ_2初始化Critic网络Q_{θ_1}、Q_{θ_2}和Actor网络π_{ϕ_1}、π_{ϕ_2}

2:初始化目标网络$\theta_1' \leftarrow \theta_1$,$\theta_2' \leftarrow \theta_1$,$\phi_1' \leftarrow \phi_1$,$\phi_2' \leftarrow \phi_2$

3:初始化经验池B

4:初始化历史信息h_0

5: for $t=1$ to T do

6: 接收观察信息o_t

7: 将观察信息和先前动作附加到历史信息中 $h_t \leftarrow h_{t-1}, a_{t-1}, o_t$

8: 基于π_ϕ选择具有探索噪声$\epsilon \sim \mathcal{N}(0, \sigma)$的动作$a_t$

9: 执行动作a_t、观察奖励r_t、新状态o_{t+1}和完成标志d

10: 将获取的数据转换为$(o_t, a_t, r_t, o_{t+1}, d)$存储在经验池$B$中

11: for $i=1, 2$ do

12: 从B中连续采样N个样本$\{(o_t, a_t, r_t, o_{t+1}, d)\}$

13: 构建历史信息$h_t \leftarrow h_{t-1}, a_t, o_t$

14: 样本噪声K为$\epsilon \sim \mathcal{N}(0, \sigma)$

15: $\hat{a}_t' \leftarrow \pi_i\left(h_{t+1};\ \phi_i^-\right) + \mathrm{clip}(\epsilon, -c, c)$

16: $\hat{Q}\left(h_{t+1}, \hat{a}_t'\right) \leftarrow \min_{j=1,2}\left(Q_j\left(h_{t+1}, \hat{a}_t';\ \theta_j^-\right)\right)$

17: $\mathrm{softmax}_{\beta}\left(\hat{Q}\left(h_{t+1}, \cdot\right)\right) \leftarrow \mathbb{E}_{\hat{a}' \sim p}\left(\dfrac{\exp\left(\beta Q\left(h_{t+1}, \hat{a}_t';\ \theta'\right)\right) Q(s', \hat{a}';\ \theta')}{p(\hat{a}')}\right) \Big/ \mathbb{E}_{\hat{a}' \sim p}\left(\dfrac{\exp\left(\beta Q\left(h_{t+1}, \hat{a}_t';\ \theta'\right)\right)}{p(\hat{a}')}\right)$

18: $y_i \leftarrow r_t + \gamma(1-d)\,\mathrm{softmax}_{\beta}\left(\hat{Q}\left(h_{t+1}, \cdot\right)\right)$

19: 更新时序评价网络θ_i $-\dfrac{1}{NT}\sum_i\sum_t\left(Q_i\left(h_t, a_t;\ \theta_i\right) - y_i\right)^2$

20: 更新时序策略网络ϕ_i $\dfrac{1}{NT}\sum_i\sum_t\left[\nabla_{\phi_i}\left(\pi\left(h_t;\ \phi_i\right)\right)\nabla_a Q_i\left(h_t, a_t;\ \theta_i\right)\big|_{a=\pi(s;\,\phi_i)}\right]$

21: 更新目标网络 $\theta_i' \leftarrow \sigma\theta_i + (1-\sigma)\theta_i'$, $\phi_i' \leftarrow \sigma\phi_i + (1-\sigma)\phi_i'$

22: end for

23: end for

由算法1可以看出,G-SD3算法由2组集成了GRU网络的Actor网络和Critic网络组成。环境初始化后,无人机从起点位置开始进行探索,将获取的时间步数据转换为$(o_t, a_t, r_t, o_{t+1}, d)$存储在经验池$B$中,积累一定数据后开始进行网络训练,将样本数据利用GRU网络处理,构建历史信息集h_t,利用双目标Acotr网络计

算对应观测 o_t 下的动作 a' 并根据目标 Crictic 网络评价值选择最优目标动作，之后在目标动作上加入噪声 ϵ，基于双重网络思想取 2 个 Critic 网络输出的最小值作为目标 Q 值，将 Q 值用 Softmax 函数转换为概率分布计算目标值 y，使用历史信息更新时序 Critic 网络中参数，同时 Acotr 网络计算观测 o 下的动作 a，并利用更新后 Critic 网络评估获取的观测动作对，之后将评估值以及历史信息输入 Actor 网络完成对 Actor 网络更新，最终采用软更新策略完成对目标网络的更新。G-SD3 算法的总体框架如图 8 所示。

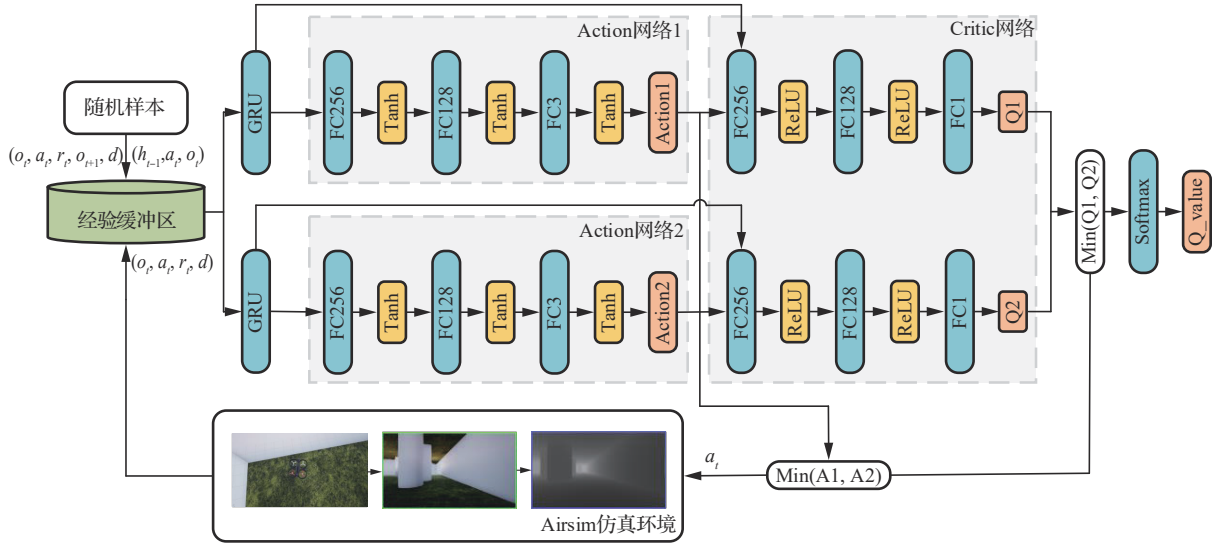


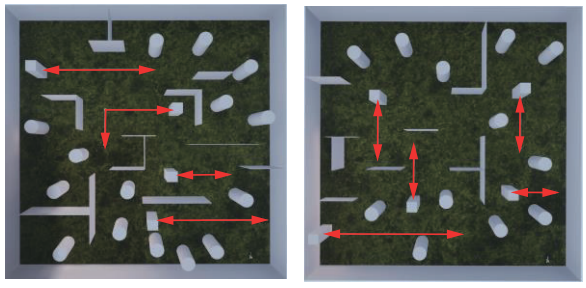
图 8 G-SD3 网络框架图

Fig. 8 G-SD3 network frame diagram

3 仿真实验及分析

3.1 实验环境设置

本节通过在不同复杂度的动态仿真环境中进行实验测试，以验证 G-SD3 算法性能。使用 AirSim 仿真平台构建如图 9 所示 2 组动态仿真环境。仿真环境区域面积约为 $40 \times 40\ \mathrm{m}^2$，地形中障碍物随机摆放，包含各类静态和动态障碍物，其中动态障碍物以 0.2 m/s 的速度在红色轨迹上往复运动。在整个实验过程中，无人机将在环境地图未知的情况下完成导航路径规划。



(a) 环境1 (b) 环境2

图 9 训练环境示意图

Fig. 9 Training environment diagram

Actor 网络的输入包含传感器的观测信息和无人机飞行过程中的状态信息，最终组合为 $\boldsymbol{o}=[\boldsymbol{\psi}, \boldsymbol{\xi}]$，其中 $\boldsymbol{\psi}$ 为深度图像数据进行特征提取获取信息，由于深度图像分辨率较高，若将其直接作为观测输入会导致内存消耗过大计算成本大大增加，因此将深度图像进行栅格化处理，为保证无人机前方信息完整，采用栅格交点范围内最小的深度值，最终得到 $\boldsymbol{\psi}=[d_{i0}, d_{i1}, d_{i2}, d_{i3}, d_{i4}]_{i=0,1,\cdots,5}$ 特征矩阵。无人机自身状态无人机自身速度信息、机体相对目标点的角度和无人机距目标点的距离组成 $\boldsymbol{\xi}=[\varphi_v, \varphi_h, d]$。将 ψ, ξ 拼接后组成 25 维输入状态向量。

组合后的状态向量经过策略网络，最终输出动作 $\boldsymbol{a}_t=[\boldsymbol{\sigma}, \omega]$，其中 $\boldsymbol{\sigma}$ 是无人机轴线方向线

速度向量$[v_x, v_y, v_z]$，ω是无人机偏航角速度，最终将动作向量$\boldsymbol{a}_t$放缩至$(-1,1)$方便后续计算。Critic网络具有相同的结构来加速训练，区别在于它同时使用了状态和动作作为输入。无人机的速度范围限制为$(0,1)$ m/s，飞行高度范围限制为$(0,5)$ m，其他超参数设置如表1所示。

表1 模型超参数设置

Table 1 Model hyperparameter setting

参数	数值
折扣率γ	0.99
学习率μ	1×10^{-4}
经验池尺寸	10^6
经验池批量大小N	256
探索噪声参数τ	2×10^{-1}
目标网络更新率σ	5×10^{-3}

3.2 训练过程展示

每个算法在训练环境中共训练6 000轮，每轮开始时从2个训练环境中任选1组，无人机的初始位置和目标位置在场景固定区域内随机分配，当无人机到达目标点、发生碰撞、或步数达到600步时，结束本轮训练。每进行100轮训练，进行3轮性能测试，并记录奖励曲线。

图10展示了G-SD3算法在2组不同的训练仿真环境中的整体训练轨迹图。可以看出，所提算法能够在无地图条件下顺利完成导航任务，并能在训练仿真环境中进行完整探索。训练结果表明，深度强化学习是有效应对动态环境下无人机导航任务的解决方案之一。G-SD3算法利用历史信息和平滑策略，优化了无人机导航决策，在复杂动态环境中展现出优异的性能。

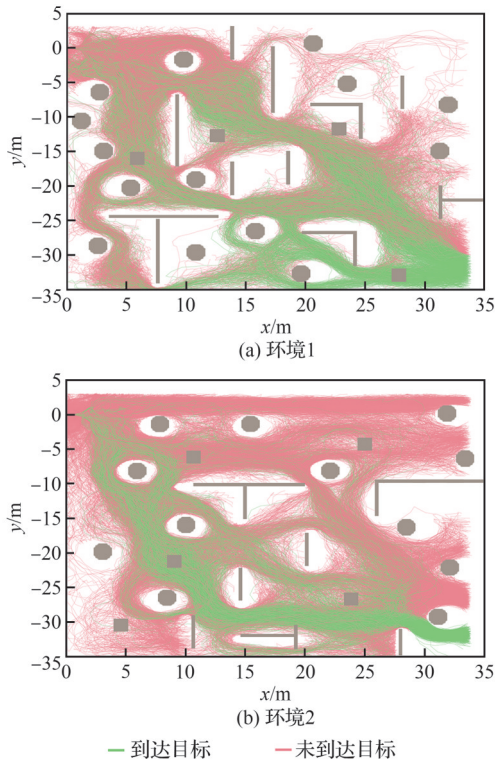


图10 训练轨迹图

Fig. 10 Training trajectory diagram

3.3 对比实验分析

为评估G-SD3算法训练整体效果，选择与目前主流的DRL算法进行对比实验，每种算法采用相同的训练参数设置：算法总训练轮数为6 000轮，每轮最大步数设置200，算法最大训练步数设置为2×10^6步，对比算法介绍如下。

1）DDPG[15]：适用于处理高维度的状态空间和连续的动作空间，通过经验回放提高了训练效率和稳定性。在需要精确控制和平滑动作的任务中表现出色，如机器人运动控制和自动驾驶。

2）TD3[16]：通过延迟更新和双Q网络，有效地减少了过度估计问题，提升了算法的收敛性和表现。适合用于处理高度噪声环境和完成稀疏奖励任务。

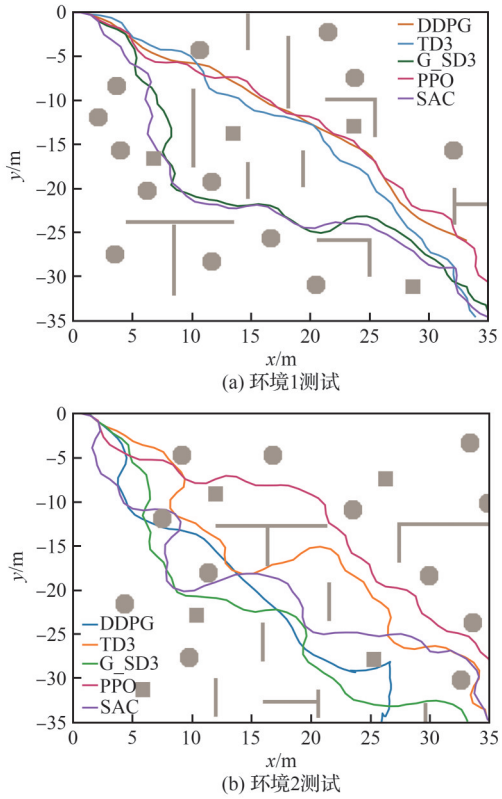
3）PPO[30]：它通过限制策略更新的步长并使用截断的重要性采样来平衡探索与利用，从而稳定和优化策略网络。

4）SAC[31]：一种基于价值的强化学习算法，它通过最大化结合了预期回报和熵（即探索性）的下界来平衡探索和利用。

训练完成后，将训练完成的算法重新部署到训练环境中进行轨迹对比测试，分别评估了5种算法的实际效果。对比结果如图11所示，DDPG面对突然出现的障碍物，无法顺利规避，导航策略整体较为僵硬，无法顺利规避障碍。PPO整体抖动较大，并且学习到的策略较为单一，难以灵活应对动态障碍物。SAC、TD3在路径选择上有着更好的决策，但导航轨迹波动较大，在仿真过程中表现出过度探索的不确定性

行为，导致行进轨迹不平滑。G-SD3算法在图中导航轨迹更为流畅，能够自然的选择更优路径，避障行为更加合理。整体来看，本文所提G-SD3算法在平衡与利用方面表现的更加高效可靠，生成导航轨迹更加稳定。

实验记录每轮的累积奖励，曲线如图12所示。DDPG算法在训练过程中出现较大波动，这可能是因为其过于依赖于目标网络判断，且未采用软更新等策略来增加网络稳定性。使得目标网络参数的更新过于剧烈，导致训练过程出现震荡等不良特性。PPO算法由于其策略更新的截断机制，导致了学习过程不稳定整体效果较差，其保守的更新策略，可能需要更多的训练时间才能达到与其他算法相同的性能水平。TD3算法训练最后得到的累积回报均值不高且波动较大，可能是由于无人机在动态环境中难以预测未来状态和奖励，缺乏有效应对动态环境的策略。在训练过程中容易陷入局部最优解，无法找到全局最优路径，导致累积回报较低。



(a) 环境1测试

(b) 环境2测试

图 11 训练环境下导航轨迹图

Fig. 11 Navigation trajectory diagram in training environment

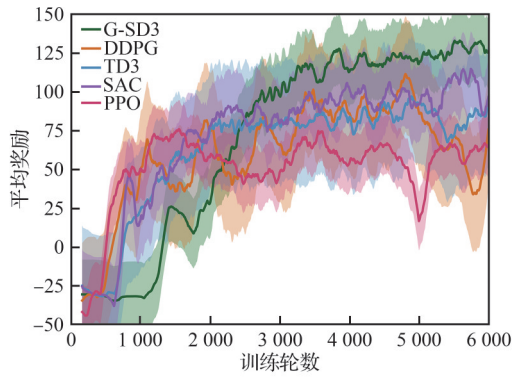


图 12 训练奖励

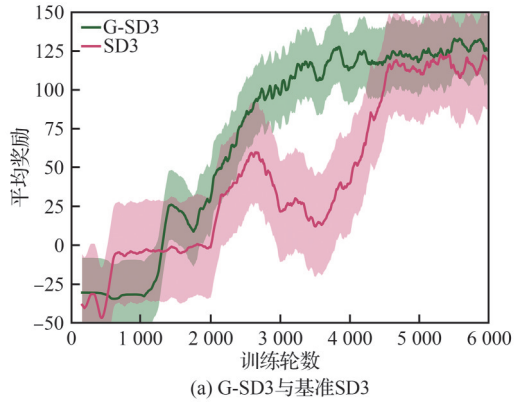
Fig. 12 Training reward

G-SD3算法由于网络模型较为复杂，初期评价网络输出可能不准确，无法准确鉴别价值更高的动作，导致训练曲线表现较差，导航效果不稳定。然而，在经过1 000轮训练后，评价网络能够根据动作的时序性更准确地估计动作价值，并通过Softmax算子降低估计偏差，从而加快模型的收敛速度。收敛后，G-SD3的训练曲线波动较小，且其累积回报在所选算法中表现最优。

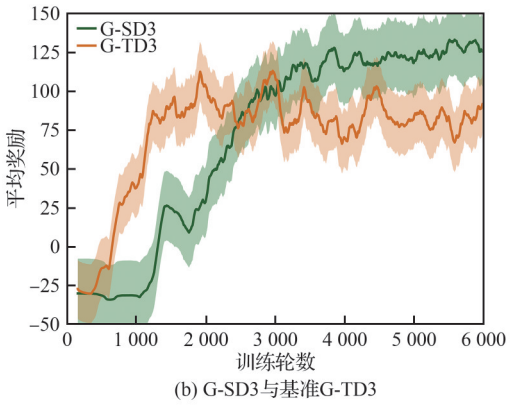
3.4 消融实验分析

为评估G-SD3中各个组件对算法的影响，将以G-SD3算法作为对照，使用移除Softmax更新策略的G-TD3，和移除GRU时序网络的SD3网络作对比，于训练环境中分别进行训练，训练设置与上文相同，最终获得奖励曲线如图13所示。

由图13可得，去除GRU网络的SD3在训练



(a) G-SD3与基准SD3



(b) G-SD3与基准G-TD3

图 13 消融实验训练奖励

Fig. 13 Ablation lab training incentives

后期能够达到与G-SD3相同的累积奖励，但在训练中期出现陷入局部最优导致奖励减少的现象，同时，算法前期收敛速度低于G-SD3。仅加入GRU的G-TD3在前期训练速度优于G-SD3，但无法得到较高的累积奖励。由此可得加入GRU网络可以加快算法的收敛速度，Softmax算子与双Actor网络增大了网络的复杂度，使得算法收敛较为困难，但同时加强了算法对复杂环境的理解能力，最终使算法能稳定取得较高累计奖励。综上所述，实验结果表明Softmax算子与GRU网络均在G-SD3算法中起到重要作用，各模块存在的负面效果均在可接受范围内且能被其他组件弥补。

3.5 泛化结果分析

将传统的强化学习算法与提出的G-SD3算法在测试环境下分别通过成功率、碰撞率、行驶步数、和行驶时间进行100轮测试，定量评估改进算法，无人机初始位置和目标位置均固定。在导航任务中共设计4套测试环境如图13所示，环境a为静态环境，环境b、c为混合环境，环境d为全动态障碍物环境，在环境中加入不同类型障碍物以改变环境特征，从而可以更好的测试提出算法的泛化效果，记录数据如表2和表3所示。从表中可以看出，在4种环境中，DDPG、PPO的成功率均未超过60%，这在实际应用中是不可接受的。TD3、SAC算法虽然也能完成导航任务，但在复杂动态环境中比G-SD3算法更容易陷入局部最优，导致任务失败。G-SD3代理在所有环境下的成功率均超过80%，平均成功率为88%，因此可以验证所提算法具有较好的泛化能力，能够在不同类型的环境中完成导航任务。综上所述，相较于其他算法本文所

表 2 测试环境导航成功率对比

Table 2 Test environment navigation success rate comparison

环境	成功率/%					碰撞率/%				
	DDPG	TD3	SAC	PPO	G-SD3	DDPG	TD3	SAC	PPO	G-SD3
环境a	48	67	68	41	86	52	33	32	59	14
环境b	53	74	77	50	95	47	26	23	50	5
环境c	31	56	61	32	89	69	44	39	68	11
环境d	45	51	60	31	82	55	49	40	69	18
平均值	45	62	67	39	88	55	38	34	62	12

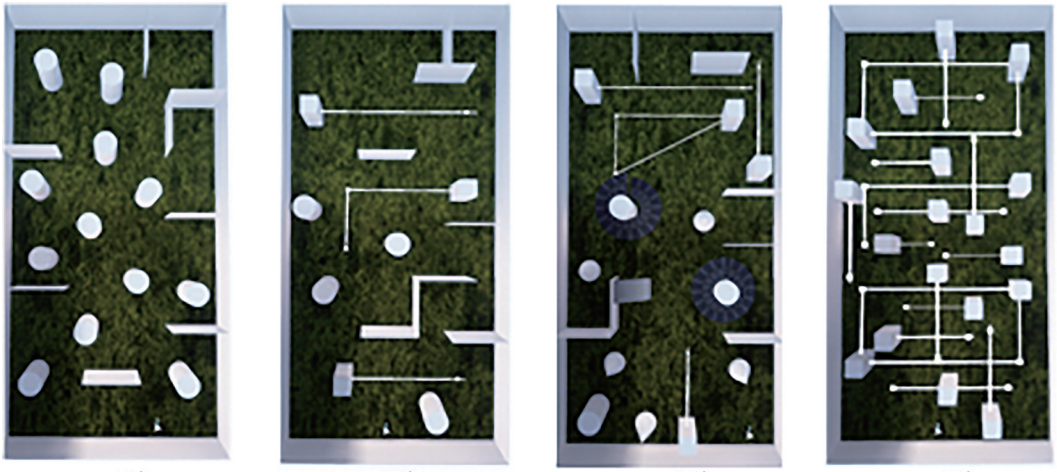
表 3 导航算法综合对比

Table 3 Comprehensive comparison of navigation algorithms

算法	平均步数	最大步数	最小步数	平均行驶时间/s	最小行驶时间/s	成功率/%
DDPG	67.15	129	17	73.71	18.67	45.0
TD3	58.60	65	7	62.59	6.47	62.0
PPO	71.70	201	14	80.20	16.43	38.5
SAC	54.70	61	15	59.62	14.72	66.5
G-SD3	53.40	77	12	57.68	12.42	88.0

提算法在无人机未知环境导航任务中具有较高优势。

图14是测试环境图，图15展示了G-SD3算法在4组测试环境中的导航轨迹。可以明显看出，G-SD3算法能够根据障碍物的位置随时调整自身姿态，其导航轨迹更加平滑且成功率更高。这表明G-SD3在动态环境中具备更强的实时反应能力和避障能力。以上测试环境表明通过引入循环网络的G-SD3算法可以利用时序信息进行决策，从而降低陷入局部最优的概率。G-SD3相较于传统的深度强化学习网络能获得更合理的导航结果。



(a) 环境a (b) 环境b (c) 环境c (d) 环境d

图 14 测试环境图

Fig. 14 Test environment diagram

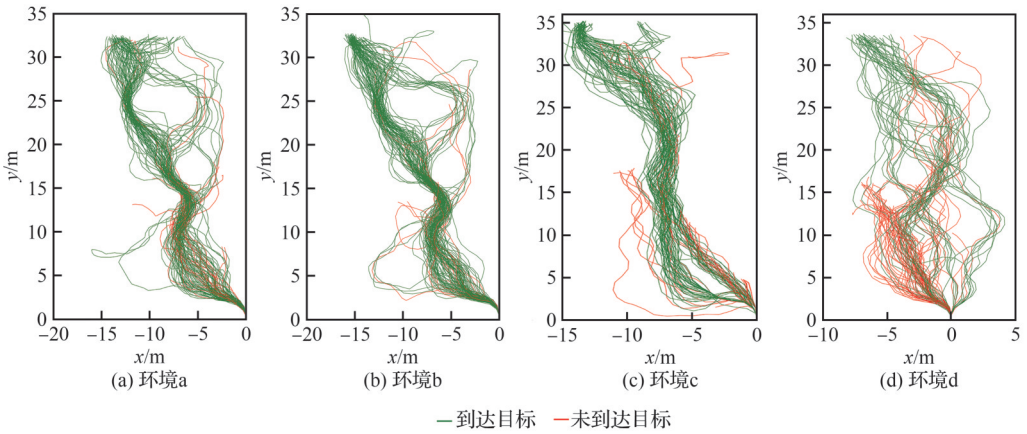


图 15 G-SD3测试轨迹对比图

Fig. 15 Test trajectory comparison diagram of G-SD3 algorithms

4 结 论

本文研究了在动态未知环境下无人机自主导航问题，针对现有深度强化学习自主导航模型面临感知受限值函数偏估问题，提出一种基于TD3的改进无人机自主避障导航算法G-SD3。该算法通过加入GRU时序网络处理历史记忆信息，提取观测数据时间关系。同时引入softmax函数将价值函数进行转换，优化了策略获取，显著提高了算法的收敛速度。实验结果显示，与其他强化学习算法（DDPG和TD3）相比，G-SD3在累积回报、单步奖励和模型收敛速度等方面均有明显提升。该实验结果表明本文所提算法在执行动态环境避障导航任

务时具有良好的稳定性。

参 考 文 献

[1] HUANG Z Y, WU J D, LV C. Efficient deep reinforcement learning with imitative expert priors for autonomous driving[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 34(10): 7391-7403.

[2] ADIL M, SONG H B, AHMAD JAN M, et al. UAV-assisted IoT applications, QoS requirements and challenges with future research directions[J]. ACM Computing Surveys, 2024, 56(10): 1-35.

[3] XUE Z H, GONSALVES T. Vision based drone obstacle avoidance by deep reinforcement learning[J]. AI, 2021, 2(3): 366-380.

[4] LI J, QIN H, WANG J Z, et al. OpenStreetMap-based autonomous navigation for the four wheel-legged robot via 3D-lidar and CCD camera[J]. IEEE Transactions on Industrial Electronics, 2022, 69(3): 2708-2717.

[5] CAI D P, LI R Q, HU Z H, et al. A comprehensive overview of core modules in visual SLAM framework [J]. Neurocomputing, 2024, 590: 127760.

[6] YANG C G, CHEN C Z, HE W, et al. Robot learning system based on adaptive neural control and dynamic movement primitives[J]. IEEE Transactions on Neural Networks and Learning Systems, 2019, 30(3): 777-787.

[7] ALMAZROUEI K, KAMEL I, RABIE T. Dynamic obstacle avoidance and path planning through reinforcement learning[J]. Applied Sciences, 2023, 13(14): 8174.

[8] SATHYAMOORTHY A J, PATEL U, GUAN T R, et al. Frozone: Freezing-free, pedestrian-friendly navigation in human crowds[J]. IEEE Robotics and Automation Letters, 2020, 5(3): 4352-4359.

[9] 周彬, 郭艳, 李宁, 等. 基于导向强化Q学习的无人机路径规划[J]. 航空学报, 2021, 42(9): 325109.
ZHOU B, GUO Y, LI N, et al. Path planning of UAV using guided enhancement Q-learning algorithm[J]. Acta Aeronautica et Astronautica Sinica, 2021, 42(9): 325109 (in Chinese).

[10] CHAI R Q, NIU H L, CARRASCO J, et al. Design and experimental validation of deep reinforcement learning-based fast trajectory planning and control for mobile robot in unknown environment[J]. IEEE Transactions on Neural Networks and Learning Systems, 2024, 35(4): 5778-5792.

[11] XIE Z T, DAMES P. DRL-VO: Learning to navigate through crowded dynamic scenes using velocity obstacles [J]. IEEE Transactions on Robotics, 2023, 39(4): 2700-2719.

[12] CAO X, REN L, SUN C Y. Research on obstacle detection and avoidance of autonomous underwater vehicle based on forward-looking sonar[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 34(11): 9198-9208.

[13] WANG W Y, MA F, LIU J L. Course tracking control for smart ships based on A deep deterministic policy gradient-based algorithm[C]//2019 5th International Conference on Transportation Information and Safety (ICTIS). Piscataway: IEEE Press, 2019.

[14] LILLICRAP T P, HUNT J, PRITZEL A, et al. Continuous control with deep reinforcement learning [DB/OL]. arXiv preprint: 1509.02971,2019.

[15] SILVER D, LEVER G, HEESS N, et al. Deterministic policy gradient algorithms[C]//Proceedings of the 31st International Conference on International Conference on Machine Learning. New York: ACM, 2014.

[16] FUJIMOTO S, HOOF H V, MEGER D. Addressing function approximation error in actor-critic methods[C]// Proceedings of the 35th International Conference on Machine Learning. New York: ACM, 2018

[17] 寇凯, 杨刚, 张文启, 等. 基于SAC的无人机自主导航方法研究[J]. 西北工业大学学报, 2024, 42(2): 310-318.
KOU K, YANG G, ZHANG W Q, et al. Exploring UAV autonomous navigation algorithm based on soft actor-critic[J]. Journal of Northwestern Polytechnical University, 2024, 42(2): 310-318 (in Chinese).

[18] SINGLA A, PADAKANDLA S, BHATNAGAR S. Memory-based deep reinforcement learning for obstacle avoidance in UAV with limited environment knowledge [J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(1): 107-118.

[19] CUI Z Y, WANG Y. UAV path planning based on multilayer reinforcement learning technique[J]. IEEE Access, 2021, 9: 59486-59497.

[20] XUE Y T, CHEN W S. A UAV navigation approach based on deep reinforcement learning in large cluttered 3D environments[J]. IEEE Transactions on Vehicular Technology, 2023, 72(3): 3001-3014.

[21] EVERETT M, CHEN Y F, HOW J P. Motion planning among dynamic, decision-making agents with deep reinforcement learning[C]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Piscataway: IEEE Press, 2018.

[22] KAELBLING L P, LITTMAN M L, CASSANDRA A R. Planning and acting in partially observable stochastic do-

mains[J]. Artificial Intelligence, 1998, 101(1): 99-134.

[23] XIAO C X, LU P, HE Q Z. Flying through a narrow gap using end-to-end deep reinforcement learning augmented with curriculum learning and Sim2Real[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 34(5): 2701-2708.

[24] JIA J Y, XING X W, CHANG D E. GRU-attention based TD3 network for mobile robot navigation[C]//2022 22nd International Conference on Control, Automation and Systems (ICCAS). Piscataway: IEEE Press, 2022.

[25] DEY R, SALEM F M. Gate-variants of gated recurrent unit (GRU) neural networks[C]//2017 IEEE 60th International Midwest Symposium on Circuits and Systems (MWSCAS). Piscataway: IEEE Press, 2017.

[26] KALIDAS A P, JOSHUA C J, MD A Q, et al. Deep reinforcement learning for vision-based navigation of UAVs in avoiding stationary and mobile obstacles[J]. Drones, 2023, 7(4): 245.

[27] 杨卫平. 新一代飞行器导航制导与控制技术发展趋势[J]. 航空学报, 2024, 45(5): 529720.
YANG W P. Development trend of navigation guidance and control technology for new generation aircraft[J]. Acta Aeronautica et Astronautica Sinica, 2024, 45(5): 529720 (in Chinese).

[28] ZHANG F J, LI J, LI Z. A TD3-based multi-agent deep reinforcement learning method in mixed cooperation-competition environment[J]. Neurocomputing, 2020, 411: 206-215.

[29] PAN L, CAI Q P, HUANG L B. Softmax deep double deterministic policy gradients[DB/OL]. arXiv preprint: 2010.09177, 2020.

[30] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[DB/OL]. arXiv preprint: 1707.06347, 2017.

[31] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[DB/OL]. arXiv preprint: 1801.01290, 2018.

（责任编辑：佟路）

Mapless navigation of UAVs in dynamic environments based on an improved TD3 algorithm

JIANG Lingfeng[1], LI Xinkai[1,*], ZHANG Hai[2], LI Hanwei[1], ZHANG Hongli[3]

1. *School of Electrical Engineering, Xinjiang University, Urumqi 830017, China*
2. *Engineering Training Center, Xinjiang University, Urumqi 830017, China*
3. *School of Intelligent Science and Technology (School of Future Technology), Xinjiang University, Urumqi 830017, China*

Abstract: To address the challenges of mapping and navigation in unknown dynamic environments for drone navigation systems, a mapless navigation method based on an improved Twin Delayed Deep Deterministic policy gradient (TD3) is proposed. To solve the perception limitations in a mapless environment, the navigation model is defined as a Partially Observable Markov Decision Process (POMDP). A Gated Recurrent Units (GRU) is introduced to enable the policy network to utilize the temporal information from historical states, allowing it to obtain an optimal policy and avoid falling into local optima. Based on the TD3 algorithm, a softmax operator is employed to the value function, and a dual policy networks is adopted to address issues of policy function instability and value function underestimation in the TD3 algorithm. A non-sparse reward function is designed to resolve the challenge of policy convergence in reinforcement learning under sparse reward conditions. Finally, simulation experiments conducted on the AirSim platform demonstrate that the improved algorithm achieves faster convergence and higher task success rates in drone mapless obstacle avoidance navigation compared to traditional deep reinforcement learning algorithms.

Keywords: mapless navigation; deep reinforcement learning; deterministic policy gradient; UAVs; dynamic environment

Received: 2024-08-02; **Revised**: 2024-11-04; **Accepted**: 2024-12-06; **Published online**: 2024-12-13 13:34
URL: https://hkxb.buaa.edu.cn/CN/Y2025/V46/I8/331035
Foundation items: National Natural Science Foundation of China (62263030); Natural Science Foundation of Xinjiang Uygur Autonomous Region (2022D01C86)
* **Corresponding author.** E-mail: lxk@xju.edu.cn