http://htkz.cn
引用格式：胥斌，王青. 融合深度强化学习的自适应势场路径规划算法[J]. 航天控制，2026，44(3)：26-34. (XU Bin, WANG Qing. The adaptive potential field path planning algorithm integrated with deep reinforcement learning[J]. Aerospace Control, 2026, 44(3): 26-34.)

融合深度强化学习的自适应势场路径规划算法

胥 斌[1]，王 青[1,2]
1. 杭州市北京航空航天大学国际创新研究院，杭州 311115
2. 北京航空航天大学自动化科学与电气工程学院，北京 100191

摘 要 针对无人机在复杂未知环境下的路径规划中，传统人工势场法(APF)易陷入局部极小值和参数敏感，以及深度强化学习在训练初期收敛慢、样本效率低等问题，提出一种融合近端策略优化(PPO)与改进势场的自适应路径规划算法(PPO-APF)。该算法采用分层架构：上层利用PPO网络根据无人机局部感知信息，自适应输出斥力系数、起效距离及速率调节系数；下层基于引入目标距离因子和运动学约束的改进APF模型生成飞行指令。同时，设计包含路径平滑度与参数稳定性的复合奖励函数以抑制路径抖动。仿真结果表明，在障碍覆盖率约22%的复杂场景中，PPO-APF规划成功率可达97.33%，显著优于改进APF(53.67%)与纯强化学习的PPO(85%)。该算法具备显著“冷启动”优势，能使无人机自主习得狭道减速穿越和提前避让等策略，有效结合了深度强化学习的自适应性与势场法的稳定性。

关键词 无人机；路径规划；人工势场法；深度强化学习；近端策略优化
中图分类号：TP242 **文献标识码**：A **文章编号**：1006-3242(2026)03-0026-09
DOI：10.16804/j.cnki.issn1006-3242.2026.03.004

The adaptive potential field path planning algorithm integrated with deep reinforcement learning

XU Bin[1], WANG Qing[1,2]
1. Hangzhou International Innovation Institute, Beihang University, Hangzhou 311115, China
2. School of Automation Science and Electrical Engineering, Beihang University, Beijing 100191, China

Abstract To address the issues of local minima and parameter sensitivity in the traditional artificial potential field (APF), as well as the slow convergence and low sample efficiency of deep reinforcement learning in UAV path planning in complex unknown environments, an adaptive path planning algorithm fusing proximal policy optimization (PPO) and improved artificial potential field (PPO-APF) is pro-

资助项目：杭州市北京航空航天大学国际创新研究院科研启动经费资助(2024KQ024)
收稿日期：2025-12-23
作者简介：胥 斌(2001-)，男，硕士研究生，主要研究方向为飞行器制导与强化学习；王 青(1968-)，女，博士，教授，博士生导师，主要研究方向为飞行器制导与控制及智能控制，本文通信作者。

posed. A hierarchical architecture is applied in this algorithm. The repulsive force coefficient, effective distance, and rate adjustment coefficient are adaptively outputted by the upper-layer PPO network based on local perception, and flight commands are generated by the lower-layer improved APF model, where a target distance factor and kinematic constraints are introduced. Meantime, a composite reward function incorporating path smoothness with parameter stability is designed to suppress path jitter. Simulation results demonstrate that in complex scenarios with 22% obstacle coverage, the planning success rate of PPO-APF reaches 97.33%, which is significantly superior to the improved APF by 53.67% and pure reinforcement learning based PPO by 85%. The proposed algorithm takes advantage of a significant "cold start" mode, which effectively combines the adaptability of DRL with the stability of APF to realize UAV's autonomous learning of slow-down crossing on narrow passage and preemptive avoidance strategies, etc.

Key words　UAV; Path planning; Artificial potential field; Deep reinforcement learning; Proximal policy optimization

0　引　言

随着无人机在低空感知[1]、物流配送[2]及灾后救援[3]等领域的广泛应用,其在复杂未知环境中实现安全高效的路径规划,已成为当前研究领域的重点方向。

在传统路径规划方法中,全局规划算法如A*算法及快速扩展随机树等在静态已知环境中表现良好,但是在未知环境中适应性较差[4]。人工势场法作为反应式避障的代表算法,以其模型简洁和计算高效的特点,常用于实时避障[5],但其在复杂场景中易陷入局部极小值或因斥力过大导致目标不可达,对参数设置较为敏感[6]。为此,学者们提出了多种改进思路,如通过修正斥力势场函数缓解目标不可达问题[7];在Frenet坐标系中结合安全椭圆与预测距离动态调节斥力范围[8];借助神经网络调整人工势场参数[9]。

近年来,深度强化学习为路径规划提供了新的解决途径,其能够通过智能体与环境的交互,从高维数据中学习行动策略[10]。例如,基于近端策略优化算法的端到端策略应用于无人机去中心化避障[11];采用双延迟深度确定性策略梯度算法,根据深度图像直接确定所需的控制指令,并由飞行控制器执行[12]。然而,这类方法在训练初期样本效率低、收敛速度慢,且模型可解释性较弱,在未知环境中的泛化能力仍有局限。

因此,结合传统方法可解释性与深度强化学习自适应性的融合思路,逐渐成为研究趋势。主流方法之一是利用深度强化学习动态调整传统算法的关键参数,例如通过注意力机制编码环境特征以调节人工势场斥力系数[13],采用双延迟深度确定性策略梯度算法优化扰动流体动态系统的参数组合[14]。

针对人工势场法在复杂环境适应性不足及易陷入局部最优等问题,本文提出一种融合近端策略优化与改进人工势场的自适应路径规划算法(PPO-APF)。在强化学习训练过程中,设计了包含路径平滑度与参数稳定性的复合奖励函数,引入课程学习机制以提升收敛效率与鲁棒性。

1　问题描述与系统建模

1.1　问题描述与无人机运动学模型

无人机的路径规划是指在给定无人机起始点、目标点、飞行环境信息以及无人机的性能参数的条件下,寻找一条从起始点到目标点的最优或可行飞行路径。在二维平面的路径规划研究中,传统人工势场法通常将无人机简化为质点,其理想化的一阶运动学模型可表示为

$$\dot{\boldsymbol{q}} = \boldsymbol{v} \tag{1}$$

式中:$\boldsymbol{q} \in \mathbb{R}^2$表示无人机的位置向量,$\boldsymbol{v} \in \mathbb{R}^2$表示无人机的速度向量。

然而,上述理想模型忽略了实际四旋翼无人机的物理惯性和执行机构限制。在实际飞行任务中,无人机的运动受到严格的动力学约束,主要体现在最大飞行速率和最大偏航角速度上。为了保证规划出的轨迹在物理上可执行,本文在规划模型中引入以下两类硬性约束:

1)最大飞行速率约束:无人机的瞬时飞行速率$\|\boldsymbol{v}\|$不能超过其物理极限$v_{\max}$,即$\|\boldsymbol{v}\| \leqslant v_{\max}$。

2)最大偏航角速度约束:受限于机体惯性,无人机在单位时间内的航向角变化量是有限的。设t时刻无人机的速度方向角为ψ_t,单位时间最大转角为$\Delta\psi_{\max}$,则相邻时刻的航向角变化量必须满足:

$$\left|\psi_{t+1} - \psi_t\right| \leqslant \Delta\psi_{\max} \tag{2}$$

1.2 无人机飞行环境建模

假设$A(x,y)$是二维规划空间中的任意一点,x和y分别为横、纵坐标,则二维空间可以表示为

$$\{(x,y)|X_{\min} \leqslant x \leqslant X_{\max}, Y_{\min} \leqslant y \leqslant X_{\max}\} \tag{3}$$

式中:$X_{\min}$和$X_{\max}$分别是x方向的下界值和上界值,$Y_{\min}$和$Y_{\max}$分别是y方向的下界值和上界值。

如图1所示,为保证无人机与障碍物之间的最小安全距离,将场景中的不规则障碍物以其最小外接圆进行近似,并在此基础上进行外向膨胀处理,从而构建用于避障判据的圆形防护区域。算法工作于连续状态与动作空间,无人机在满足运动约束条件下可朝任意方向运动。

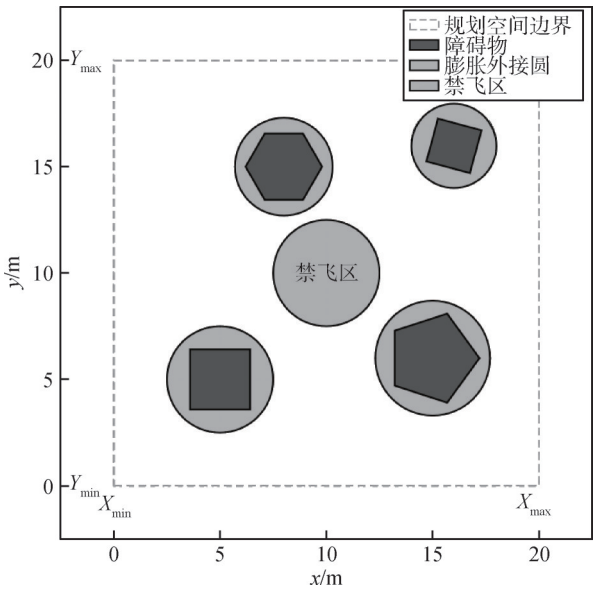


图1 规划空间示意图

2 基于PPO自适应势场路径规划方法

本文提出的PPO-APF算法采用分层控制架构如图2所示:参数决策层利用PPO深度策略网络根据局部环境感知编码与无人机当前状态,自适应输出组合系数;路径生成层基于改进的人工势场模型结合运动学约束计算路径点,直到到达终点。

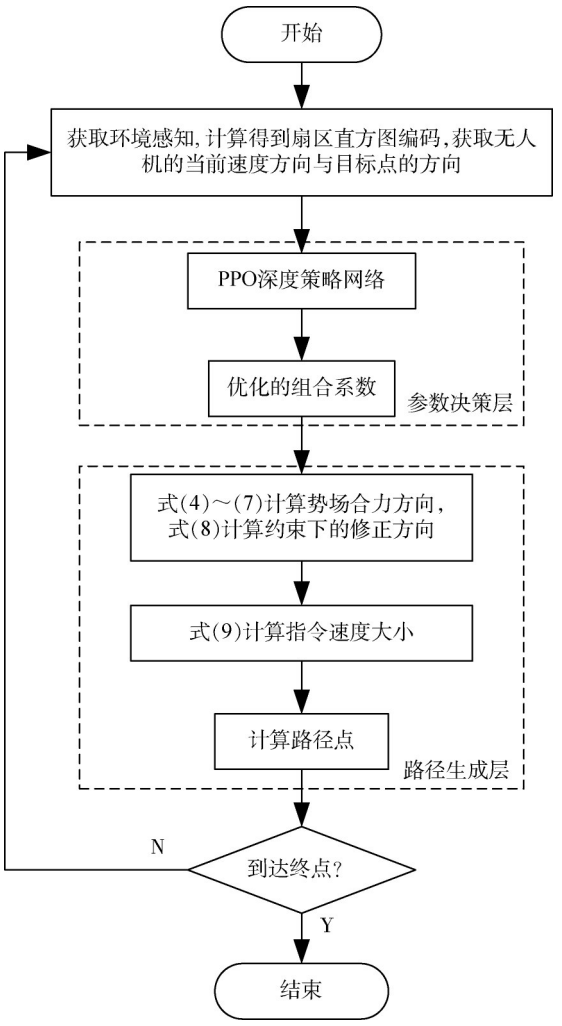


图2 自适应势场路径规划算法流程图

2.1 改进的人工势场算法

传统人工势场法在复杂环境中易陷入局部极小值且难以满足无人机动力学约束。本文在Ge等[7]的基础上引入无人机运动学约束与速率调节因子。

2.1.1 改进引力与斥力场

为避免长距离下引力过大导致速度失控,采用分段引力函数。设无人机位置为$\boldsymbol{P}$,目标点为$\boldsymbol{P}_{\text{goal}}$,两者的距离为$\rho(\boldsymbol{P},\boldsymbol{P}_{\text{goal}})$,引力势场$U_{\text{att}}$的负梯度$\boldsymbol{F}_{\text{att}}$定义为

$$\boldsymbol{F}_{\text{att}}(\boldsymbol{P}) = \begin{cases} -k_{\text{att}}(\boldsymbol{P} - \boldsymbol{P}_{\text{goal}}), & \rho(\boldsymbol{P},\boldsymbol{P}_{\text{goal}}) \leqslant d_{\text{th}} \\ -d_{\text{th}}k_{\text{att}}\dfrac{\boldsymbol{P} - \boldsymbol{P}_{\text{goal}}}{\rho(\boldsymbol{P},\boldsymbol{P}_{\text{goal}})}, & \rho(\boldsymbol{P},\boldsymbol{P}_{\text{goal}}) > d_{\text{th}} \end{cases} \tag{4}$$

式中:k_{att}为引力系数(本文固定为3,以减少动作空间维度),d_{th}为距离阈值。

针对“目标不可达”问题,在斥力场中引入目标距离因子$\rho^n(\boldsymbol{P},\boldsymbol{P}_{goal})$。改进后的斥力$\boldsymbol{F}_{rep}$分解为背离障碍物的排斥力$\boldsymbol{F}_{rep1}$和指向目标的引力分量$\boldsymbol{F}_{rep2}$:

$$\boldsymbol{F}_{rep}=\boldsymbol{F}_{rep1}+\boldsymbol{F}_{rep2} \tag{5}$$

$$\boldsymbol{F}_{rep1}=k_{rep}\left(\frac{1}{\rho(\boldsymbol{P},\boldsymbol{P}_{obs})}-\frac{1}{\rho_0}\right)\frac{\rho^n(\boldsymbol{P},\boldsymbol{P}_{goal})}{\rho^2(\boldsymbol{P},\boldsymbol{P}_{obs})}\nabla\rho(\boldsymbol{P},\boldsymbol{P}_{obs}) \tag{6}$$

$$\boldsymbol{F}_{rep2}=-\frac{n}{2}k_{rep}\left(\frac{1}{\rho(\boldsymbol{P},\boldsymbol{P}_{obs})}-\frac{1}{\rho_0}\right)^2\rho^{n-1}(\boldsymbol{P},\boldsymbol{P}_{goal})\nabla\rho(\boldsymbol{P},\boldsymbol{P}_{goal}) \tag{7}$$

式中:$\rho(\boldsymbol{P},\boldsymbol{P}_{obs})$为障碍物距离,$\rho_0$为障碍物斥力起效距离,$k_{rep}$为斥力系数。当无人机接近目标点时,斥力合力趋于0,保证全局收敛。

在上述模型中,k_{att},k_{rep}以及ρ_0是决定路径质量的关键参数。大k_{att}/k_{rep}:无人机趋向目标的动力强,路径平直,但通过障碍物密集区时可能因避障不及时而发生碰撞。小k_{att}/k_{rep}:避障安全性高,但无人机可能过早产生绕行,导致路径冗余。ρ_0的选择直接影响路径的质量,增大ρ_0会提前绕障、路径更平滑但更可能导致局部最小值问题;减小ρ_0使路径能够更贴近障碍物,穿越狭窄通道,但风险上升。

图3展示了在同一障碍环境下,不同参数组合规划出的路径差异。可以看出,固定参数难以兼顾安全性与效率,尤其在障碍物分布复杂的环境中。因此,本文后续重点研究如何根据感知环境自适应调节k_{att}/k_{rep}和ρ_0。

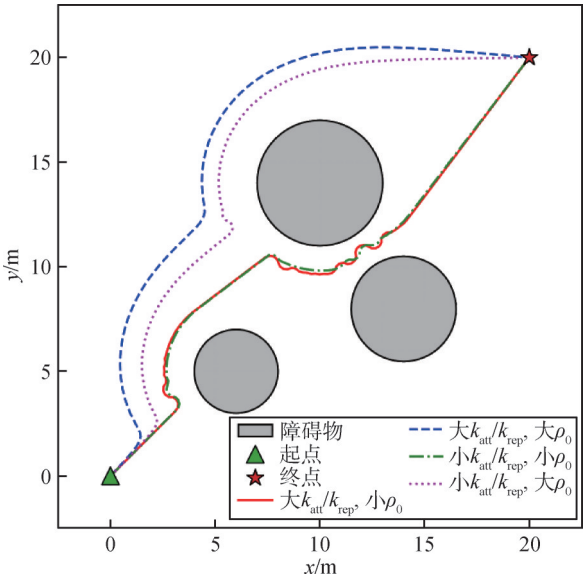


图3　不同势场参数组合下的路径对比图

2)基于强化学习的自适应速率调节

为了提高飞行效率与安全性,无人机的飞行速度v不应是恒定值,而应根据当前飞行状态调整,在接近密集障碍物时应降低速度,以确保安全通过;而在远离障碍物时则应提高速度,以加快向目标点的飞行。因此引入速率调节系数α,该系数由深度强化学习策略输出,设基础飞行速度为v_0,则下一时刻的指令速度大小如下:

$$v_{next}=\alpha\cdot v_0 \tag{9}$$

2.2　马尔可夫决策过程建模

上文中的k_{rep},ρ_0与α参数由深度强化学习策略将本文问题建模为马尔可夫决策过程$(\boldsymbol{S},\boldsymbol{A},\boldsymbol{P},\boldsymbol{R})$,其中,$\boldsymbol{S}$表征状态空间,$\boldsymbol{A}$对应动作空间,$\boldsymbol{P}$为状态转移,$\boldsymbol{R}$为奖励函数,具体如下:

2.1.2　基于运动学约束的修正与自适应速率调节

传统人工势场法通常直接将合力$\boldsymbol{F}_{res}=\boldsymbol{F}_{att}+\boldsymbol{F}_{rep}$的方向作为期望速度方向,且假设速率恒定。为解决1.1节中提出的运动学约束问题,并提升复杂环境下的避障效率,本文在势场输出的基础上,设计了方向修正策略与自适应速率调节机制。

1)满足最大偏航角约束的方向修正

设无人机当前时刻的实际速度方向为ψ_{cur},由改进势场计算出的期望合力方向为ψ_{des}。为了保证轨迹的平滑性并满足式(2)定义的偏航角约束,下一时刻的实际速度方向ψ_{next}修正如下:

$$\psi_{next}=\begin{cases}\psi_{des}, & |\psi_{des}-\psi_{cur}|\leqslant\Delta\psi_{max}\\ \psi_{cur}+\mathrm{sgn}(\psi_{des}-\psi_{cur})\cdot\Delta\psi_{max}, & |\psi_{des}-\psi_{cur}|>\Delta\psi_{max}\end{cases} \tag{8}$$

1)状态空间$\boldsymbol{S}$

状态向量$\boldsymbol{s}_t=(\boldsymbol{s}_t^{env},\boldsymbol{s}_t^{uav})$由环境感知与自身状态组成。环境感知$\boldsymbol{s}_t^{env}$:采用扇区直方图编码。以速度方向为中心将前方180°视场划分为45个子扇区,记录各扇区内障碍物归一化距离h_i,形成45维特征向量。自身状态$\boldsymbol{s}_t^{uav}$:包含当前速度单位向量与目标方向单位向量,共4维。总状态维度为49。

2)动作空间$\boldsymbol{A}$

动作直接对应势场关键参数$\boldsymbol{a}_t=(k_{rep,t},\rho_{0,t},\alpha_t)$。为保证训练稳定性,将连续动作空间离散化,各参数在预设范围内选取(如$k_{rep}\in[3,12]$),策略网络输出多维离散索引。

3）奖励函数 $\boldsymbol{R}$

为兼顾避障安全与轨迹平滑，设计多目标复合奖励函数：

$$R_t = \lambda_1 R_{\text{dis}} + \lambda_2 R_{\text{time}} + \lambda_3 R_{\text{curve}} + \lambda_4 R_{\text{threat}} + \lambda_5 R_{\text{params}} + R_{\text{event}} \tag{10}$$

各分项定义如下：引导奖励 R_{dis} 为相邻时刻目标距离差，鼓励趋近目标。平滑奖励为 R_{curve} 与 R_{params}，R_{curve} 为惩罚速度方向突变，R_{params} 为惩罚参数序列方差，抑制因参数跳变导致的轨迹抖动。安全奖励为 R_{threat}，当进入障碍物威胁半径时给予惩罚。稀疏奖励为 R_{event}，成功到达奖励时+100，碰撞或超时惩罚−100。

2.3 近端策略优化算法训练

采用近端策略优化（Proximal policy optimization，PPO）算法训练策略网络 π_θ。PPO 通过引入裁剪目标函数 L^{CLIP} 限制策略更新幅度，避免训练震荡：

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t\Big[\min\big(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t\big)\Big] \tag{11}$$

网络采用 Actor−Critic 架构，Actor 网络输出上述 3 个参数的概率分布，Critic 网络评估状态价值。本文提出的融合算法采用“采样−更新”的在线学习模式：在每一时间步，将状态向量输入网络，采样得到组合系数，代入 2.1 节模型计算合力与位置，将轨迹数据存入经验回放池，满足批量后利用广义优势估计更新网络参数。

3 仿真校验

本节通过二维无人机仿真验证所提 PPO−APF 算法的有效性与鲁棒性，并在典型场景下分析其自适应机理。计算机仿真硬件配置为 Intel Core i7−13620H 4.90GHz 处理器，环境搭建采用 Python3.10 作为主要编程语言，深度强化学习算法框架基于 PyTorch2.6.0 构建。

3.1 实验描述与参数设定

无人机运动学模型参数设定如下：最大飞行速度 $v_{\max}$ 为 3 m/s；最大偏航角速度 $\omega_{\max}$ 为 30 (◦)/s（在仿真步长 $\Delta t = 1$ s 下，最大转角 $\Delta\psi_{\max} = 30°$）；雷达探测半径为 20 m；雷达视场角为 180°（前向）。仿真地图尺寸为 100 m × 100 m。为了验证算法的泛化能力，实验分为“训练阶段”与“测试阶段”。

1）训练阶段场景

训练地图设置如图 4 所示，起点与终点在地图两侧随机生成，该设置使得无人机必须穿越地图中的大片障碍区，以提高其训练数据质量。障碍物由 14 个半径在 6～8 m 之间的圆形组成，位置随机且互不重叠，覆盖率约为 22%，确保训练样本具有足够的复杂度。

2）测试阶段场景

为全面评估算法性能，设置覆盖率约为 22% 难度的测试地图集，包含 300 张固定起终点的随机地图，起点为 (0, 0)，终点为 (100, 100)。

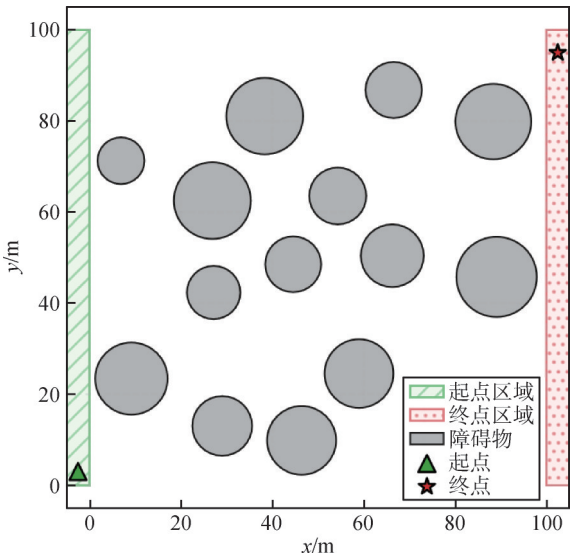


图 4 训练阶段场景图

3）对比算法

APF−Ge：基于文献的改进势场函数，其关键参数经遗传算法优化后固定，代表传统方法的性能上限；PPO：采用与 PPO−APF 完全相同的网络与奖励设计，但直接输出动作，用于检验势场融合机制的有效性；A*：在 1 m 分辨率的栅格地图上进行全局搜索，其结果作为路径长度的理论下界参考。PPO−APF 算法的关键训练超参数如表 1 所示。

表 1 强化学习参数

参数	含义	数值
γ	奖励折扣因子	0.99
α	神经网络学习率	0.003
ϵ	目标函数裁剪率	0.2
λ	广义优势估计参数	0.95
net_arch(pi)	策略网络隐藏层结构	[96, 96]
net_arch(vf)	价值网络隐藏层结构	[96, 96]
$N_{\text{batch_size}}$	批次大小	256
N_{steps}	单个环境采样步数	128

3.2　训练过程与结果分析

3.2.1　训练阶段分析

图 5 对比了 PPO-APF 与基准 PPO 算法的训练过程。训练初期,PPO-APF 在势场引导下获得较高初始奖励(约-10),而 PPO 奖励极低(约-130),表明势场有效减少了无效探索。PPO 算法训练中出现明显震荡和高方差,尤其在 750k 步(其中 k 代表 10^3)附近发生性能坍塌;PPO-APF 则全程保持平滑稳定、方差较小。最终,PPO-APF 约在 1000k 步收敛至 125 左右,而 PPO 仅收敛至约 100 且持续波动。实验证明,引入人工势场显著提升了探索效率、稳定性及最终性能。

3.2.2　测试阶段算法对比

为全面评估所提出算法的性能,本文从成功率、路径效率和轨迹平滑度 3 个维度对 4 种算法进行对比分析,其统计结果如表 2 所示。

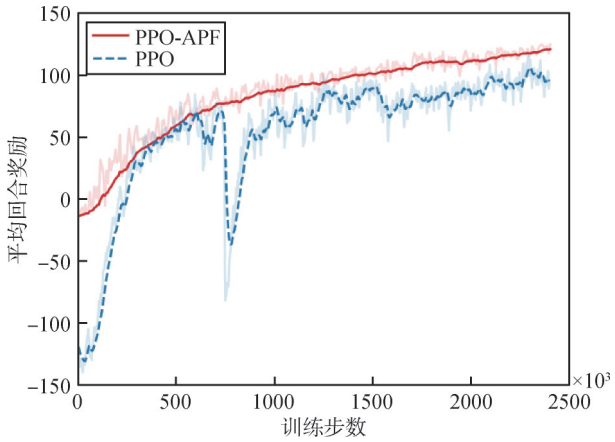


图 5　训练过程平均回合奖励曲线

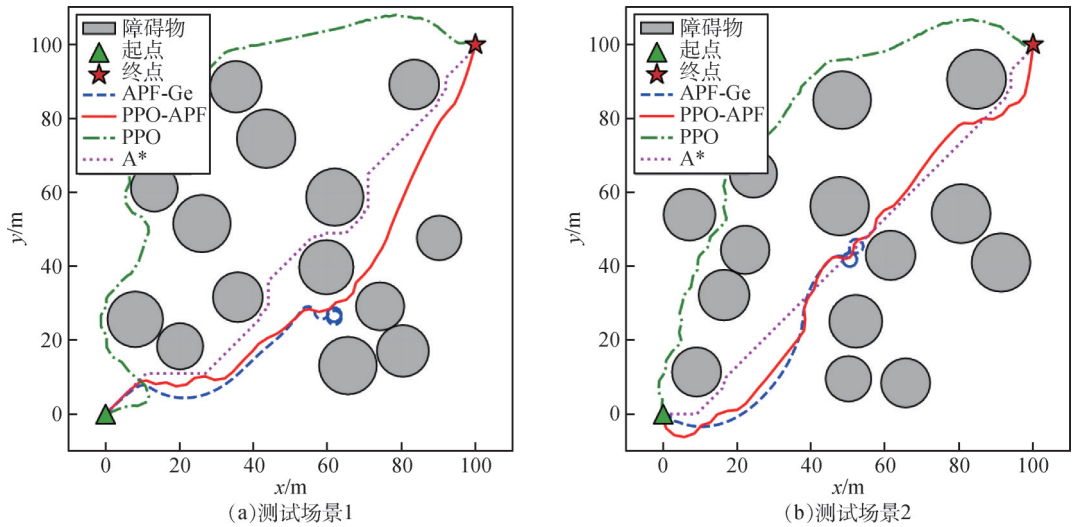
表 2　各算法在测试集上的性能对比

指标	APF-Ge	PPO-APF	PPO	A*
成功率/%	53.67	97.33	85	100
平均长度/m	166.842	175.631	185.427	151.593
平均曲率/rad	16.436	17.614	26.742	11.403

PPO-APF 算法的规划成功率为 97.33%,显著高于经参数优化的传统 APF-Ge 算法(53.67%),并接近全局最优算法 A*的成功率(100%)。这表明通过深度强化学习动态调节势场参数,PPO-APF 有效克服了传统势场法易陷入局部极小值的缺陷,提升了在复杂障碍环境中的鲁棒性。相比之下,PPO 算法的成功率为 85%,其在狭窄场景下的泛化能力不足。

在路径长度方面,A*算法给出了理论最短路径 151.593 m。PPO-APF 的平均路径长度为 175.631 m,较 A*仅增加约 15.8%,且优于 PPO 算法的 185.427 m。需要说明的是,APF-Ge 的平均长度 166.842 m 虽然更短,但该结果仅基于其在简单障碍场景中成功的部分案例,在复杂场景中多数规划失败并未计入统计,因此其长度结果不具备广泛代表性。

在路径平滑度上,PPO-APF 算法的平均曲率为 17.614 rad,与 APF-Ge 的 16.436 rad 相当,并显著低于 PPO 算法的 26.742 rad。这表明融合算法继承了势场法生成平滑路径的优势,有利于实际飞行控制;而 PPO 算法所产生的路径存在明显抖动。



(a)测试场景1　　(b)测试场景2

图 6　测试场景下不同算法路径规划结果

如图 6 所示，APF-Ge 在密集障碍中易陷入局部极小值而失败；PPO 算法缺乏全局导向，路径冗余且曲折；PPO-APF 则能自适应调整势场参数，在狭窄通道等场景中灵活平衡斥力作用，在确保轨迹平滑的同时实现高效避障，综合性能最佳。

3.3　自适应机理分析

为进一步揭示算法如何自适应调节势场参数，本节结合轨迹与参数变化曲线进行分析。如图 7 所示，在狭窄通道穿越场景 12～18 时间步中，当无人机接近通道入口时，策略网络主动调低斥力起效距离 ρ_0 并减小速率系数 α。降低 ρ_0 减少了通道两侧的合斥力大小和影响距离，使无人机得以“挤入”通道；降低速度则便于进行更安全的避障操作。穿越完成后，速度迅速恢复。而固定参数的 APF-Ge 陷入局部最小点，无法穿越障碍物。在连续障碍规避场景 44～56 时间步中，面对前方大面积阻挡，策略网络将斥力影响距离 ρ_0 持续维持在较高水平。这使得无人机能够在更远处感知到障碍物的横向排斥力分量，从而“早发现、早反应”，提前开始平滑绕行，有效避免了路径抖动明显的现象。

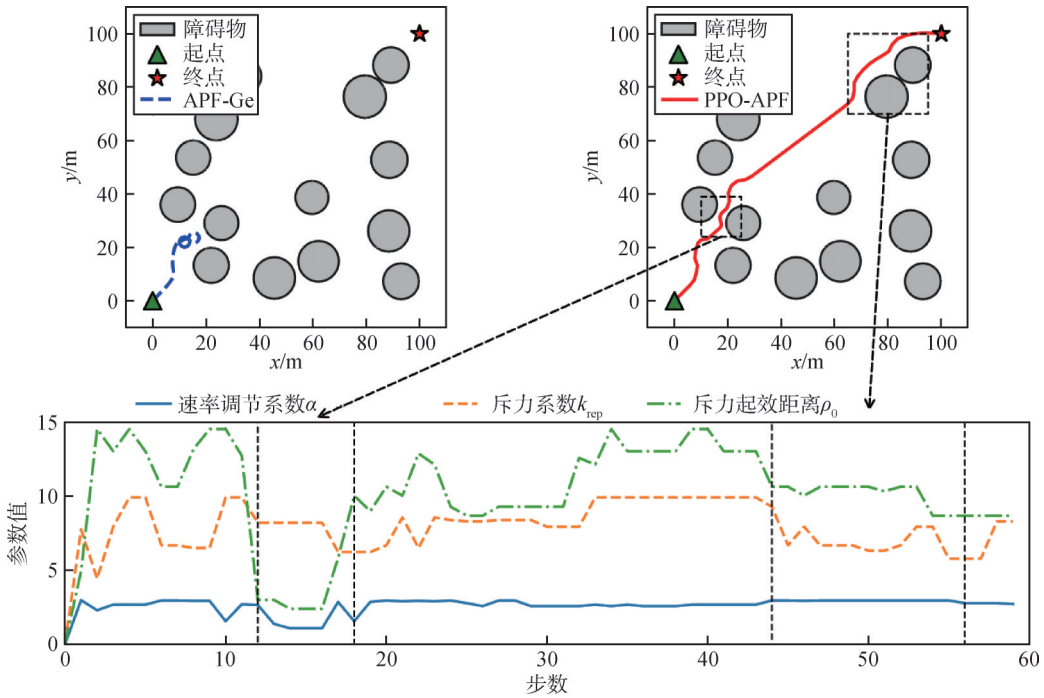


图 7　狭窄通道场景下的参数自适应变化

在图 8 的避障场景 14～22 与 51～57 时间步中，由于靠近障碍物时的速度方向与出口方向夹角较大，因此策略网络降低速度，并动态调节斥力相关系数，使得无人机能够安全地避开障碍物，并将速度方向调整至出口方向，最终穿越复杂障碍物群，而固定参数的 APF-Ge 则难以应对复杂障碍物群。

4　结　论

本文针对无人机在复杂环境中的路径规划问题，提出了一种融合近端策略优化与人工势场法的自适应路径规划算法。该方法将强化学习的策略决策能力与势场法的解析优势相结合，使无人机能够基于局部环境感知信息，实时自适应调节斥力场关键参数及飞行速度，从而有效克服传统人工势场法依赖固定参数且易陷入局部极小值的问题，同时缓解纯强化学习方法训练收敛缓慢和路径抖动较大的不足。

仿真结果表明，在障碍物覆盖率达 22% 的复杂场景中，PPO-APF 算法规划成功率达到 97.33%，显著优于传统 APF-Ge 算法和 PPO 算法。此外，算法能够在狭窄通道及复杂障碍环境中学习到合理的减速与绕行策略，兼顾路径可行性与平滑性，体现出良好的环境适应能力与规划鲁棒性。

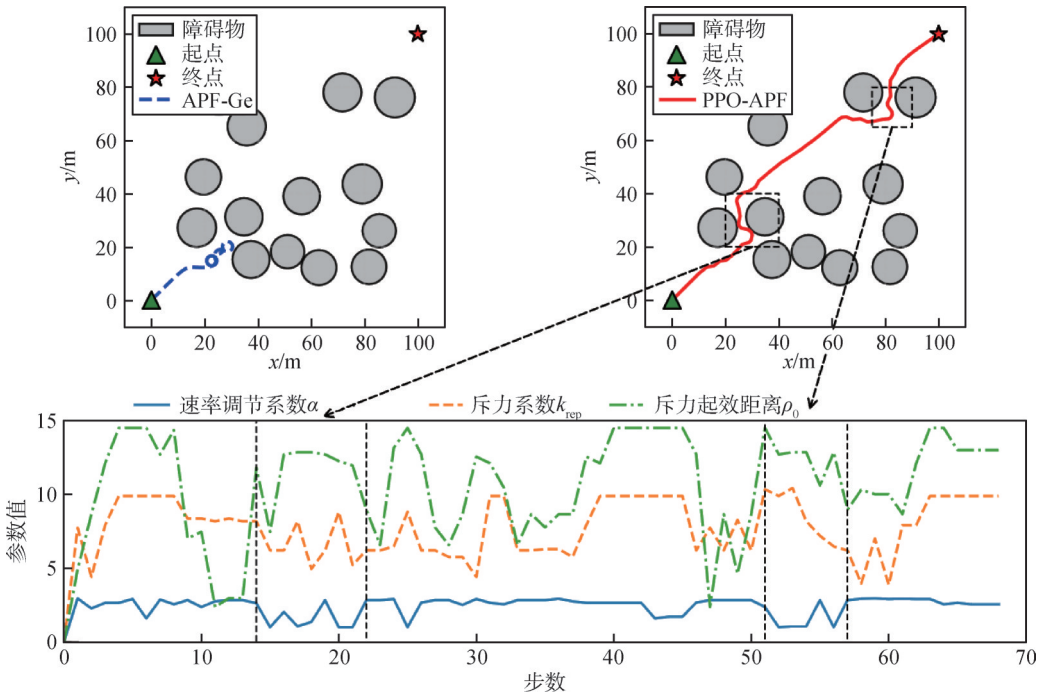


图 8　复杂障碍群场景下的参数自适应变化

参　考　文　献

[1] 蔡忻怡, 刘翼, 张恩齐, 等. 固定翼无人机协同区域覆盖监视优化部署[J]. 航天控制, 2025, 43(5): 34-41. (CAI Xinyi, LIU Yi, ZHANG Enqi, et al. Optimized deployment of cooperative fixed-wing UAVs for area coverage surveillance [J]. Aerospace Control, 2025, 43(5): 34-41.)

[2] 王飞, 杨清平. 面向多无人机物流配送的双层任务规划方法[J]. 北京航空航天大学学报, 2026, 52(1): 94-103. (WANG Fei, YANG Qingping. Two-layer task planning method for multi-UAV logistics distribution[J]. Journal of Beijing University of Aeronautics and Astronautics, 2026, 52(1): 94-103.)

[3] 陈锦涛, 李鸿一, 任鸿儒, 等. 基于RRT森林算法的高层消防多无人机室内协同路径规划[J]. 自动化学报, 2023, 49(12): 2615-2626. (CHEN Jintao, LI Hongyi, REN Hongru, et al. Indoor collaborative path planning of high-rise fire multi-UAV based on RRT forest algorithm[J]. Acta Automatica Sinica, 2023, 49(12): 2615-2626.)

[4] LIU L, WANG X, YANG X, et al. Path planning techniques for mobile robots: review and prospect [J]. Expert Systems with Applications, 2023, 227: 120254.

[5] KHATIB O. Real-time obstacle avoidance for manipulators and mobile robots[J]. The International Journal of Robotics Research, 1986, 5(1): 90-98.

[6] 杨萌, 王玥. 基于改进人工势场法的无人机避让航迹规划[J]. 导航与控制, 2019, 18(1): 76-82. (YANG Meng, WANG Yue. UAV avoidance path planning based on improved artificial potential field method [J]. Navigation and Control, 2019, 18(1): 76-82.)

[7] GE S S, CUI Y J. New potential functions for mobile robot path planning[J]. IEEE Transactions on Robotics and Automation, 2000, 16(5): 615-620.

[8] 姬鹏, 郭明皓. 基于Frenet坐标下改进人工势场法的无人车局部路径规划[J]. 兵工学报, 2024, 45(7): 2097-2109. (JI Peng, GUO Minghao. Localized path planning for unmanned vehicles based on improved artificial potential field method in Frenet coordinates [J]. Acta Armamentarii, 2024, 45(7): 2097-2109.)

[9] 张菁, 何友, 彭应宁, 等. 基于神经网络和人工势场的协同博弈路径规划[J]. 航空学报, 2019, 40(3): 228-238. (ZHANG Jing, HE You, PENG Yingning, et al. Cooperative game path planning based on neural network and artificial potential field[J]. Acta Aeronautica et Astronautica Sinica, 2019, 40(3): 228-238.)

[10] ZHANG Y, ZHAO W, WANG J Y, et al. Recent progress, challenges and future prospects of applied deep reinforcement learning: A practical perspective in path planning[J]. Neurocomputing, 2024, 608: 128423.

[11] UGURLU H I, PHAM X H, KAVACAN E. Sim-to-real deep reinforcement learning for safe end-to-end planning of aerial robots[J]. Robotics, 2022, 11(5): 109.

[12] LEI H, NABIL A, SONG B, et al. Explainable deep reinforcement learning for UAV autonomous path planning[J]. Aerospace Science and Technology, 2021, 118: 107052.

[13] ZHANG D Y, ZHANG X Y, ZHANG Z, et al. Reinforced potential field for multi-robot motion planning in cluttered environments [C]// IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), Detroit, MI, USA, 2023: 699-704.

[14] 吴健发, 王宏伦, 王延祥, 等. 无人机反应式扰动流体路径规划[J]. 自动化学报, 2023, 49(2): 272-287. (WU Jianfa, WANG Honglun, WANG Yanxiang, et al. UAV reactive interfered fluid path planning[J]. Acta Automatica Sinica, 2023, 49(2): 272-287.)