航 空 学 报
Acta Aeronautica et Astronautica Sinica

Sep. 15 2025 Vol. 46 No. 17
ISSN 1000-6893 CN 11-1929/V

http://hkxb.buaa.edu.cn hkxb@buaa.edu.cn

引用格式：黄湘松，王梦宇，潘大鹏. 基于对抗强化学习的无人机逃离路径规划方法[J]. 航空学报，2025，46(17)：331637. HUANG X S，WANG M Y，PAN D P. Adversarial reinforcement learning-based UAV escape path planning method [J]. Acta Aeronautica et Astronautica Sinica，2025，46(17)：331637 (in Chinese). doi：10.7527/S1000-6893.2024.31637

基于对抗强化学习的无人机逃离路径规划方法

黄湘松[1,2]，王梦宇[1]，潘大鹏[1,2,*]

1．哈尔滨工程大学 信息与通信工程学院，哈尔滨 150001
2．哈尔滨工程大学 先进船舶通信与信息技术工业和信息化部重点实验室，哈尔滨 150001

摘 要：在无人机技术迅速发展的背景下，如何应对其他无人机的恶意追捕成为了无人机安全防护中的重要课题。针对通过使用对抗强化学习算法，提升无人机在敌对环境中的适应性和生存能力这一问题，利用对抗强化学习框架，针对无人机逃逸过程中接收错误信息对决策产生干扰的问题进行了处理，以围捕者与逃逸者之间的对抗为基础，优化运输无人机的策略以应对围捕者的行为。针对传统的强化学习方法中的稀疏奖励问题，结合人工势场法提出逐步奖励策略机制，使得无人机可以更有效地适应围捕环境。结果表明，该算法相比于近端策略优化(PPO)算法，无人机的逃逸成功率提升了54.47%，同时运输时间减少了34.35%，显著提高了无人机的运输效率。结果为无人机的安全防护提供了新的技术方案，并探索了对抗强化学习在恶意追捕情境下的应用潜力。

关键词：对抗训练；强化学习；逃逸路径规划；逃逸决策；奖励函数

中图分类号：V279；TP18 **文献标识码**：A **文章编号**：1000-6893(2025)17-331637-16

在当今社会，无人机技术的快速发展为各个领域带来了广泛的应用和发展机遇，由于其具有造价低廉、操作简单等特点，无人机的大量应用可以代替飞行员在危险的战争环境下完成补给运输等任务[1-3]，极大的降低了运输成本。然而，随着无人机技术的普及和成熟，无人机的安全性问题也越来越受到关注。尤其是在安全防护领域中，如何在被恶意无人机的围捕和攻击[4]的情景下完成逃逸成为一项紧迫的任务。在此类场景下，为保护无人机成功运送资源到达目的地，必须使无人机具有应对敌方追捕的逃逸能力，快速找到安全的逃生路径，因此，设计一种有效的无人机逃离路径规划算法变得尤为重要。本文旨在探讨无人机逃离路径规划的相关技术和方法，通过对抗强化学习算法，训练无人机在敌方围捕和攻击下做出智能应对，从而提高无人机在敌对环境下的适应性和生存能力；希望为无人机安全防护领域提供一种新的技术解决方案，并探索对抗强化学习在此类问题上的应用潜力。

目前无人机安全防护领域研究主要集中在无人机飞行过程中有效规避静态或动态障碍物的策略构建[5-6]、全局路径规划[7]以及针对复杂飞行环境中各种突发状况设计实时性局部路径调整[8]等问题，但面对追捕无人机的恶意追逐，现有研究存在明显不足，需深入探索相关策略和技术，以提升无人机在复杂环境下的安全防护能力。躲避无人机的恶意追捕是一种追逃决策问

收稿日期：2024-12-09；退修日期：2025-01-10；录用日期：2025-03-18；网络出版时间：2025-04-15 16:11
网络出版地址：https://hkxb.buaa.edu.cn/CN/Y2025/V46/I17/331637
基金项目：国家自然科学基金(62001136)
* 通信作者. E-mail：pandapeng@hrbeu.edu.cn

题[9]，目前无人机追逃决策算法主要包括传统算法和人工智能算法[10]。传统无人机追逃决策方法有微分博弈论[11]、影响图法[12]、专家系统法[13]等，其缺点是规则基础复杂，难以涵盖所有追逃情况，灵活性差。进入21世纪以来，人工智能在无人机追逃中的应用取得了良好的效果。研究人员将无人机视为强化学习的代理，使他们能够在环境中经过一定阶段的试错学习后，在复杂环境中逐渐获得优化的策略。张耀中等[14]设计了一种基于深度确定性策略梯度（DDPG）算法的无人机追逃任务指导奖励函数，并引入了一种基于滑动平均的软更新策略。无人机群可以成功执行追击任务。然而，多架无人机和一架无人机之间的博弈导致对方之间存在显著的优势差距。Kouzeghar等[15]提出了一种基于多智能体深度确定性策略梯度（MADDPG）算法的新方法，通过异构角色和基于Voronoi的奖励策略加强探索和协同控制策略解决了解决多无人机系统在动态、复杂环境中追踪多个规避目标的问题。符小卫等[16]研究了多无人机攻防对抗问题，设计了基于优先经验回放机制的PER-MATD3算法，并通过仿真实验验证了其在攻防对抗中的优越性能。文献[15-16]所提方法在无法准确感知地方信息时，可能导致算法稳定性和鲁棒性问题。Xiong和Zhang[17]在多追逃博弈框架下设计了结合前馈控制和强化学习的控制策略，实现了对逃逸者的有效包围，但算法的实时性和稳定性需要进一步验证。Guo等[18]提出了一种层次化强化学习（HRL）框架，通过将任务分解为多个子任务，HRL方法有效减少了奖励稀疏的影响，但该方法子任务之间的协作和奖励设计可能导致模型训练的稳定性问题。综上所述，现有的无人机逃离路径规划方法在应对无法准确感知的敌方围捕场景时，仍存在适应性、泛化能力和鲁棒性等方面的局限性[19]，由于难以克服稀疏奖励问题，使得无人机追逃问题存在计算效率低和效果差的问题。

本文探讨了无人机在面临被围捕的高威胁环境下的逃离路径规划策略，提出了一种逐步奖励对抗近端策略优化算法（Stepwise Reward Adversarial Proximal Policy Optimization，ADR-PPO）。针对强化学习鲁棒性低的问题，引入对抗训练[20]，考虑到实战中敌方目标的位置信息很难精确感知，设计有干扰测试，即通过对无人机观测信息加入噪声模仿无人机观测信息与实际信息的误差，验证了对抗训练的有效性，提高无人机飞行的安全性；针对传统稀疏奖励问题[21]，设计基于人工势场的逐步奖励函数[22]，提高逃逸的成功率。本文提出的算法使得有干扰条件下运输无人机逃逸成功率相较于PPO算法提高了54.47%。不仅如此，ADR-PPO算法更使得无人机的运输时间在PPO基础上减少了34.35%，显著提高了无人机运输效率。

1 问题描述

1.1 任务场景描述

为研究无人机逃离路径规划，设定如图1所示无人机逃逸空战场景，其中，2架蓝方运输无人机起点为蓝色圆圈范围内，终点为黄色圆圈，红方为4架追捕无人机，绿色区域为禁飞区。在该场景中，蓝方运输无人机需完成由起点到终点的运输任务，运输无人机达到终点认为任务成功。红方追捕无人机对蓝方运输无人机展开追捕，形成围捕趋势，即在运输无人机完成运输任务的飞行过程中，会受到追捕无人机的有意图追捕，因此本文建立以下6个前提条件来分析无人机逃逸问题。

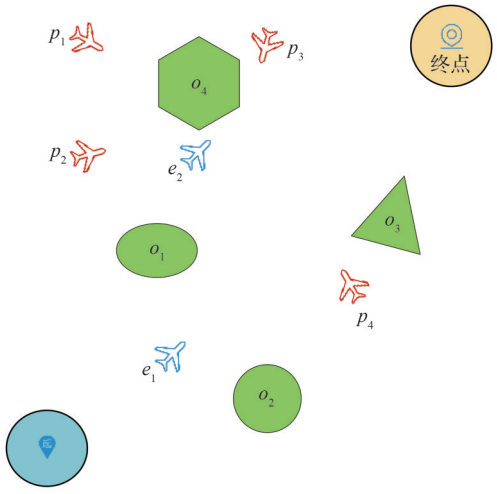


图1 无人机逃逸空战场景

Fig. 1 Drone escape air combat scenario

1）训练阶段可获得完整的先验信息：对于运输无人机逃逸场景模型，其感知系统具备对追捕者与无人机自身的动态参数（位置与速度信息）以及环境静态参数（障碍物、目标点位置信息）的全维度感知能力。由于实战中敌方目标的位置信息很难精确感知，在测试阶段，对算法的状态空间施加高斯噪声，模仿无人机观测到的障碍物位置、追捕无人机位置以及自身位置相较于实际位置均存在误差，误差范围在10～100 m之间。

2）假设追逃双方处在同一水平面上，不考虑高度因素，因此所讨论的无人机逃离路径规划可认为是二维场景。

3）设置m架运输无人机$\{e_1, e_2, \cdots, e_m\}$，此类无人机基于强化学习算法构建，其首要任务是到达目标点，完成运输任务。在此过程中需要完成躲避静态障碍物和蓝方多追捕无人机的有意识追捕，使自身始终处于较为安全的状态下，且该无人机不具备攻击能力，即在此场景设定下运输无人机$\{e_1, e_2, \cdots, e_m\}$只能选择逃逸。

4）设置n架追捕无人机$\{p_1, p_2, \cdots, p_n\}$，此类无人机对运输无人机展开追捕，形成围捕趋势，该无人机进行火力打击的规则为纯追踪法：其速度方向将时刻指向运输无人机。

5）每局随机产生k个禁飞区域$\{o_1, o_2, \cdots, o_k\}$，禁飞区域指禁止通过的危险区，通过禁飞区将认为无人机坠毁。

6）本文所设置任务场景中，追捕者无人机群的融合规则是或（OR）规则，即只要任意一架无人机击落红方运输无人机，都可以认为红方无人机被捕获，此时判定运输任务失败。

在本文所设置场景下，运输任务失败存在2种情况：

1）运输无人机在运输途中逃逸失败，处在追捕无人机攻击范围内，被追捕无人机击落，即$\forall p \in \{p_1, p_2, \cdots, p_n\}$满足

$$\sqrt{(X_{e_m} - X_{p_n})^2 + (Y_{e_m} - Y_{p_n})^2} \leqslant d_{\max} \tag{1}$$

式中：X_{e_m}、Y_{e_m}为运输无人机位置坐标；X_{p_n}、Y_{p_n}为追捕无人机位置坐标；$d_{\max}$为追捕者能攻击到的最大距离。

2）运输无人机飞入禁飞区坠毁，即$\forall o \in \{o_1, o_2, \cdots, o_k\}$满足

$$\sqrt{(X_{e_m} - X_{o_k})^2 + (Y_{e_m} - Y_{o_k})^2} \leqslant d_{\min} \tag{2}$$

式中：X_{o_k}、Y_{o_k}为无人机所靠近的禁飞区边缘位置坐标；$d_{\min}$为最小碰撞距离。

1.2 无人机物理约束

运输无人机$\{e_1, e_2, \cdots, e_m\}$可提高到的最大速度小于追捕无人机$\{p_1, p_2, \cdots, p_n\}$最大速度。任务场景中，无人机要服从以下5个约束。

1）对抗环境边界约束

$$\begin{cases} -x_{\max} \leqslant X \leqslant x_{\max} \\ -y_{\max} \leqslant Y \leqslant y_{\max} \end{cases} \tag{3}$$

2）速度约束

$$v_{\min} \leqslant V \leqslant v_{\max} \tag{4}$$

3）最大偏航角约束

$$-\varphi_{\max} \leqslant \Delta\varphi \leqslant \varphi_{\max} \tag{5}$$

4）最大加速度约束

$$-c_{\max} \leqslant c \leqslant c_{\max} \tag{6}$$

5）最大角速度约束

$$-\varpi_{\max} \leqslant \varpi \leqslant \varpi_{\max} \tag{7}$$

式中：V为无人机速度；φ为无人机航向角；(X, Y)为无人机坐标位置。

2 无人机逃逸方法

2.1 运输无人机逃逸方法描述

针对运输无人机逃离路径规划问题，为使运输无人机能够更快、更安全地完成运输任务顺利到达目的地，使用基于ADR-PPO算法框架构建运输无人机。具体而言，采用了对抗强化学习框架，用于解决无人机逃逸过程中无人机观测到的状态信息与实际信息存在误差对无人机决策的干扰的问题，提高了强化学习框架的鲁棒性；针对传统的强化学习方法中的稀疏奖励问题，结合人工势场法提出逐步奖励函数，使得无人机可以更好地适应围捕环境。

图2所示是无人机逃离路径规划算法结构图。对于无人机逃离路径规划而言，该算法首先通过环境感知模块收集无人机的当前状态和外部威胁信息，然后将这些信息输入到基于近端策略优化（PPO）算法的行为决策系统中。在该系

统内部,状态空间定义了无人机的感知范围,动作空间提供了可能的逃逸动作选项。奖励函数的设计对无人机的学习过程至关重要,它根据无人机的行动和环境的反馈来评估行动的优劣,为成功避开围捕、接近目标点、远离障碍物和禁飞区等行为提供正向激励,同时对可能导致无人机被捕或撞击障碍物的行为给予负向惩罚。神经网络结构处理输入的状态信息,在此引入对抗训练,确保学习框架的鲁棒性,最终输出最优的动作策略。随后,这些决策被传递至执行层,在满足物理约束和环境条件下,无人机根据指令执行相应的机动动作。

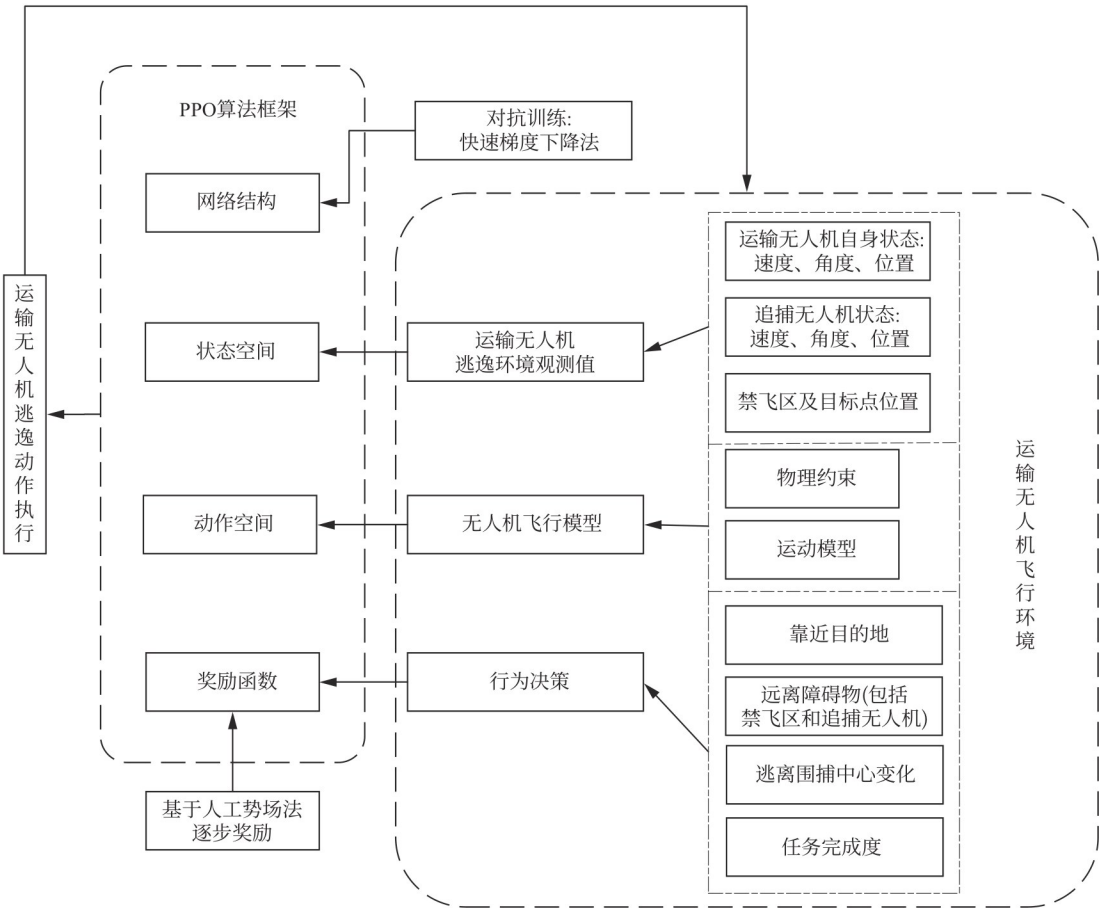


图 2 无人机逃离路径规划方法的结构图

Fig. 2 Block diagram of drone escape path planning method

2.2 基于对抗强化学习的无人机逃逸方法

2.2.1 PPO算法

PPO算法是一种用于强化学习中策略优化的算法,旨在解决策略梯度方法在优化时面临的问题,该算法在每次更新时限制新策略与旧策略之间的距离,从而保证更新的稳定性和收敛性。尤其是对于无人机空战这类复杂的应急环境,稳定的更新范围更有利于更快速、更高效的无人机系统进行训练,因此本文在运输无人机逃离路径规划方法中选择PPO算法学习框架。

PPO算法基于演员-评论家(AC)框架,包含2个网络。在运输无人机逃离路径规划中,策略网络负责生成无人机的动作,而评价网络则评估当前策略的效果,以指导策略的改进。策略网络能够在连续动作空间中学习,输出连续的实值向量作为动作。这2个网络的参数更新都基于策略梯度方法,以持续优化策略。具体来说,Actor网络更新部分定义了如式(8)和式(9)所示的surro-

gate目标

$$\max L^{\mathrm{CPI}}(\theta)=\max \hat{E}_t\left[r_t(\theta)\hat{A}_t\right] \tag{8}$$

$$r_t(\theta)=\frac{\pi_\theta\left(a_t|s_t\right)}{\pi_{\theta_{\mathrm{old}}}\left(a_t|s_t\right)} \tag{9}$$

式中：θ为策略网络参数；θ_{old}是旧策略网络参数；$\hat{E}_t$表示对0到t区间求均值；π_θ表示当前时刻的策略；$\pi_{\theta_{\mathrm{old}}}$表示上一时刻的策略；$\hat{A}_t$估计了在状态$s_t$下动作$a_t$的优势函数。

在PPO中，对上述surrogate目标进行了裁剪，如式(10)和式(11)所示

$$L^{\mathrm{clip}}(\theta)=\hat{E}_t\left[\min\left(r_t(\theta)\hat{A}_t,\mathrm{clip}\left(r_t(\theta),1-\varepsilon,1+\varepsilon\right)\hat{A}_t\right)\right] \tag{10}$$

$$\mathrm{clip}\left(x,x_{\min},x_{\max}\right)=\begin{cases}x & x_{\min}\leqslant x\leqslant x_{\max}\\ x_{\min} & x<x_{\min}\\ x_{\max} & x>x_{\max}\end{cases} \tag{11}$$

式中：$r_t(\theta)$代表新策略与旧策略在给定状态下选择某个动作的概率比率；ε是一个超参数，用于将限制在一定范围内，确保新旧策略之间动作差不会太大；目标$L^{\mathrm{clip}}(\theta)$实现了一种与随机梯度下降兼容的信赖域修正方法，减小适应性修正的需求。

2.2.2 对抗训练原理

对抗性训练被认为是提高深度强化学习系统的鲁棒性和泛化能力的有效策略，其基本理念是通过引入扰动噪声来应对深度强化学习模型在遭遇干扰时可能出现的决策波动问题。

通过快速梯度下降法(Fast Gradient Sign Method，FGSM)来实现对抗攻击。在对抗攻击领域，FGSM是一种常用的攻击手段。其核心思想在于通过精确计算损失函数相对于输入样本的梯度，精准地判定扰动的方向及幅度，进而构造出对抗样本，诱导模型做出错误的分类判断。这里的关键是计算这个扰动，以确保在满足一定范数限制的情况下，最大化损失函数。

对模型参数θ而言，FGSM方法将线性化损失函数，并使用反向传播计算梯度，从而得到无穷范数下的最优扰动(即$\|\eta\|_\infty<\varsigma$，$\varsigma$是对抗性扰动的大小)，扰动值具体为

$$\eta=\varepsilon\cdot\mathrm{sign}\left(\nabla_x J(x,y;\theta)\right) \tag{12}$$

式中：sign为符号函数，自变量大于0时取1，小于0时取-1；x为输入数据，即模型在训练或推理时所接收的输入，在运输无人机逃逸方法中为运输机当前的状态，如位置、速度、目标点等信息；y表示目标输出，即模型在训练时所期望的输出或模型在推理时的预测结果，在运输无人机逃逸方法中是无人机的下一个动作；θ为模型参数，L为损失函数，∇为取偏导数；$J(x,y;\theta)$是训练神经网络的损失函数。

FGSM给定了在白盒攻击下的扰动计算的统一的方法，即根据梯度来计算扰动，梯度下降法本身旨在尽量让模型的损失函数最快下降，而攻击则旨在让模型产生最大的损失，因此直接根据梯度来计算扰动是比较合理的。FGSM的思路非常简单，仅根据梯度的符号来计算对抗攻击的扰动值。FGSM的攻击表达为

$$x'=x+\varepsilon\cdot\mathrm{sign}\left(\nabla_x L(x,y;\theta)\right) \tag{13}$$

实际上，对于式(13)中的x'再进行前向传播，并在反向传播中重新计算梯度后，可以发现模型的梯度下降幅度实际上被反向加强了$\varepsilon\cdot\mathrm{sign}\left(\nabla_x L(x,y;\theta)\right)$，也就是说，模型参数的更新会导致模型的损失相对于未扰动时增大。

2.2.3 基于对抗强化学习的无人机逃逸方法

在PPO算法框架内融入FGSM技术，是通过在计算策略损失值的过程中引入对抗性扰动，以此来增强算法的鲁棒性。在运输无人机逃逸方法中，这种对抗式训练方法能够助力无人机系统更好地面对多样化的环境扰动与潜在攻击，确保路径规划既稳定又安全。在策略梯度的计算阶段，将对抗性扰动加入到原始策略参数中，借此调整策略更新的导向，最终构建出了本文所提出的ADR-PPO算法架构。

基于ADR-PPO算法的运输无人机逃逸算法流程图如图3所示。

1) 初始化环境和网络参数

初始化环境和PPO算法策略参数θ和对抗性扰动大小ς，设置学习率α，迭代次数等超参数。

2) 收集经验数据

利用当前的策略网络在环境中执行动作，根

据式(14)收集经验轨迹和奖励放入经验池。

$$\tau=\left\{\left(s_i,a_i,r_i\right)\right\}_{i=1}^{K} \tag{14}$$

式中:τ表示一次完整的经验轨迹,包括状态s_i、动作a_i和奖励r_i;K表示轨迹的长度。

3) 计算优势函数

根据收集的经验数据计算优势函数,用于评估每个行动的优劣。

$$A(s,a)=Q(s,a)-V(s) \tag{15}$$

式中:$A(s,a)$表示该状态动作的优势函数;$Q(s,a)$是状态动作的价值函数;$V(s)$是状态的价值函数。

4) 计算梯度

根据PPO算法定义的目标函数式(8)~式(11),计算当前策略网络的梯度。

5) 添加对抗性扰动

对原始策略参数θ和观测状态s,根据式(12)计算对抗性梯度

$$\nabla_\theta^{\mathrm{adv}}=\mathrm{sign}\left(\nabla_\theta J(\theta,s,a)\right)\cdot\varepsilon \tag{16}$$

式中:$J(\theta,s,a)$是策略的损失函数。

6) 根据式(13)构造对抗性更新的策略参数

$$\tilde{\theta}=\theta+\alpha\cdot\nabla_\theta^{\mathrm{adv}} \tag{17}$$

7) 更新策略网络参数

根据式(18)来更新策略网络的参数,使得策略朝着最优方向调整,生成新的运输无人机动作。

$$\theta_{\mathrm{new}}=\theta_{\mathrm{old}}+\alpha\nabla_\theta L^{\mathrm{clip}}(\theta) \tag{18}$$

式中:θ_{new}表示更新后的策略网络参数;θ_{old}表示更新前的策略网络参数;α是学习率。

8) 重复步骤2)~7)

循环执行步骤2)~7),直到达到指定的训练轮数或收敛条件。

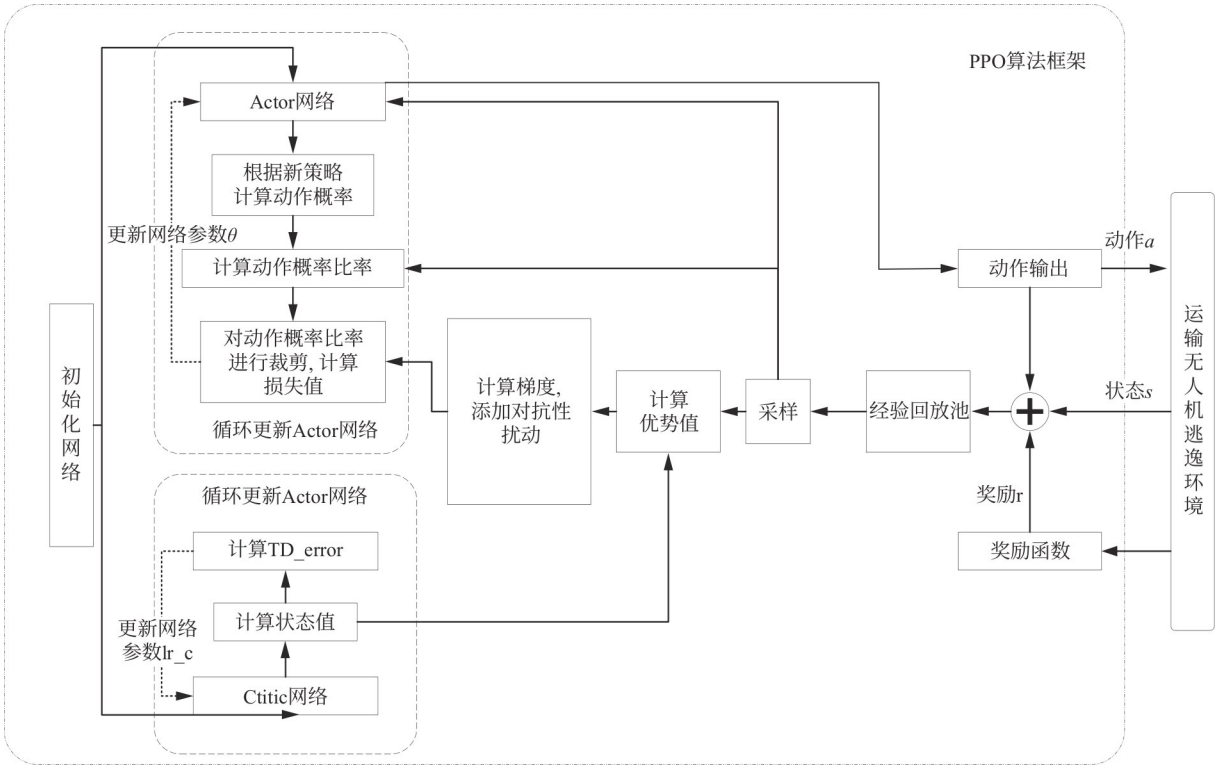


图 3 基于ADR-PPO算法的运输无人机逃逸算法流程图

Fig. 3 Flow chart of cargo crone escape algorithm based on ADR-PPO agorithm

2.3 状态空间

对于运输无人机自身的状态信息可表示为

$$S_{\mathrm{e}}=\left\{X_{\mathrm{e}},Y_{\mathrm{e}},V_{\mathrm{e}},\varphi_{\mathrm{e}}\right\} \tag{19}$$

式中:X_{e}、Y_{e}为运输无人机位置坐标;V_{e}为运输无人机速度;φ_{e}为运输无人机航偏角。

设定状态空间S_{p_i}为运输无人机获取到的第i个追捕无人机的状态信息为

$$S_{p_i}=\left\{X_{p_i},Y_{p_i},V_{p_i},\varphi_{p_i}\right\}\quad i\in[1,n] \tag{20}$$

式中：X_{p_i}、Y_{p_i}为追捕无人机位置坐标；V_{p_i}为追捕无人机速度；φ_{p_i}为追捕无人机航偏角。

在运输无人机的逃逸过程中，其状态空间的构建基于对周围环境的精确感知。运输无人机能够准确观测到追捕无人机与自身的位置和速度信息，同时也能获取障碍物及目标点的位置数据，故在运输任务仿真中，状态空间为

$$S=\left\{S_e,S_{p_i},D,D_o\right\} \tag{21}$$

式中：D表示运输无人机到目标点的距离；D_O表示运输无人机与障碍物的距离。

2.4 动作空间

在深度强化学习的训练环节，常见做法是把将连续决策过程划分为相等时间的离散决策单元，使得智能体能更频繁地感知环境并迅速做出决策。在每一个这样的时间间隔里，智能体会选取一个动作，随后系统更新环境状态计算奖励函数，对该动作进行评估，进而构建马尔科夫决策过程。

为方便建模，定义T为离散化处理单元，即仿真学习环境中的时间步长，则无人机逃离路径规划的完整决策周期可被量化为f个T的累加过程。对抗双方的状态信息随T同步更新，以确保学习主体能够及时感知环境的变化并做出相应的决策。

在无人机运动学描述方面，采用二维运动学参量构建，即无人机航向和速度2个基本维度。无人机i的动作空间$a=\{a_1,a_2,a_3,a_4\}$，a_1为无人机当前速度，a_2为上一时刻无人机速度，a_3为无人机当前航向角，a_4为上一时刻无人机航向角，$c=a_2-a_1$为无人机的速度改变值，$q=a_4-a_3$为无人机的航向改变值。

无人机的运动方程如式(22)所示

$$\begin{cases}\varphi_{t+1}=\varphi_t+q_t\cdot\Delta\varphi\\ V_{t+1}=V_t+c_t\\ X_{t+1}=X_t+V_t\cdot\cos\varphi_t\cdot T\\ Y_{t+1}=Y_t+V_t\cdot\sin\varphi_t\cdot T\end{cases} \tag{22}$$

式中：φ_t为无人机在t时刻的航向；V_t为无人机在t时刻的速度；c_t为无人机速度在t时刻的改变值；X_t、Y_t为无人机在t时刻的位置；X_{t+1}、Y_{t+1}为无人机在$t+1$时刻的位置；T为无人机在该状态持续的时间即一个时间步长。

2.5 奖励函数

在传统的强化学习中，采用二元离散的稀疏奖励反馈机制，智能体在与环境的交互中只在一个回合结束后获得奖励信号，而在其他状态或动作下则没有或很少获得奖励。这种方法虽然在大多数强化学习任务中展现出普适性，但在一些任务中，特别是时间步数较长的任务，会使得学习更加困难，且缺乏足够的针对性，导致训练过程不够高效。

对于无人机逃逸问题而言，其具有复杂性和多变性，使得设计出适合该场景的奖励函数更加困难。提出基于人工势场法设计的逐步奖励函数设计，通过密集的逐步奖励信号引导学习，使无人机逃离过程更加智能和高效。

1）靠近目的地奖励

将人工势场引入奖励函数设计后，对于运输无人机而言，则是将其置于由目标点产生的势力场下，运输无人机在该势力场下的运动将会带来势能变化。因为本文假设无人机能够感知目标点的位置，设置由目标点对运输无人机产生一个全局的引力场，并将无人机在目标点势能场中的势能变迁，作为每个训练迭代步骤的奖赏依据。通过给予距离奖励，实际上是让输出的动作能够尽量输出一个朝向目标点的合力，以此来尽快找到一条最优路径。根据常用引力势场表达式，定义目标点产生的引力势能为

$$U_{att}(\boldsymbol{p}_e)=\frac{1}{2}\eta\boldsymbol{\rho}^2(\boldsymbol{p}_e,\boldsymbol{p}_t) \tag{23}$$

式中：η为正比例增益系数；$\boldsymbol{\rho}(\boldsymbol{p}_e,\boldsymbol{p}_t)$表示运输无人机位置$\boldsymbol{p}_e$与目的地位置$\boldsymbol{p}_t$的欧氏距离，其方向是由无人机位置指向目的地位置。

因此，将靠近目的地奖励设计为

$$r_{att}=\Delta U_{att}(\boldsymbol{p}_e) \tag{24}$$

式中：$\Delta U_{att}(\boldsymbol{p}_e)$为训练过程中每一个时间步前后，运输无人机在目标点引力场下的势能变化。

2）远离障碍物奖励设计

在运输无人机执行运输任务途中，存在静止障碍物及有追捕意识的移动障碍物（追捕无人机），障碍物对运输无人机产生斥力场，将无人机在障碍物斥力场中的势能变动视作每个训练时段的奖励依据。

在强化学习框架下每完成一个时间步的训练后，如果无人机和障碍物之间的距离变近，那么障碍物产生的虚拟力场中的势能就会增加。特别是当两者距离近道一定阈值时，就意味着无人机处境非常危险，则斥力势能会急剧增强，其变化速率与相对距离呈负相关关系，距离越近变化越快。因此，在训练过程中，一旦发现无人机和障碍物之间的距离在缩小，就应该对无人机的策略进行惩罚。这里需要注意的是，由于无人机和障碍物之间的距离越近，危险就越大，所以惩罚的大小应该根据距离的远近来调整：对于那些导致无人机和障碍物距离缩小的行为，设定一个负向奖励，距离缩得越近，惩罚就越重。

根据常用斥力势场表达式，定义单个障碍物产生的斥力势能为

$$U_{\mathrm{req}}(\boldsymbol{p}_{\mathrm{e}})=\begin{cases}\dfrac{1}{2}g\left(\dfrac{1}{\rho(\boldsymbol{p}_{\mathrm{e}},\boldsymbol{p}_{\mathrm{o}})}-\dfrac{1}{\rho_0}\right)^2 & 0<\rho(\boldsymbol{p}_{\mathrm{e}},\boldsymbol{p}_{\mathrm{o}})\leqslant\rho_0\\ 0 & \rho(\boldsymbol{p}_{\mathrm{e}},\boldsymbol{p}_{\mathrm{o}})>\rho_0\end{cases} \tag{25}$$

式中：g为正比例系数；$\rho(\boldsymbol{p}_{\mathrm{e}},\boldsymbol{p}_{\mathrm{o}})$为矢量，方向为由障碍物指向运输无人机，大小为运输无人机与障碍物间的欧式距离；ρ_0为一常数，表示障碍物对运输无人机产生作用的最大影响范围。

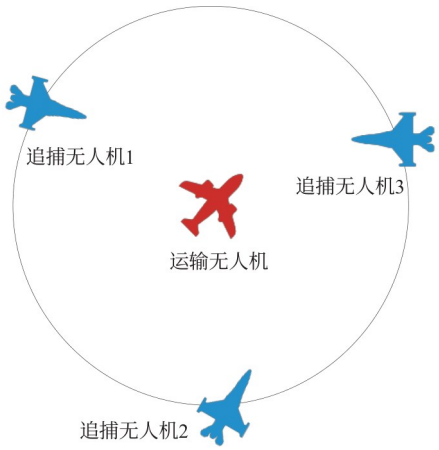
当障碍物离得更近时，奖励值越低；反之，奖励值越高。因此，将远离障碍物奖励设计为

$$r_{\mathrm{rep}}=-\sum_{i=1}^{n}\Delta U_{\mathrm{rep}}(\boldsymbol{p}_{\mathrm{e}}) \tag{26}$$

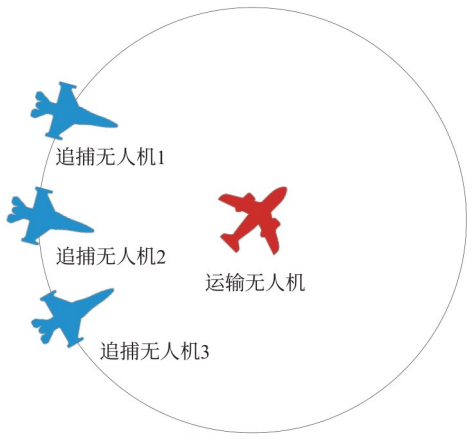
式中：$\Delta U_{\mathrm{rep}}(\boldsymbol{p}_e)$为训练过程中每一个时间步前后，运输无人机在单个障碍物斥力场下的势能变化；i是障碍物个数，包括静态障碍物和追捕无人机。

3）逃离围捕中心奖励

本文中的多智能体协同追捕任务场景存在特殊性，由于追捕无人机的空间分布会直接影响运输无人机的安全威胁程度，因此需要建立一个能够衡量围捕态势的评估系统。因此引入了虚拟围捕中心坐标的概念，在此概念下，距离围捕中心越远的飞行策略越安全，即当运输无人机朝着远离了虚拟围捕中心的方向飞行时，其决策将获得正向奖励。围捕情况如图4所示。



(a) 无人机位于围捕中心



(b) 无人机未在围捕中心

图 4 多无人机围捕情况示意图

Fig. 4 Multi-drone surrounding and capturing situation

图4(a)表明无人机处在围捕中心，此时运输无人机的安全等级低，但由于距离大于最小安全距离，所以并不是围捕成功，图4(b)则表明无人机没有处在围捕中心，此时安全等级更高。即当运输无人机与追捕无人机位置关系满足式，则认为运输无人机出于围捕状态，此时定义围捕中心点为

$$\begin{cases}\min\{X_{p_1},X_{p_2},\cdots,X_{p_n}\}\leqslant X_{p_1}\leqslant\max\{X_{p_1},X_{p_2},\cdots,X_{p_n}\}\\ \min\{Y_{p_1},Y_{p_2},\cdots,Y_{p_n}\}\leqslant Y_{p_1}\leqslant\max\{Y_{p_1},Y_{p_2},\cdots,Y_{p_n}\}\end{cases} \tag{27}$$

$$\boldsymbol{p}_{\mathrm{rc}}=\frac{1}{n}\sum_{i=1}^{n}\left[X_{p_n},Y_{p_n}\right] \tag{28}$$

为促使运输无人机安全到达目标点，需使无人机逃离围捕中心，设置奖励函数为

$$r_{\mathrm{rc}}=\Delta\rho(\boldsymbol{p}_{\mathrm{c}},\boldsymbol{p}_{\mathrm{rc}}) \tag{29}$$

式(29)描述了针对运输无人机在一个时间步前后与围捕中心的距离变化，若逃离围捕中心时获得正奖励，若靠近在围捕中心获得负奖励。

4) 任务奖励

无人机最终要完成的是运输任务，不论时间耗尽还是发生碰撞都将导致任务失败，因此传统奖励函数不能被忽视，设置式(27)所示奖励作为任务奖励，若成功获得巨大正奖励，若失败获得巨大负奖励。

$$r_{\mathrm{a}}=\begin{cases}-1 & \text{失败}\\ 1 & \text{成功}\end{cases} \tag{30}$$

5) 综合奖励

综上所述，将多追捕环境下无人机运输过程的奖励函数设计为

$$r=\omega_1 r_{\mathrm{att}}+\omega_2 r_{\mathrm{rep}}+\omega_3 r_{\mathrm{rc}}+\omega_4 r_{\mathrm{a}} \tag{31}$$

式中：ω_1，ω_2，ω_3，ω_4是常数，可自行调节。

在本文中，对奖励函数进行式(32)所示线性处理，避免太大的数会引发数值问题

$$r'=r/99 \tag{32}$$

3 仿真实验及结果分析

3.1 实验描述及参数设定

为验证算法的有效性，以Python3.9作为编程语言、借助Pygame1.9.4图形界面库和Tensorflow2.15深度学习框架，在Linux环境下搭建了多无人机围捕仿真环境。

仿真实验分为2个阶段，第1阶段为训练阶段，其核心目标是分析多无人机逃逸运动中基于ADR-PPO算法在训练过程中的性能，包括学习效率、奖励函数平滑度以及最终的收敛性能等指标，并与深度Q网络学习(Deep Q-Network，DQN)算法、逐步奖励函数DQN(Stepwise Reward Deep Q-Network，R-DQN)算法、逐步奖励函数PPO(Stepwise Reward Proximal Policy Optimization，R-PPO)算法以及经典的PPO算法进行对比。第2阶段为测试阶段，该阶段主要目的为证明ADR-PPO算法对于前期出现的扰动具有自行修正作用，能在观测到的环境状态信息存在误差时成功完成运输任务。

在仿真实验中，追捕无人机的数量为3，追捕者在一定范围内随机生成，通过控制追捕者生成的横纵坐标来控制其生成位置，横坐标范围为[−5，5] km之间，纵坐标范围在[−3.5，1.5] km之间。为了避免运输无人机与障碍物或其他无人机发生碰撞，如果生成的位置与其他运输无人机或障碍物发生重叠，系统会重新生成位置直到满足合理性条件。

在本环境中，障碍物是通过随机生成的椭圆形来模拟的，总障碍物个数为0～3随机，大小和位置随机，每个椭圆的旋转角度也是随机选择的，从而增加了障碍物的多样性。初始参数设置如表1所示，奖励函数中参数设定如表2所示，运输无人机的性能设定如表3所示，追捕无人机的性能设定如表4所示。

表1 强化学习参数

Table 1 Reinforcement learning parameter

参数	含义	数值
γ	奖励折扣因子	0.99
α	神经网络学习率	0.003
ϵ	剪切参数	0.2
lr_c	价值网络参数	0.003
λ	GAE	0.95
$N_{\mathrm{max_episode_steps}}$	单回合最大时间步数	1 000
T/s	时间步长	0.5
$N_{\mathrm{batch_size}}$	批次大小(Mini-batch)	2 048

表2 奖励函数参数

Table 2 Reward function parameter

参数	数值
η	1
μ	1
ρ_0	1
ω_1	200
ω_2	100
ω_3	0.3
ω_4	0.1

表3 运输无人机性能

Table 3 Cargo drone performance

参数	含义	数值
m	运输无人机数量	1
$v_{e\min}/(\mathrm{m\cdot s^{-1}})$	运输最小速度	50
$v_{e\max}/(\mathrm{m\cdot s^{-1}})$	运输最大速度	100
$\varphi_{e\max}/(^\circ)$	运输无人机最大航偏角	45
R_e/km	感知范围	10
$c_e/(\mathrm{m\cdot s^{-2}})$	运输无人机最大加速度	7
$\varpi_e/((^\circ)\cdot\mathrm{s^{-1}})$	运输无人机最大角速度	7

表4 追捕无人机性能

Table 4 Pursuit drone performance

参数	含义	数值
n	追捕无人机数量	3
$v_{p\min}/(\mathrm{m\cdot s^{-1}})$	追捕最小速度	50
$v_{p\max}/(\mathrm{m\cdot s^{-1}})$	追捕最大速度	110
$\varphi_{p\max}/(^\circ)$	追捕无人机最大航偏角	25
$d_{p\max}$/km	攻击范围	100
$c_p/(\mathrm{m\cdot s^{-2}})$	追捕无人机最大加速度	7
$\varpi_p/((^\circ)\cdot\mathrm{s^{-1}})$	追捕无人机最大角速度	7

3.2 逃逸过程及结果分析

1) 训练阶段

运用本文所提出的基于人工势场法的逐步奖励函数的对抗强化学习，对无人机进行多回合训练，在奖励函数趋于稳定后停在，因为对于R-DQN、R-PPO和ADR-PPO进行30 000回合训练，对于PPO和DQN算法分别进行50 000和55 000回合训练，训练结果如表5所示，训练过程奖励函数曲线如图5所示。

由图5可以看出，PPO算法的收敛速度和奖励函数值都优于DQN算法；R-DQN与R-PPO算法奖励值优于PPO算法；ADR-PPO算法奖励函数与R-PPO值相差不大，但ADR-PPO奖励函数曲线后期更加平滑，说明其相比于R-PPO算法更加稳定。表5统计了4种算法的奖励函数收敛后平滑度及最大值和算法训练时间，平滑度数值越大越平滑，说明算法越稳定。佐证了图5所表明ADR-PPO相较于R-PPO更加稳定，更适应于已知数据与实际有出入的战场环境。

表5 无人机逃逸训练结果

Table 5 Drone escape training results

算法	平滑度	奖励函数最大值	运行时间/h
DQN	4.06	2.57	1.38
PPO	3.78	3.02	0.57
R-DQN	4.32	3.67	2.99
R-PPO	4.53	4.47	3.22
ADR-PPO	4.64	4.49	3.42

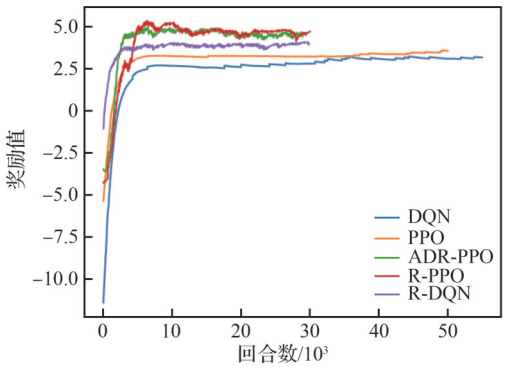


图5 训练过程奖励函数曲线

Fig. 5 Reward function curves in training process

不仅如此，由于最终目的是使运输无人机完成运输任务，分别使用PPO，R-PPO，ADR-PPO算法进行30 000回合训练，每100次训练记录当前100次训练的胜率。训练过程成功率曲线如图6所示，可以看出，ADR-PPO与R-PPO的胜率相差不大，由于ADR-PPO加入了对抗训练能够对环境变化或小噪声扰动做出相应改变，使得其波动较小，而PPO算法由于稀

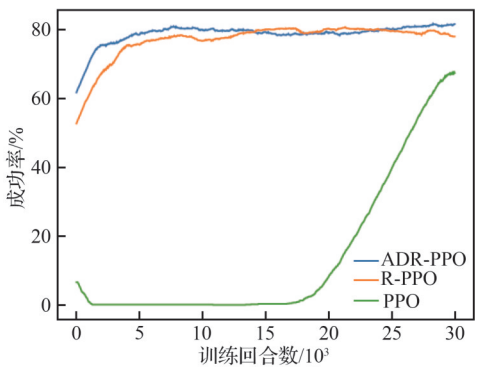


图6 训练过程成功率曲线

Fig. 6 Success rate curves in training process

疏奖励问题的存在，导致其前期成功率基本为0。

2）测试阶段

算法训练完成后，对以上提到的4种算法进行了1 000次仿真测试，为验证对抗训练的有效性，测试实验包括无干扰测试和有干扰测试。有干扰测试是指，对算法的状态空间施加高斯噪声，则意味着无人机观测到的障碍物位置、追捕无人机位置以及自身位置相较于实际位置均存在误差，误差范围在10～100 m之间。设置每次最大时间步长为1 000，该时间步之内运输无人机未到达目的地则判定任务失败。

测试结果如表6，仿真表明，在无干扰场景下本文提出的ADR-PPO成功率相较于PPO算法提高了16.83%，R-PPO和ADR-PPO均可达到较高的成功率，但当有干扰即观测信息有误差时，只有ADR-PPO算法保持较高成功率，其余均较低，表明本文提出的对抗训练的有效性，本文提出算法使得有干扰条件下运输无人机逃逸成功率相较于PPO算法提高了54.47%。不仅如此，ADR-PPO算法更使得无人机的运输时间在PPO基础上减少了34.35%，显著提高了无人机运输效率。

表6 测试结果

Table 6 Test results

场景	算法	成功率/%	运输成功时平均飞行时间/s
无干扰	DQN	51.7	355.98
	PPO	69.5	292.54
	R-PPO	81.0	176.87
	ADR-PPO	81.2	173.25
有干扰	DQN	36.9	392.81
	PPO	51.4	328.44
	R-PPO	66.7	178.01
	ADR-PPO	79.4	175.62

图7为算法有干扰场景下测试1 000次的奖励函数值，对比了R-PPO和ADR-PPO算法在有干扰测试中的奖励函数值。在该图中，奖励函数值低于0即为逃离失败，显然该图表明在无人机接收到的位置信息存在误差时ADR-PPO算法逃逸成功率高于R-PPO算法，同时也佐证了表6中在有干扰场景中的成功率数据：R-PPO成功率为66.7%，ADR-PPO成功率为79.4%。

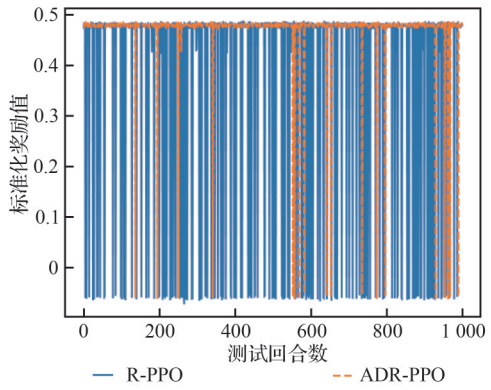


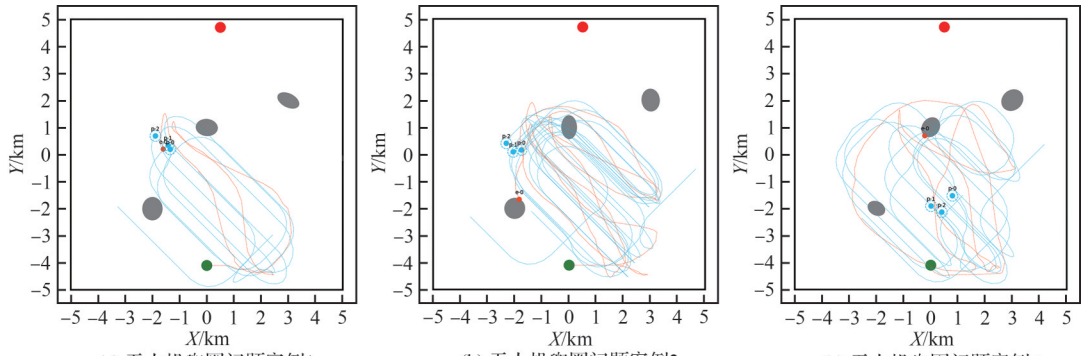
图7 算法有干扰场景下测试奖励函数值

Fig. 7 Test reward function values of algorithm in disturbed scene

图8为无干扰测试场景下DQN算法逃离路径结果，其中蓝方无人机为追捕者，周围虚线圆为追捕者攻击范围，红方为运输无人机。由于稀疏奖励问题的存在，使得无人机在几次测试过程中出现了兜圈的问题，该无人机全程躲避追捕但不向目标前进，最终以被捕获或撞墙结束此次测试。

图9为有干扰测试场景下R-PPO算法逃离路径结果。在有干扰场景测试中，由于在算法状态空间添加了噪声，使得无人机观测到的障碍物位置、追捕无人机位置以及自身位置相较于实际位置均存在误差，从而干扰了策略输出，使得无人机在运输过程中出现了一系列问题，如图9(a)～图9(c)中，由于对追捕无人机位置速度判断有误，导致运输无人机被捕获，则运输任务失败；如图9(d)～图9(f)中，由于观测到的边界信息和终点位置信息有误，导致运输无人机飞向终点时出界，运输任务失败；如图9(g)～图9(i)中，由于障碍物位置信息存在误差，导致运输无人机在逃逸过程中撞到障碍物坠毁，运输任务失败。

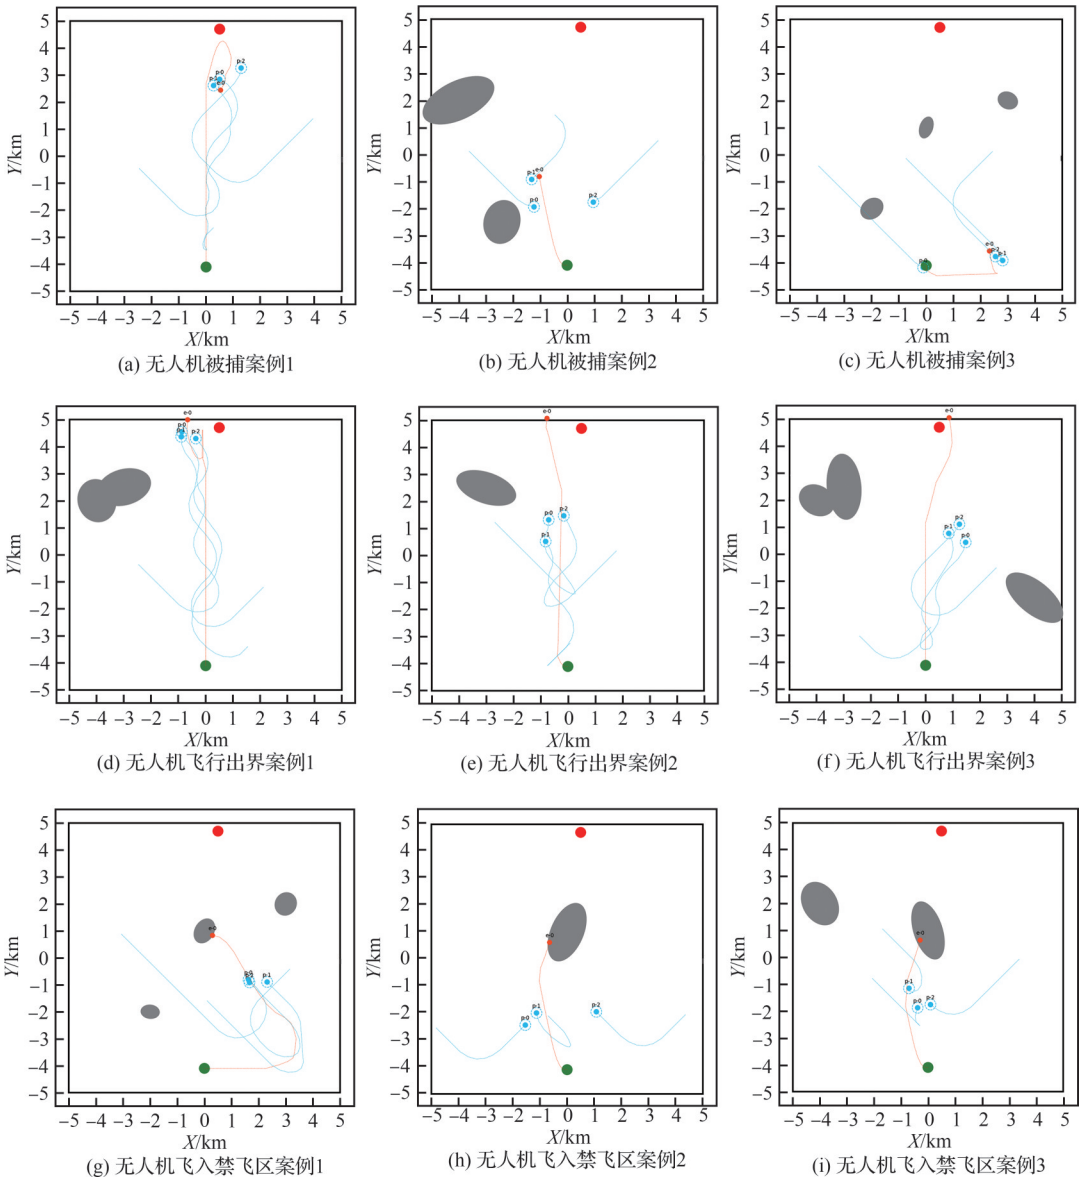
图10为有干扰测试场景下ADR-PPO算法逃离路径结果，显然运输无人机对追捕者的追捕采取了措施来躲避追捕攻击，最后成功到达了实验设置的重点，完成运输任务。



(a) 无人机兜圈问题案例1　(b) 无人机兜圈问题案例2　(c) 无人机兜圈问题案例3

图 8　无干扰测试场景下DQN算法逃离路径结果

Fig. 8　Test escape path result of DQN algorithm in undisturbed scene



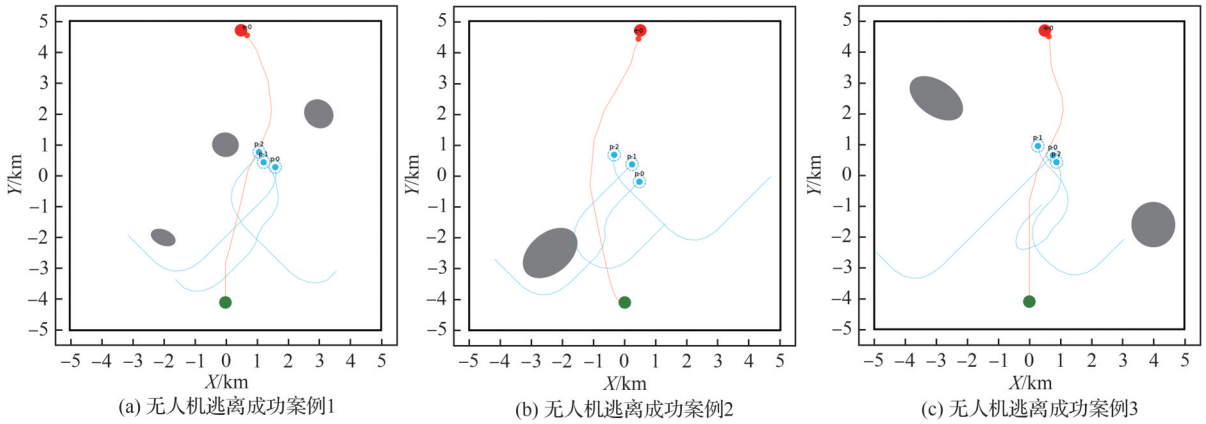
(a) 无人机被捕案例1　(b) 无人机被捕案例2　(c) 无人机被捕案例3

(d) 无人机飞行出界案例1　(e) 无人机飞行出界案例2　(f) 无人机飞行出界案例3

(g) 无人机飞入禁飞区案例1　(h) 无人机飞入禁飞区案例2　(i) 无人机飞入禁飞区案例3

图 9　有干扰测试场景下R-PPO算法逃离路径结果

Fig. 9　Escape path result diagram of R-PPO algorithm in disturbed test scene.

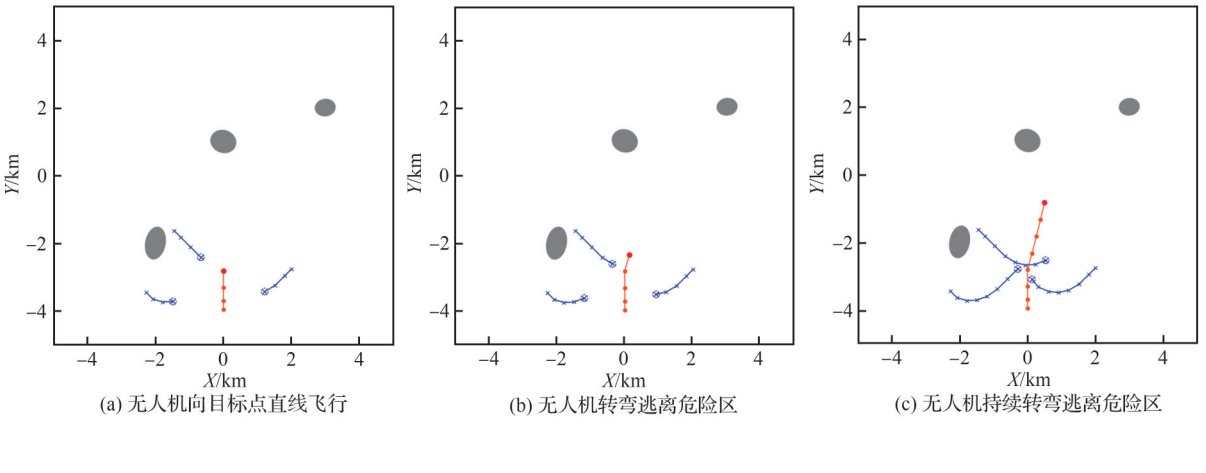


(a) 无人机逃离成功案例1　(b) 无人机逃离成功案例2　(c) 无人机逃离成功案例3

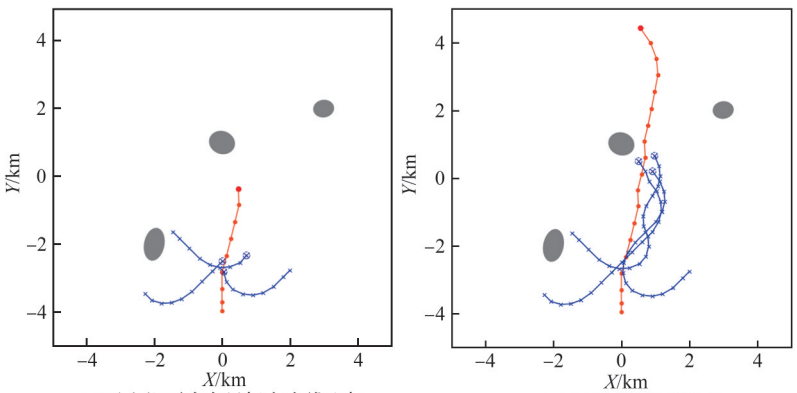
图 10　有干扰测试场景下ADR-PPO算法逃离路径结果

Fig. 10　Test escape path result of ADR-PPO algorithm in disturbed scene

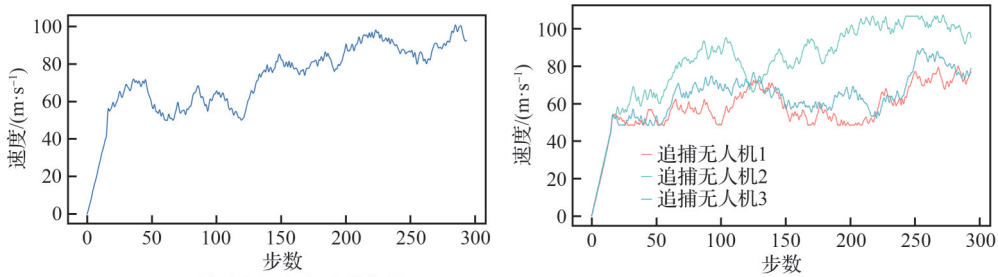
图 11 为有干扰测试场景下 ADR-PPO 算法逃离路径过程，图 11(a)中无人机为保证完成任务路径最短，选择朝终点方向直线飞行，图 11(b)和图 11(c)中，由于追捕者与运输无人机距离缩短，对运输无人机产生较大危险，运输无人机选择拐弯躲避，图 11(d)为躲避后回正，继续朝终点方向飞行，图 11(e)为最终到达终点，图 11(f)为运输无人机全程的速度曲线图，可以看出运输无人机经常快速提速用于逃离追捕，如第 97 和 122 步，图 11(g)为追捕无人机的速度曲线，在运输无人机提速逃离时，追捕者也同时提高到更高的速度来追捕运输无人机。



(a) 无人机向目标点直线飞行　(b) 无人机转弯逃离危险区　(c) 无人机持续转弯逃离危险区



(d)无人机再次向目标点直线飞行　(e) 无人机最终飞行路径



(f) 运输无人机速度-步数曲线　　(g) 追捕无人机速度-步数曲线

图 11　有干扰测试场景下ADR-PPO算法逃离路径过程

Fig. 11　Test escape path process of ADR-PPO algorithm in disturbed scene

4　结　论

本文针对无人机逃逸路径规划问题，提出ADR-PPO算法。该方法将对抗训练引入PPO算法，解决了强化学习算法鲁棒性低的问题，同时使用基于人工势场法的逐步奖励函数设计，取代传统奖励函数设计，解决稀疏奖励问题。

1）在ADR-PPO算法下，运输无人机学到的策略训练前期的学习效率高且训练后期收敛更稳定。

2）通过仿真实验，本文提出算法能有效应对测试过程中的噪声干扰，提高运输任务的成功率。

3）本文假设无人机的状态全局可观测感知，而真实空战环境下，受我方无人机感知范围有限的影响，敌机位置及障碍物位置等态势信息并不能时刻被精确获取。不仅如此，本文未考虑高度因素，但在实际战场中，高度因素对无人机也存在影响。下一步研究的重点会放在构建三维战场环境，解决不完全信息条件下空战逃逸决策问题上。

参　考　文　献

[1] CHEN B X. Research on AI application in the field of quadcopter UAVs[C]//2020 IEEE 2nd International Conference on Civil Aviation Safety and Information Technology. Piscataway: IEEE, 2020: 569-571.

[2] LI B, GAN Z G, CHEN D Q, et al. UAV maneuvering target tracking in uncertain environments based on deep reinforcement learning and meta-learning[J]. Remote Sensing, 2020, 12(22): 3789.

[3] LI B, SONG C, BAI S X, et al. Multi-UAV trajectory planning during cooperative tracking based on a fusion algorithm integrating MPC and standoff[J]. Drones, 2023, 7(3): 196.

[4] 范之琳，杨洪勇，韩艺琳. 基于强化学习的多智能体系统目标围捕控制[J]. 航空学报，2023，44(S1)：727487.
FAN Z L, YANG H Y, HAN Y L. Target hunting control of multi-agent system based on reinforcement learning[J]. Acta Aeronautica et Astronautica Sinica, 2023, 44(S1): 727487 (in Chinese).

[5] 郭华，郭小和. 改进速度障碍法的无人机局部路径规划算法[J]. 航空学报，2023，44(11)：327586.
GUO H, GUO X H. Local path planning algorithm for UAV based on improved velocity obstacle method[J]. Acta Aeronautica et Astronautica Sinica, 2023, 44(11): 327586 (in Chinese).

[6] 赵江，张璇，池沛，等. 空地无人集群自调节控制与动态路径规划方法[J]. 航空学报，2024，45(16)：329809.
ZHAO J, ZHANG X, CHI P, et al. Self-adaptive formation control and dynamic path planning for air-ground heterogeneous swarm[J]. Acta Aeronautica et Astronautica Sinica, 2024, 45(16): 329809 (in Chinese).

[7] 黄湘松，于日龙，潘大鹏. 面向目标定位精度的主从式无人机编队航迹规划方法[J]. 电子学报，2023，51(9)：2289-2300.
HUANG X S, YU R L, PAN D P. Route planning method of master-slave UAV formation for target positioning accuracy[J]. Acta Electronica Sinica, 2023, 51(9): 2289-2300 (in Chinese).

[8] FAN X Y, LI H, CHEN Y, et al. A path-planning method for UAV swarm under multiple environmental threats[J]. Drones, 2024, 8(5): 171.

[9] DONG Q X. Reinforcement learning based anti-UAV three-dimensional pursuit-evasion game for substation security[C]//2024 5th International Conference on Mechatronics Technology and Intelligent Manufacturing (ICMTIM). Piscataway: IEEE Press, 2024: 224-227.

[10] MA X H. Application of artificial intelligence in computer network technology[C]//2023 2nd International Conference on Artificial Intelligence and Autonomous

Robot Systems (AIARS). Piscataway: IEEE Press, 2023: 182-186.

[11] YU F, ZHANG X, LI Q. Determination of the barrier in the qualitatively pursuit-evasion differential game[C]// 2018 IEEE CSAA Guidance, Navigation and Control Conference (CGNCC). Piscataway: IEEE Press, 2018: 1-6.

[12] PAN Q, ZHOU D Y, HUANG J C, et al. Maneuver decision for cooperative close-range air combat based on state predicted influence diagram[C]//2017 IEEE International Conference on Information and Automation (ICIA). Piscataway: IEEE Press, 2017: 726-731.

[13] 傅莉, 谢福怀, 孟光磊, 等. 基于滚动时域的无人机空战决策专家系统[J]. 北京航空航天大学学报, 2015, 41(11): 1994-1999.
FU L, XIE F H, MENG G L, et al. An UAV air-combat decision expert system based on receding horizon control[J]. Journal of Beijing University of Aeronautics and Astronautics, 2015, 41(11): 1994-1999 (in Chinese).

[14] 张耀中, 许佳林, 姚康佳, 等. 基于DDPG算法的无人机集群追击任务[J]. 航空学报, 2020, 41(10): 324000.
ZHANG Y, XU J, YAO K, et al. Pursuit missions for UAV swarms based on DDPG algorithm[J]. Acta Aeronautica et Astronautica Sinica, 2020, 41(10): 324000 (in Chinese).

[15] KOUZEGHAR M, SONG Y, MEGHJANI M, et al. Multi-target pursuit by a decentralized heterogeneous UAV swarm using deep multi-agent reinforcement learning[C]//2023 IEEE International Conference on Robotics and Automation (ICRA). Piscataway: IEEE Press, 2023: 3289-3295.

[16] 符小卫, 徐哲, 朱金冬, 等. 基于PER-MATD3的多无人机攻防对抗机动决策[J]. 航空学报, 2023, 44(7): 327083.
FU X W, XU Z, ZHU J D, et al. Maneuvering decision-making of multi-UAV attack-defence confrontation based on PER-MATD3[J]. Acta Aeronautica et Astronautica Sinica, 2023, 44(7): 327083 (in Chinese).

[17] XIONG H, ZHANG Y. Reinforcement learning-based formation-surrounding control for multiple quadrotor UAVs pursuit-evasion games[J]. ISA Transactions, 2024, 145: 205-224.

[18] GUO Y, ZHANG N Z, JIANG H R, et al. Layered reinforcement learning design for safe flight control of UAV in urban environments[C]//2023 International Annual Conference on Complex Systems and Intelligent Science (CSIS-IAC). Piscataway: IEEE Press, 2023: 673-678.

[19] WANG J, XIAO Y, LI T S, et al. A jamming aware artificial potential field method to counter GPS jamming for unmanned surface ship path planning[J]. IEEE Systems Journal, 2023, 17(3): 4555-4566.

[20] SHRIVASTAVA A, PFISTER T, TUZEL O, et al. Learning from simulated and unsupervised images through adversarial training[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Piscataway: IEEE Press, 2017: 2242-2251.

[21] 杨振, 李琳, 柴仕元, 等. 面向多战术需求的无人机空战自主规避机动方法[J]. 航空学报, 2024, 45(20): 630629.
YANG Z, LI L, CHAI S Y, et al. Autonomous evasive maneuver method for unmanned combat aerial vehicle in air combat with multiple tactical requirements[J]. Acta Aeronautica et Astronautica Sinica, 2024, 45(20): 630629 (in Chinese).

[22] CESA-BIANCHI N, CONCONI A, GENTILE C. On the generalization ability of on-line learning algorithms[J]. IEEE Transactions on Information Theory, 2004, 50(9): 2050-2057.

(责任编辑: 宋金超)

Adversarial reinforcement learning-based UAV escape path planning method

HUANG Xiangsong[1,2], WANG Mengyu[1], PAN Dapeng[1,2,*]

1. *College of Information And Communication Engineering, Harbin Engineering University, Harbin 150001, China*
2. *Key Laboratory of Advanced Marine Communication and Information Technology, Ministry of Industry and Information Technology, Harbin Engineering University, Harbin 150001, China*

Abstract: In the context of the rapid development of drone technology, how to deal with malicious pursuit by other drones has become an important issue in drone security protection. To address the problem of enhancing a drone's adaptability and survivability in hostile environments using adversarial reinforcement learning algorithms, this work employs an adversarial reinforcement learning framework. Specifically, it tackles the issue of erroneous information interfering with decision-making during the evasion process. Building upon the adversarial interaction between pursuers and evaders, the strategy of the transport drone is optimized to counter the pursuers' behavior. To overcome the sparse reward problem inherent in traditional reinforcement learning methods, a progressive reward strategy mechanism incorporating the artificial potential field method is proposed. This enables the drone to adapt more effectively to the pursuit environment. The results demonstrate that, compared to the Proximal Policy Optimization (PPO) algorithm, this algorithm increases the drone's escape success rate by 54.47% and simultaneously reduces transport time by 34.35%, significantly enhancing the drone's transport efficiency. These findings provide a new technical solution for drone security protection and explore the application potential of adversarial reinforcement learning in scenarios involving malicious pursuit.

Keywords: adversarial training; reinforcement learning; escape path planning; escape decision making; reward function

Received: 2024-12-09; **Revised**: 2025-01-10; **Accepted**: 2025-03-18; **Published online**: 2025-04-15 16:11
URL: https://hkxb.buaa.edu.cn/CN/Y2025/V46/I17/331637
Foundation item: National Natural Science Foundation of China (62001136)
* **Corresponding author.** E-mail: pandapeng@hrbeu.edu.cn