# 基于改进A-DDQN算法的机器人路径规划

倪培龙，毛鹏军*，王宁，杨孟杰
(河南科技大学 机电工程学院，河南 洛阳 471003)

**摘要：**针对传统DQN算法在机器人路径规划过程中存在奖励稀疏、无法区分样本重要性等问题，提出一种A-DDQN改进算法。*在原有DQN的基础上，利用Double-DQN在目标网络的基础上做出改进，通过最大化预测Q值网络所给出的估值，并采用Q网络选出的动作去更新这个预测Q值网络，而非直接利用预测的Q值来选择行动，降低了最大化造成的高估问题；引入APF (artificial potential field)的思想，在机器人运动过程中，针对每一步设计相应的奖励，来引导机器人移动，改善奖励稀疏的问题；加入PER(prioritized experience replay)机制，通过对经验进行优先级排序来调整样本的采样概率，从而加速学习过程并提高性能。*通过在二维栅格地图下对算法改进前后的路径规划效果进行了对比分析，仿真结果表明：改进A-DDQN算法的路径长度、迭代次数、拐点数量在小范围地图中分别减少11.5%、23.1%、61.5%；在大范围地图障碍物稀疏环境中分别减少19.4%、50.0%、52.9%；在大范围地图障碍物密集环境中分别减少29.7%、48.1%、64.3%，证明了改进算法能够实现更快的收敛速度和更优的路径规划效果。

**关键词：**机器人；路径规划；深度强化学习；人工势场；优先经验回放
中图分类号：TP242 文献标志码：A 文章编号：1004-731X(2025)09-2420-11
DOI: 10.16182/j.issn1004731x.joss.24-0369
**引用格式:** 倪培龙, 毛鹏军, 王宁, 等. 基于改进A-DDQN算法的机器人路径规划[J]. 系统仿真学报, 2025, 37(9): 2420-2430.
**Reference format:** Ni Peilong, Mao Pengjun, Wang Ning, et al. Robot Path Planning Based on Improved A-DDQN Algorithm[J]. Journal of System Simulation, 2025, 37(9): 2420-2430.

## Robot Path Planning Based on Improved A-DDQN Algorithm

*Ni Peilong*, *Mao Pengjun**, *Wang Ning*, *Yang Mengjie*
(School of Mechanical and Electrical Engineering, Henan University of Science and Technology, Luoyang 471003, China)

**Abstract:** An improved A-DDQN algorithm is proposed to address the challenges of reward sparsity and the inability to distinguish sample importance in traditional DQN algorithms during robot path planning. *Building on the original DQN, an enhancement is made by incorporating the Double-DQN approach, which updates the predictive Q-value network based on actions selected by the Q network, rather than directly using the predicted Q-values for action selection, thereby mitigating overestimation issues. Secondly, the concept of artificial potential field (APF) is introduced to design specific rewards for each step of the robot's movement, guiding the robot and addressing the problem of sparse rewards. Lastly, the prioritized experience replay (PER) mechanism is integrated, adjusting the sampling probability of experiences through priority ranking to accelerate the learning process and enhance performance.* Comparative analysis of path planning before and after the algorithm improvements in a two-dimensional

收稿日期：2024-04-09 修回日期：2024-04-22
基金项目：洛阳市科技重大专项(2101018A)
第一作者：倪培龙(2000-)，男，硕士生，研究方向为机器人路径规划、强化学习。
通信作者：毛鹏军(1972-)，男，教授，博士，研究方向为强化学习、人工智能算法应用。

grid map shows that in small-scale maps, the improved A-DDQN algorithm reduces path length, iteration times, and the number of turning points by 11.5%, 23.1%, and 61.5% respectively; in large-scale maps with sparse obstacles, these reductions are 19.4%, 50.0%, and 52.9% respectively; and in large-scale maps with dense obstacles, reductions are 29.7%, 48.1%, and 64.3%. These simulation results prove that the improved algorithm achieves faster convergence and superior path planning performance.

**Keywords:** robots; path planning; deep reinforcement learning; artificial potential field(APF); priority experience replay(PER)

## 0 引言

在当今快速发展的自动化和智能化时代，机器人技术的进步显得尤为重要。机器人路径规划，作为机器人技术中的核心问题之一，负责指导机器人高效、安全地在复杂环境中移动，从起点到达指定终点。路径规划直接关系到机器人的工作效率、安全性以及应用的广泛性。因此，深入研究与不断优化路径规划算法，不仅对推动机器人学科的发展具有重大意义，也对促进相关工业和技术的现代化升级有着不可估量的影响。

传统的路径规划算法有基于启发式的A*算法[1]、基于图搜索式的快速扩展随机树算法[2]、人工势场(artificial potential field, APF)法[3-4]、模拟退火法[5]；群体智能算法如蚁群算法[6]、粒子群算法[7]、遗传算法[8]等。但这些传统算法均存在实时性不高、易陷入局部最优等缺点。

2021年以来，人工智能技术发展速度呈现出前所未有的加速态势，作为AI技术的核心分支，强化学习算法在路径规划领域展现出了巨大的潜力和应用前景。利用强化学习算法，机器人通过与环境进行交互和学习，优化路径规划的效果，使其能够在复杂环境下高效地完成路径规划任务，到达目标位置[9]。传统强化学习算法有动态规划[10]、Q-learning[11]、SARSA[12]等，但这些基于表格的强化学习技术在处理大型状态空间和动作空间时存在明显的限制。2013年，DeepMind团队发表了一篇论文介绍了一种基于深度卷积神经网络的强化学习算法，DQN(deep Q-network)算法[13]。DQN融合了深度学习网络与Q学习的策略，利用深度神经网络对Q值函数进行估计，从而能够在复杂的环境下学习并提升决策过程。然而，传统DQN算法应用在路径规划方面存在以下一些问题：①会过高估计Q值：传统算法直接根据目标网络的参数选择Q值最大的动作，使得Q值的计算不够准确；②样本复用问题：传统算法均匀采样的方法无法区分存放在经验回放区的样本的重要性，会重复利用经验数据，导致学习的效率和性能下降；③奖励稀疏问题：传统算法仅在达成目标或碰撞障碍物时获得奖励，导致奖励信号稀疏，这会显著拖慢模型的训练收敛速度，甚至在前期的探索中，如果一直没有探索到目标点，可能会陷入局部最优的情况。

学者们针对以上问题提出了各种基于DQN的改进算法。文献[14]在DQN的基础上，提出了一种基于不同学习阶段对经验深度和广度的不同需求的改进学习策略，并借鉴稠密连接方法对网络结构进行改进，使得模型在收敛速度、规划成功率、路径准确率等方面都有一定的提高。文献[15]针对智能体逃生路径规划问题，提出了双层DQN算法，并在此基础上提出了一种基于改进的K-medoids算法的智能体分组策略方法，提高了网络架构收敛速度，学习更加稳定，模型性能得到有效提升。文献[16]针对模型过度依赖与过度估计问题，提出一种抑制过度估计深度Q网络算法，其将DQN算法与信息熵结合，实时评估更新过程，借此缓解传统DQN的过估计问题，最后通过建立的环境模型验证了改进后的算法可减少过估计造

成输出错误动作的次数。文献[17]针对沙漠复杂环境下机器人路径规划问题，在传统DQN算法的基础上改进了探索因子，使探索因子的值可以根据机器人对环境认识程度的改变而变化，并设置了一种动态的奖励函数，经实验验证，改进后算法迭代次数和规划时间分别减少了32.6%和17.4%，提高了算法的收敛速度和搜索效率。文献[18]针对传统路径规划车辆模型经验回放效率低下问题，提出了一种IDQNPER算法模型，在DQN的基础上加入优先经验回放(priority experience replay, PER)模块，给存储在经验回放区的样本附上权重，并按优先级顺序发送到网络进行训练，同时删除相似度高的序列，结果表明，总奖励值提升10%左右。

在传统DQN的基础上，本文提出A-DDQN改进算法，首先，采用DDQN(Double-DQN)学习算法对目标网络进行改进，降低了最大化造成的高估问题；其次，借鉴人工势场(APF)的思想设置奖励函数，改善了机器人寻找目标点过程中奖励稀疏的问题；最后，加入基于均方误差的优先经验回放(PER)模块，优先选择对模型学习更有帮助的经验，提高学习效率，加速收敛。

# 1 强化学习

## 1.1 强化学习概念

强化学习是机器学习的一种关键策略，其基本原理是使智能体通过与环境的互动、尝试和学习来最大化长期总奖励。这一过程通过马尔可夫决策过程建模[19]，涵盖状态空间、行动空间、转移概率、奖励函数等要素。在MDP(Markov decision process)中，智能体根据当前状态选择行为，然后根据环境反馈的奖励信号调整其策略，通过不断优化决策过程来提高自主学习和智能决策的能力，实现累计奖励的最大化。强化学习的基本框架如图1所示。

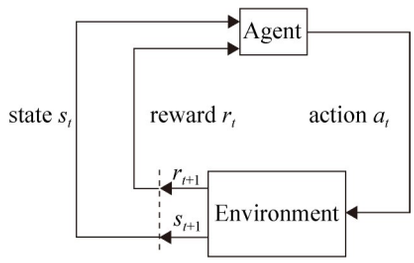



图1 强化学习基本框架
Fig. 1 Basic framework of reinforcement learning

## 1.2 Q-learning算法

Q-learning作为经典的强化学习算法，可以用来找到在给定状态下采取行动的最优策略，即如何从当前状态通过学习得到最大的长期奖励[20]。

Q-learning的核心概念是Q函数，即动作价值函数，它代表在某状态(state)下采取某动作(action)所能获得的预期未来奖励(reward)。Q-learning的目标是学习最优的Q函数，即Q*函数，通过这个函数，可以知道在任何状态下应采取什么行动以最大化长期奖励。

Q-learning的工作原理是通过不断地探索环境并更新Q值来进行学习。它使用以下的更新规则(Q-learning更新公式)来不断调整Q值，以期望收敛到最优的Q函数，更新过程为

$$Q(s_t,a_t)\leftarrow Q(s_t,a_t)+\alpha(r_t+\gamma\max_{a_t+1}Q(s_{t+1},a_{t+1})-Q(s_t,a_t)) \tag{1}$$

式中：$s_t$为$t$时刻的状态；$a_t$为在状态$s_t$下采取的动作；$r_t$为采取动作$a_t$之后获得的即时奖励；$s_{t+1}$为采取动作$a_t$之后到达的新状态；$a_{t+1}$为在新状态$s_{t+1}$下可能采取的任一动作；$\alpha$为学习率$(0<\alpha\leqslant 1)$，控制学习过程中新信息的重要性；$\gamma$为折扣因子$(0\leqslant\gamma<1)$，决定了在计算当前动作的总体预期效益时，未来奖励对当前决策的影响程度。

## 1.3 DQN算法

Q-learning算法依赖于一个Q表来存储和更新每个状态–动作对应的Q值，在面对状态空间和动作空间非常大的情况时，Q表的规模会迅速膨胀，

导致计算和存储成本过高。DQN算法通过引入深度神经网络来克服这一问题，如图2所示。

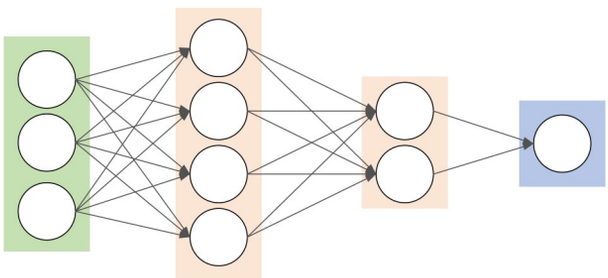


图2　神经网络结构
Fig. 2　Neural network structure

神经网络用于学习并近似表示Q函数,公式为

$$Q(s,a;\theta)\approx Q(s,a) \tag{2}$$

式中：$\theta$为神经网络参数；更新值函数$Q(s,a)$是对参数$\theta$的调整。当参数$\theta$被固定下来时，相应的值函数$Q(s,a)$也随之确定。通过增加对网络参数$\theta$的关注，标准DQN的学习目标可以被重写为

$$y_t^{\mathrm{DQN}}=r_t+\gamma\hat{Q}(s_{t+1},\arg\max_a \hat{Q}(s_{t+1},a;\hat{\theta});\hat{\theta}) \tag{3}$$

# 2　改进DDQN算法

## 2.1　DDQN算法

DDQN通过引入目标网络(target network)来减轻过高估计问题。在传统的DQN算法中，使用单一的神经网络来同时估计当前状态下各个动作的价值。而在DDQN中，引入一个独立的目标网络来估计下一个状态的动作价值。目标网络的参数是通过固定间隔从评估网络(evaluation network)中复制得来的，这样可以减少价值函数的波动性，缓解过估计问题。DDQN中使用的Q学习目标公式为

$$y_t^{\mathrm{DDQN}}=r_t+\gamma\hat{Q}(s_{t+1},\arg\max_a Q(s_{t+1},a;\theta);\hat{\theta}) \tag{4}$$

DDQN算法的基本原理如下：①使用评估网络来选择当前状态下的动作；②对于下一个状态，使用目标网络来计算对应的Q值；③使用目标网络计算得到的Q值，选择最优动作；④使用目标网络的最优动作和主网络的Q值作为目标来更新主网络的参数；⑤定期更新目标网络的参数。

通过使用目标网络来估计下一个状态的动作价值，DDQN可以减轻过高估计问题，提高了算法的稳定性和训练效果。

## 2.2　APF奖励函数

人工势场法通过模拟虚拟力场来指导机器人运动[4]，其中目标点产生引力，障碍物产生斥力，如图3所示。二者的合力就是机器人运动的控制力，有了这个控制力，就可以规划出一条无碰撞的路径到达目标点。随着机器人靠近目标点，引力减弱；接近障碍物时，斥力上升。

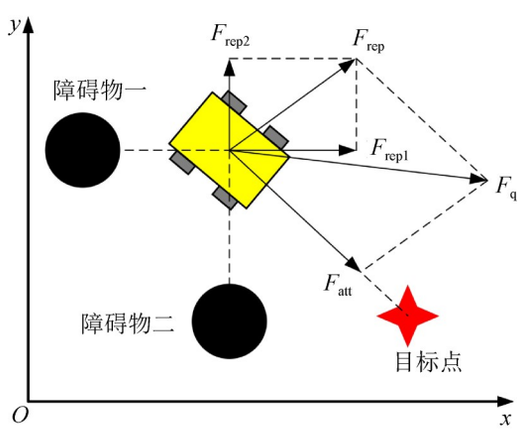



图3　人工势场
Fig. 3　Artificial potential field

在人工势场中，使用势函数$U$来创建人工势场，其中引力势函数表示为

$$U_{\mathrm{att},\,q}=\frac{1}{2}\zeta d_{q,q_{\mathrm{goal}}}^2 \tag{5}$$

式中：$\zeta$为引力场系数；$d_{q,q_{\mathrm{goal}}}^2$为当前点$q$与目标点$q_{\mathrm{goal}}$间的距离。

斥力势函数表示为

$$U_{\mathrm{rep},\,q}=\begin{cases}\dfrac{1}{2}\eta\left(\dfrac{1}{D_q}-\dfrac{1}{Q^*}\right)^2, & D_q<Q^*\\ 0, & D_q\geqslant Q^*\end{cases} \tag{6}$$

式中：$\eta$为斥力场系数；$D_q$为从当前点$q$到最近障碍物的距离；$Q^*$为障碍物产生排斥力的阈值，当

机器人与最近障碍物的距离小于该阈值时产生斥力。

则势场中作用在机器人上的合力为

$$U_q = U_{\text{att},\,q} + U_{\text{rep},\,q} \tag{7}$$

移动的机器人在点$q$处的势函数$U_q$表示该点处的能量的大小，并且该点处的力矢量由梯度$\nabla U_q$表示，其定义式为

$$\nabla \boldsymbol{U}_q = D\boldsymbol{U}_q^{\mathrm{T}} = \left[\frac{\partial U_q}{\partial q_1}, \frac{\partial U_q}{\partial q_2}, \cdots, \frac{\partial U_q}{\partial q_m}\right]^{\mathrm{T}} \tag{8}$$

分别求引力和斥力势函数的负导数即可得到$q$点处的引力和斥力函数为

$$F_{\text{att},\,q} = -\nabla \boldsymbol{U}_{\text{att},\,q} = -\zeta d_{q,q_{\text{goal}}} \tag{9}$$

$$F_{\text{rep},\,q} = \begin{cases} \eta\left[\dfrac{1}{D_q} - \dfrac{1}{Q^*}\right]\dfrac{1}{D_q^2}\dfrac{\partial D_q}{\partial x}, & D_q < Q^* \\ 0, & D_q \geqslant Q^* \end{cases} \tag{10}$$

二者的矢量和即为机器人在势场中的合力：

$$F_q = F_{\text{att},\,q} + F_{\text{rep},\,q} \tag{11}$$

根据人工势场的思想，当机器人向目标点移动时，将奖励函数分解为2部分：一是位置奖励，分为目标奖励和避障奖励，前者旨在快速引领机器人移动至目标点，后者确保机器人避开障碍物，保持安全距离。二是方向奖励，机器人当前的方向对合理导航起着关键作用，通过将人工势场中作用于机器人的合力的方向与其移动方向相匹配，创建了方向奖励以促使机器人朝目标位置前进。

在位置奖励函数中，首先使用引力势场函数思想来构造目标奖励函数：

$$R_{\text{tar}} = -\alpha_1 d_{\text{goal}} \tag{12}$$

式中：$\alpha_1$为引力奖励函数常数；$d_{\text{goal}}$为当前位置与目标位置之间的欧式距离。

避障奖励函数部分使用排斥势场函数构建：

$$R_{\text{rep}} = \begin{cases} -\dfrac{1}{2}\alpha_2\left(\dfrac{1}{d_{\text{obs}}} - \dfrac{1}{d_0}\right), & d_{\text{obs}} \leqslant d_0 \\ 0, & d_{\text{obs}} > d_0 \end{cases} \tag{13}$$

式中：$\alpha_2$为排斥奖励函数的常数；$d_{\text{obs}}$为当前位置与最近障碍物间的欧式距离；$d_0$为机器人与障碍物的安全距离。

方向奖励函数构建为

$$R_{\text{away}} = \begin{cases} \alpha_3\left(d_{\text{pre}} - d_{\text{goal}}\right), & d_{\text{pre}} > d_{\text{goal}} \\ 0, & d_{\text{pre}} \leqslant d_{\text{goal}} \end{cases} \tag{14}$$

式中：$\alpha_3$为方向奖励常数；$d_{\text{pre}}$为前一时刻位置与目标位置的欧式距离。

## 2.3 PER优先经验回放

经验回放机制是DQN算法中的一个关键技术，传统强化学习的学习过程是连续且具有显著的时序关联性。经验回放机制通过存储智能体的经验到一个回放缓冲区(经验池)中，并在训练时随机采样这些经验来更新网络，从而提高了数据的再利用率，并减少了样本间的相关性。

尽管经验回放机制带来了显著的效益，但它也存在一些缺点：

(1) 均匀采样问题：传统的经验回放采用均匀随机采样，这意味着每个经验被再次采样的概率是相同的。这可能导致一些重要的但不频繁的经验被忽略，而一些频繁但不那么重要的经验被过度采样。

(2) 效率问题：由于缺乏区分经验重要性的机制，学习过程可能不够高效，特别是在复杂环境中。

为了解决上述问题，本文采用优先经验回放(PER)机制。其核心思想是根据经验的重要性来调整其被采样的概率，即更重要的经验会有更高的概率被采样。重要性通常通过每个经验引起的TD误差(temporal difference error)的大小来衡量，TD误差较大的经验被认为是重要的，因为它表明当前的价值函数对这个经验的预测与实际回报之间有较大的偏差。本文将纯贪婪优先与均匀随机抽样相结合。确保样本的优先级与TD误差成比例，同时确保最低优先级的采样概率不为0。

采样转变$i$的概率定义为

$$P_i = p_i^{\alpha} \Big/ \sum_k p_k^{\alpha} \tag{15}$$

式中：$p_i$为第$i$次体验的优先级，指数决定使用多少优先级，当$\alpha=0$时，是均匀随机抽样的情况。$p(i)$有2种变体，第一种是按比例优先，表示为

$$p_i=\left|\delta_i\right|+\varepsilon \tag{16}$$

式中：$\delta_i$为状态转移$i$的TD误差；$\varepsilon$为一个用于数值稳定的小正数。

第二种是基于顺序的优先，表示为

$$p_i=1/rank(i) \tag{17}$$

式中：$rank(i)$为状态转移$i$基于$\left|\delta_i\right|$的等级评定，是TD误差经验池中第$i$个经验的排名。

在回放缓存中，随机采样有助于消除样本间的相关性。而在使用优先采样时，又放弃了纯随机采样。因此需要减少高优先级状态转移数据的训练权重，采用重要性采样权重来修正状态转移$i$的偏差。

在概率统计中，采用一定分布的抽样样本会引入偏差，而增加重要性抽样可以消除偏差。重要性抽样的权重为

$$\omega_j=(\frac{1}{N}\cdot\frac{1}{p_j})^{\beta} \tag{18}$$

式中：$N$为回放缓存的容量大小；$\beta$为训练过程中将会退火到1的超参数，用来调整偏差程度的。

### 2.4 A-DDQN整体框架

改进后算法的整体流程如图4所示，首先机器人将初始状态发送给神经网络参数为$\theta$的评估网络，评估网络通过$\varepsilon$-greedy策略得到在状态$s_t$下的动作$a_t$，机器人与环境交互后得到$s_{t+1}$，并通过APF奖励函数得到奖励$r_t$，并将$s_t$，$a_t$，$s_{t+1}$，$r_t$存储在经验回放缓冲区中，采用优先经验回放抽取训练数据，利用评估网络和目标网络生成预测Q值和目标Q值，计算二者之间的误差后采用梯度下降更新参数$\theta$并传递给评估网络。评估网络将参数$\theta$延时复制到神经网络参数为$\hat{\theta}$的目标网络中。

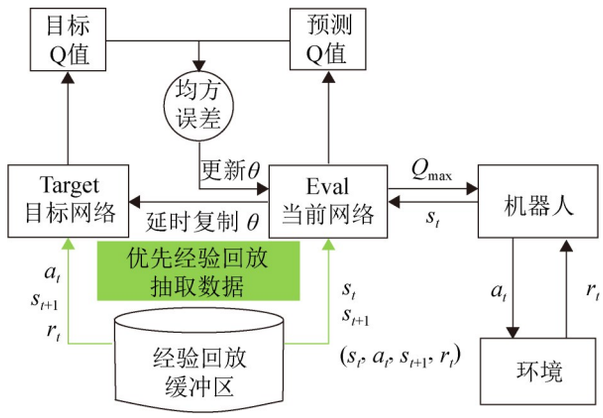



图4 A-DDQN整体框架图

Fig. 4 A-DDQN overall framework diagram

## 3 实验结果及分析

### 3.1 环境建立

实验环境为CPU i5-12400、python 3.8，pytorch 1.11，在Pycharm中构建二维栅格地图，用来表示整体环境信息，具体仿真环境如图5所示。其中黑色方块表示障碍物，白色部分为自由通行区域，蓝色方块表示移动机器人，红色方块表示目标位置。机器人有8种移动方式，如图6所示。当机器人在二维栅格地图移动时，遇到障碍物、超出地图边界和到达目标位置代表一个回合结束。

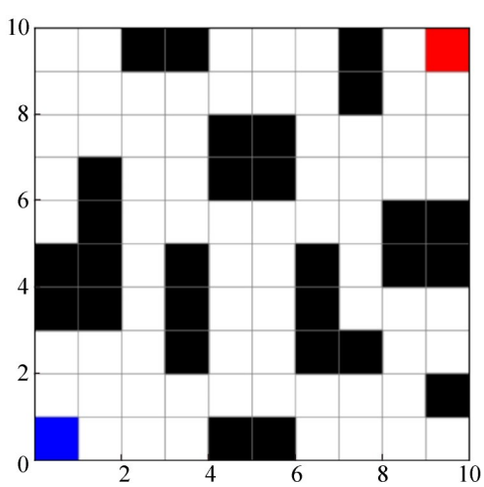



图5 仿真地图

Fig. 5 Simulation map

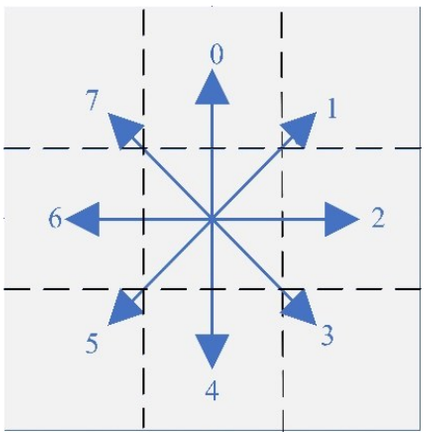



图6　机器人移动方向
Fig. 6　Robot movement direction

## 3.2 参数设置

本文所提出的改进DQN算法的超参数配置如表1所示。为了确保实验的一致性，原始DQN算法的超参数设置与改进算法保持一致，除了改进算法特有的人工势场奖励常数之外。

表1　超参数设置
Table 1　Hyperparameter settings

| 超参数 | 数值 | 超参数 | 数值 |
|---|---|---|---|
| 折扣率$\gamma$ | 0.9 | 动作空间大小$a$ | 8 |
| 学习率$\alpha$ | 0.1 | 迭代次数 | 200 |
| 初始探索率 | 1 | 引力奖励常数$\alpha_1$ | 0.000 01 |
| 最小探索率 | 0.1 | 排斥奖励常数$\alpha_2$ | 0.05 |
| 探索衰减值 | 0.998 | 方向奖励常数$\alpha_3$ | 0.05 |

## 3.3 算法比较

本文通过3组对照实验来评估原始DQN算法与所提出的改进DQN算法的性能。实验分为3个场景：

第1组实验：在一个小尺寸地图上进行测试，其中地图的维度为15×15。机器人起始位置(0,0)，目标位置(14,14)，假设一个单位长度为1 m。

第2组实验：在一个更广阔的空间中进行，地图的尺寸扩大到20×20。在这个简单场景中，障碍物较为分散。机器人同样从(0,0)点出发，目标是达到(19,19)点。

第3组实验：保持地图尺寸为20×20不变，并在相同的起始点和目的地设置下，增加了障碍物的密度来模拟一个复杂的场景。

通过以上实验全面评估算法在不同环境条件下的路径规划能力，从小规模简单环境到大规模复杂环境，检验算法的适应性和优化效果。

(1) 小范围地图下的对比实验

用传统DQN路径规划算法和改进后的算法规划的路径结果如图7~8所示。在实现路径规划的任务中，尽管传统DQN算法和改进算法都能成功引导机器人抵达目标位置，但区别在于路径效率和行进路线的复杂度。传统DQN算法的路径平均长度为24.4 m，而改进算法将路径长度缩短至21.6 m，和传统算法相比节约了11.5%。此外，传统算法规划的路径中包含了多达13个拐点，而改进算法大幅减少到仅5个，这意味着改进算法不仅提高了路径的直线性，还可能降低了机器人在实际导航中的能量消耗和时间成本，表现出更高的导航效率和路径优化能力。

图9~10展示了2种算法的奖励值和步数随迭代轮次增加的变化趋势。通过这些曲线图可以直观看出，传统的DQN算法在训练到65轮次之后奖励及步数值才收敛，而改进后的算法在迭代到50轮次后就已经保持稳定，收敛速度提高了23.1%。

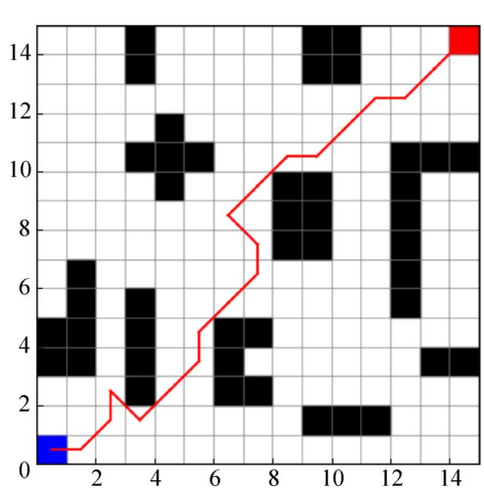



图7　传统算法路径规划效果
Fig. 7　Traditional algorithm path planning effect

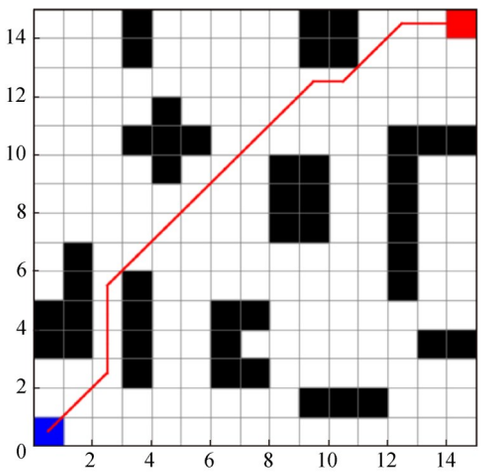


图8　改进算法路径规划效果
Fig. 8　Improvement algorithm path planning effect

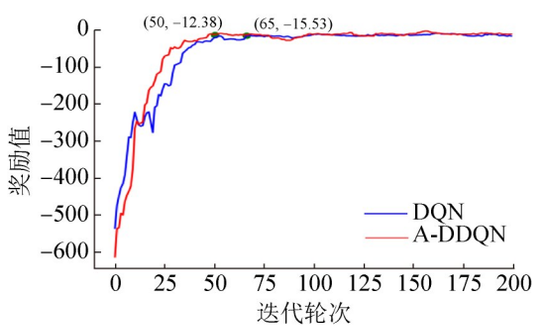



图9　奖励对比曲线
Fig. 9　Reward comparison curve

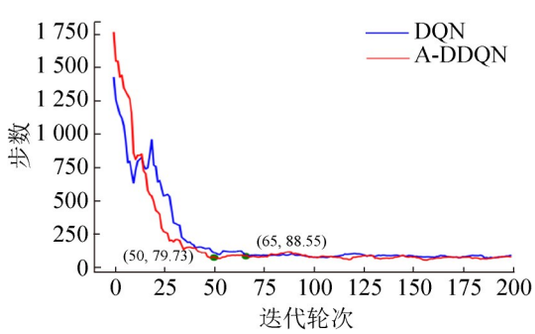



图10　步数对比曲线
Fig. 10　Comparison curve of steps

详细指标对比如表2所示。

表2　算法结果指标对比
Table 2　Comparison of algorithm results indicators

| 算法 | 路径长度/m | 迭代轮次 | 拐点个数 |
|---|---|---|---|
| DQN | 24.4 | 65 | 13 |
| A-DDQN | 21.6 | 50 | 5 |
| 性能提升/% | 11.5 | 23.1 | 61.5 |

(2) 大范围地图障碍物稀疏下的对比实验

如图11~12所示，当地图规模扩大，且在障碍物较为稀疏的条件下。传统DQN算法规划出的路径显得缺乏明确目的性，即使能够到达目标，也往往是曲折迂回，效率不高，其规划的路径长度达到了35.5 m，拥有高达17个拐点。而改进后的算法表现出了更强的目的性，显著缩短了路径长度，仅为28.6 m，相较于传统算法缩短了19.4%，且拐点个数降低至8个，减少了一半的数量，规划出了更为直接和高效的路径。

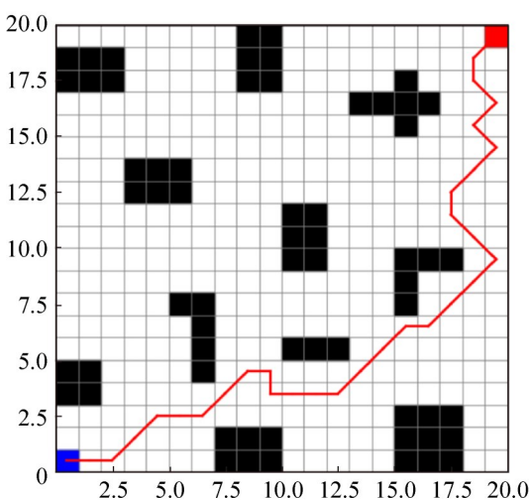


图11　传统算法路径规划效果
Fig. 11　Traditional algorithm path planning effect

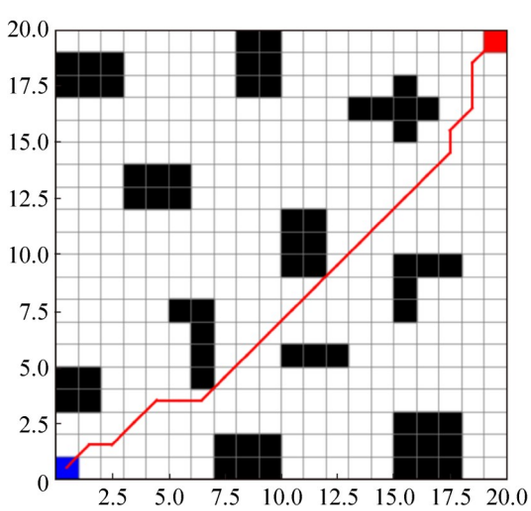


图12　改进算法路径规划效果
Fig. 12　Improvement algorithm path planning effect

二者的奖励值及步数随着迭代轮次增加而变化的对比如图13~14所示。通过奖励值的曲线图可以直观看出，在经过60轮的训练之后，传统DQN算法的奖励值才开始趋于收敛。相比之下，改进后的算法展示出更加快速的适应性，其奖励值在仅仅30轮迭代后就达到了收敛，并迅速稳定下来。细究步数对比图，在训练初期，改进算法可能需要比传统DQN算法更多的步数来定位目标。然而，随着迭代次数的增加，改进算法的耗费步数迅速下降并趋于稳定，显示出其在学习效率上的明显优势。

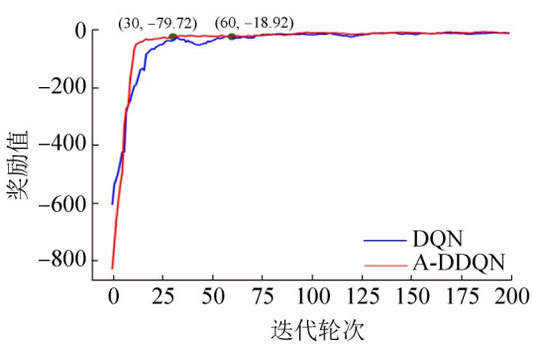



图13　奖励对比曲线
Fig. 13　Reward comparison curve

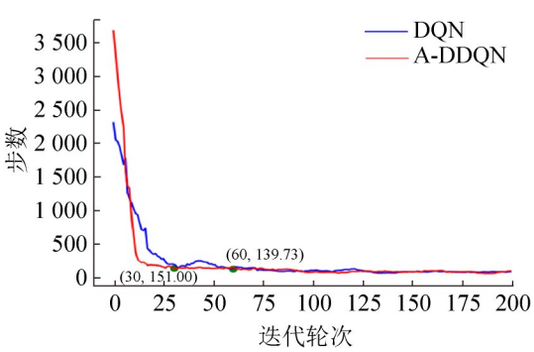



图14　步数对比曲线
Fig. 14　Comparison curve of steps

详细指标对比如表3所示。

表3　算法结果指标对比
Table 3　Comparison of algorithm results indicators

| 算法 | 路径长度/m | 迭代轮次 | 拐点个数 |
|---|---|---|---|
| DQN | 35.5 | 60 | 17 |
| A-DDQN | 28.6 | 30 | 8 |
| 性能提升/% | 19.4 | 50.0 | 52.9 |

(3) 大范围地图障碍物密集下的对比实验

图15~16展示了在障碍物密集环境中，使用传统DQN算法和改进后算法进行路径规划的结果对比。面对复杂的环境时，传统DQN算法成功规划的路径长度为40.7 m，且包含28个拐点，这凸显了传统DQN算法在处理高难度路径规划任务时的局限性。相比之下，改进后的算法却表现出了更强的适应性和效率。只需要10个拐点便成功规避了密集障碍物，并规划出长度为28.6 m的路径到达目标位置。

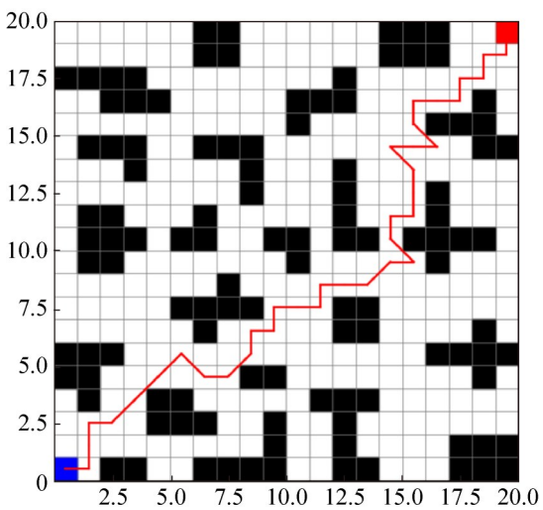


图15　传统算法路径规划效果
Fig. 15　Traditional algorithm path planning effect

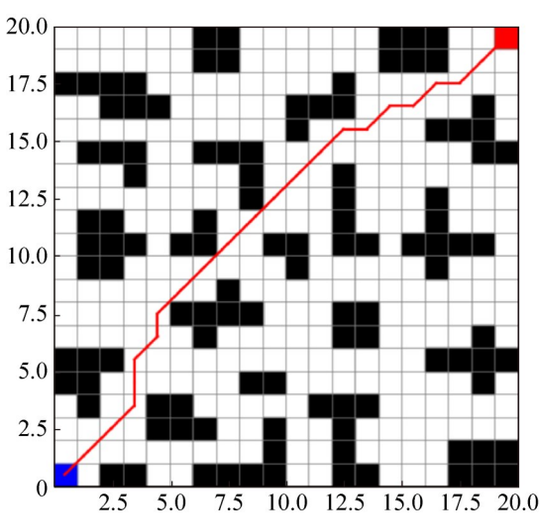


图16　改进算法路径规划效果
Fig. 16　Improvement algorithm path planning effect

观察对比图17~18中的数据，在复杂环境中，传统DQN算法的奖励值和步数在迭代到77轮次之后才逐渐收敛，再次印证了算法在面对复杂环境时的缺陷。路径规划上的不确定性和效率低下成为了该算法的短板。

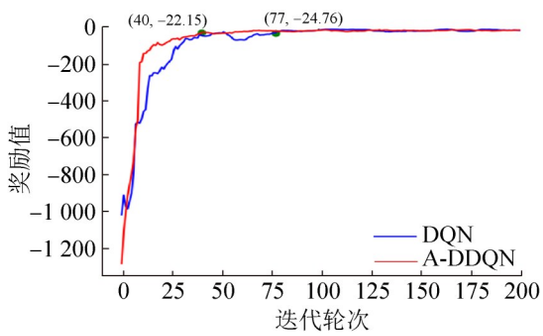



图17　奖励对比曲线
Fig. 17　Reward comparison curve

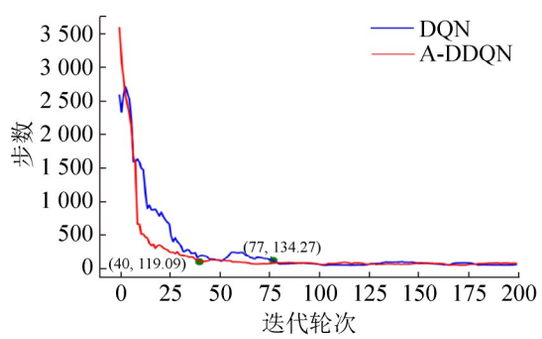



图18　步数对比曲线
Fig. 18　Comparison curve of steps

反观改进后的算法，仅仅经过40轮的迭代，奖励值和步数就已经达到了稳定状态。这一结果不仅表明了改进DQN算法的强大适应性和高效性，也有效地证实了其在高难度环境中的实际应用潜力。通过这样的改进，机器人能够以更短的时间、更优的路径完成任务，有力地证明了改进算法的有效性。

详细指标对比如表4所示。

表4　算法结果指标对比
Table 4　Comparison of algorithm results indicators

| 算法 | 路径长度/m | 迭代轮次 | 拐点个数 |
|---|---|---|---|
| DQN | 40.7 | 77 | 28 |
| A-DDQN | 28.6 | 40 | 10 |
| 性能提升/% | 29.7 | 48.1 | 64.3 |

## 4　结论

本文针对机器人巡检中的路径规划问题，提出了一种改进的深度强化学习方法，旨在提高算法的效率并优化路径规划结果。改进方法基于3个核心改进策略：

(1) Double-DQN (DDQN)：使用DDQN算法解决了传统DQN算法在估计Q值时倾向于过高估计的问题。DDQN通过分离目标网络和评估网络来减少过估计现象，即在评估网络中选择动作，而在目标网络中评估该动作的价值。

(2) 人工势场法 (APF): 受到人工势场法的启发，通过设定一种新的奖励函数，解决了原有算法中奖励信号稀疏的问题。这种设计的奖励机制能更有效地引导机器人沿着优化后的路径移动，从而提高路径规划的效率和质量。

(3) 优先经验回放 (PER): 引入了PER模块解决了传统经验回放机制中无法区分不同样本重要性的问题。在PER中，经验按照其对学习过程的重要性被赋予不同的优先级，这使得算法能够倾向于从更有价值的经验中学习，加速了学习过程并提升了性能。

最后通过在二维栅格地图中的仿真实验，结果表明改进后的算法在多种复杂环境中都表现出较好的适应能力。与传统的DQN算法相比，改进A-DDQN算法的路径长度、迭代次数、拐点数量在小范围地图中分别减少11.5%、23.1%、61.5%；在大范围地图障碍物稀疏环境中分别减少19.4%、50.0%、52.9%；在大范围地图障碍物密集环境中分别减少29.7%、48.1%、64.3%。这些改进不仅提高了路径规划的效率，也增强了算法的稳定性和可靠性，为机器人路径规划提供了一个可行且高效的解决方案。

但本文仍存在以下几个潜在的局限性：①虽然DDQN有效减少了Q值的过估计现象，但它仍依赖于经验回放机制来稳定学习过程，这可能限制了算法在非平稳环境中的快速适应能力。②人工势场法虽然提高了奖励信号的效率，但在处理

动态障碍物时可能需要进一步的调整和优化，因为静态势场可能无法准确反映动态环境的复杂性。

未来的研究方向为：首先，开发新的策略，以提高模型在非平稳环境中的适应能力和稳定性；其次，对人工势场法进行扩展，以更好地处理动态障碍物。通过引入预测模型来估计障碍物的未来状态，从而实现更加灵活和准确的路径规划。

## 参考文献：

[1] 林桂娟, 李子涵, 王宇. 基于全局关键点提取的改进A* 算法全局路径规划研究[J]. 系统仿真学报, 2025, 37(3): 667-678.
Lin Guijuan, Li Zihan, Wang Yu. Research on Improved A* Algorithm Path Planning Based on Global Key Point Extraction[J]. Journal of System Simulation, 2025, 37(3): 667-678.

[2] 张瑞, 周丽, 刘正洋. 融合RRT*与DWA算法的移动机器人动态路径规划[J]. 系统仿真学报, 2024, 36(4): 957-968.
Zhang Rui, Zhou Li, Liu Zhengyang. Dynamic Path Planning for Mobile Robot Based on RRT* and Dynamic Window Approach[J]. Journal of System Simulation, 2024, 36(4): 957-968.

[3] Lin Zenan, Yue Ming, Chen Guangyi, et al. Path Planning of Mobile Robot with PSO-based APF and Fuzzy-based DWA Subject to Moving Obstacles[J]. Transactions of the Institute of Measurement and Control, 2022, 44(1): 121-132.

[4] Chen Yanli, Bai Guiqiang, Zhan Yin, et al. Path Planning and Obstacle Avoiding of the USV Based on Improved ACO-APF Hybrid Algorithm with Adaptive Early-warning[J]. IEEE Access, 2021, 9: 40728-40742.

[5] Cheng Jin, Wang Bin. Flocking Control of Mobile Robots with Obstacle Avoidance Based on Simulated Annealing Algorithm[J]. Mathematical Problems in Engineering, 2020, 2020(1): 7357464.

[6] 邓向阳, 张立民, 方伟, 等. 基于双向汇聚引导蚁群算法的机器人路径规划[J]. 系统仿真学报, 2022, 34(5): 1101-1108.
Deng Xiangyang, Zhang Limin, Fang Wei, et al. Robot Path Planning Based on Bidirectional Aggregation Ant Colony Optimization[J]. Journal of System Simulation, 2022, 34(5): 1101-1108.

[7] Tian Shasha, Li Yuanxiang, Kang Yilin, et al. Multi-robot Path Planning in Wireless Sensor Networks Based on Jump Mechanism PSO and Safety Gap Obstacle Avoidance[J]. Future Generation Computer Systems, 2021, 118: 37-47.

[8] Chen Deping. Fuzzy Obstacle Avoidance Optimization of Soccer Robot Based on an Improved Genetic Algorithm [J]. Journal of Ambient Intelligence and Humanized Computing, 2020, 11(12): 6187-6198.

[9] Geesara Kulathunga. A Reinforcement Learning Based Path Planning Approach in 3D Environment[J]. Procedia Computer Science, 2022, 212: 152-160.

[10] Li Xin, Wang Lei, An Yi, et al. Dynamic Path Planning of Mobile Robots Using Adaptive Dynamic Programming [J]. Expert Systems with Applications, 2024, 235: 121112.

[11] 李子怡, 胡祥涛, 张勇乐, 等. 基于虚拟目标制导的自适应Q学习路径规划算法[J]. 计算机集成制造系统, 2024, 30(2): 553-568.
Li Ziyi, Hu Xiangtao, Zhang Yongle, et al. Adaptive Q-learning Path Planning Algorithm Based on Virtual Target Guidance[J]. Computer Integrated Manufacturing Systems, 2024, 30(2): 553-568.

[12] Andrius Daranda, Gintautas Dzemyda. Reinforcement Learning Strategies for Vessel Navigation[J]. Integrated Computer-Aided Engineering, 2023, 30(1): 53-66.

[13] Mnih V, Kavukcuoglu K, Silver D, et al. Playing Atari with Deep Reinforcement Learning[EB/OL]. [2024-03-02]. https://www.cs.toronto.edu/~vmnih/docs/dqn.pdf.

[14] Lü Liangheng, Zhang Sunjie, Ding Derui, et al. Path Planning via an Improved DQN-based Learning Policy [J]. IEEE Access, 2019, 7: 67319-67330.

[15] 张晨, 蒋文英, 陈思源, 等. 基于双层DQN的多智能体路径规划[J]. 中国图象图形学报, 2023, 28(7): 2167-2181.
Zhang Chen, Jiang Wenying, Chen Siyuan, et al. Multi-agent Path Planning Based on Improved Double DQN[J]. Journal of Image and Graphics, 2023, 28(7): 2167-2181.

[16] 韩玲, 张晖, 方若愚, 等. 基于改进深度强化学习的全局路径规划策略[J]. 汽车安全与节能学报, 2023, 14(2): 202-211.
Han Ling, Zhang Hui, Fang Ruoyu, et al. Global Path Planning Strategy Based on an Improved Deep Reinforcement Learning[J]. Journal of Automotive Safety and Energy, 2023, 14(2): 202-211.

[17] 李明, 叶汪忠, 燕洁华. 基于深度强化学习的沙漠机器人路径规划[J]. 系统仿真学报, 2024, 36(12): 2917-2925.
Li Ming, Ye Wangzhong, Yan Jiehua. Path Planning of Desert Robot Based on Deep Reinforcement Learning[J]. Journal of System Simulation, 2024, 36(12): 2917-2925.

[18] Li Jianxin, Chen Yiting, Zhao Xiuniao, et al. An Improved DQN Path Planning Algorithm[J]. The Journal of Supercomputing, 2022, 78(1): 616-639.

[19] Jens Kober, Bagnell J A, Jan Peters. Reinforcement Learning in Robotics: A Survey[J]. International Journal of Robotics Research, 2013, 32(11): 1238-1274.

[20] 段建民, 陈强龙. 利用先验知识的Q-Learning路径规划算法研究[J]. 电光与控制, 2019, 26(9): 29-33.
Duan Jianmin, Chen Qianglong. Prior Knowledge Based Q-learning Path Planning Algorithm[J]. Electronics Optics & Control, 2019, 26(9): 29-33.