基于深度强化学习的四旋翼航迹跟踪控制方法

伍国华[1]，曾家恒[2]，王得志[3*]，郑龙[4]，邹伟[5]

(1. 中南大学 自动化学院，湖南 长沙 410083；2. 中南大学 交通运输工程学院，湖南 长沙 410083；3. 国防科技大学 气象海洋学院，湖南 长沙 410015；4. 国防科技大学 军事职业教育技术服务中心，湖南 长沙 410015；5. 中南大学 计算机学院，湖南 长沙 410083)

摘要：受限于模型方程决定的固定结构，传统四旋翼控制器设计难以有效应对模型参数和环境扰动变化带来的控制误差。*提出了基于深度强化学习的四旋翼航迹跟踪控制方法，构建了对应的马尔可夫决策模型，并基于PPO框架提出了PPO-SAG(PPO with self adaptive guide)算法。PPO-SAG在学习过程中加入自适应机制，利用PID专家知识进行引导和学习，提高了训练的收敛效果和稳定性。根据问题特点，设计了带有距离约束惩罚和熵策略的目标函数，提出扰动误差信息补充结构和航迹特征选择结构，补充控制误差信息、提取未来航迹关键要素，提高了收敛效果。*并利用状态动态标准化、优势函数批标准化及奖励缩放策略，更合理地处理三维空间中的状态表征和奖励优势表达。单种航迹与混合航迹实验表明，所提出的PPO-SAG算法在收敛效果和稳定性上均取得了最好的效果，消融实验说明所提出的改进机制和结构均起到正向作用。所研究的未知扰动下基于深度强化学习的四旋翼航迹跟踪控制问题，为设计更加鲁棒高效的四旋翼控制器提供了解决方案。

关键词：深度强化学习；四旋翼航迹跟踪控制；近端策略优化(PPO)；自适应机制；注意力机制

中图分类号：TP273　　文献标志码：A　　文章编号：1004-731X(2025)05-1169-19

DOI: 10.16182/j.issn1004731x.joss.24-0025

引用格式: 伍国华, 曾家恒, 王得志, 等. 基于深度强化学习的四旋翼航迹跟踪控制方法[J]. 系统仿真学报, 2025, 37(5): 1169-1187.

Reference format: Wu Guohua, Zeng Jiaheng, Wang Dezhi, et al. A Quadrotor Trajectory Tracking Control Method Based on Deep Reinforcement Learning[J]. Journal of System Simulation, 2025, 37(5): 1169-1187.

A Quadrotor Trajectory Tracking Control Method Based on Deep Reinforcement Learning

Wu Guohua[1], *Zeng Jiaheng*[2], *Wang Dezhi*[3*], *Zheng Long*[4], *Zou Wei*[5]

(1. School of Automation Central South University, Changsha 410083, China; 2. School of Traffic and Transportation Engineering, Central South University, Changsha 410083, China; 3. School of Meteorology and Oceanography, National University of Defense Technology, Changsha 410015, China; 4. Military Vocational Education Technology Service Center, National University of Defense Technology , Changsha 410015, China; 5. School of Computer Science and Engineering, Central South University, Changsha 410083, China)

Abstract: Traditional quadrotor controllers, constrained by fixed model equation structures, encounter challenges in addressing control errors stemming from variations in parameters and environmental disturbances. *This paper proposes a deep reinforcement learning solution for the quadrotor trajectory following control problem. We present the PPO-SAG algorithm incorporated into the PPO framework, utilizing adaptive mechanisms and PID expert knowledge to enhance training convergence and stability. Target functions incorporating distance constraint penalties and entropy policies are designed in alignment with the characteristics of the given problem. We also devise innovative disturbance-adaptive*

收稿日期：2024-01-08　　修回日期：2024-03-12

基金项目：国家自然科学基金(62373380)

第一作者：伍国华(1986-)，男，教授，博士，研究方向为无人机系统与强化学习算法设计。

通信作者：王得志(1985-)，男，副研究员，博士，研究方向为海洋智能信息处理与强化学习。

structures and trajectory feature selection mechanisms to augment control error information and extract crucial elements from future trajectories, thereby enhancing convergence. Experiments on single and mixed trajectories indicate that the PPO-SAG algorithm achieves superior performance in both convergence and stability. Verification experiments confirm positive effects of proposed improvements. The trajectory tracking control problem of quadrotors based on deep reinforcement learning under unknown disturbances studied in this paper provides a solution for designing more robust and efficient quadrotor controllers.

Keywords: deep reinforcement learning; track following control; proximal policy optimization(PPO); adaptive mechanism; attention mechanism

0 引言

四旋翼无人机具有垂直起降、小巧灵活和成本低廉等优点，在如物流包裹配送[1]，应急事故救援，军事目标跟踪，协同侦察搜索等众多领域具有潜在的利用价值[2]。这些应用场景往往环境未知且复杂，而四旋翼是一个非线性且高度耦合的复杂控制系统，在控制解算中容易受到飞行阻力变化、传感器误差或自身物理属性突变等未知因素的影响，产生因未知干扰导致的控制误差，严重影响着飞行安全。因此，设计一个能够应对未知干扰的四旋翼控制器，以实现低误差且稳定的飞行至关重要[3]。

在众多传统的四旋翼控制方法中，PID[4]控制方法以其简单的控制计算形式最为轻便和快速，得到了学术界和工业界的广泛使用。然而，一个好的PID控制器对四旋翼模型参数的精确测量有很大的要求，并且难以有效解决未知环境扰动影响带来的控制误差[3]。此外，有如模型预测控制[5]等其他优化类型控制方法，能够在扰动环境中进行一定程度的适应性调整，以减小控制误差。但这些方法更加依赖动态模型的准确性[6]和有效的系统与环境信息，并且往往需要较长的求解时间[7]。

深度强化学习作为一种发展迅速的人工智能技术，将其应用于机器人运动控制领域，正作为新兴的研究方向吸引了越来越多科研人员的关注[8]。文献[9]提出了用深度强化学习方法进行四旋翼无人机控制器的训练，提出了一种相对保守的强化学习算法，在四旋翼控制任务上获得了比基线算法更快和更稳定的训练效果。在非常苛刻的大姿态角度初始实验状态下，实现了四旋翼手动抛飞后的定点悬停。文献[10]接着探索了深度强化学习方法在四旋翼姿态控制方面的能力，实验对比了PPO、TRPO、DDPG三种算法的性能，其中PPO算法训练好的控制器能够在角速度控制误差上超过PID算法。他们还将训练好的神经网络控制器部署在四旋翼上进行实机飞行实验，验证了从仿真到实飞的可行性，并对控制器进行了开源[11]。

随后，多种深度强化学习算法被应用于四旋翼无人机的控制问题，以探索不同算法在四旋翼上的控制性能。文献[12]将PPO算法用于四旋翼的悬停控制问题，然后利用四旋翼对定点的移动进行航迹跟踪控制，并讨论了随机策略和确定策略的差异。文献[3]基于PPO改进的PPO-PPD算法完成了悬停控制任务。文献[13]利用TD3算法跟踪随机生成点位，通过目标点相对位置的变化来提高四旋翼从不同方向抵达点位的能力，通过2种航迹展示了算法的有效性。文献[14]利用SAC算法训练四旋翼在定点的悬停控制，证明了该算法的有效性，并进一步利用在航迹跟踪控制中。文献[15]介绍了一种将积分补偿器结合到DDPG算法框架中的方法，并且提出了一种在线学习和离线学习相结合的两阶段训练策略，离线学习提高了控制鲁棒性，在线学习方法提高了控制的表现性能。文献[16]考虑了利用DDPG方法来动态调整

PID 算法的增益系数，实现了扰动环境下对四旋翼姿态和悬停位置的更精确控制，提高了控制稳定性。文献[17]针对单个航迹的深度强化学习跟踪控制问题提出了 ESAC 算法，将当前策略与优秀策略的均方误差加入到优化损失函数中，提高了强化学习的训练收敛速度和控制器性能。文献[18]研究了基于深度强化学习的四旋翼无人机姿态控制器设计，修改了强化学习中的奖励构成，提高了对目标姿态值的控制能力和抗干扰能力。文献[19]考虑了四旋翼从任意初始状态到目标位置的稳定悬停，提出了带积分补偿的改进深度确定性策略梯度算法，提高了控制的准确性。文献[20]提出了基于深度强化学习的四旋翼航线跟随问题，使用 DDPG 算法在仿真环境训练多个回合后，实现了四旋翼对随机任务航线的高精度跟随控制。文献[21]还提出了一种结合示教知识辅助的深度强化学习控制器训练方式，讨论了针对悬停任务和单一航迹跟踪任务，采用不同算法或不同奖励设置的控制效果。文献[22]设计了一个用于强化学习的新越界惩罚奖励函数，以引导四旋翼智能体在安全范围内飞行，他们基于 DDPG 算法实现了四旋翼快速到达指定目标高度的悬停任务。

此外，还有研究人员针对深度强化学习四旋翼无人机控制的训练过程进行了更为深入的实验与分析。文献[23]研究了在深度强化学习中设置不同奖励函数、噪声建模和环境随机化等训练条件对四旋翼控制器训练的影响，并将同一个控制网络应用于不同机体参数的四旋翼，实现了神经网络控制器在多型号四旋翼上的直接部署。文献[24]重点讨论了策略动作选择对四旋翼控制误差带来的影响，为四旋翼采用深度强化学习方法进行训练的动作空间选择提供了参考。

四旋翼的控制可分为内环姿态控制和外环位置跟踪控制 2 个问题[10]，其中位置跟踪控制又可以简单划分为定点悬停和航迹跟踪控制 2 个应用任务。航迹跟踪控制任务应用广泛，在四旋翼竞速[25-26]，无人机物流运输[27]和无人机交通路口侦察[28]等预规划航迹的飞行场景下具有重要应用价值。然而，上述现有深度强化学习四旋翼控制研究多关注悬停任务，并直接将对点的悬停策略迁移到对航迹的跟踪控制[3,12-14]，未能有效利用航迹信息，导致航迹跟踪误差较大。或仅研究了对某个单一航迹的深度强化学习训练效果和测试控制误差，未针对混合航迹数据集进行强化学习算法设计和性能讨论，在与训练集不同的航迹上，难以直接实现低误差控制，限制了控制器的应用范围，存在一定的局限性。

针对所讨论的既有研究局限，本文研究了深度强化学习在四旋翼单一和混合航迹跟踪控制上的训练方法，构建了对应的马尔可夫决策过程模型，所研究的场景更贴近四旋翼在航迹跟踪控制任务中的需要。针对所研究的单一和混合航迹的四旋翼控制器深度强化学习训练问题，提出了带有自适应引导机制的 PPO-SAG 算法，合理利用 PID 专家控制知识引导，提高了算法的收敛效果，并设计了扰动误差信息补充结构和航迹特征选择结构，在训练时采用了符合问题特点的特征处理技术和奖励设计，提高了神经网络控制器的性能。将所提出算法与多个强化学习算法和 PID 算法的控制效果进行了对比，并进行了消融实验、泛化实验等详细的仿真实验与讨论分析，结果表明了所提出算法的优异性。

1 问题描述及建模

1.1 四旋翼动力学模型

为方便表述，分别建立世界坐标系 W 和机体坐标系 B，两个坐标系分别由对应的单位向量正交基 $\{x_w, y_w, z_w\}$ 和 $\{x_B, y_B, z_B\}$ 组成与表达。其中机体坐标系的原点构建于机身重心，z_B 垂直机体向上。机体坐标系构建与无人机结构的关系，以及世界坐标系和机体坐标系之间的关系如图 1 所示。

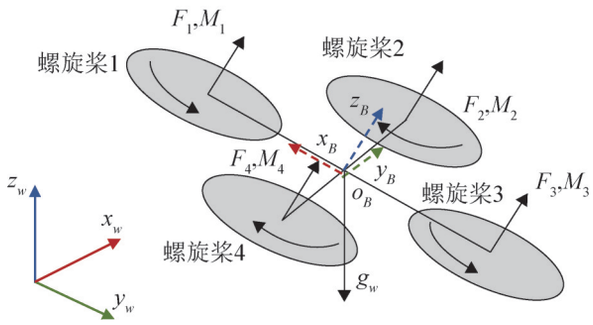


图1　四旋翼无人机结构示意图

Fig. 1　Illustration of quadrotor structure

在三维空间中，将四旋翼无人机建模成质量为$m\in\mathbb{R}^+$，转动惯量为$\boldsymbol{J}\in\mathbb{R}^{3\times3}$的一个拥有6个自由度的刚体。在飞行过程中，四旋翼无人机的状态向量可表示为$\boldsymbol{x}=[\boldsymbol{p}_W,\boldsymbol{q}_{WB},\boldsymbol{v}_W,\boldsymbol{\omega}_B,\boldsymbol{\Omega}]^{\mathrm{T}}$，在该向量中$\boldsymbol{p}_W\in\mathbb{R}^3$表示四旋翼在世界坐标系下的空间坐标，$\boldsymbol{v}_W\in\mathbb{R}^3$表示在世界系中的飞行速度，$\boldsymbol{q}_{WB}$是表达机体坐标系到世界坐标系旋转关系的四元数，$\boldsymbol{\omega}_B$是在机体坐标系下的无人机角速度，$\boldsymbol{\Omega}$是当前4个旋翼的旋转速度向量。于是，可以得到4旋翼无人机的动力学模型：

$$\dot{\boldsymbol{x}}=\begin{bmatrix}\dot{\boldsymbol{p}}_W\\ \dot{\boldsymbol{q}}_{WB}\\ \dot{\boldsymbol{v}}_W\\ \dot{\boldsymbol{\omega}}_B\\ \dot{\boldsymbol{\Omega}}\end{bmatrix}=\begin{bmatrix}\boldsymbol{v}_W\\ \boldsymbol{q}_{WB}\odot[0,\boldsymbol{\omega}_B]^{\mathrm{T}}\\ R(\boldsymbol{q})(\boldsymbol{f}_T+\boldsymbol{f}_D)/m+\boldsymbol{g}_W\\ \boldsymbol{J}^{-1}(\boldsymbol{\tau}-\boldsymbol{\omega}_B\times\boldsymbol{J}\boldsymbol{\omega}_B)\\ (\boldsymbol{\Omega}_{\mathrm{cmd}}-\boldsymbol{\Omega})/k_{\mathrm{mot}}\end{bmatrix}\tag{1}$$

式中：符号⊙代表四元数乘法；函数$R(\boldsymbol{q})$将四元数映射为对应的旋转矩阵；$\boldsymbol{g}_W$是重力加速度向量。螺旋桨转速建立为一阶响应系统，Ω_{cmd}为控制命令输入的转速；k_{mot}是螺旋桨的响应时间常数。4个螺旋桨i产生的总推力$\boldsymbol{f}_{\mathrm{T}}$和总转动力矩$\boldsymbol{\tau}$的计算公式如下：

$$\boldsymbol{f}_{\mathrm{T}}=\sum_i\boldsymbol{f}_i,\ \boldsymbol{\tau}=\sum_i\boldsymbol{\tau}_i+d_i\boldsymbol{f}_i\tag{2}$$

四旋翼的每个螺旋桨产生的推力$\boldsymbol{f}_i$和旋转力矩$\boldsymbol{\tau}_i$均建模为与转速平方的正比关系：

$$\boldsymbol{f}_i(\boldsymbol{\Omega})=[0\ 0\ c_{\mathrm{l}}\cdot\Omega_i^2]^{\mathrm{T}}\boldsymbol{\tau}_i(\boldsymbol{\Omega})=[0\ 0\ c_{\mathrm{d}}\cdot\Omega_i^2]^{\mathrm{T}}\tag{3}$$

所需要的推力系数c_{l}和转动力矩系数c_{d}以及式(2)中的每个螺旋桨臂长d_i，可以通过实验或测量直接获得。此外，四旋翼无人机还会在飞行的过程中受到与机体速度$\boldsymbol{v}_B$成正比的空气阻力向量$\boldsymbol{f}_{\mathrm{D}}$，由空气阻力系数$(k_{vx},k_{vy},k_{vz})$决定[29]：

$$\boldsymbol{f}_{\mathrm{D}}=-[k_{vx}v_{Bx}\ \ k_{vy}v_{By}\ \ k_{vz}v_{Bz}]^{\mathrm{T}}\tag{4}$$

最后，为符合物理约束，四旋翼的每个螺旋桨转速具有限制范围：

$$\Omega_{\min}\leqslant\Omega_i\leqslant\Omega_{\max},\forall i\in\{1,2,3,4\}\tag{5}$$

于是，通过动力学方程，四旋翼在空间中的位置变化和姿态变化，将由四旋翼的4个螺旋桨转速控制，进而影响到四旋翼的航迹跟踪效果。

1.2　四旋翼航迹跟踪控制问题描述

本文使用符合四旋翼飞行动力学的连续航迹作为强化学习四旋翼控制器控制任务的训练目标。以城市场景无人机交通路口侦察[28]为例，四旋翼根据已知城市障碍物信息、出发点S和侦察点E，需要规划出一条安全的飞行航迹以抵达侦察路口。航迹规划方法分为2个步骤，首先通过A*[30]等算法确定离散序列航迹点，如图2中紫色点所示。



图2　四旋翼航迹跟踪任务示意图

Fig. 2　Illustration of quadrotor trajectory tracking task

得到序列航迹点后，采用Minimum-snap[31]方法，生成通过航迹点且连续平滑的目标航迹。具体而言，对于空间中的$M+1$个航迹点，构造M条独立的，由n阶多项式表达的子航迹，其中每条三维空间中的子航迹可由时间变量t表达：

$$f(t)=\begin{cases}\sum\limits_{k=0}^{n}p_{1,k}t_k,\ t_0\leqslant t<t_1\\ \sum\limits_{k=0}^{n}p_{2,k}t_k,\ t_1\leqslant t<t_2\\ \vdots\\ \sum\limits_{k=0}^{n}p_{M,k}t_k,\ t_{M-1}\leqslant t<t_M\end{cases}\tag{6}$$

式中：$p_{M,k}$为对应于第M段航迹内第k阶时间变量的系数。在每个航迹点m预设无人机期望位置、速度和加速度分别为x_m,v_m,a_m，期望偏航角ψ以及偏航角变化速率，则可以建立关于航迹的四阶导数(Snap)的二次型优化目标函数：

$$\min\sum_{i=1}^{M}\int_{t_{i-1}}^{t_i}(p_i^4(t))^2\mathrm{d}t=\min\boldsymbol{p}^{\mathrm{T}}\boldsymbol{Q}\boldsymbol{p}\tag{7}$$

式中：$\boldsymbol{p}=[p_1,p_2,\cdots,p_M]$，为待求解的高阶系数向量，对角矩阵$\boldsymbol{Q}=diag\{Q_1,Q_2,\cdots,Q_M\}$，为每一段航迹四阶导数平方对时间$t$在时间段内的积分：

$$\boldsymbol{Q}_i=\begin{bmatrix}0_{4\times4} & 0_{4\times(n-3)}\\ 0_{(n-3)\times4} & \dfrac{r!c!(t_i^{(r+c-7)}-t_{i-1}^{(r+c-7)})}{(r-4)!(c-4)!(r+c-7)}\end{bmatrix}\tag{8}$$

式中：r和c分别对应从零开始的位置行与列索引。为满足初始条件值和各航迹段之间的平滑要求，优化方程还需要加入等式约束：

$$\boldsymbol{A}_{eq}\boldsymbol{p}=\boldsymbol{b}_{eq}\tag{9}$$

式中：$\boldsymbol{b}_{eq}=[x_0,v_0,a_0,\cdots,x_i,v_i,a_i,0,0,\cdots,0],\ i\in\{1,2,\cdots,M\}$，分别对应初始状态约束、中间航迹点状态约束、终点状态约束和中间航迹点连续约束。$\boldsymbol{A}_{eq}$包含每段航迹多项式的多阶导数，当约束涉及其他航迹部分时，其他航迹段系数置零，因此稀疏矩阵为

$$\boldsymbol{A}_{eq}=\begin{bmatrix}1,t_0,t_0^{(2)},\cdots,t_0^{(n)},[\boldsymbol{0}]\\ 0,1,2t_0,\cdots,nt_0^{(n-1)},[\boldsymbol{0}]\\ 0,0,2,\cdots,n(n-1)nt_0^{(n-2)},[\boldsymbol{0}]\\ \vdots\\ [\boldsymbol{0}],0,0,2,\cdots,n(n-1)t_M^{(n-2)}\\ [\boldsymbol{0}],1,t_i,\cdots,t_i^{(n)},-1,-t_i,\cdots,-t_i^{(n)},[\boldsymbol{0}]\\ [\boldsymbol{0}],(1,t_i,\cdots,t_i^n)^{(1)},(-1,-t_i,\cdots,-t_i^n)^{(1)},[\boldsymbol{0}]\\ [\boldsymbol{0}],(1,t_i,\cdots,t_i^n)^{(2)},(-1,-t_i,\cdots,-t_i^n)^{(2)},[\boldsymbol{0}]\end{bmatrix}\tag{10}$$

$\boldsymbol{A}_{eq}$的维度为$(4M+2)\times(n+1)M$，式(10)中[**0**]代表对应个数的补全零向量。于是，航迹生成方法是一个以时间系数为变量的，仅带有等式约束的二次型优化问题，由式(7)和式(9)表达。

$$t_i=\frac{\left\|x_{i-1}-x_i\right\|_2}{k_v\log(\left\|x_{i-1}-x_i\right\|_2)+v_b}+t_{i-1}\tag{11}$$

最后，采用对数关系确定每段子轨迹的飞行时间，以确定航迹点的抵达时刻，如式(11)所示。获得分段时间后，通过优化式(9)，得到航迹空间的时间式(6)。然后，控制器需要在环境扰动下最小控制误差跟踪航迹，安全抵达侦察终点。

1.3 航迹跟踪控制马尔可夫决策过程

强化学习通过对问题构建马尔可夫决策过程(Markov decision process, MDP)来描述训练中的关键要素，该过程可以用一个四元组(S,A,P,R)来表示。在四旋翼的强化学习航迹跟踪控制问题中，状态空间S对应于四旋翼状态向量$\boldsymbol{x}$和待跟踪航迹信息；动作空间A对应于螺旋桨转速指令Ω_{cmd}；状态转移空间P对应于态转移方程式(1)，受环境未知扰动的影响，转移概率未知；奖励空间R对应于无人机在每个时刻t决策得到的对应奖励反馈表达r_t，根据航迹跟踪误差等要素决定。

通过利用深度强化学习方法，四旋翼智能体与环境进行反复交互，找到包含未知扰动情况下，航迹跟踪控制的最佳控制策略π_θ^*，以获得最大化期望时间推移奖励。关于无人机控制策略π_θ的目标函数，可以用长期奖励期望表示：

$$J(\pi_\theta)=\mathbb{E}_{\tau\sim\pi_\theta}[R(\tau)]=p_{\tau\sim\pi_\theta}\left[\sum_{t=0}^{\infty}\gamma^t r_t\right]\tag{12}$$

式中：$\tau=(s_0,a_0,r_0,s_1,q_1,r_1,\cdots,s_T,a_T,r_T)$是无人机在控制策略$\pi_\theta$决策下产生的一条飞行轨迹，初始化位置$s_0\sim p_0(S)$由环境决定；折扣因子$\gamma\in[0,1]$表示长远奖励对当前时刻的重要程度。为使得强化学习轨迹的期望奖励最大化，优化目标函数等价为求出最佳策略π_θ^*对应的深度策略网络参数θ^*：

$$\theta^*=\arg\max_\theta\mathbb{E}_{\tau\sim\pi_\theta}[R(\tau)]\tag{13}$$

于是，通过对四旋翼航迹跟踪控制问题的状态、动作、环境和奖励空间进行拆解分析，将该问题转换为了一个标准的、可由深度强化学习方法训练求解的马尔可夫决策过程模型。

2 深度强化学习训练方法

2.1 PPO-SAG强化学习算法

针对四旋翼航迹跟踪控制的问题特点，本文提出PPO-SAG (PPO with self adaptive guide)算法，在PPO算法上融合模拟退火机制，自适应利用PID专家控制知识进行引导学习。同时，设计了新的优化目标函数，以提高强化学习训练效果。

模拟退火算法[32]是基于蒙特卡洛思想设计的，一种可在较大解空间搜索全局最优解的方法，本文将其思想利用到强化学习训练流程。设一轮航迹跟踪控制训练完成后的累计奖励为$R(\tau)$，近N条航迹平均控制步长为$\bar{S}_N$，奖励均值为$\bar{R}(\tau)_N$。当本轮$R(\tau)\geqslant\bar{R}(\tau)_N$时，则进行下一条新航迹训练，否则以Metropolis准则决定是否通过本次训练：

$$P=\exp((R(\tau)-\bar{R}(\tau)_N)/T_k) \tag{14}$$

式中：P为该轮航迹通过训练的概率；T_k为模拟退火温度参数，温度越高则接受条件越宽松，使得较差累计奖励航迹仍有较大概率通过训练。

$$T_k'=kT_k,\ k\in(0,1) \tag{15}$$

设初始温度为T_0，随着训练每L轮次，使用系数k衰减温度至T_k'，以更严格拒绝低于平均奖励值的航迹，降低接受低于平均水平奖励航迹的概率。本次训练航迹被拒绝后，将舍弃控制经验，以PID作为专家控制策略重新进行步长为$\bar{S}_N$的控制引导。

PPO算法是一种对TRPO[33]改进的，基于策略的强化学习方法。根据式(12)给出的目标函数，可以得到直接对策略函数优化的梯度表达式[34]：

$$\nabla_\theta J(\pi_\theta)=\mathbb{E}_\tau\left[\sum_{t=0}^{T}\nabla_\theta\log\pi_\theta(A_t|S_t)R(\tau)\right] \tag{16}$$

PPO引入了重要性采样原则以及GAE广义优势函数[35]，以利用多条历史轨迹数据进行更新，提高数据利用效率，降低模型估计方差，提高训练稳定性。设参数$\rho_t(\theta)=\pi_\theta(a_t|s_t)/\pi_{\theta_{\text{old}}}(a_t|s_t)$代表新旧策略的分布比，式(16)应进一步改写为

$$\mathbb{E}_{\pi_{\theta\text{old}}}[\rho_t(\theta)\nabla_\theta\log\pi_\theta(A_t|S_t)\hat{A}_t^{\text{GAE}}(s_t,a_t)]$$

为使得新旧策略之间的差异不超过优化范围，TRPO应用了带有全变分距离(TV距离)约束的优化方程，并用相对熵(KL散度)进行替换以解决TV距离不具有连续性，导致优化过程中存在梯度会消失的缺点。PPO算法在TRPO基础上进行了简化，采用梯度裁剪策略直接限制策略的更新幅度[36]：

$$\begin{aligned}J^{\text{PPO}}(\pi_\theta)=&\sum_{s_t,a_t}\min[\rho_t(\theta)\hat{A}_t^{\text{GAE}}(s_t,a_t),\\&clip(\rho_r(\theta),1-\varepsilon,1+\varepsilon)\hat{A}_t^{\text{GAE}}(s_t,a_t)]\end{aligned} \tag{17}$$

但PPO算法采用的梯度裁剪策略被证明仍可能存在更新步长违反信赖域约束[37]，于是本文采用平方距离[38]惩罚项加入目标函数进一步进行约束，并加入最大熵策略[39]弥补PPO的探索性不足：

$$\begin{aligned}J_{\text{Ours}}(\pi_\theta)=&J_{\text{PPO}}(\pi_\theta)+\sum_{a_t}\beta(\log\pi_{\theta_{\text{old}a_t}}-\log\pi_{\theta_{\text{new}a_t}})^2-\\&\sum_{a_t}\pi_{\theta_{\text{new}}}(a_t|s_t)\log(\pi_{\theta_{\text{new}}}(a_t|s_t))\end{aligned} \tag{18}$$

平方距离具有连续且对称的良好性质，以解决KL散度在计算形式上的不对称性，与最大熵策略一同加入目标函数，以提升最终训练效果。

2.2 训练特征处理技术

四旋翼的强化学习训练在三维空间中进行，难以获得其状态向量$\boldsymbol{x}$的上下界限，进行标准化处理。因此，本文对每个状态采用动态标准化技术：

$$\mu_{\text{new}}=\mu_{\text{old}}+(\boldsymbol{x}-\mu_{\text{old}})/n_{\text{step}} \tag{19}$$

$$q=q+(\boldsymbol{x}-\mu_{\text{old}})(x-\mu_{\text{new}}),\ \sigma=\sqrt{q/n_{\text{step}}} \tag{20}$$

式中：μ与σ分别为正态分布的均值与标准差，变量q动态维护标准差的计算过程。除状态动作标准化外，对优势函数$\hat{A}_t^{\text{GAE}}$也采用批标准化处理[40]：

$$\hat{A}_{t/\text{Norm}}^{\text{GAE}}\sim N(\mu_{\text{batch}},\sigma_{\text{batch}}^2)$$

奖励函数采用奖励缩放方法[41]替代奖励标准化。该方法通过维护一个滚动折扣奖励和的标准差，对当前动作奖励值做动态更新计算：

$$r_t = r_{\text{total}}/(\sigma_r + \varepsilon) \tag{21}$$

式中：σ_r进行动态更新，更新方法与式(11)相同，ε为一个防止分母置零的极小值。最后，为避免训练后期出现震荡，设计学习率线性衰减：

$$Lr = Lr_{\max}(1 - step_{\text{now}}/step_{\max}) \tag{22}$$

式中：$Lr_{\max}$为初始的较大学习率，以在早期大幅度更新策略；$step_{\max}$为总训练步长。表明在接近训练结束时学习率变小，以确保训练的稳定。

2.3 网络结构设置

在航迹跟踪控制任务中，控制器可以获取到航迹信息，并且需要应对未知的环境扰动。因此，需要设计更有效的网络结构来有效提取航迹特征以及补充表达扰动造成的影响，以减少控制误差。

如图3所示，为在策略神经网络中充分利用航迹未来时间段H_{front}的信息，本文基于注意力机制[42]设计了航迹特征选择结构。在结构中，采用相同的查询矩阵$\boldsymbol{W}_Q$以提高计算效率，而采用多个独立的键矩阵$\boldsymbol{W}_K$来体现航迹在时序上的差异：

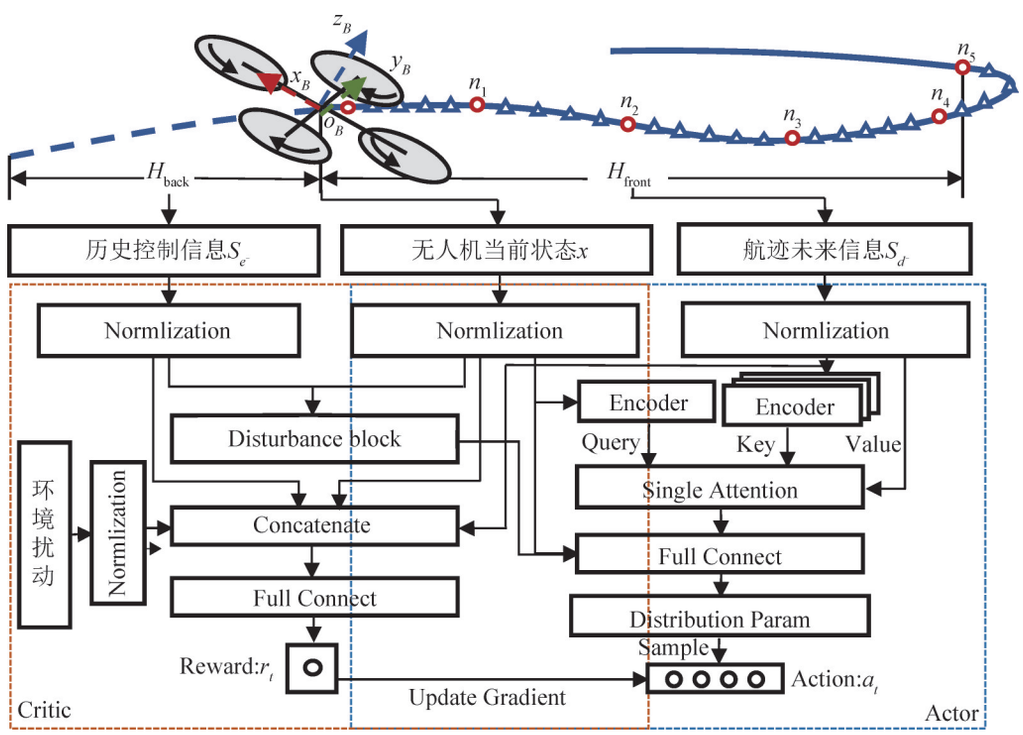


图3　价值与策略网络结构

Fig. 3　Critic and actor network structure

$$\boldsymbol{q}_t = \boldsymbol{W}^Q \boldsymbol{s}_t^{d^-};\ \boldsymbol{k}_{t+i} = \boldsymbol{W}^K \boldsymbol{s}_{t+i}^{d^-};\ \boldsymbol{v}_{t+i} = \boldsymbol{s}_{t+i}^{d^-} \tag{23}$$

$$\boldsymbol{h}_{\text{att}} = \sum_{i=1}^{1+ns} softmax(\boldsymbol{q}_t \boldsymbol{k}_{t+i}/\sqrt{\boldsymbol{d}_k})\boldsymbol{v}_{t+i} \tag{24}$$

式中：$\boldsymbol{s}_t^{d^-}$为除去转速控制量$\boldsymbol{\Omega}$后，对当前期望位置和期望速度做差的状态向量$\boldsymbol{x}$。$\boldsymbol{s}_{t+i}^{d^-}$为未来航迹状态信息，下标$i \in \{1, k+1, \cdots, nk+1\}$表示模型对航迹向前观测信息的总时间范围，由间隔步长s和前向信息点个数n共同决定，上标d^-为将当前状态与期望状态做差；d_k为向量$\boldsymbol{s}_{t+i}^{d^-}$的编码长度。

为对环境的未知扰动造成的控制误差进行信息补充，利用过往时刻的控制后验信息，设计扰动误差信息补充结构以补充控制误差信息：

$$\boldsymbol{h}_{\text{his}} = ReLU(FC(\boldsymbol{s}^{e^-}, \boldsymbol{v}_t, R(\boldsymbol{q}_t)))\odot \boldsymbol{s}^{e^-} \tag{25}$$

$$\boldsymbol{s}^{e^-} = R(\boldsymbol{q}_t)\cdot(\boldsymbol{p}_t - \boldsymbol{p}_{t-1}^{\text{des}}) \tag{26}$$

式中：$\boldsymbol{v},\boldsymbol{q},\boldsymbol{p}$分别为无人机对应时刻的速度、四元数和位置；$\boldsymbol{s}^{e^-}$为转换为机体坐标系的当前时刻实

际位置与过去时刻期望位置的距离，⊙符号表示哈达玛积，利用ReLU激活函数负数区域置零的特点，保留机体坐标系重要方向的误差信息，无人机智能体的策略输出动力为

$$\boldsymbol{a}_t = FC(\boldsymbol{x}, \boldsymbol{h}_{\text{att}}, \boldsymbol{h}_{\text{his}}) \tag{27}$$

通过注意力层编码和扰动误差补充后，两个额外编码与四旋翼无人机当前状态向量$\boldsymbol{x}$合并，进行全连接层前向传播得到控制分布参数，然后对分布采样得到输出的旋翼转速控制动作a_t，状态到奖励的映射关系为

$$r_t = FC(\boldsymbol{x},\ \boldsymbol{s}^{e^-}, \boldsymbol{s}^{d^-}, \boldsymbol{D}^t) \tag{28}$$

评论家网络设计为全连接神经网络结构，额外将训练时可获得的环境扰动情况$\boldsymbol{D}^t$加入评价网络，隐式学习环境扰动对控制动作带来的影响。

于是，根据上述价值网络与策略网络的结构设计，强化学习传递的状态向量如式(29)所示。

$$\boldsymbol{s}_t = [\boldsymbol{x}, \boldsymbol{p}_{t-1}^{\text{des}}, \boldsymbol{s}_t^{d^-}, \boldsymbol{s}_{t+i}^{d^-}, \boldsymbol{D}^t],\ i \in \{1, 2, \cdots, nk+1\} \tag{29}$$

2.4 奖励函数设置

奖励设置是强化学习的重要部分，在悬停点控制任务中，奖励将无人机与悬停点的欧式距离负值作为奖励，引导无人机向目标点靠近：

$$r_p = -k_p \sqrt{x_e^2 + y_e^2 + z_e^2} \tag{30}$$

式中：下标e代表当前状态与期望值的差值。本文在此基础上，进一步提出符合航迹跟踪的训练奖励函数设计。首先，由于航迹中包含了每个时刻的速度信息，因此将速度信息加入奖励函数：

$$r_v = -k_v \sqrt{v_{xe}^2 + v_{ye}^2 + v_{ze}^2} \tag{31}$$

在训练前期，更小的机体转动角度能够有助于四旋翼的稳定飞行，减少坠机的控制经验可以保障策略函数更快地对减少航迹跟踪误差进行探索：

$$r_\omega = \begin{cases} -k_\omega^1 \sqrt{\theta^2 + \phi^2 + \psi^2}, & step < K_{\text{step}} \\ -k_\omega^2 \sqrt{\theta_e^2 + \phi_e^2 + \psi_e^2}, & step \geqslant K_{\text{step}} \end{cases} \tag{32}$$

在训练后期，角度期望差可成为另外一个引导航迹逼近的奖励特征，当训练超过步数K_{step}后奖励r_ω更变为角度期望差。

$$r_{\text{bound}} = \begin{cases} 0, & \sqrt{x_e^2 + y_e^2 + z_e^2} \leqslant Max_{\text{bound}} \\ -k_b, & \sqrt{x_e^2 + y_e^2 + z_e^2} > Max_{\text{bound}} \end{cases} \tag{33}$$

为及时终止训练早期的坠机飞行导致收集的较差经验轨迹，设置位置差异边界奖励，以惩罚无人机距离目标航迹过远。该条件Max_{bound}一旦触发，则终止本次训练流程，如式(34)所示。

$$r_{\text{total}} = r_p + r_v + r_\omega + r_{\text{bound}} + r_{\text{alive}} \tag{34}$$

最后，加入无人机持续存活奖励r_{alive}，得到最终的奖励值r_{total}，表达为多个奖励之和。

2.5 四旋翼航迹跟踪控制算法训练流程

根据上述对任务和算法的介绍，图4展示了使用PPO-SAG算法进行四旋翼航迹跟踪控制训练的整体流程，算法的核心模块在于利用自适应机制，来接受或拒绝上一训练回合的控制经验。如图中自适机制部分所示，当经验被拒绝时，重新利用PID专家控制算法进行控制数据采集，以提高经验回放池中的数据质量。每L个训练回合后，在进行自适应机制判断的同时调整参数T_k，来严格化该机制的接受标准，以实现算法在早期的充分探索，从而提高控制器的鲁棒性，并保证收敛时的数据质量，以减小最终的控制误差。最后，与训练流程图相对应，给出基于PPO-SAG算法的四旋翼航迹跟踪控制训练任务的算法伪代码，如算法1所示。

3 仿真实验分析

本文对提出的PPO-SAG算法在不同航迹上进行训练与性能评估，与经典PID控制方法[31]以及既研究使用过的TD3算法[13]、SAC算法[14]、PPO算法[12]和PPO-PPD[3]算法进行各类实验对比分析。

所有实验均在CPU为Intel(R) Core(TM) i7-10 700K CPU@3.80 GHz 64 G，显卡为RTX30708 G的计算机硬件配置上进行。所有算法测试程序在Ubuntu20.04系统上采用Python3.8版本实现，仿真环境采用V-rep[44]和对应强化学习接口库Pyrep[45]。

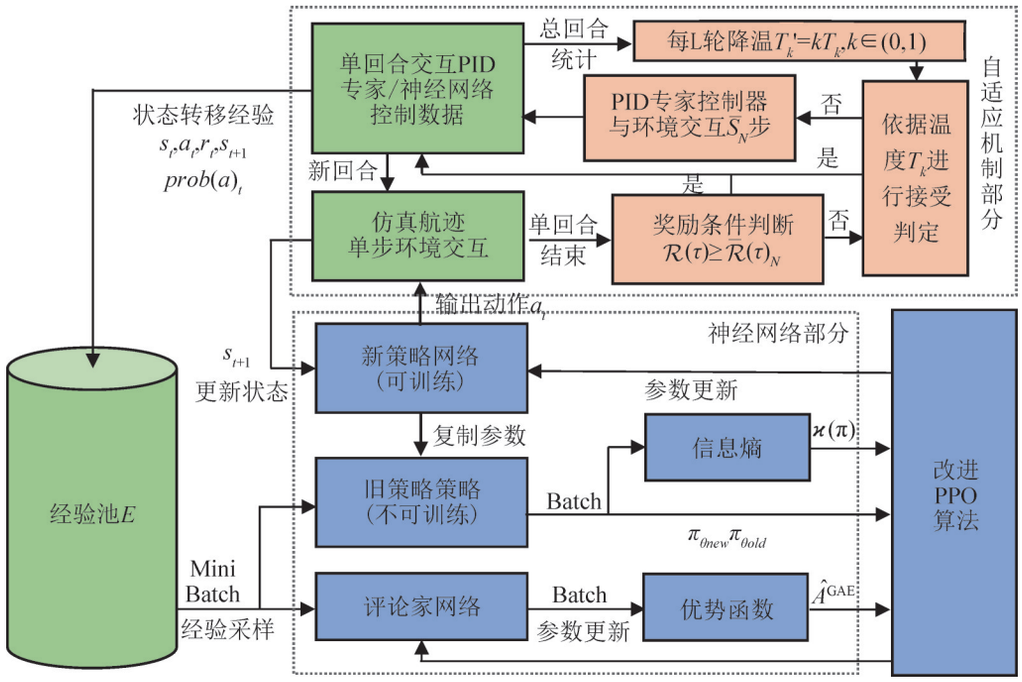


图4　基于PPO-SAG算法的四旋翼航迹跟踪训练流程图

Fig. 4　Illustration of the training process based on PPO-SAG

算法 1 基于PPO-SAG算法的四旋翼航迹跟踪控制

初始化：仿真环境、网络结构和参数、训练特征处理参数

输入：无人机模型参数和算法超参数

While $Step\leqslant Step_{\max}$

重置无人机位置；重置累计奖励$R(\tau)=0$；训练步长$t=0$；重新获取目标航迹；满足退火频率L时对T_k按式(15)进行退温

While $t\leqslant N_t$ and $\left\| p-p_e \right\|_2\leqslant Max_{\text{bound}}$

观察根据式(31)确立的强化学习当前时刻状态s_t，并通过式(20,21)进行动态标准化处理

将动态标准化后的状态输入策略网络π_θ,通过前向传播后得到分布参数，采样得到控制动作a_t,$Step=Step+1$

将动作a_t作用于仿真环境无人机输入，获得下一状态s_{t+1},用式(23)处理奖励r_{total}得到奖励缩放后的r_t

将本次交互结果$<s_t,a_t,r_t,s_{t+1}>$以及当前策略对动作a_t的概率$prob(a_t)$暂存至列表$List$;$t=t+1$

If 经验回放池大于经验池阈值$E_{\max}$,采用Minibatch更新

对经验池中所有样本状态s_t,s_{t+1}用评论家网络估计状态价值并计算优势值$\hat{A}_t^{GAE}$和状态目标价值v_{target}^t，并通过式(22)进行批标准化处理得到$\hat{A}_{t/Norm}^{GAE}$用于计算更新梯度，计算a_t在当前策略下的概率$prob^{new}(a_t)$

以式(24)计算的学习率，使用Adam[43]优化方法，根据采样批数据对目标函数(19)进行反向梯度传播优化，以更新当前控制策略函数$\pi_{\theta_{old}}\rightarrow\pi_\theta$

对本批次的评论家网络评估状态s_t价值，与利用经验池计算好的状态目标价值v_{target}^t采用均方误差更新

End If 批量数据策略和价值网络更新完成

将单步动作奖励加入累计奖励$R(\tau)=R(\tau)+r_{total}$

End While

If not $R(\tau)>\bar{R}(\tau)_N\ and\ \exp((R(\tau)-\bar{R}(\tau)_N)/T_k)>rand(0,1)$:

舍弃本轮 *List* 中的控制数据，以PID控制对目标航迹进行 $\bar{S}_N$ 步跟随控制，并将此专家经验数据存入回放池 E

Else 将列表 *List* 中控制数据存入回放池 E，并清空列表

End While

Return 最优控制策略 π_{θ^*}；动态标准化参数 μ 与 σ

3.1 模型与算法参数设置

在 V-rep 仿真环境中，四旋翼模型采用科研用小型无人机 Crazyflie 参数[46]设置，控制频率设置为100 Hz，无人机的各项参数和环境参数如表1所示，并说明了各项参数的均匀分布扰动范围。

表1 Crazyflie参数及扰动范围设置
Table 1 Crazyflie parameters and disturbance range

Crazyflie参数	标称值	扰动
四旋翼质量 m/kg	0.03	±15%
转动惯量 J/(kg m^2)	$[1.43\times10^{-5}, 1.43\times10^{-5}, 2.89\times10^{-5}]$	±15%
重力加速度 $\boldsymbol{g}$/(m/s^2)	[0, 0, −9.81]	±0.1
x 轴空气阻力 k_{vx}/(Ns/m)	0.1	±0.05
y 轴空气阻力 k_{vy}/(Ns/m)	0.1	±0.05
z 轴空气阻力 k_{vz}/(Ns/m)	0.05	±0.03
四旋翼螺旋桨臂长 d_i/m	0.046	0
最大转速 $\Omega_{\max}$/(rad/s)	2 500	0
推力系数 c_l/(N/(rad·s))	2.3×10^{-8}	0
转动矩 c_d/(N·m/(rad·s))	7.8×10^{-11}	0

PID作为一种经典的控制方法，需要通过精确的参数调整才能达到较好的控制性能。对应于上述的参数设置，调整好的PID控制参数如表2所示[31]。

表2 PID控制算法参数设置
Table 2 PID control algorithm parameter settings

PID控制参数名称	参数设置
位置误差系数 K_p	*diag*(22, 22, 15)
速度误差系数 K_v	*diag*(7.9, 7.9, 6.45)
姿态误差系数 K_R	*diag*(3 500, 3 500, 400)
角速度误差系数 K_ω	*diag*(107.75, 107.75, 43.75)

实验采用的策略网络结构中，航迹特征选择结构设间隔步长 $s=10$，前向信息点个数 $n=6$，查询值与键值编码输出维度为32，全连接层神经元个数设置为128，网络层数为2，扰动模块采用16单层全连接层。控制策略采用Beta分布，将输出结果映射到螺旋桨转速范围内。算法参数如表3所示。

表3 深度强化学习算法参数设置
Table 3 Parameter settings for PPO-SAG algorithm

参数名称	参数设置	参数名称	参数设置
折扣因子 γ	0.99	最大步长	1×10^7
学习率 Lr	$\leqslant3\times10^{-4}$	批训练大小	64
距离系数 β	5.0	回合步长	1 800
裁剪率 ε	0.2	经验池大小	1 024
航迹数	50	退火轮次 L	100
模拟退火系数	0.95	初始温度	1 000

对于奖励函数系数，设置距离误差惩罚参数系数 $k_p=0.5$，速度误差惩罚参数 $k_v=0.1$，大角度状态惩罚参数 $k_\omega^1=0.2$，角度误差惩罚参数 $k_\omega^2=0.1$，四旋翼距离越界惩罚参数 $k_{\mathrm{b}}=5$，边界触发距离 $Max_{\mathrm{bound}}=8$，存活奖励值 $k_{\mathrm{alive}}=1.5$，无人机角度惩罚项步长参数 $K_{\mathrm{step}}=2\times10^5$。

实验采用6组不同的航迹，每一组航迹的航迹点在一定空间范围内具有随机性，由这些不同航迹点生成各组中50个相似的独立航迹，得到共300条用于深度强化学习的训练和测试的平滑航迹。

如图5，航迹设置方式从下述4个角度出发：

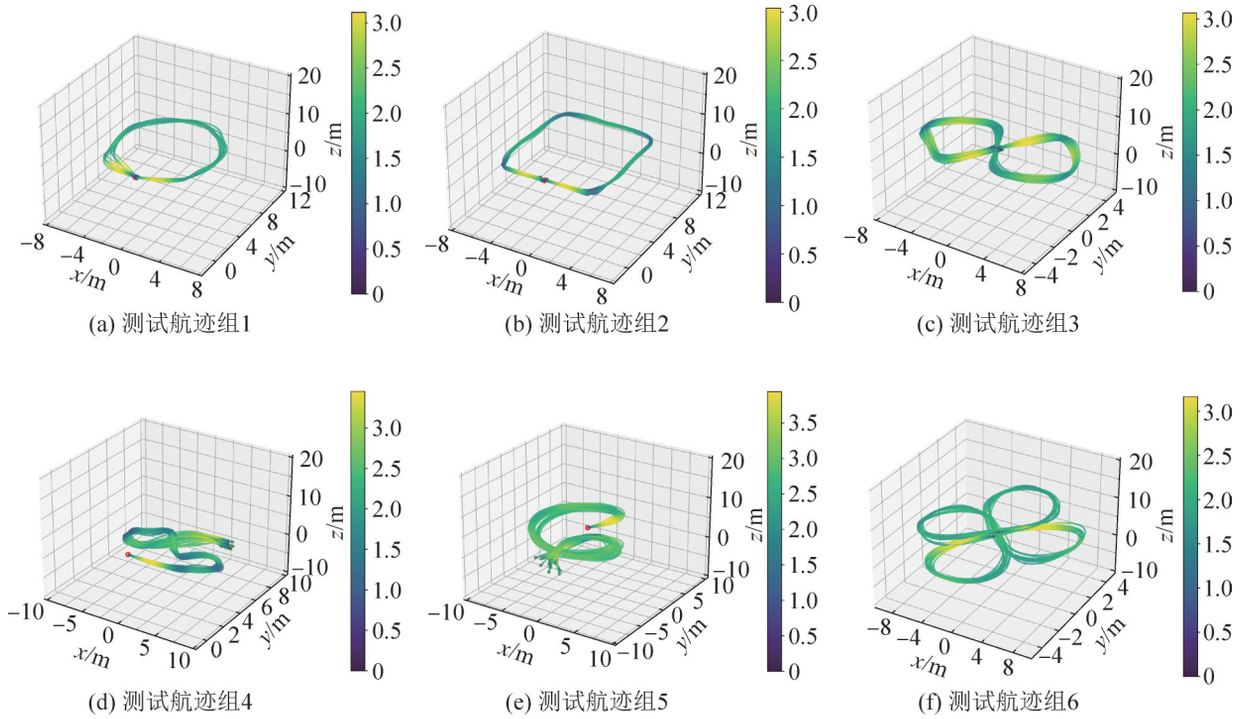
(1) 6组航迹均存在大幅转向，跟踪控制难度大于一般规划结果的避障飞行航迹。以提高算法的训练验证难度，充分保证规划航迹跟踪的可行性；

(2) 同组50条航迹相似，模拟任务规划结果的多条近似航迹，保障在相似航迹上具有稳定的控制性能，对应于实际规划时航迹的小幅度变化；

(3) 前三组航迹在高度上的变化较小，而后三组航道在高度上的变化较大，航迹跟踪控制任务的难度由简单到困难递增。

(4) 由于控制器本质是对航迹信息的获取与跟

踪，因此训练数据不考虑因避障规划而给出的具体航迹点案例。而是在一定范围内随机设定航迹点，以训练神经网络对曲线航迹的跟踪控制能力，具体避障规划航迹的案例在泛化性实验中进行讨论。



(a) 测试航迹组1　(b) 测试航迹组2　(c) 测试航迹组3

(d) 测试航迹组4　(e) 测试航迹组5　(f) 测试航迹组6

图5　强化学习无人机训练和测试航迹示例

Fig. 5　Illustration of the trajectory data for training

3.2 强化学习算法收敛效果分析

本节将 TD3 算法、SAC 算法、PPO 算法、PPO-PPD 算法和所提出的 PPO-SAG 算法在 2 种航迹跟踪控制任务场景下，进行同条件同步长的深度强化学习训练，然后对收敛奖励进行对比与分析。

实验设置单种类航迹和混合航迹跟踪 2 种训练任务，对应于四旋翼仅需完成单点侦察的单种航迹跟踪和进行多点侦察的混合航迹跟踪任务。图 6 和图 7 分别是对 50 条单种类航迹和 300 条混合航迹，采用不同算法相同网络结构的训练收敛图。

单种航迹下 PPO-SAG 算法最终收敛奖励值在 2 550 左右，收敛步长为 2×10^6 左右，小幅度优于 PPO 算法和 PPO-PPD 算法，且收敛更加稳定。另外 2 个适合连续任务的算法中，SAC 算法收敛效果一般，收敛奖励值在 1 200 左右。而 TD3 算法未能收敛，无法有效完成航迹跟踪控制器的训练。

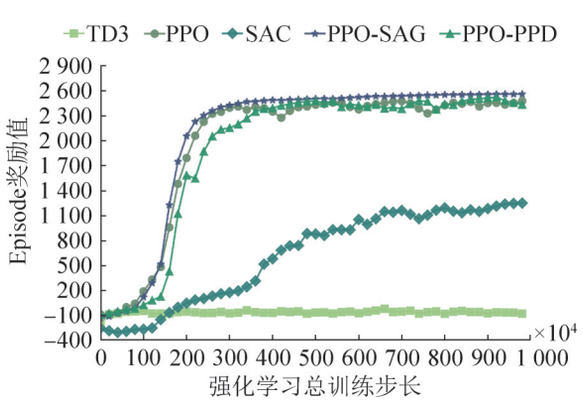


图6　单种航迹(S)收敛曲线(航迹类型 4 为例)

Fig. 6　Convergence curves in single-trajectory for algorithms

混合航迹跟踪控制训练中，PPO-SAG 在收敛奖励值上显著高于其他算法，最终奖励收敛于 2 450 左右，收敛步长在 5×10^6 左右。PPO 算法和 PPO-PPD 算法此场景下收敛不稳定，奖励呈现较

大的波动。SAC 算法与 TD3 算法均不能取得较好的收敛。

结合单种航迹与混合航迹奖励收敛情况可以看出，PPO-SAG 算法收敛奖励值和收敛稳定性均较好，具有最优的训练效果。PPO-SAG 中的自适应引导机能够提高整体的控制效果、增加稳定性，尤其在混合航迹跟踪控制任务上体现明显。受到混合航迹间差异较大的影响，PPO 算法和 PPO-PPD 算法的收敛稳定性差，奖励值难以进一步提高。

3.3 航迹控制误差对比

本小节进一步对训练好的控制器在不同航迹上进行测试，以详细比较强化学习与经典 PID 方法之间的控制性能差异。表 4 展现了多种航迹下不同控制算法产生的控制误差均值和标准差,控制误差定义为每个时刻四旋翼与期望轨迹的空间距离：

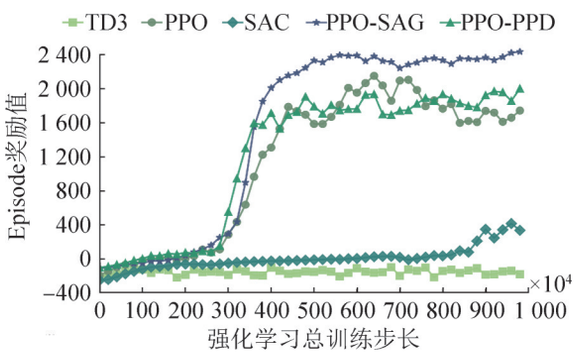


图 7　混合航迹(M)收敛曲线

Fig. 7　Convergence curves in Multi-trajectory for algorithms

表 4　训练误差内多方法航迹跟踪误差比较

Table 4　Comparison of tracking errors for multiple algorithms within training little disturbance　m

航迹	SAC(S)	PPO(S)	PPO-PPD(S)	PPO-SAG(P)	PPO-SAG(S)	PPO-SAG (FC-M)	PPO-SAG (M)	PID
1	0.196 ± 0.095	0.072 ± 0.036	0.061 ± 0.061	1.055 ± 0.430	**0.054 ± 0.037**	0.092 ± 0.064	0.087 ± 0.052	0.248 ± 0.073
2	0.473 ± 0.198	0.048 ± 0.032	0.038 ± 0.032	1.024 ± 0.459	**0.030 ± 0.021**	0.087 ± 0.074	0.075 ± 0.048	0.227 ± 0.078
3	0.404 ± 0.128	0.092 ± 0.208	0.064 ± 0.084	1.138 ± 0.369	**0.038 ± 0.079**	0.132 ± 0.106	0.107 ± 0.077	0.267 ± 0.082
4	0.344 ± 0.232	0.087 ± 0.105	0.073 ± 0.104	1.142 ± 0.420	**0.046 ± 0.026**	0.151 ± 0.142	0.110 ± 0.074	0.273 ± 0.212
5	0.979 ± 0.425	0.116 ± 0.227	0.077 ± 0.079	1.372 ± 0.471	**0.068 ± 0.053**	0.189 ± 0.371	0.152 ± 0.088	0.332 ± 0.113
6	0.451 ± 0.197	0.121 ± 0.246	0.091 ± 0.187	1.201 ± 0.436	**0.062 ± 0.093**	0.149 ± 0.189	0.147 ± 0.124	0.279 ± 0.085

注：S 代表针对单种航迹训练，M 代表采用混合航迹训练，FC 代表仅采用全连接网络，P 代表以悬停点引导控制。

$$P_{\text{error}}^{t}=\left\| p_t^{\text{true}}-p_t^{\text{des}} \right\|_2 \tag{35}$$

测试中采用与训练时相同的环境扰动范围，对每个航迹进行 5 次测试。用单种航迹训练的策略中，基于 PPO 框架的算法均能有效应对环境扰动，提高对指定类型航迹的控制精度，控制误差均小于 PID 算法。而点引导策略未利用航迹信息，在多种方案中，控制误差最大。以混合航迹训练的策略中，PPO-SAG 算法训练的控制器仍具有较好的控制性能，超过了单种航迹训练下的 SAC 算法和 PID 的航迹跟踪控制效果。任务难度加大后，其他算法在混合航迹任务下的航迹跟踪控制误差显著增大，控制性能下降，因此未在表 4 中提供具体误差数值。

3.4 算法模块有效性分析

本小节针对所提出的 PPO-SAG 算法、特征处理技术以及网络结构模块进行分析，验证所提出方法在训练中的有效性。PPO-SAG 算法利用退火机制改变训练过程，对低于均值奖励的航迹进行重采样 PID 引导，因此需对航迹采样次数进行统计。

图 8 展示了航迹类型 4 为例的训练采样和重采样分布情况，可以看出利用 PPO-SAG 算法训练后，算法针对部分航迹产生了多次拒绝，这些航迹表现为较难提高控制精度或在扰动下容易产生较大的控制误差。而对于一些训练难度较低的航迹，PPO-SAG 算法的自适应机制重采样次数

为零。

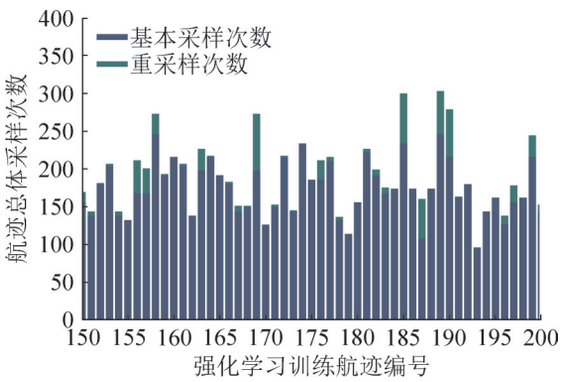


图8　单种航迹(S)采样频率

Fig. 8　Single trajectory (S) sampling frequency

以重采样较多的169号航迹为例，使用多种不同的控制算法进行控制仿真测试，如图9所示。在示例中，本文提出的PPO-SAG(M)策略始终与期望航迹保持较高的重合度，能够较好地保持对期望航迹的跟踪控制。点引导策略在所有控制曲线中距离期望位置差距最大，具有明显的曲线偏离。所有策略中，大控制误差多数体现在z轴方向上，印证了航迹设置中高度变化带来的跟踪困难。

图10进一步展示了对混合航迹训练的采样情况，从重采样的归一化占比折线可以看出，重采样偏向于大编号航迹，对应于训练集合图5中难度较高的后3种航迹。通过混合航迹采样结果同样可以推断，自适应引导机制偏好拒绝高难度航迹的训练结果，对困难航迹进行PID专家控制引导，提高经验回放池中对困难航迹控制的数据质量，从而更好地解决困难航迹的控制优化。当不采用该种自适应机制时，算法均等采样所有训练航迹，对某些航迹的进一步控制精度优化可导致控制器的过拟合，从而降低了控制器在整体混合航迹集上的控制性能。

图11展示了对PPO-SAG算法中自适应引导策略超参数$[T_0,k,L]$的灵敏度分析，$[2\,000,0.98,200]$对应宽松接受准则，$[800,0.9,50]$对应严格接受准则。从图11中可以看出，合适的自适应超参数设置(例如$[1\,000,0.95,100]$)有助于奖励的收敛和稳定。

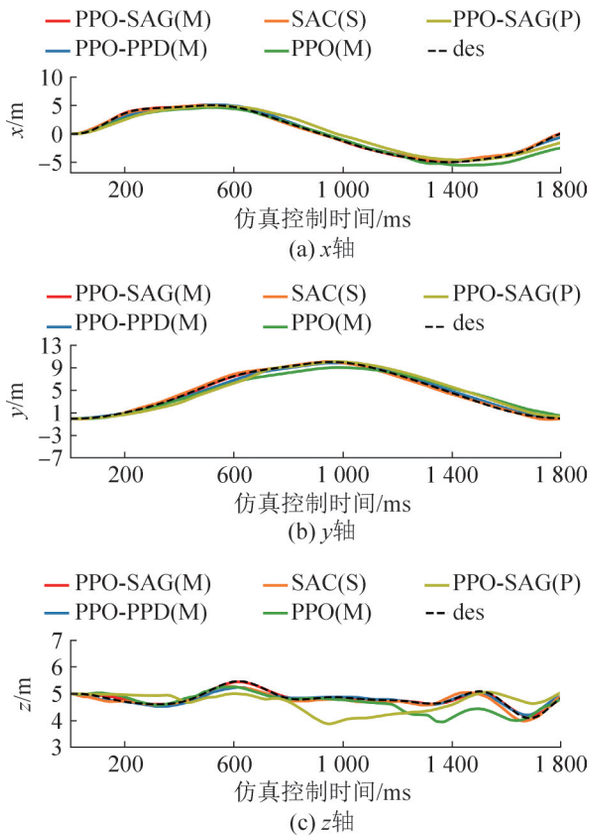


图9　四旋翼位置变化曲线(小扰动)

Fig. 9　Quadrotor position change curve(Little disturbance)

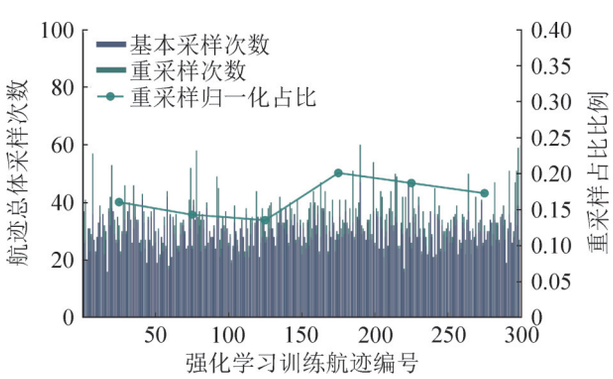


图10　混合航迹(M)采样频率

Fig. 10　Mixed trajectory (M) sampling frequency

当接受准则宽松时(可宽泛等价于不采用自适应机制)，几乎不对训练集进行重采样，此时算法收敛区域表现为因部分航迹的较大控制误差(甚至存在失控坠机)而导致震荡，整体奖励回报不稳定。当接受准则严格时，控制策略奖励回报的下

界由PID算法主导，阻碍了四旋翼在低奖励航迹下增加对控制精度的探索，导致强化学习无法利用新的探索数据对扰动下的控制进行进一步优化。

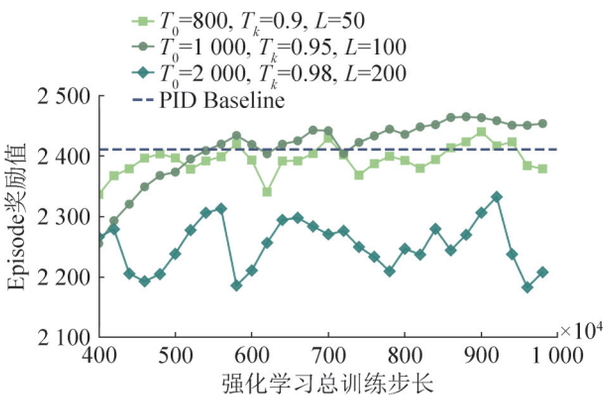


图11　自适应超参数灵敏度分析

Fig. 11　Sensitivity analysis of SA parameters

对特征处理技术、网络结构模块以及目标函数模块进行消融实验，如图12所示。特征处理技术方面，状态动态标准化和优势函数批标准化更为重要，其中优势函数批标准化大幅度提高了最终收敛奖励水平，状态动态标准化则直接影响到训练能否正常进行。除此之外，学习率衰减和奖励缩放技巧对收敛效果也有小量正向影响。

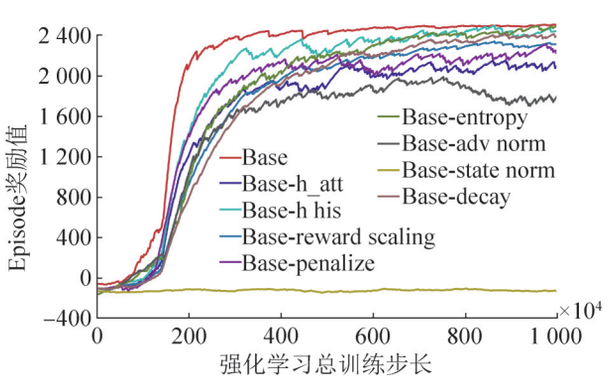


图12　消融实验收敛图

Fig. 12　Convergence curves of ablation experiment

网络结构模块方面，扰动误差信息补充结构 h_{his} 和航迹特征选择结构 h_{att} 均起到了正向作用，对奖励提升有较大帮助。其中航迹特征选择结构大幅度提高了收敛奖励，扰动适应结构提高了最终的收敛稳定性，降低了收敛时的震荡，说明在一定程度上学习到了环境未知干扰。目标函数中加入熵策略后，鼓励探索概率较低的动作，提高了训练探索效率，去除后收敛速度变得更加缓慢。平方距离惩罚增强了对策略更新的约束，对奖励的最终收敛值提升有重要影响。结合图11可知，正是PPO-SAG算法中的自适应引导机制和新目标函数提高了训练奖励收敛值，提升了航迹跟踪控制的效果。

图13以单种航迹4训练任务为例，讨论了注意力机制参数设置对训练收敛的影响。对前向点个数 $N=\{6,11\}$ 和间隔步长 $S=\{1,5,10\}$ 取不同实验组合 $E\{(n,s)|n\in N,s\in S\}$ 进行训练。实验结果可以看出，四旋翼控制输出频率高，密集时刻的航迹信息数值变化较小，连续航迹信息(即小间隔步长)的提取对收敛没有帮助。此外，利用更多航迹点位信息(即大前向点个数)并不会带来更多的收敛奖励提升。为减少参数的大小，提高网络决策速度，本文选择最为合适参数的参数设置 $E=(6,10)$。

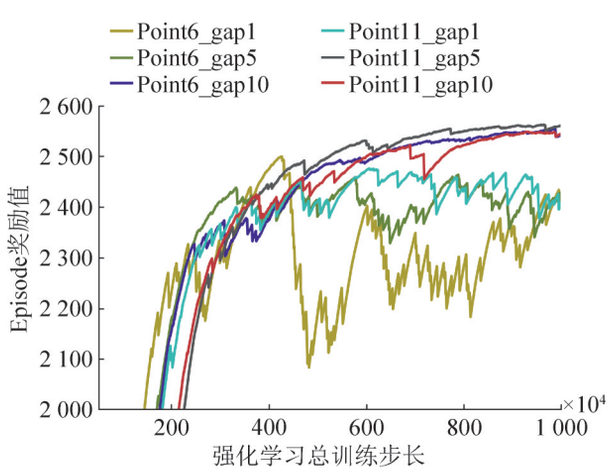
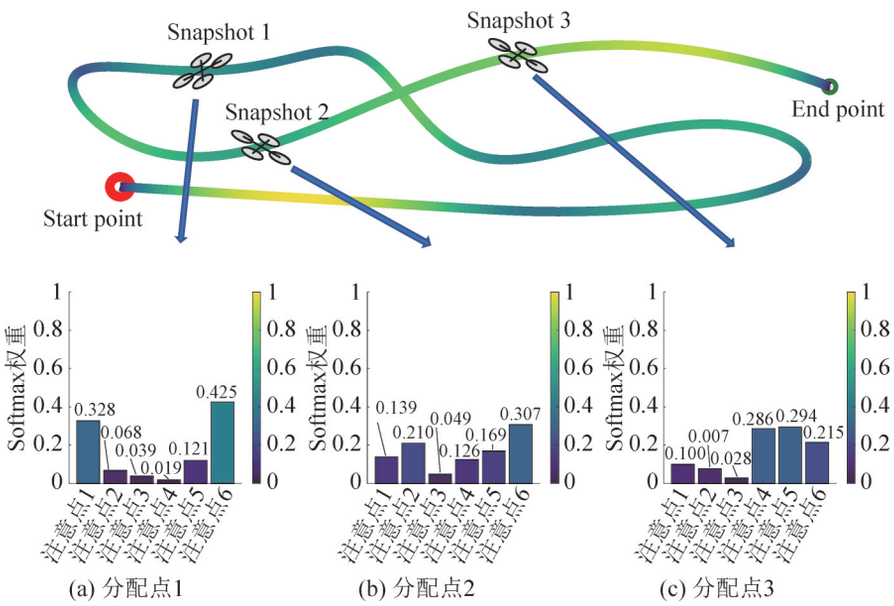


图13　不同注意力机制参数收敛曲线图

Fig. 13　Convergence curves of different attention parameters

图14展示了一个训练好的控制器在航迹4飞行中注意力权重的变化。在点位1，当无人机即将进行较大角度的转向，注意力权重主要分布在近距离点位和将要到来的转向点位上。在点位2，四旋翼正进行直线段飞行，此时的注意力权重分布

较为平均，不具有特别的倾向性。在点位3，四旋翼即将通过高速弧形区域，大权重更加集中在该弧形区域的高速度部分。注意力权重根据航迹特点的不断变化，将主要的注意力集中于将来时间段航迹中较为重要的位置，进一步说明该机制有效提取了未来航迹的特征，进而提高了训练的收敛效果。



(a) 分配点1　(b) 分配点2　(c) 分配点3

图14　注意力权重变化示意图(航迹4为例)

Fig. 14　Illustration of the attention value changing in flying

3.5 泛化性分析

本小节针对深度神经网络控制策略的泛化性进行探讨，包控制器在训练扰动设置范围之外的控制性能以及控制器应对非学习航迹的控制效果和对新航迹的迁移学习能力和收敛效果。

为验证深度强化学习控制方法的泛化性，进一步扩大环境参数和机身参数的扰动范围如表5所示。参数扰动范围的增大，扩大了状态转移空间P的范围，为控制器的控制精度带来了更大的挑战。

从表6的实验结果可以看出，尽管参数扰动误差大于训练时的设置，基于PPO-SAG算法的2种控制策略在控制误差上对比PID算法仍然具有优势，证明基于深度神经网络的控制器对未知的参数扰动具备较好的泛化性。此外，当扰动增加时，PPO-SAG(M)策略在多个航迹上的控制误差增量更小，说明混合航迹的训练带来了更加多样的航迹控制数据，有利于提高控制器的泛化性能。

表5　大扰动范围设置

Table 5　Large disturbance range setting

参数名称	新扰动范围	参数名称	新扰动范围
四旋翼质量	±20%	x轴空气阻力	±0.08
转动惯量	±20%	y轴空气阻力	±0.08
重力加速度	±0.12	z轴空气阻力	±0.05

表6　大扰动航迹控制误差对比

Table 6　Track errors comparison in large disturbance

航迹	PPO-SAG (S)	PPO-SAG (M)	PID
1	**0.084 ± 0.174**	0.120 ± 0.070	0.254 ± 0.096
2	**0.054 ± 0.218**	0.104 ± 0.116	0.231 ± 0.100
3	**0.086 ± 0.252**	0.159 ± 0.140	0.273 ± 0.103
4	**0.105 ± 0.276**	0.162 ± 0.181	0.293 ± 0.185
5	**0.125 ± 0.289**	0.238 ± 0.285	0.371 ± 0.472
6	**0.131 ± 0.335**	0.205 ± 0.245	0.289 ± 0.137

图15是对图10同航迹，固定大扰动后的不同算法控制效果。扰动增大后，所有算法的控制误差均有提升，其中PPO(M)策略和PPO-PPD(M)策略在扰动增大后控制误差提升显著，期望航迹变化

较大时控制误差明显。点引导控制策略进一步发散，在z轴方向上难以正确对航迹进行跟踪。尽管SAC(S)策略对该种类航迹进行了针对性训练，但由于算法性能的限制，控制精度不及PPO-SAG(M)策略。所提出算法的PPO-SAG(M)策略在混合航迹有最好的控制性能，与期望航迹的重合度最高。

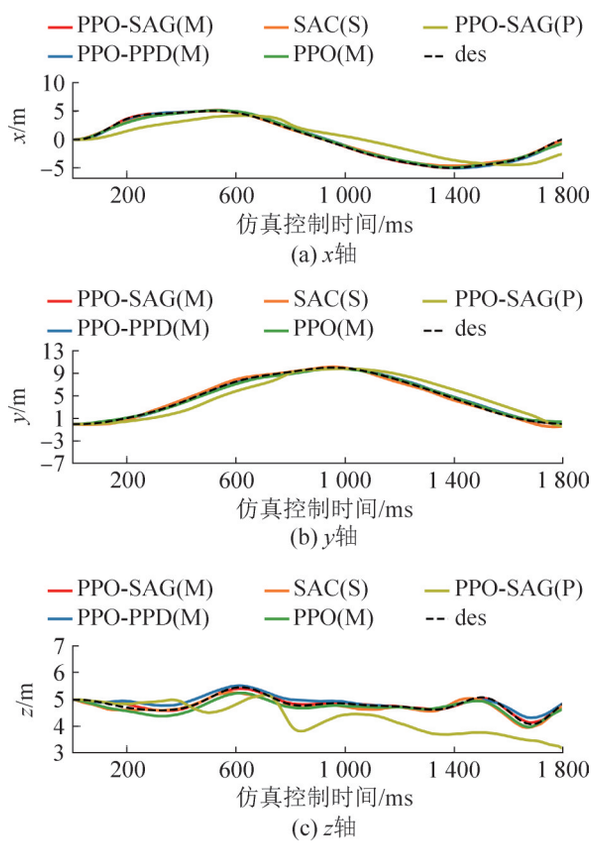


图15　四旋翼位置变化曲线(大扰动)

Fig. 15　Quadrotor position change curve(large disturbance)

最后，为讨论深度神经网络控制器面向多样化航迹的实用性，将训练好的混合航迹跟踪策略迁移到更为简单的避障导航航迹跟踪控制任务。图16展示了利用V-rep仿真软件搭建的四旋翼侦察任务障碍物环境，与前文预规划航迹应用场景相对应。

采用A*算法求解最短路径获得航迹点后，利用Minimum-snap航迹平滑方法得到四旋翼预规划的侦察航迹，该航迹未出现于强化学习的训练集，如图17所示。PPO-SAG(M)策略下训练的控制器可以成功完成航迹跟踪控制，在未知扰动障碍环境中，以小控制误差跟踪预规划航迹飞行，安全抵达目标终点。在训练扰动的范围内测试50次控制效果，深度网络控制器的统计控制误差为0.065±0.045，显著低于采用PID算法时的控制误差0.168±0.117。仿真实验表明，通过对混合航迹数据的训练学习，神经网络控制器能够在样本中有效学习到对航迹曲线变化的控制规律，可较好地直接应用在训练航迹数据集之外的航迹控制中，具备直接可迁移性。

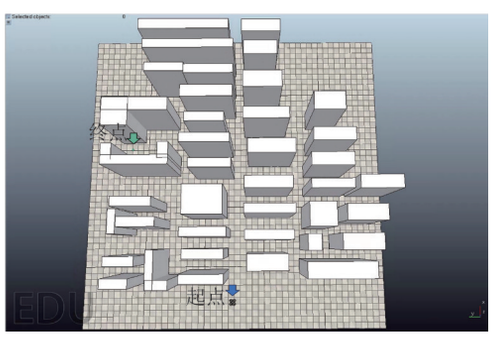


图16　仿真障碍环境下导航示意图

Fig. 16　Illustration of navigation in V-rep simulator

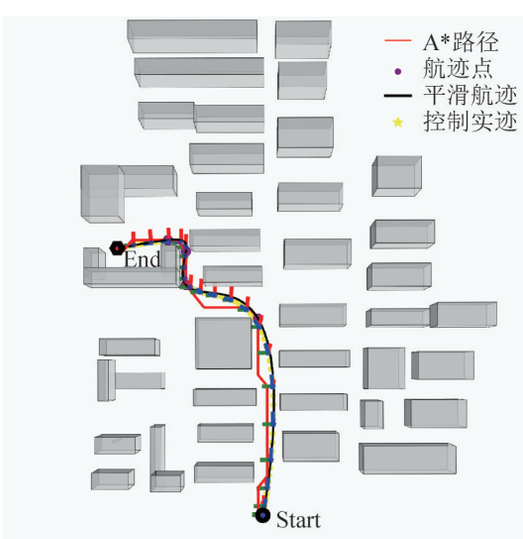


图17　航迹规划与控制飞行结果示意图

Fig. 17　Illustration of planned trajectory and control result

如图18展示了利用提出的PPO-SAG算法和改进网络结构与否，在迁移学习能力上的表现。左侧分别是PPO-SAG(S)、PPO-SAG(M)和PPO(M)

策略的奖励收敛曲线，右侧是针对新航迹进行迁移学习的奖励曲线。采用本文提出的PPO-SAG算法和网络改进结构能够更加稳定有效地对新航迹进行迁移学习，并且在短暂的训练步长后，更快地收敛。其中，PPO-SAG(S)策略针对单航迹训练，对新航迹的初始迁移奖励较PPO-SAG(M)更低，但最终的迁移学习奖励收敛值几乎无差异。PPO(FC-M)策略作为最原始无改进的基础算法策略在初始训练和迁移任务上都不具备较好的奖励收敛表现。

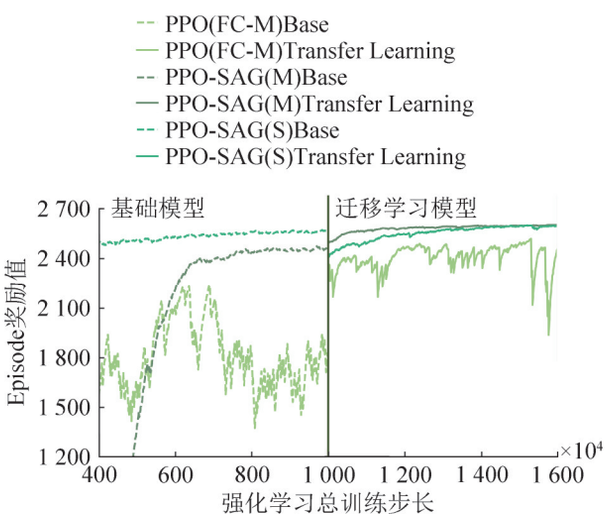


图18　迁移强化学习训练结果

Fig. 18　Transfer reinforcement learning training results

4　结论

本文研究了四旋翼航迹跟踪控制的深度强化学习方法。针对问题特点，提出了PPO-SAG算法，设计了策略网络结构，采用了有效的训练处理技术。提供了多种算法的仿真对比实验和消融实验结果，通过对比分析，所提出的算法能够有效提升航迹跟踪控制的效果。深度神经网络控制器可以通过预训练模型，较好地直接利用或迁移学习到新的航迹上，快速获得扰动情况下控制误差小的四旋翼控制器，实现对预规划航迹的跟踪控制。根据实验结论，该方法可应用于2种场景：①采用单种类航迹训练方法，以进行点到点四旋翼侦察或竞速等任务的控制；②采用混合航迹训练方法，获得直接利用到新规划航迹的或针对指定航迹快速迁移学习的基础控制策略。所提出的方法创新性地将强化学习微调与自适应策略相结合，通过自适应引导机制，实现了对策略性能的更有效优化。

参考文献：

[1] 伍国华, 毛妮, 徐彬杰, 等. 基于自适应大规模邻域搜索算法的多车辆与多无人机协同配送方法[J]. 控制与决策, 2023, 38(1): 201-210.
Wu Guohua, Mao Ni, Xu Binjie, et al. The Cooperative Delivery of Multiple Vehicles and Multiple Drones Based on Adaptive Large Neighborhood Search[J]. Control and Decision, 2023, 38(1): 201-210.

[2] AlMahamid F, Grolinger K. Autonomous Unmanned Aerial Vehicle Navigation Using Reinforcement Learning: A Systematic Review[J]. Engineering Applications of Artificial Intelligence, 2022, 115: 105321.

[3] Xue Wentao, Wu Hangxing, Ye Hui, et al. An Improved Proximal Policy Optimization Method for Low-level Control of a Quadrotor[J]. Actuators, 2022, 11(4): 105.

[4] Lee T, Leok M, McClamroch N H. Geometric Tracking Control of a Quadrotor UAV on SE(3) [C]//49th IEEE conference on decision and control (CDC). Piscataway: IEEE, 2010: 5420-5425.

[5] Mina Kamel, Michael Burri, Roland Siegwart. Linear vs Nonlinear MPC for Trajectory Tracking Applied to Rotary Wing Micro Aerial Vehicles[J]. IFAC-PapersOnLine, 2017, 50(1): 3463-3469.

[6] Pi Chenhuan, Ye Weiyuan, Cheng S. Robust Quadrotor Control Through Reinforcement Learning with Disturbance Compensation[J]. Applied Sciences, 2021, 11(7): 3257.

[7] Lambert N O, Drew D S, Yaconelli J, et al. Low-level Control of a Quadrotor with Deep Model-based Reinforcement Learning[J]. IEEE Robotics and Automation Letters, 2019, 4(4): 4224-4230.

[8] 董豪, 杨静, 李少波, 等. 基于深度强化学习的机器人运动控制研究进展[J]. 控制与决策, 2022, 37(2): 278-292.
Dong Hao, Yang Jing, Li Shaobo, et al. Research Progress of Robot Motion Control Based on Deep Reinforcement Learning[J]. Control and Decision, 2022, 37(2): 278-292.

[9] Jemin Hwangbo, Inkyu Sa, Roland Siegwart, et al. Control of a Quadrotor with Reinforcement Learning[J]. IEEE Robotics and Automation Letters, 2017, 2(4): 2096-2103.

[10] Koch W, Mancuso R, West R, et al. Reinforcement Learning for UAV Attitude Control[J]. ACM Transactions on Cyber-Physical Systems, 2019, 3(2): 22.

[11] Koch W, Mancuso R, Bestavros A. Neuroflight: Next Generation Flight Control Firmware[EB/OL]. (2019-09-16) [2022-10-06]. https://arxiv.org/abs/1901.06553.

[12] Guilherme Cano Lopes, Murillo Ferreira, Alexandre da Silva Simões, et al. Intelligent Control of a Quadrotor with Proximal Policy Optimization Reinforcement Learning[C]//2018 Latin American Robotic Symposium, 2018 Brazilian Symposium on Robotics (SBR) and 2018 Workshop on Robotics in Education (WRE). Piscataway: IEEE, 2018: 503-508.

[13] Mazen Shehab, Ahmed Zaghloul, Ayman El-Badawy. Low-level Control of a Quadrotor Using Twin Delayed Deep Deterministic Policy Gradient (TD3)[C]//2021 18th International Conference on Electrical Engineering, Computing Science and Automatic Control (CCE). Piscataway: IEEE, 2021: 1-6.

[14] Gabriel Moraes Barros, Esther Luna Colombini. Using Soft Actor-critic for Low-level UAV Control[EB/OL]. (2020-10-05) [2023-10-06]. https://arxiv. org/abs/2010.02293.

[15] Wang Yuanda, Sun Jia, He Haibo, et al. Deterministic Policy Gradient with Integral Compensator for Robust Quadrotor Control[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2020, 50(10): 3713-3725.

[16] Ali Barzegar, Deok Jin Lee. Deep Reinforcement Learning-based Adaptive Controller for Trajectory Tracking and Altitude Control of an Aerial Robot[J]. Applied Sciences, 2022, 12(9): 4764.

[17] 梁吉, 王立松, 黄昱洲, 等. 基于深度强化学习的四旋翼无人机自主控制方法[J]. 计算机科学, 2023, 50(增2): 1-7.
Liang Ji, Wang Lisong, Huang Yuzhou, et al. Autonomous Control Algorithm for Quadrotor Based on Deep Reinforcement Learning[J]. Computer Science, 2023, 50(S2): 1-7.

[18] 王伟, 吴昊, 刘鸿勋, 等. 基于深度强化学习的无人机姿态控制器设计[J]. 科学技术与工程, 2023, 23(34): 14888-14895.
Wang Wei, Wu Hao, Liu Hongxun, et al. An Attitude Controller for Quadrotor Drone Using RM-DDPG[J]. Science Technology and Engineering, 2023, 23(34): 14888-14895.

[19] 孙丹, 高东, 郑建华, 等. 引入积分补偿的四旋翼确定性策略梯度控制器[J]. 计算机工程与设计, 2023, 44(1): 255-261.
Sun Dan, Gao Dong, Zheng Jianhua, et al. Deterministic Policy Gradient Controller with integral compensator for quadrotor[J]. Computer Engineering and Design, 2023, 44(1): 255-261.

[20] 杨志鹏, 李波, 甘志刚, 等. 基于深度强化学习的四旋翼无人机航线跟随[J]. 指挥与控制学报, 2022, 8(4): 477-482.
Yang Zhipeng, Li Bo, Gan Zhigang, et al. Route Following of Quadrotor UAV Based on Deep Reinforcement Learning[J]. Journal of Command and Control, 2022, 8(4): 477-482.

[21] 孙丹, 高东, 郑建华, 等. 示教知识辅助的无人机强化学习控制算法[J]. 北京航空航天大学学报, 2023, 49(6): 1424-1433.
Sun Dan, Gao Dong, Zheng Jianhua, et al. UAV Reinforcement Learning Control Algorithm with Demonstrations[J]. Journal of Beijing University of Aeronautics and Astronautics, 2023, 49(6): 1424-1433.

[22] 刘安林, 时正华. 基于DDPG策略的四旋翼飞行器目标高度控制[J]. 陕西科技大学学报, 2021, 39(6): 141-147.
Liu Anlin, Shi Zhenghua. Desired Height Control of Quadrotor Vehicle Based on DDPG Strategy[J]. Journal of Shaanxi University of Science & Technology, 2021, 39 (6): 141-147.

[23] Molchanov A, Chen Tao, Wolfgang Hönig, et al. Sim-to-(multi) -real: Transfer of Low-level Robust Control Policies to Multiple Quadrotors[C]//2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Piscataway: IEEE, 2019: 59-66.

[24] Elia Kaufmann, Leonard Bauersfeld, Davide Scaramuzza. A Benchmark Comparison of Learned Control Policies for Agile Quadrotor Flight[C]//2022 International Conference on Robotics and Automation (ICRA). Piscataway: IEEE, 2022: 10504-10510.

[25] Song Yunlong, Mats Steinweg, Elia Kaufmann, et al. Autonomous Drone Racing with Deep Reinforcement Learning[C]//2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Piscataway: IEEE, 2021: 1205-1212.

[26] Robert Penicka, Song Yunlong, Elia Kaufmann, et al. Learning Minimum-time Flight in Cluttered Environments[J]. IEEE Robotics and Automation Letters, 2022, 7(3): 7209-7216.

[27] Wu Guohua, Mao Ni, Luo Qizhang, et al. Collaborative Truck-drone Routing for Contactless Parcel Delivery During the Epidemic[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(12): 25077-25091.

[28] Xu Binjie, Zhao Kexin, Luo Qizhang, et al. A GV-drone Arc Routing Approach for Urban Traffic Patrol by

Coordinating a Ground Vehicle and Multiple Drones[J]. Swarm and Evolutionary Computation, 2023, 77: 101246.

[29] Matthias Faessler, Antonio Franchi, Davide Scaramuzza. Differential Flatness of Quadrotor Dynamics Subject to Rotor Drag for Accurate Tracking of High-speed Trajectories[J]. IEEE Robotics and Automation Letters, 2018, 3(2): 620-626.

[30] Hart P E, Nilsson N J, Raphael B. A Formal Basis for the Heuristic Determination of Minimum Cost Paths[J]. IEEE Transactions on Systems Science and Cybernetics, 1968, 4(2): 100-107.

[31] Mellinger D, Kumar V. Minimum Snap Trajectory Generation and Control for Quadrotors[C]//2011 IEEE international conference on robotics and automation. Piscataway: IEEE, 2011: 2520-2525.

[32] Kirkpatrick S, Gelatt C D Jr, Vecchi M P. Optimization by Simulated Annealing[J]. Science, 1983, 220(4598): 671-680.

[33] Schulman J, Levine S, Moritz P, et al. Trust Region Policy Optimization[C]//Proceedings of the 32nd International Conference on International Conference on Machine Learning. Chia Laguna Resort: PMLR, 2015: 1889-1897.

[34] Williams R J. Simple Statistical Gradient-following Algorithms for Connectionist Reinforcement Learning [J]. Machine Learning, 1992, 8(3): 229-256.

[35] Schulman J, Moritz P, Levine S, et al. High-dimensional Continuous Control Using Generalized Advantage Estimation[EB/OL]. (2018-10-20) [2023-10-06]. https://arxiv.org/abs/1506.02438.

[36] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms[EB/OL]. (2017-08-28) [2023-10-06]. https://arxiv.org/abs/1707.06347.

[37] Ilyas A, Engstrom L, Santurkar S, et al. Are Deep Policy Gradient Algorithms Truly Policy Gradient Algorithms? [EB/OL]. (2020-05-25) [2023-10-06]. https://arxiv. org/abs/1811.02553v2.

[38] Chu Xiangxiang. Policy Optimization with Penalized Point Probability Distance: An Alternative to Proximal Policy Optimization[EB/OL]. (2019-02-14) [2023-10-06]. https://arxiv.org/abs/1807.00442.

[39] Haarnoja T, Tang Haoran, Abbeel P, et al. Reinforcement Learning with Deep Energy-based Policies[C]// Proceedings of the 34th International Conference on Machine Learning. Chia Laguna Resort: PMLR, 2017: 1352-1361.

[40] Tucker G, Bhupatiraju S, Gu Shixiang, et al. The Mirage of Action-dependent Baselines in Reinforcement Learning[C]//Proceedings of the 35th International Conference on Machine Learning. Chia Laguna Resort: PMLR, 2018: 5015-5024.

[41] Engstrom L, Ilyas A, Santurkar S, et al. Implementation Matters in Deep Policy Gradients: A Case Study on PPO and TRPO[EB/OL]. (2020-05-25) [2023-10-06]. https://arxiv.org/abs/2005.12729.

[42] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 6000-6010.

[43] Kingma D P, Ba J. Adam: A Method for Stochastic Optimization[EB/OL]. (2017-01-30) [2023-10-06]. https://arxiv.org/abs/1412.6980.

[44] Eric Rohmer, Singh S P N, Marc Freese. V-REP: A Versatile and Scalable Robot Simulation Framework[C]// 2013 IEEE/RSJ international conference on intelligent robots and systems. Piscataway: IEEE, 2013: 1321-1326.

[45] James S, Freese M, Davison A J. PyRep: Bringing V-REP to Deep Robot Learning[EB/OL]. (2019-06-26) [2023-10-06]. https://arxiv.org/abs/1906.11176.

[46] Julian Förster. System Identification of the Crazyflie 2.0 Nano Quadrocopter[D]. Zurich: ETH Zurich, 2015.