基于联合DQN的定向能系统火力智能决策建模仿真方法

屈长虹，王俊杰*，王坤，崔清勇，陈蒋洋，王鑫鹏
(中国久远高新技术装备有限公司，北京 100094)

摘要：针对利用定向能系统反无人机集群作战中如何兼容多种部署方案动态解决火力智能决策的问题，建立了一个深度强化学习模型，并针对该模型多智能体状态和动作空间维度高的特点，提出了一种基于联合深度Q网络(DQN)的定向能系统火力智能决策建模仿真方法。以定向能系统的状态、无人机集群的状态和定向能系统部署区域的状态构造状态空间，*利用联合机制共享各个装备的状态信息以及同类型装备的网络参数，设计威胁评估机制提高泛化性，并建立动作屏蔽机制屏蔽无效动作*，有效解决了多智能体因状态和动作维度灾难引起的训练发散、收敛缓慢等问题，提高基于联合DQN网络学习效率和泛化性。根据仿真实验结果，该方法优于传统基于规则的方法，验证了该方法的可行性与实用性，为兼容多种部署方案的定向能系统反无人机集群火力智能决策提供一个新思路。

关键词：定向能系统；反无人机集群；深度Q网络；联合机制；威胁评估机制；动作屏蔽机制
中图分类号：TP391.9 文献标志码：A 文章编号：1004-731X(2025)05-1256-10
DOI: 10.16182/j.issn1004731x.joss.24-0079
引用格式: 屈长虹, 王俊杰, 王坤, 等. 基于联合DQN的定向能系统火力智能决策建模仿真方法[J]. 系统仿真学报, 2025, 37(5): 1256-1265.
Reference format: Qu Changhong, Wang Junjie, Wang Kun, et al. A Modeling and Simulation Method for Firepower Intelligent Decision-making of Directed Energy System Based on Joint DQN[J]. Journal of System Simulation, 2025, 37 (5): 1256-1265.

A Modeling and Simulation Method for Firepower Intelligent Decision-making of Directed Energy System Based on Joint DQN

Qu Changhong, *Wang Junjie**, *Wang Kun*, *Cui Qingyong*, *Chen Jiangyang*, *Wang Xinpeng*
(China Jiuyuan Hi-tech Equipment Corporation Limited, Beijing 100094, China)

Abstract: In order to solve the problem of dynamically addressing firepower intelligent decision-making in anti-UAV cluster combat using a directed energy system, a deep reinforcement learning model is established. Based on the high multi-agent state and action space dimensions of this model, a modeling and simulation method of firepower intelligent decision-making of directed energy system based on joint deep Q network (DQN) is proposed. The state space is constructed from the state of directed energy system, UAV cluster and the directed energy system deployment area. *The joint mechanism is used to share the state information of each equipment and the network parameters of the same type of equipment. The threat assessment mechanism is designed to improve generalization, and the action shielding mechanism is established to shield invalid actions*. The problems of divergence and slow convergence of multi-agent training, caused by state and action dimension disasters, are effectively solved, and the learning efficiency and generalization of Joint DQN network are improved. According to the simulation

收稿日期：2024-01-19 修回日期：2024-04-23
第一作者：屈长虹(1979-)，男，副研究员，硕士，研究方向为高新技术装备论证与效能评估。
通信作者：王俊杰(1996-)，男，工程师，硕士，研究方向为深度学习、强化学习。

results, this method is superior to the traditional rule-based method, which verifies the feasibility and practicability of this method, and provides a new idea for intelligent decision-making of anti-UAV cluster firepower of directed energy system compatible with various deployment schemes.

Keywords: directed energy system; anti-UAV cluster; deep Q network(DQN); joint mechanism; threat assessment mechanism; action shielding mechanism

0 引言

随着科学和技术的快速发展，无人机得到广泛应用，特别是在军事领域，无人机集群[1]作战和反无人机[2]集群作战已经成为了非常重要的形式[3]。在反无人机集群作战中，目前普遍采用传统防空导弹装备系统进行防御，但在对抗小型、廉价的无人机集群上性价比不高。以强激光、高功率微波等为代表的定向能装备因其独有的特点和能力脱颖而出，非常适合用于反无人机集群。由于无人机集群智能化程度的提升，其对反无人机集群作战的威胁和挑战程度也急剧提升，如何对快速来袭的无人机集群合理分配火力，给出最优的火力智能决策方案，是现代反无人机集群作战的一个重要课题。目前装备火力分配的研究，主要分为数学求解、优化搜索和智能算法三类方法。数学求解的方法是利用数学的形式解决火力分配问题，文献[4]利用防空导弹和高炮武器系统的特点，建立了炮弹混编防空兵群的火力分配数学模型，并利用遗传算法进行求解。但是该类方法需要严格的数学逻辑，模型构建复杂，仅对简单的场景适用，难以满足三维空间下的火力分配问题。优化搜索的方法通常是利用优化算法[5]进行火力分配，包括粒子群算法[6-7]、遗传算法[8-9]等，文献[10]将防御装备和无人机集群的博弈过程量化表示，提出了一种基于嵌套粒子群算法的反无人机集群防空系统。但是该类方法存在粒度难以把握、算法搜索效率低、实时决策性低以及泛化能力差等问题。智能算法是以神经网络技术为主，采用强化学习[11]或深度强化学习[12-14]进行装备的火力分配，但是目前该方法仅适用一些简单的装备火力分配场景，且难以移植到复杂的场景，泛化迁移能力较差。

综上所述不同方法的缺点，本文提出了一种基于联合DQN的定向能系统火力智能决策建模仿真方法。该方法可以降低部署场景的复杂度，兼容多种部署装备以及多种场景，解决了传统强化学习的强依赖性，同时提出的5种机制有效提高了深度强化学习算法在此问题下的收敛速度、稳定性和泛化迁移性，为火力分配决策问题提供一个全新的思路。

1 问题建模

1.1 定向能系统模型

由于传统常规防空装备难以满足拦截大批量无人机集群的作战需求，具有速度快、能量强等特点的定向能装备成为反无人机集群的利器。其中以强激光、高功率微波为代表的定向能装备[15-16]非常适合防御低空、超低空无人机集群。为了有效对抗无人机集群，基于定向能装备的特点构建了一个定向能系统防御模型，该模型以雷达为探测手段，以激光和微波装备为硬杀伤手段，搭配软杀伤电子干扰装备构成。本文在防御区域内拟防护的要地区域周围布置定向能系统防御无人机集群，如图1所示，在实际应用中可根据具体情况搭配定向能系统的装备数量、位置等。

1.2 复杂决策系统模型

在反无人机集群作战中，如何对定向能系统的装备火力进行智能决策是有效抵抗无人机集群的关键，本文对此建立了一个复杂决策系统模型，如图2所示。整个系统模型以环境数据为驱动，中心控制台控制整个系统，通过通信协议获取其仿真环境中的数据，即态势信息数据，并对其进

行解析与归一化处理，得到态势信息数据中有价值的状态信息数据；然后对状态信息数据进行融合后输入到火力智能决策模块输出火力分配结果；最后将输出数据通过通信协议传给中心控制平台执行结果。

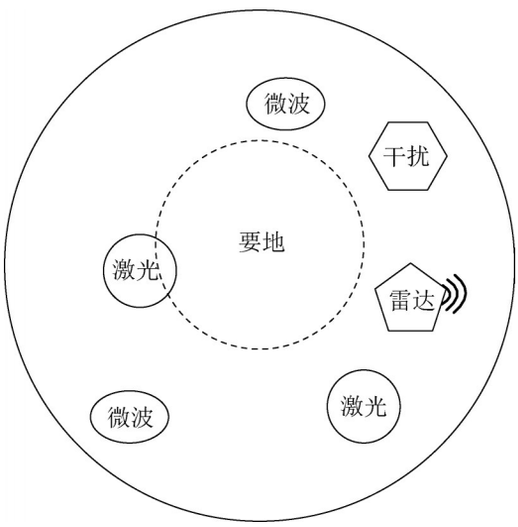


图1　定向能系统防御模型示意图
Fig. 1　Schematic diagram of directed energy system defense model

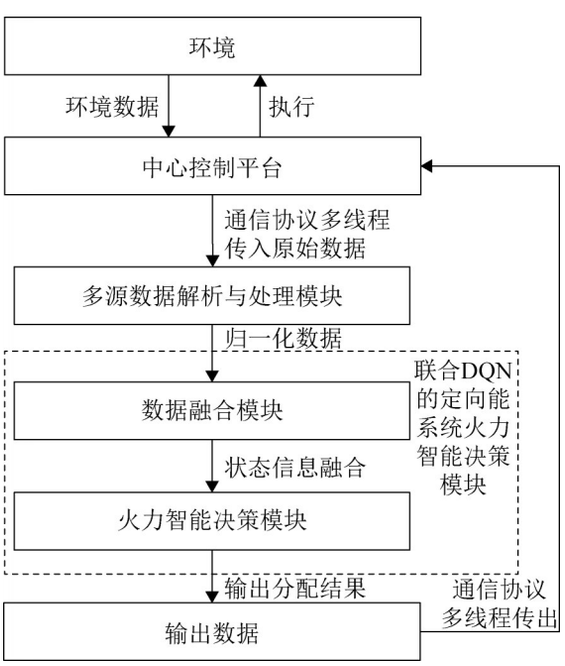


图2　复杂决策系统模型图
Fig. 2　Complex decision system model diagram

2　联合DQN的定向能系统智能决策设计

本文将定向能装备、部署环境和无人机集群作为交互环境，由于装备数量和类型众多，而DQN通常用作单智能体的建模，因此为了克服DQN在多智能体场景下难以建模的问题，本文基于集中式训练–执行架构提出了多智能体DQN联合策略，设计了全方位联合机制和动作屏蔽机制，实现多智能体间相同类型装备模型参数共享和各个装备之间的状态信息共享的目的。当智能体拥有其队友相关状态信息时，数据需求更少，联合动作空间更小，有利于提高多智能体合作性和联合效应，弥补单智能体DQN难以适用于多智能体环境，同时提高传统多智能体算法的收敛性。图3所示为联合DQN智能决策方法。多智能体从环境中获取定向能装备、无人机集群和装备部署区域的状态信息，利用联合机制共享各个装备的状态信息，获得联合状态信息，同时对无人机集群进行威胁评估，将整个态势信息输入DQN模块，利用动作屏蔽机制屏蔽无效动作，输出有效动作，对相应的智能体进行控制。运行一步后，环境转移为新的状态，更新态势信息和奖励值，开始下一步的决策。通过执行新动作获得新的态势信息、奖励值和决策的环境态势信息、动作组成四元组存储进经验回放池。

2.1　集中式训练–执行架构设计

在强化学习中，单智能体环境的状态转移只与其动作有关，而多智能体环境的状态转移则与所有智能体相关，同时每个智能体获得的奖励不仅仅与其自身的动作有关，还与其他智能体相关，导致通过训练学习改变其中一个智能体的策略会影响整个多智能体策略的选择，同时难以估计Q函数，保证算法的收敛性。为了解决这一问题，本文设计了一种集中式训练–执行的架构，如图4所示。

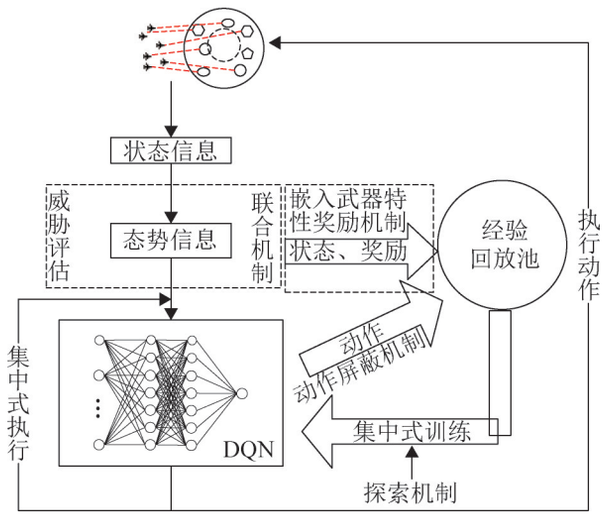


图3　联合DQN的定向能系统火力智能决策框架

Fig. 3　Intelligent Decision Framework for Directed Energy Systems Based on Joint DQN

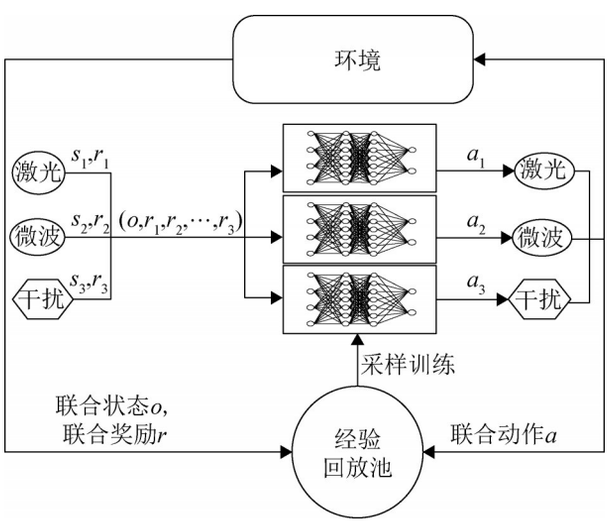


图4　集中式训练—执行架构

Fig. 4　Centralized Training-Execution Architecture

图4中，集中式训练是指在训练过程中输入全局的态势信息o和所有的动作信息$a_1,a_2,\cdots,a_n$，与单智能体训练过程中输入的局部态势信息s_1和动作a_1相比，所有装备共享状态信息，同类型装备之间共享网络参数，在决策动作时考虑智能体之间的耦合关系，实现联合状态—策略的评估，有效防止一个智能体的策略影响其他智能体的策略，算法难以收敛。集中式执行是指在真正执行的时候，输入决策网络的仍然是所有智能体态势信息，输出的是单智能体的决策动作，该决策方式可以弥补不同智能体间动作区分不大的缺点，提高智能体之间的协作能力。

2.2　联合机制设计

由于场景中包含多个装备以及多个无人机，且场景中态势信息众多，导致算法输入的状态空间较大，同时装备的实际动作复杂，导致动作空间较大。而单智能体的搜索空间有限，因此本文设计了联合机制，该机制包括共享状态信息和网络参数。共享状态信息是指将全部态势信息s_t、智能体动作a_t、智能体执行新动作后的新态势信息s_{t+1}和奖励值r_{t+1}按照四元组的形式存放进经验回放池。共享网络参数是指同一类型的装备使用同一个网络参数，由于存在不同的装备类型，故在定义总的状态空间时，需要保留不同装备类型的所有状态，每类装备只需要在其包含的状态维度上填充数据，其余状态补0，从而统一网络的输入维度。达到多智能体间相同类型装备模型参数共享，各个装备之间的状态信息共享，减少数据需求，提高多智能体合作性和联合效应，使DQN可适用于多智能体场景，提高DQN算法的收敛性。

在实验仿真时，可获得的战场态势信息众多，包含各个装备的信息、无人机集群的信息以及装备部署区域的信息，状态信息表示如下：

$$s_{\mathrm{e}}=(h_{\mathrm{e}},\gamma_{\mathrm{e}},\varphi_{\mathrm{e}},p_{\mathrm{e}},a_{\mathrm{e}},d_{\mathrm{e}}^{\max},d_{\mathrm{e}}^{\min}) \tag{1}$$

$$s_{\mathrm{u}}=(h_{\mathrm{u}},r_{\mathrm{u}},\gamma_{\mathrm{u}},m_{\mathrm{u}},v_{\mathrm{u}},p_{\mathrm{u}}) \tag{2}$$

$$s_{\mathrm{a}}=(\tau_{\mathrm{a}},w_{\mathrm{a}},l_{\mathrm{a}},c_{\mathrm{a}},\theta_{\mathrm{a}}) \tag{3}$$

式中：s_{e}为装备的状态信息；h_{e}为装备的健康值；γ_{e}为装备的经度；φ_{e}为装备的纬度；p_{e}为装备的姿态；a_{e}为装备的可用的状态；$d_{\mathrm{e}}^{\max}$为装备的最大攻击距离；$d_{\mathrm{e}}^{\min}$为装备的最小攻击距离；s_{u}为无人机的状态信息；h_{u}为无人机的生命值；r_{u}为无人机的路线；γ_{u}为无人机的经纬度；m_{u}为无人机的材质；v_{u}为无人机的速度；p_{u}为无人机的姿态；s_{a}为装备部署区域的信息；τ_{a}为部署区域的类型；w_{a}为部署区域的宽度；l_{a}为部署区域的长度；c_{a}为部署区域的中心点；θ_{a}为部署区域的旋转角。

由于状态信息众多且复杂，因此在设定状态空间前需要对各种状态信息进行归一化以及状态信息的融合。本文采用L2范式归一化，将所有数据进行压缩，目的是减少奇异状态数据的干扰、提高网络的泛化能力以及方便后续状态信息的融合，公式如下：

$$o_i = \frac{s_i}{\sqrt{\sum_{i=1}^{k} s_i^2}} \tag{4}$$

为了便于网络的输入，将所有归一化后的状态信息进行组合，融合成长度为m的状态空间向量，状态空间向量表示如下：

$$\boldsymbol{o} = \left[o_1, o_2, \cdots, o_m\right] \tag{5}$$

2.3 威胁评估和动作屏蔽机制设计

由于实际场景复杂，装备和无人机数量不定，在对战过程中的策略和战术便极为丰富，而DQN的学习搜索能力有限，这就导致算法学习策略的过程中无法学习到最好的策略，会在次优策略中来回跳转，模型震荡，无法收敛，故引入威胁评估机制。

威胁评估算法思想是对于目前可探测到的无人机，根据无人机所处的位置和速度，评估每一个无人机对装备防御区域的威胁程度。由于获得的是坐标是经纬度，因此计算最短距离的步骤如下。假设坐标的经纬度分别为(x_1, y_1)和(x_2, y_2)，转换为弧度值的公式如下：

$$\theta = (x \cdot \pi)/180 \tag{6}$$

两坐标的距离d_1的计算公式为

$$d_1 = r \cdot 2\arcsin\left(\sin\left(\frac{\alpha}{2}\right)^2 + \cos(\theta_1) \cdot \cos(\theta_2) \cdot \sin\left(\frac{\beta}{2}\right)^2\right)^{1/2} \tag{7}$$

式中：r为地球的半径；θ_1为经度的弧度值；θ_2为纬度的弧度值；α为两点经度的弧度值差；β为两点纬度的弧度值差。

利用速度计算UAV到达部署区域所需的时间：

$$t_e = e \cdot (d_2/v) + (1-e) \cdot (d_2/v_{\max}) \tag{8}$$

式中：d_2为UAV到部署区域的最短距离；$v_{\max}$为探测到的UAV中的最大速度；$e \in (0, 1)$为加权系数，可以根据实际情况设定。

根据UAV的时间t计算威胁程度T，公式如下所示：

$$T = \frac{(t_c^{\max} - t_c)}{t_c^{\max}} \tag{9}$$

威胁评估算法如算法1所示。利用该机制，可以引导装备在探测到的无人机中选择威胁程度最大的几个无人机执行动作，有效抑制了装备在整个无人机集群中选择无人机执行动作，当无人机数量较多时，可防止装备在威胁程度较小的无人机上执行动作，算法搜索空间变小，加速收敛。

算法1：UAV威胁评估

(1) 获得装备部署区域和每个UAV的坐标；

(2) 利用式(7)计算每个UAV到部署区域的最短距离；

(3) 遍历每一个UAV，得到这些UAV中的最大速度$v_{\max}$；

(4) 对于每一个UAV，利用式(8)计算时间；

(5) 记录所有UAV中时间的最大值$t_c^{\max}$；

(6) 利用式(9)对每一个UAV计算威胁程度；

(7) 对所有UAV的威胁程度排序，得到威胁程度结果。

装备的动作通常包含追踪、瞄准、攻击等，由于本实验仿真环境下瞄准是装备本身建模自动生成的，因此装备动作确定有追踪和攻击2个动作。同时根据实验对战情况，装备在特定情况下会呈现持续追击1个目标、从1个目标转火到另1个目标和无法工作等状态，故增加持续追踪、重置和空闲3个动作。利用上述威胁评估算法可以获得可探测到的UAV的威胁程度列表，在装备的自身攻击范围内选择威胁程度最高的5个目标进行追踪，因此将动作空间中的动作设定为更大的9个，分别为5个追踪、1个攻击、1个重置、1个继续追踪和1个空闲，如式(10)所示。

$$\boldsymbol{A}=[0,0,0,0,0,1,0,0,0] \tag{10}$$

式中：$\boldsymbol{A}_0$~$\boldsymbol{A}_4$代表的动作是追踪；$\boldsymbol{A}_5$代表的动作是攻击；$\boldsymbol{A}_6$代表的动作是重置；$\boldsymbol{A}_7$代表的动作是继续追踪；$\boldsymbol{A}_8$代表的动作是空闲；数字0代表不可执行该动作；数字1代表可执行该动作。

由于环境的特殊性，多个智能体在选择动作的时候会出现有很多动作选择的情况，但是有些动作的选择不利于火力的合理分配，因此本文引入动作屏蔽机制在一些特定情况下来屏蔽掉智能体的一部分动作，减少学习成本，加快模型的收敛速度。动作屏蔽机制的原理如下所示。

假设模型需要学习的动作空间为$\boldsymbol{A}_1$，掩码的向量为$\boldsymbol{M}$，屏蔽后的动作为$\tilde{\boldsymbol{A}}$，计算公式如下所示：

$$\tilde{\boldsymbol{A}}=\boldsymbol{A}_1\cdot\boldsymbol{M} \tag{11}$$

以追踪状态为例，$\tilde{\boldsymbol{A}}$计算公式如下：

$$\boldsymbol{A}_1=[1,2,3,4,5,6,7] \tag{12}$$

$$\boldsymbol{M}=[1,1,1,1,1,0,0] \tag{13}$$

$$\tilde{\boldsymbol{A}}=[1,2,3,4,5,6,7]\cdot[1,1,1,1,1,0,0]=[1,2,3,4,5,0,0] \tag{14}$$

式中：$\boldsymbol{A}_1$中的$(\boldsymbol{A}_1)_0$~$(\boldsymbol{A}_1)_4$代表的动作是追踪；$(\boldsymbol{A}_1)_5$代表的动作是攻击；$(\boldsymbol{A}_1)_6$代表的动作是继续跟踪；$\boldsymbol{M}$中的$\boldsymbol{M}_0$~$\boldsymbol{M}_4$代表的是追踪的掩码；$\boldsymbol{M}_5$代表的是攻击的掩码；$\boldsymbol{M}_6$代表的是继续追踪的掩码，由于是追踪状态，故追踪的掩码为1，其余掩码为0，得到的$\tilde{\boldsymbol{A}}$结果赋值到原动作空间$\boldsymbol{A}$中完成动作屏蔽。

2.4 嵌入装备特性奖励机制设计

在对战过程中，通常使用的奖励是根据双方对战的输赢获得得分，即获胜得r值，对局的输赢奖励函数为

$$R=r \tag{15}$$

击落全部无人机，判定为胜利，$r=10$；若未击落全部无人机，判定为负，$r=-10$。

但是这样设置奖励太过稀疏，算法难以收敛。为了解决这一问题，在对战输赢的奖励上基于定向能装备的特性，加入单步上的奖励。由于定向能装备相对于传统的防空导弹具有攻击速度快等特点，即定向能装备打击无人机具有即时性，能更快地损伤和击落无人机，获得奖励的步长相对传统防空导弹较短，能更快地获得奖励，因此可以根据定向能装备的特性设置奖励函数。由于激光装备是每步都会对无人机造成伤害，故激光装备的奖励函数为

$$R_1=\alpha\cdot r_1+(1-\alpha)\cdot r_2+r_3+x\cdot 0.05 \tag{16}$$

式中：$\alpha\epsilon(0,1)$；r_1表示激光装备单步打击无人机获得奖励值，其值为1；r_2表示其它所有装备打击无人机获得的奖励之和，r_1和r_2按照一定比例和，保证了当前装备兼顾个人和全局的奖励；r_3是一个惩罚奖励，其值为0或−10，当打击发生冲突时，值为−10，其余情况为0；x为单步打击无人机的毁伤值。

微波装备攻击是瞬时的，为了获得胜利，需要鼓励微波装备攻击，微波装备的奖励函数为

$$R_2=\alpha\cdot r_1+(1-\alpha)\cdot r_2+r_3+(5-n)\cdot 0.2 \tag{17}$$

式中：n为上次攻击的无人机对应的威胁排序的序号，序号越小威胁越大，鼓励微波先打威胁度大的。

干扰装备不能毁伤无人机，只能扰乱其飞行规划，其奖励函数为

$$R_3=\alpha\cdot r_1+(1-a)\cdot r_2+r_3 \tag{18}$$

综上利用该机制，根据装备的特性加入其每步的奖励，给装备自身最好的奖励，引导其学习，并结合“每局输赢”这一奖惩，解决奖励稀疏性，引导模型更好的学习最优策略。

2.5 探索机制设计

强化学习在学习过程中常常需要先进行探索，充分利用环境信息，在学习到一定程度后，需要利用现有的信息，故加入探索机制。本文选择$\varepsilon-greedy$贪心选择策略为探索机制，该策略也是DQN算法中最常用的。当值落在$(0,\varepsilon)$之间，随机选择一个动作，当值落在$(\varepsilon,1)$之间，选择价值

最大的一个动作，即ε代表智能体对探索和利用的平衡。探索能够获取环境中更多的信息，不会拘泥于现有的信息；利用是从现有的信息中获取最大的奖励。为了让智能体在充分探索后，开始选择我们需要的动作，本文采用指数衰减的方法，公式如下：

$$\varepsilon=\varepsilon_{\text{end}}+(\varepsilon_{\text{start}}-\varepsilon_{\text{end}})\cdot\delta \tag{19}$$

式中：$\varepsilon_{\text{start}}$为探索率起始值；$\varepsilon_{\text{end}}$为探索率最终最小值；$\delta\epsilon(0,1)$为指数衰减因子，训练网络时候，将$\varepsilon_{\text{start}}$作为$\varepsilon$的初值，然后根据式(19)逐渐衰减探索率。

2.6 联合DQN框架流程

本文基于深度强化学习，设计的基于联合DQN的智能决策方法如算法2所示。

算法2：基于联合DQN的智能决策

(1) 初始化网络训练的超参数；

(2) 开始仿真；

(3) 训练模型，多智能体获取状态信息$\{s_1,s_2,\cdots,s_n\}$，进入联合状态得到$\{o_1,o_2,\cdots,o_n\}$；

(4) 根据联合状态$\{o_1,o_2,\cdots,o_n\}$和动作屏蔽机制，为每个智能体分配一个动作$\{a_1,a_2,\cdots,a_n\}$；

(5) 根据动作运行一步，多智能体得到新的状态信息、可执行的动作和奖励$\{r_1,r_2,\cdots,r_n\}$；

(6) 将上一步的状态、动作获得奖励和当前状态、上一步动作以及是否为终结状态存入经验回放池；

(7) 更新状态、动作和奖励；

(8) 在每局仿真结束时，判断经验回放池大小是否大于预设大小。进行epochs轮训练，每轮从经验回放池中随机抽取batch大小的回放数据进行训练；

(9) 达到设定的训练回合数，测试训练结果。

3 仿真实验及结果

3.1 实验设置

本文在配置为i7-10700，2.4+ GHz CPU，128 G内存，单GPU 4070，windows10操作系统上构建仿真服务，包括定向能系统模型服务、无人机集群模型服务和中心控制平台；在配置为i7-10700，2.4+ GHz CPU，128 G内存，GPU A100，windows10操作系统上，使用Python构建智能决策模型并训练，两个平台通过通信协议进行数据传输。以定向能系统反无人机集群典型攻防场景为仿真实验背景，无人机集群和装备可分别部署于一个或多个固定区域，可根据需要设定无人机集群和防御装备的数量规模。仿真时，在设定数量规模的约束下在不同部署区域的无人机集群的数量和位置随机生成；可设置要地防护区域大小，在设定数量规模的约束下在不同部署区域的防御装备的数量和位置随机生成。假设无人机集群以固定的速度飞往要地，定向能装备通过智能算法进行调度，对无人机集群进行拦截打击，阻止无人机集群飞往要地上空。一旦无人机集群中有无人机飞入要地，则无人机集群获胜，反之则无人机集群失败。图5为用于研究的对抗场景图。

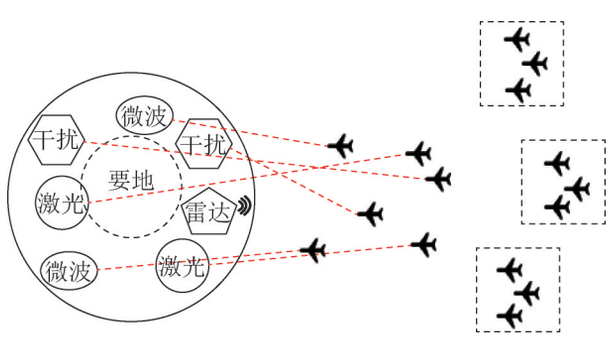


图5 仿真实验场景图

Fig. 5 Simulation experiment scene diagram

为了验证本文联合DQN算法的可行性，使用仿真软件对实验进行仿真测试。设计对战场景，设置防御装备和无人机的相关参数，构建用于实验的对战模型。为了验证实验效果，与基于规则的决策方法进行对比，以胜率作为评价指标，比较本文提出的基于联合DQN的智能决策方法与基于规则的决策方法之间的决策效果。

基于规则的决策方法是利用预先设定好的方式控制装备进行火力决策分配，打击无人机集群。根据仿真实验环境和最常见的威胁评估影响因素，

通过大量实验确定了基于规则的决策方法，该方法通过无人机的距离、速度、与要地中心点的方位角等参数来评估无人机的威胁程度，威胁程度越大的优先打击。威胁程度为

$$T_r = 0.2t + 0.1h + 0.3v + 03l + 0.1f \tag{20}$$

式中：t为无人机的类型；h为无人机的高度，v为无人机的速度；l为无人机离要地区域的距离；f为无人机相对要地区域中心点的方位角。

DQN的超参数是在开始学习之前提前设置好的网络参数，不是通过训练获得的参数。因此在网络开始训练之前需要进行调参，选择出一组最优的超参数训练模型从而提高学习的性能。最终采用的超参数如表1所示。

表1　DQN相关超参数
Table 1　DQN related hyper-parameters

名称	参数	取值
学习率	*lr*	0.001*w*
最大探索率	ε_{max}	0.99
最小探索率	ε_{min}	0.01
退火系数	τ	0.001
折扣因子	γ	0.99
每轮学习次数	*C*	150
批处理大小	*batch_size*	256
经验池	*reply_buffer*	30 000

表1中，γ=0.99是为了前期保证足够的概率探索，后期保证足够的概率利用；设置ε_{max}=0.99和ε_{min}=0.01是为了保证有一定的概率探索；*lr*为动态变化的超参数，原因在于固定的学习率容易导致模型不收敛，而本文最开始利用大的学习率保证模型收敛，在最优值附近利用小的学习率保证模型不来回震荡，更新公式如下：

$$w = \begin{cases} 1, round < 600 \\ 0.1, 600 \leqslant round < 1000 \\ 0.01, round \geqslant 1000 \end{cases} \tag{21}$$

式中：*round*为回合数。

3.2 结果分析

针对图5所示场景，假设2种仿真场景：

场景1：无人机集群30架，装备部署1个雷达、2个激光装备、1个微波装备和2个干扰装备。

场景2：无人机集群110架，装备部署1个雷达、6个激光装备、3个微波装备和2个干扰装备。

图6和图7分别为对场景1和场景2仿真后的结果图。

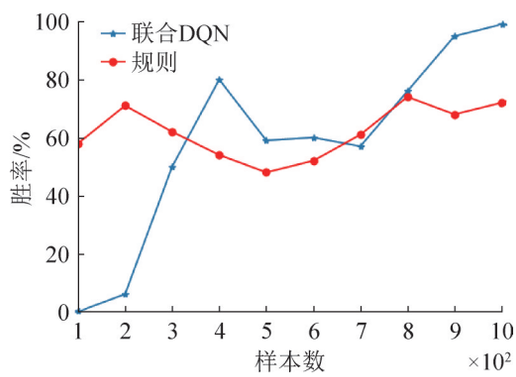


图6　场景1胜率图
Fig. 6　Scenario 1 Victory Chart

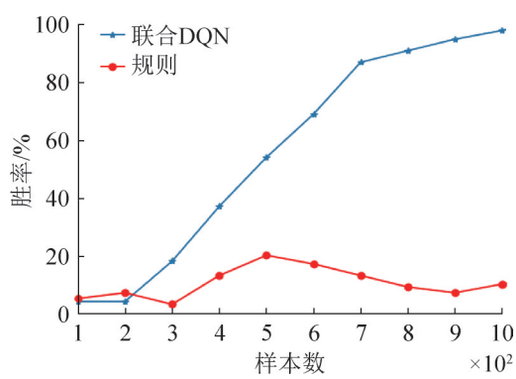


图7　场景2胜率图
Fig. 7　Scenario 2 Victory Chart

从图6~7中可以看出，随着样本数的增加，训练的联合DQN模型逐渐收敛且胜率达到98%以上，而基于规则是既定的方法，场景1的胜率在70%以下，场景2的胜率甚至在20%以下，表明基于联合DQN的方法优于基于规则的方法。由于场景1和场景2差异较大，场景2的装备数量和无人机数量远远多于场景1，导致基于规则的方法无法合理的分配火力，但是基于联合DQN的方法能逐渐收敛并合理分配火力。本文提出的方法在2种差异较大的场景下胜率相似，表明该方法具有较好的鲁棒性。

为了验证模型的泛化迁移能力，本文对仿真实验场景的参数进行了调整，如无人机的高度、速度和规模等。针对无人机集群高度进行调整，分别设置了300 m、500 m、800 m和1 000 m的高度，胜率如表2所示。针对无人机集群速度进行调整，分别设置了30 m/s、45 m/s和50 m/s，胜率如表3所示。针对不同规模的无人机集群和装备进行调整，胜率如表4所示。

表2 无人机集群不同高度下的胜率
Table 2 Winning rate of UAV clusters with height change

高度/m	胜率/%
300	99
500	98
800	93
1000	90

表3 无人机集群不同速度下的胜率
Table 3 Winning rate of UAV clusters with speed change

速度/(m/s)	胜率/%
30	99
45	99
50	96

表4 不同规模下的胜率
Table 4 Winning rates with scale change

规模	胜率/%
雷达:1 激光:3 微波:1 干扰:2 无人机:40	98
雷达:1 激光:2 微波:1 干扰:2 无人机:20	98
雷达:1 激光:6 微波:3 干扰:2 无人机:120	99

4 结论

本文针对复杂场景下防御无人机集群问题，提出了一种基于联合DQN的定向能系统火力智能决策建模仿真方法。该方法充分发挥定向能系统的优势，利用强化学习算法，设计了联合机制、威胁评估机制、动作屏蔽机制、嵌入装备特性奖励机制和探索机制等5种机制，针对性地提高了复杂场景下DQN模型的效果，有效解决了多装备、多部署场景下的状态空间和动作空间巨大、火力分配决策复杂程度高等问题。实验结果表明，本文提出的方法相较于基于规则的方法具有高胜率和性能稳定的优势。本文方法以数据为驱动并融合装备相关特性知识，引导智能体学习，减少学习成本，提升模型的泛化迁移能力，实现复杂多场景下的火力智能决策，在装备火力分配决策领域具有巨大的应用前景。

参考文献：

[1] Cai Yawei, Guo Haifeng, Zhou Kai, et al. Unmanned Aerial Vehicle Cluster Operations Under the Background of Intelligentization[C]//2021 3rd International Conference on Artificial Intelligence and Advanced Manufacture (AIAM). Piscataway: IEEE, 2021: 525-529.

[2] Yaseen N Jurn, Sawsen A Mahmood, Jaafar A Aldhaibani. Anti-drone System Based Different Technologies: Architecture, Threats and Challenges[C]// 2021 11th IEEE International Conference on Control System, Computing and Engineering (ICCSCE). Piscataway: IEEE, 2021: 114-119.

[3] 朱孟真, 陈霞, 刘旭, 等. 战术激光武器反无人机发展现状和关键技术分析[J]. 红外与激光工程, 2021, 50(7): 181-193.
Zhu Mengzhen, Chen Xia, Liu Xu, et al. Situation and Key Technology of Tactical Laser anti-UAV[J]. Infrared and Laser Engineering, 2021, 50(7): 181-193.

[4] 马海涛, 赵伟东. 基于遗传算法的弹炮混编防空群火力分配[J]. 火力与指挥控制, 2006(4), 36-38.
Ma Haitao, Zhao Weidong. Firepower allocation of missile artillery mixed air defense group based on genetic algorithm [J]. Firepower and Command Control, 2006 (4), 36-38.

[5] Jiang Guangsheng, Shi Xianming, Chen Jing, et al. A Survey of Intelligent Optimization Algorithms for Weapon Target Assignment (WTA) Problem[C]//2020 Management Science Informatization and Economic Innovation Development Conference (MSIEID). Piscataway: IEEE, 2020: 50-54.

[6] Zhai Haoran, Wang Weihong, Li Qingze, et al. Weapon-target Assignment Based on Improved PSO Algorithm [C]//2021 33rd Chinese Control and Decision Conference (CCDC). Piscataway: IEEE, 2021: 6320-6325.

[7] 杨荣军, 李长军. 粒子群算法在激光武器反无人机火力分配中的应用[J]. 指挥信息系统与技术, 2021, 12(5): 70-75, 81.
Yang Rongjun, Li Changjun. Application of Particle Swarm Optimization in Anti-UAV Fire Allocation of Laser Weapon[J]. Command Information System and

Technology, 2021, 12(5): 70-75, 81.

[8] Wang Caihong, Gao Junqiang, Lü Naibing, et al. Multi-objective Optimization of Weapon Target Assignment Based on Genetic Algorithm[C]//2021 International Conference on Computer, Internet of Things and Control Engineering (CITCE). Piscataway: IEEE, 2021: 29-34.

[9] 雷鸣, 谢斌. 基于云遗传算法的防空火力分配[J]. 系统仿真学报, 2018, 30(9): 3533-3537, 3551.
Lei Ming, Xie Bin. Air Defense Fire Distribution Based on Cloud-genetic Algorithm[J]. Journal of System Simulation, 2018, 30(9): 3533-3537, 3551.

[10] 钟伟杰, 李小兵, 常昊天, 等. 基于嵌套PSO算法的反无人机集群防空部署模型[J]. 电光与控制, 2021, 28(12): 6-10, 16.
Zhong Weijie, Li Xiaobing, Chang Haotian, et al. A Model for Air Defense Deployment Against UAV Swarm Based on Nested PSO Algorithm[J]. Electronics Optics & Control, 2021, 28(12): 6-10, 16.

[11] 石鼎, 燕雪峰, 宫丽娜, 等. 强化学习驱动的海战场多智能体协同作战仿真算法[J]. 系统仿真学报, 2023, 35(4): 786-796.
Shi Ding, Yan Xuefeng, Gong Lina, et al. Multi-agent Cooperative Combat Simulation in Naval Battlefield with Reinforcement Learning[J]. Journal of System Simulation, 2023, 35(4): 786-796.

[12] Nasir Y S, Guo Dongning. Deep Reinforcement Learning for Joint Spectrum and Power Allocation in Cellular Networks[C]//2021 IEEE Globecom Workshops (GC Wkshps). Piscataway: IEEE, 2021: 1-6.

[13] 刘家义, 王刚, 付强, 等. 基于分配策略优化算法的智能防空任务分配[J]. 系统仿真学报, 2023, 35(8): 1705-1716.
Liu Jiayi, Wang Gang, Fu Qiang, et al. Intelligent Air Defense Task Assignment Based on Assignment Strategy Optimization Algorithm[J]. Journal of System Simulation, 2023, 35(8): 1705-1716.

[14] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level Control Through Deep Reinforcement Learning[J]. Nature, 2015, 518(7540): 529-533.

[15] 董涛, 白娟, 邢清华, 等. 战术定向能武器地面防空作战研究[J]. 飞航导弹, 2021(5): 73-75, 79.

[16] Maini A K. Directed Energy Weapons[M]//Maini A K. Handbook of Defence Electronics and Optronics: Fundamentals, Technologies and Systems. Hoboken: John Wiley & Sons, Inc, 2018: 1013-1105.