基于深度强化学习的AGV行人避让策略研究

王贺[1,2]，许佳宁[1]，闫广宇[1,2*]

(1. 沈阳建筑大学 机械工程学院，辽宁 沈阳 110000；2. 沈阳建筑大学 现代建筑工程装备与技术国际合作联合实验室，辽宁 沈阳 110000)

摘要：为控制自动导引车(AGV)在智能工厂环境中避障时能够保障行人的安全舒适，提出一种基于深度强化学习的AGV端到端避障方法。引入*YOLOv8*模块提取行人位姿信息，并设计了基于视觉的状态空间；根据个人空间理论设计强化学习的奖惩机制，对*AGV*进入行人舒适空间和发生碰撞等行为进行惩罚；搭建了虚拟仿真系统，使用PPO并结合LSTM网络层完成了避障策略的训练并进行仿真实验验证。仿真结果表明：该避障策略在不建立环境地图、视觉输入的条件下，能够控制AGV在避障过程中与行人保持舒适的社交距离。

关键词：深度强化学习；自动导引车；YOLOv8；近端策略优化；避障；个人空间理论；端到端

中图分类号：TP242；TP18 文献标志码：A 文章编号：1004-731X(2025)03-0595-12

DOI: 10.16182/j.issn1004731x.joss.24-0088

引用格式: 王贺, 许佳宁, 闫广宇. 基于深度强化学习的AGV行人避让策略研究[J]. 系统仿真学报, 2025, 37(3): 595-606.

Reference format: Wang He, Xu Jianing, Yan Guangyu. Research on Pedestrian Avoidance Strategy for AGV Based on Deep Reinforcement Learning[J]. Journal of System Simulation, 2025, 37(3): 595-606.

Research on Pedestrian Avoidance Strategy for AGV Based on Deep Reinforcement Learning

Wang He[1,2], *Xu Jianing*[1], *Yan Guangyu*[1,2*]

(1. School of Mechanical Engineering, Shenyang Jianzhu University, Shenyang 110000, China; 2. Joint International Research Laboratory of Modern Construction Engineering Equipment and Technology, Shenyang Jianzhu University, Shenyang 110000, China)

Abstract: To ensure the safety and comfort of pedestrians during Automated Guided Vehicle (AGV) obstacle avoidance in smart factory environments, a deep reinforcement learning-based end-to-end obstacle avoidance method is proposed. *The YOLOv8 module is introduced to extract pedestrian pose information, and a visual-based state space is designed. A reinforcement learning mechanism is formulated based on personal space theory, penalizing AGV behaviors such as entering pedestrian comfort space and collisions.* A virtual simulation system is constructed, utilizing PPO algorithm along with LSTM network layer for obstacle avoidance strategy training and simulation experiments. Simulation results indicate that this obstacle avoidance strategy, under conditions of no environmental map establishment and visual input, can control the AGV to maintain a comfortable social distance from pedestrians during obstacle avoidance..

Keywords: DRL; AGV; YOLOv8; PPO; obstacle avoidance; personal space theory; end to end

收稿日期：2024-01-22 修回日期：2024-03-07

基金项目：国家自然科学基金(51942507)；学科创新引智项目(D18017)；中国科协青年人才托举工程项目(2023QNRC001)；辽宁省教育厅项目(Infw202017)

第一作者：王贺(1981-)，男，副教授，博士，研究方向为陶瓷零件制备及加工技术。

通信作者：闫广宇(1991-)，男，讲师，博士，研究方向为功能薄膜制备技术。

中国知网 https://www.cnki.net

0 引言

自动导引车(AGV)是一种自动化物流设备，因其具有自动化程度高、应用灵活等特点，已经成为现代智能工厂不可或缺的组成部分。导航技术是AGV在智能工厂中实现任务的必要技能之一，其目的是找到从起点到终点最短且无碰撞的路径。传统的AGV导航大多数是基于地图的方法，如SLAM[1]和路径规划[2]。通常SLAM构建环境地图，再由路径规划算法如蚁群算法[3]、A*算法[4]等生成无碰撞路径，但如果出现未构建在环境地图中的障碍物，如工厂中移动的行人，SLAM方法变得无效，无法完成后续的路径规划[5]。所以AGV应该具备从现场学习的能力，以便在检测到移动行人时能够暂时脱离路径规划算法规划的全局路线转而进入局部避障阶段，以避开突然进入视野中的行人。同时，在躲避行人的过程中，不仅要满足无碰撞，还需要AGV能够进行人类感知避障，即遵守一定的社交规则，以便AGV在避障过程中能够保障行人的安全舒适。随着人工智能时代的到来，基于深度强化学习的避障策略引起了人们的兴趣，深度强化学习避障策略作为一种通过探索和评估机制进行学习的策略，由于其强大的决策能力，它可以通过多层神经网络从当前状态中选择下一个动作，因此，越来越多地用于复杂动态环境下AGV的避障领域[6]。

在基于深度强化学习的人类感知避障策略研究中，Li等[7]通过提取人机交互的特征以筛选安全动作空间，通过深度强化学习训练使AGV在2D占用网格地图中实现人机共存环境下的高效避障，但它只考虑了避障的时间成本与路径长度，没有考虑在人机交互过程中行人的舒适性。Lu等[8]通过塑造弹性奖励函数引导移动机器人在避障过程中能够与行人保证舒适距离，并与基线策略进行比较，证明他们的算法相比基线策略在高效避障的同时还能保障行人的舒适性。上述基于学习的行人感知避障研究已经展示了较好的避障性能，但是这些研究中往往都是假设AGV在环境中有完整的全局视野，而在实际应用中，构建完整且精确的全局视野是非常昂贵的，所以一些工作尝试建立有限视野的避障模型以更贴合实际应用场合。Wang等[9]将社会时空图卷积神经网络(Social-STGCN)与强化学习相结合，通过将有限视野内观察到的历史行人轨迹嵌入到行人预测模型中，以此引导AGV进行行人感知避障，并在真实世界中使用搭载了激光雷达与深度相机的AGV进行实验验证，证明了该算法可以在有限视野下实现高效安全的导航，但是该算法的现实世界部署需要使用激光雷达与深度相机进行数据融合，并以此建立环境地图，需要消耗大量的计算成本，并且该算法所使用的高精度激光雷达也较为昂贵。

端到端(end-to-end, E2E)方法在许多机器学习和人工智能应用中得到了广泛的关注和研究，它旨在通过直接从输入数据到输出结果的映射，减少或消除传统多阶段处理流程中的中间表示和手工特征工程。基于E2E的深度强化学习避障策略不需要进行地图构建以及路径规划，它可以直接将输入的传感器数据输出成动作指令的映射来控制AGV完成避障任务，因此，采用E2E的方法可以在AGV只获得有限视野的前提下实现较好的避障效果，它的累积误差较小且计算效率更高。Cimurs等[10]将4个连续阶段的深度图像堆栈输入到卷积神经网络中进行特征提取，通过深度确定性策略梯度算法(DDPG)来训练避障模型，以E2E的方式输出包含线速度角速度的连续动作空间来规划AGV的避障线路。Lian等[11]设计了一个基于ConvLSTM的特征提取器，将同一时刻的深度图像与导航目标的关键时空特征相关联作为输入端以增强在有限视野下各个连续状态之间的时空相关性，实现了避障性能的大幅提升。以上研究都采用单深度图像数据作为输入端，而在进行行人感知避障时，使用拥有更丰富纹理信息的RGB图像是必要的。基于深度强化学习的避障算法通常需要在仿真环境中进行训练，再将训练好的策略

中国知网 https://www.cnki.net

迁移到真实世界进行应用，而受限于仿真环境的真实性，RGB图像在以往的研究中很少被使用。随着仿真软件技术的不断进步，一些具备高图形性能的仿真软件已广泛应用于机器人开发与测试领域，如Isaac Sim[12]。得益于其高度逼真的图形和物理特性，该软件可用于构建虚拟工厂环境及行人，进而开展深度强化学习模型的训练，以实现基于E2E的AGV避障策略。

基于上述问题，本文以智能工厂中的AGV避障问题为研究对象，搭建基于深度强化学习的自主避障系统。该系统在基于Isaac Sim搭建的虚拟工厂环境中学习如何在避障过程中保障行人的安全舒适。为实现这一功能，本文将RGB图像、深度图像、AGV及行人的位姿信息、目标点坐标等作为网络的输入。针对行人位姿信息提取，本文引入了YOLOv8模块，通过该模块检测图像数据中行人的位置及距离等信息。网络架构方面，本文将LSTM与PPO相结合，构建了一个视觉导航模型，并融合个人空间理论设计了奖惩机制以规范AGV的避障过程，确保AGV与行人保持舒适距离。

1 系统架构

本系统在OpenAI gym强化学习框架下完成构建，使用Isaac Sim搭建虚拟工厂环境用以传感器交互以及AGV动作指令发布，并通过ROS机器人操作系统接收与发布相关信息，并选择Pytorch深度学习框架用于搭建神经网络。整体架构如图1所示。构建AGV模型以及虚拟工厂环境，通过虚拟深度相机采集到的环境图片、轮式里程计获取到的AGV状态信息以及通过YOLOv8模型提取图像中的行人信息作为网络输入。建立避障学习模型，根据网络输入设置观测空间，并根据AGV的物理结构设定动作范围。结合个人空间理论设置奖惩机制，包括行人舒适度惩罚函数、碰撞惩罚函数、引导奖励函数等。将模型集成到PPO算法中进行训练，并结合LSTM网络以提取时空信息。在训练完成后，系统会生成一个Pytorch网络模型，该模型能够控制虚拟AGV在躲避行人的过程中与行人保持舒适安全的社交距离。

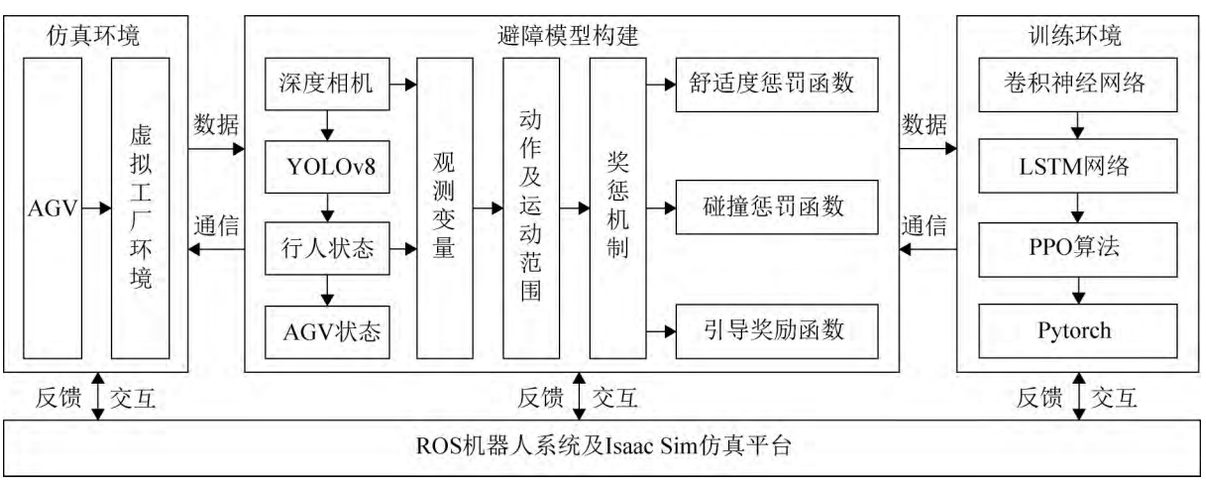


图1 系统整体架构
Fig. 1 System overall architecture

2 深度强化学习

2.1 环境建模

行人移动具有复杂性、随机性等特点，因此，针对行人的避障策略问题往往具有不确定性。对于本文的自主避障问题，最终需要求解得到最优避障策略，因此，可以用部分可观察马尔可夫决策过程进行建模。将当前t时刻状态s_t、动作a_t、

中国知网 https://www.cnki.net

奖励r_t，以及下一时刻状态s_{t+1}构建四元组(s_t, a_t, r_t, s_{t+1})，收集并存入经验池。从t时刻开始进行学习运行到本回合结束，定义从任务开始到本回合结束所运行时长为T，不断优化避障策略使所获得的累积折扣收益R_t最大化。

$$R_t = \sum_{k=0}^{T} \gamma_k r_{t+k+1} \tag{1}$$

式中：$\gamma \in (0, 1)$为折扣系数，用于衰减未来所获奖励对于整体回报的影响。

2.2 PPO 算法

强化学习旨在训练智能体(agent)在不可预测且不断变化的环境(env)中执行任务。在此过程中，环境会提供状态和奖励，智能体则根据一定的策略选择动作与环境进行交互[13]。智能体与环境不断进行交互，环境会对智能体所做动作做出反应，并返回给智能体一个新的环境。同时，环境会给予智能体奖励，智能体则试图在一段时间内最大化这些奖励，而智能体的决策过程主要由策略来实现。

根据策略优化方式的不同，深度强化学习算法主要可分为三大类：基于价值、基于策略和基于演员–评论家框架[14]。基于价值的深度强化学习算法主要有 Q-learning、DQN、Double DQN 等，它们主要拟合的是价值函数与动作–价值函数，通过估计不同状态下所处的价值，在选择动作时尽可能让智能体处于价值较高的状态以获得更多的奖励，但这些算法只能处理有限动作空间的问题，对于高维连续动作空间问题(如控制 AGV 的线速度及角速度)，基于价值的方法大多会产生维度灾难问题。基于策略的深度强化学习算法如 A3C、SAC 等，在处理连续动作空间问题上有较好的效果，被广泛应用于机器人控制及自动驾驶领域。

PPO 算法[15]是一种深度强化学习算法，是信任区域策略优化算法(TRPO)[16]的改进，它基于演员–评论家框架，这种框架融合了价值与策略 2 种方法各自的优势，因此具有较快的收敛速度与较强的鲁棒性，是目前 OpenAI 在诸多强化学习任务中使用的默认算法。PPO 算法包含一个策略网络和一个值函数网络。

策略网络输入观测状态序列s，输出对于动作a概率分布的估计值，因此，策略π可建模为$\pi(a|s)$，其网络权重参数记为θ，$\pi_\theta(a_t|s_t)$则表示在t时刻将当前状态s_t输入到策略网络中得到动作的高斯概率分布，再经由采样得到t时刻的动作a_t。策略网络负责做出决策并更新决策，是一种基于策略的方法。

状态价值函数$V_\pi(s)$和动作价值函数$Q_\pi(s, a)$可以用来对策略π进行评估，$V_\pi(s)$表示从状态s出发，智能体按照策略π来执行动作所获得回报的期望值；$Q_\pi(s, a)$表示从状态s出发，智能体执行动作a后，按照策略π执行后续的动作所获得回报的期望值。

$$V_\pi(s_t) = E_\pi[R_t|s_t] = E_\pi\left[\sum_{k=0}^{T} \gamma_k r_{t+k+1} \middle| s_t\right] \tag{2}$$

$$Q_\pi(s_t, a_t) = E_\pi[R_t|s_t, a_t] = E_\pi\left[\sum_{k=0}^{T} \gamma_k r_{t+k+1} \middle| s_t, a_t\right] \tag{3}$$

式中：E_π为期望。

PPO 算法通过估计优势函数$A_\pi(s_t, a_t)$来评价当前状态和动作相对平均水平的优劣程度，以改进当前策略。

$$A_\pi(s_t, a_t) = Q_\pi(s_t, a_t) - V_\pi(s_t) \tag{4}$$

遵循 Mnih 等[17]的实现方法，定义优势函数$A_\pi(s_t, a_t)$在t时刻得到的估计值为$\hat{A}_t$，该估计的最大时长定义为$t_{\max}$，$t_{\max}$远小于每回合的终止时长T，当每运行$t_{\max}$时长时，使用收集到的样本进行网络更新，因此

$$\hat{A}_t = -V(s_t) + r_t + \gamma r_{t+1} + \cdots + \gamma_{t_{\max}-t+1} r_{t_{\max}-1} + \gamma_{t_{\max}-t} V(s_{t_{\max}}) \tag{5}$$

该方法通过使用状态价值函数$V_\pi(s)$来表示动作价值函数$Q_\pi(s, a)$，以实现对于$\hat{A}_t$值的估计，因此，价值函数网络用来拟合状态价值函数$V_\pi(s)$，是一种基于价值的方法。

中国知网 https://www.cnki.net

在TRPO算法中，策略采用策略梯度法更新，其策略梯度损失函数为

$$L^{\mathrm{CPI}}(\theta)=\hat{E}_t[C_t(\theta)\hat{A}_t] \tag{6}$$

式中：$C_t(\theta)$为重要性采样权重。

$$C_t(\theta)=\frac{\pi_\theta(a_t,s_t)}{\pi_{\theta_{\mathrm{old}}}(a_t,s_t)} \tag{7}$$

而在PPO算法中，为了约束新旧策略更新范围，引入了剪裁项对目标函数进行自动剪裁，新的损失函数为

$$L^{\mathrm{CLIP}}(\theta)=\hat{E}_t[\min(C_t(\theta)\hat{A}_t,\mathrm{clip}(C_t(\theta),1-\varepsilon,1+\varepsilon)\hat{A}_t] \tag{8}$$

式中：ε为超参数；clip(·)为剪裁函数，目的是将$C_t(\theta)$限制在$(1-\varepsilon,1+\varepsilon)$的范围内，避免策略更新过快而无法收敛或收敛过慢。

2.3 LSTM-PPO算法

在工程应用背景下，AGV的避障任务是一个连续性的任务，其环境状态具有强时序相关性。由于LSTM网络在处理连续且相互依赖的数据输入场景时表现出更强的适用性，更适合于AGV的避障任务需求[18]。因此，本文引入LSTM网络层来增强状态序列间的时间相关性。在LSTM-PPO算法中，输入的图像数据经过卷积神经网络处理成特征向量，与AGV的位姿信息、目标点坐标信息和行人状态信息相互拼接作为状态序列s。策略网络和价值网络的LSTM层分别接收状态序列s作为网络的输入，输出的特征向量通过全连接神经网络来逼近策略函数以及价值函数。LSTM-PPO算法的网络架构见图2。

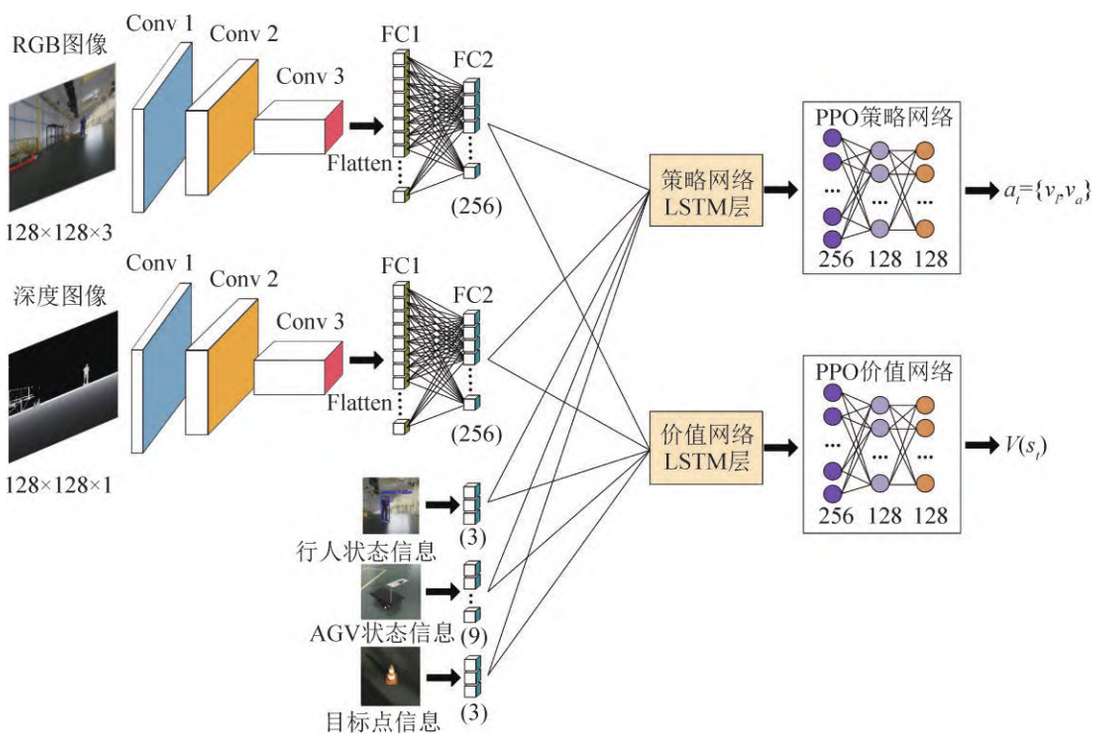


图2　网络架构

Fig. 2　Network architecture

3　AGV避障系统搭建

3.1 状态空间设定

为了实现避障功能，AGV在与环境交互的过程中需要获取足够的状态信息，本文采用深度相机来获取环境信息。深度相机采集到的图像数据有RGB图像I_{R}，深度图像I_{D}，因此，AGV与环境交互的图像状态为

中国知网　https://www.cnki.net

$$s_t^{\mathrm{I}}=\left[I_{\mathrm{R}},I_{\mathrm{D}}\right] \tag{9}$$

AGV 从轮式里程计(Odom)获取其位姿信息。位姿信息包含其在环境中的三维位置坐标 P_{A}、速度信息 v_{A} 以及方位信息 O_{A}。因此，AGV 的位姿状态为

$$s_t^{\mathrm{A}}=\left[P_{\mathrm{A}},v_{\mathrm{A}},O_{\mathrm{A}}\right] \tag{10}$$

在避障完成后，需要设定一个目标点，当到达目标点后，AGV 会脱离局部避障策略转而进入全局路径规划阶段，设定目标点坐标为 P_{G}。

在与行人交互的过程中，AGV 需要获取行人信息。行人信息可以从图像中进行提取，而提取行人信息需要用到目标检测算法，因此，本文引入 YOLOv8 模块来对行人进行检测。

YOLO 是一种目标检测模型，从最初的 v1 版本发展到如今的 v8 版本，它已经实现了检测精度与速度间的最佳平衡[19]。YOLOv8 的核心方法是利用整张图片作为网络的输入，直接在输出端回归边界框的位置以及待检测物体的所属类别，因此，本文添加 YOLOv8 模块对行人进行检测，通过该模块获取图像中行人的状态信息并将其输入到强化学习网络中。

设定当前时刻 RGB 图像 I_{R} 的尺寸为 $w_{\mathrm{R}}\times h_{\mathrm{R}}$，将 I_{R} 输入到 YOLOv8 网络中，网络会对其进行预测并返回包含待检测物体的边界框 b。边界框是能正好包含物体的矩形框，它由 (x,y) 和 (w_b,h_b) 两组元素来表示。其中，(x,y) 为边界框中心点在 RGB 图像 I_{R} 上的坐标，$x\in(0,w_{\mathrm{R}})$，$y\in(0,h_{\mathrm{R}})$，而 (w_b,h_b) 则表示边界框的宽高。对于当前时刻 YOLOv8 返回的所有边界框有

$$B_t=(b_1,b_2,\cdots,b_n) \tag{11}$$

$$b=(x,y,w_b,h_b) \tag{12}$$

在 I_{R} 中，左上角坐标定义为 $(0,0)$，右下角坐标为 (w,h)。当前时刻的深度图像 I_{D} 与 I_{R} 有相同的尺寸及坐标定义，因此，由 YOLOv8 通过输入 I_{R} 所生成包含行人的边界框 b 也适用于 I_{D}。I_{D} 上每一个像素点的信息为该像素点的深度值 D，设定边界框 b 的中心点深度值为 D_b，新的边界框为

$$b=(x,y,w_b,h_b,D_b) \tag{13}$$

在检测到多个行人时，应当优先考虑与 AGV 距离最短的行人并获取其边界框信息：

$$b_{\min}=\min B_t(D_b) \tag{14}$$

取 $b_{\min}$ 边界框的中心点坐标与深度值作为最终的行人状态信息输入到强化学习网络中：

$$P_{\mathrm{H}}=(x,y,D_b) \tag{15}$$

最终，当前时刻状态 s_t 为图像状态 s_t^{I}、AGV 位姿状态 s_t^{A}、目标点坐标 P_{G} 与行人状态信息 P_{H} 共同组合而成：

$$s_t=\left[I_{\mathrm{R}},I_{\mathrm{D}},P_{\mathrm{A}},v_{\mathrm{A}},O_{\mathrm{A}},P_{\mathrm{G}},P_{\mathrm{H}}\right] \tag{16}$$

3.2 动作空间设定

AGV 的动作空间由线速度 v_{l} 和角速度 v_{a} 组成，需要按照其真实运动情况进行设定。在本文中，AGV 搭载的深度相机观测方向为正前方，因此 AGV 不被期望向后移动。其动作空间用集合 $a_{\mathrm{t}}=\left\{v_{\mathrm{l}},v_{\mathrm{a}}\right\}$ 表示，具体如表 1 所示。

表 1　动作空间集合列表
Table 1　Action space collection list

控制方式	动作描述	取值范围
线速度 v_{l}	$v_{\mathrm{l}}>0$ 前进	$[0,1]$
	$v_{\mathrm{l}}=0$ 静止	
角速度 v_{a}	$-\pi/2\leqslant v_{\mathrm{a}}<0$ 左转	$[-\pi/2,\ \pi/2]$
	$v_{\mathrm{a}}=0$ 直行	
	$0<v_{\mathrm{a}}\leqslant\pi/2$ 右转	

3.3 奖励函数设计

针对 AGV 在避障过程中与行人保持社交距离这一任务需求，设计合理的奖励函数能对当前状态进行有效评估，从而优化避障策略。本文基于个人空间理论设计了奖惩机制，通过构建行人舒适度函数、碰撞惩罚函数及目标引导函数对 AGV 的避障策略进行评估。

3.3.1 行人舒适度函数

AGV 在与行人交互的过程中，应当尽量避免出现在行人的舒适范围内。在个人空间理论研究

中国知网 https://www.cnki.net

中，行人周围的空间可以被定义为4个距离区域，具体情况见表2。

表2　个人空间距离定义列表
Table 2　Personal space distance list

距离区域	距离范围/m	区域描述
亲密距离	$0 \leqslant D_{\text{intimate}} \leqslant 0.45$	身体接触或私人互动
私人距离	$0.45 < D_{\text{personal}} \leqslant 1.2$	亲朋互动或高度有组织的活动
社交距离	$1.2 < D_{\text{social}} \leqslant 3.5$	正式场合或公共场所的互动
公共距离	$D_{\text{public}} > 3.5$	没有互动或单向互动

假设AGV当前位置在行人坐标系中的坐标为(x_0, y_0)，AGV与行人的欧式距离可为

$$D_{\text{AH}} = \sqrt{x_0^2 + y_0^2} \tag{17}$$

在个人空间理论中，行人之间的距离指的是行人中心点的距离，而在人机交互的场景中，还应将AGV的半径r_{A}与人的半径r_{H}考虑进去。因此修改后的距离可为

$$D_{\text{AH}} = \sqrt{x_0^2 + y_0^2} + (r_{\text{A}} + r_{\text{H}}) \tag{18}$$

当AGV处于行人的公共空间外，此时的避障策略应该被鼓励；当AGV处于行人的社交空间内，此时的避障策略可以被允许，但应当给予一定的惩罚；当AGV处于行人的私人距离内时，意味着该避障策略使行人感到不舒服，因此要给予更大的处罚值。基于以上几点，行人舒适度函数被定义为

$$R_{\text{H}} = \begin{cases} -1, & D'_{\text{AH}} \in D_{\text{social}} \\ -5, & D'_{\text{AH}} \in (D_{\text{personal}} \cup D_{\text{intimate}}) \end{cases} \tag{19}$$

在本文的智能工厂环境中，AGV的行驶线路在道路两侧安全黄线的范围内，因此，可以近似看成单一维度的空间交互问题[20]。当处于单一维度的交互时，行人的个人空间可以被建模成一个围绕行人的椭圆形区域，如图3所示。

图3引用孙立香等[21]对于单一维度交互模型指示函数的定义：

$$I(x_0, y_0) = \begin{cases} 0, & x_0^2/D_{\text{front}}^2 + y_0^2/D_{\text{side}}^2 > 1 \\ 1, & x_0^2/D_{\text{front}}^2 + y_0^2/D_{\text{side}}^2 \leqslant 1 \end{cases} \tag{20}$$

式中：$D_{\text{front}} = 1.2$ m是该椭圆区域的长轴，为私人距离的最大值；$D_{\text{side}} = 0.7$ m是该椭圆的短轴，为侧边舒适距离。该指示函数可以用于评估AGV是否行驶到了行人的舒适区域内，因此，本文引入该指示函数用以评估AGV的避障策略是否使行人感到舒适。如果AGV到达了行人的舒适区域内，则$I(x_0, y_0)$为1，即判定该回合的避障策略使行人感到不舒适，反之$I(x_0, y_0)$为0，即表示该回合AGV在避障过程中与行人保持了舒适距离。

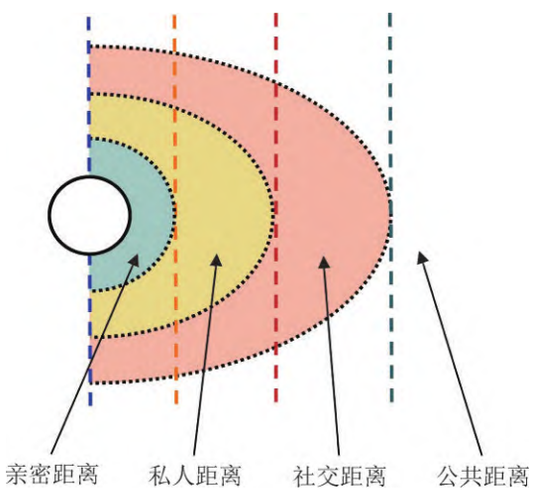


图3　单一维度交互下的个人空间距离区域
Fig. 3　Spatial distance zones for one-dimensional interaction

3.3.2 碰撞惩罚函数

当AGV与边界线、障碍物或是行人相撞时，应当给予一个惩罚值并结束该轮任务。在行人与AGV模型实体上设置了碰撞检测，并在安全黄线处设置了边界检测，正常情况下，该项惩罚为0，一旦发生碰撞或超出边界，该项惩罚生效，该轮任务即判定为结束，碰撞惩罚函数为

$$R_{\text{C}} = \begin{cases} 0, & \text{避障失败} \\ -500, & \text{避障成功} \end{cases} \tag{21}$$

3.3.3 目标引导函数

AGV在避障过程中需要向目标点前进并最终到达目标点，在向目标点前进的过程中也要维持速度从而保证避障的时效性。因此，目标引导函数由位置奖励函数R_{P}、速度奖励函数R_{V}、时间惩

中国知网 https://www.cnki.net

罚函数R_T以及到达目标奖励R_G组成。如图4所示，在当前时刻t，AGV的位置为$P_A=(x_t,y_t)$，目标点位置为$P_G=(x_g,y_g)$，两者间的距离为

$$D_{AG}=\sqrt{(x_t-x_g)^2+(y_t-y_g)^2} \tag{22}$$

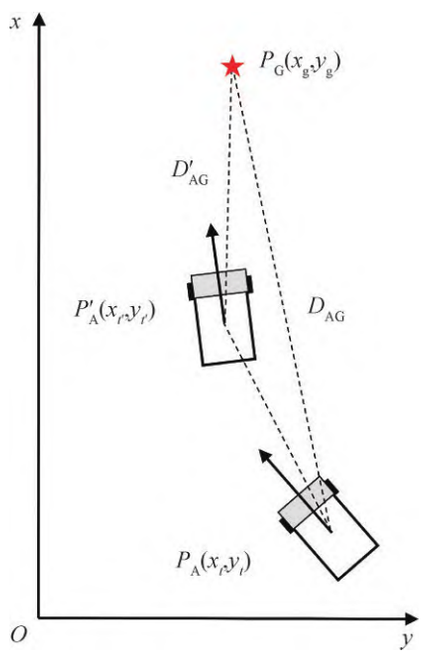


图4 AGV运动模型
Fig. 4 AGV kinematic model

在下一时刻t'，AGV移动到了新的位置$P'_A=(x_{t'},y_{t'})$，此时AGV与目标点的距离更新为

$$D'_{AG}=\sqrt{(x_{t'}-x_g)^2+(y_{t'}-y_g)^2} \tag{23}$$

为引导AGV不断向目标点前进，当AGV比上一步更靠近终点时，应给予奖励。因此，位置奖励函数定义为

$$R_P=\begin{cases}1, & D_{AG}>D'_{AG}\\ 0, & D_{AG}\leqslant D'_{AG}\end{cases} \tag{24}$$

速度奖励函数R_V与当前时刻线速度v_l相关，由于$v_l\in[0,1]$，因此，该项奖励始终为正值。速度奖励函数定义为

$$R_V=v_l \tag{25}$$

时间惩罚函数R_T会随着该轮任务运行时间步数t_T的增长而递增，以此来约束AGV避免在避障过程中消耗过多的时间：

$$R_T=-10^3\times t_T \tag{26}$$

当AGV最终到达目标区域时，应结束本回合任务，给出到达目标的奖励并计算本轮所获奖励总和，因此，到达目标奖励应设置为高奖励项。到达目标奖励定义为

$$R_G=\begin{cases}1\,000, & D_{AG}=0\\ 0, & D_{AG}>0\end{cases} \tag{27}$$

综上所述，本系统的总奖励数为

$$R_t=R_H+R_C+R_P+R_V+R_T+R_G \tag{28}$$

4 环境搭建与网络训练

4.1 训练环境搭建

本文基于OpenAI gym框架构建深度强化学习环境，定义了奖励函数及初始化方法等必要组成。基于Omniverse Isaac Sim搭建虚拟工厂环境、AGV及可移动的行人模型。AGV由差速驱动器驱动，并搭载深度相机，由ROS系统订阅AGV发布的轮式里程计信息以及图像数据。

本文建立的仿真环境中，左右两侧安全黄线相距8 m，其内部区域为AGV可行驶区域，当AGV中心点超过该区域时，则判定回合结束；AGV的半径r_A设为0.5 m，行人的半径r_H设为0.3 m，当两者中心点距离小于0.8 m时，则判定为碰撞，回合结束，否则，当该轮任务运行时间步T_t超过1 000时，也会判定回合结束。目标点坐标P_G设置为(15, 0, 0)，当AGV中心点距离目标点2 m内时，判定为任务完成。行人与AGV在每回合任务重置时进行刷新，行人的刷新点坐标设为(x_r^H,y_r^H)，其中$x_r^H=10$，$y_r^H\in[-2,2]$；AGV的刷新点坐标设为(x_r^A,y_r^A)，其中，$x_r^A=0$，$y_r^A=y_r^H+k$，$k\in[-1,1]$，AGV刷新点采用这样的设置方式是为了确保其在每一回合避障任务中都能与行人产生交互。

4.2 训练结果分析

本文实验训练平台硬件配置为AMD Ryzen5 5600X CPU和RTX 3060 12 G GPU，网络计算环境为Python3.7和Pytorch 1.13。训练超参数如表3

中国知网 https://www.cnki.net

所示。

表3　超参数设置列表
Table 3　hyperparameter settings list

超参数	设置
batch_size	256
经验缓存池容量	2 560
折扣系数γ	0.99
裁剪系数ε	0.2
学习率l_r	2×10^{-4}
优化器	Adam

4.2.1 预训练结果分析

为了加快避障策略的收敛速度，提高训练效率，本文先进行了预训练。预训练网络用于控制AGV在没有行人的工厂环境中移动到目标点，预训练环境为无障碍环境，行人被移除，AGV刷新点坐标$(x_r^{\mathrm{A}},y_r^{\mathrm{A}})$中，$x_r^{\mathrm{A}}=0$，$y_r^{\mathrm{A}}\in[-3,3]$。预训练共进行了$6\times10^5$步，所获得的平均回合奖励结果如图5所示。

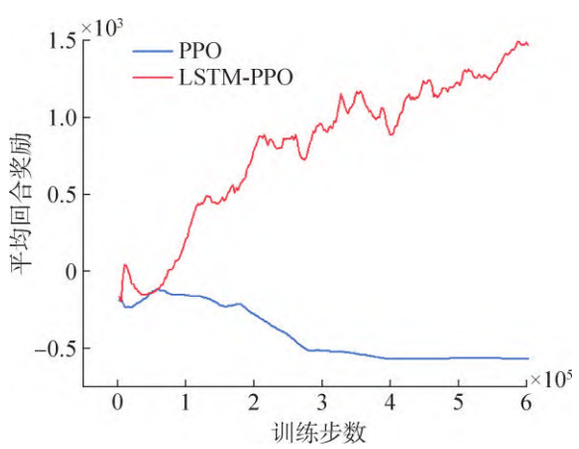
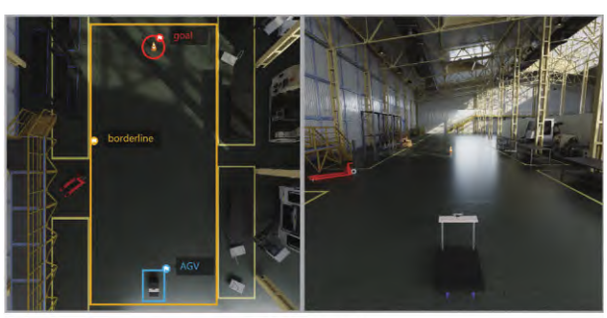


图5　预训练平均回合奖励
Fig. 5　Pre-trained mean episode reward

将本文所搭建的LSTM-PPO算法与基线算法PPO进行比较，二者采用了相同的超参数设置，基线算法没有LSTM网络层，状态序列被直接输入到策略网络与价值网络中进行拟合。从图5可以看到，在预训练的过程中，采用LSTM-PPO网络结构的模型其平均回合奖励随着训练的进程不断增加，在训练到6×10^5步时达到了最高点，此时每回合获得的平均奖励达到了1 500，意味着AGV能够快速、稳定地向目标点前进并最终到达目标点。采用基线PPO算法训练过程中所获得的回合平均奖励始终为负值并缓慢减少，训练进行到2.8×10^5步时降到最低约−500，并在小幅度范围内变化，意味着该模型陷入了局部最优解，无法收敛到全局最优策略。

4.2.2 正式训练结果分析

在正式训练中，每回合开始时在$(x_r^{\mathrm{H}},y_r^{\mathrm{H}})$位置处刷新，面向AGV并向前方以0.5 m/s的速度作直线运动。正式训练将训练AGV在避障过程中能够保持在行人的舒适区域外，共进行2.5×10^5步。正式训练的行人障碍环境如图6(b)所示，所获得的平均回合奖励结果如图7所示。



(a) 无障碍环境



(b) 行人障碍环境

图6　训练环境
Fig. 6　Train environment

从图7可知，每回合所获得的平均奖励变化趋势。在训练过程中，由于AGV无法完全避免进入行人的社交空间，因此，会受到一定的处罚，导致模型收敛时每回合所获得的总奖励略低于预训练时的总奖励。

中国知网　https://www.cnki.net

当训练进行到约 2.3×10^5 步时，每回合的平均奖励值趋于稳定，不再增长。因此，可以判断模型已经收敛，AGV 在躲避行人的过程中得到的奖励已经接近最大，此时，每回合所获得的平均奖励值约为 1 380。由于在预训练中基线 PPO 算法没能取得较好的效果，所训练的策略无法驱动 AGV 到达目标点，因此，基于预训练模型所训练的避障策略依然无法获得较高的奖励，其平均回合奖励始终低于−500，AGV 在原地转圈，陷入局部最优解，无法实现避障功能。

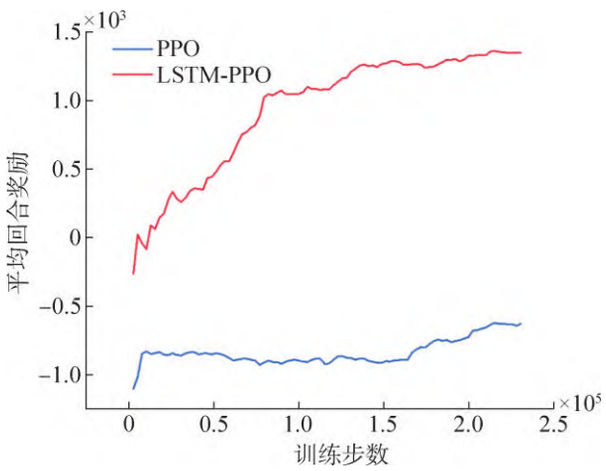


图 7　正式训练平均回合奖励
Fig. 7　Formal training mean episode reward

5　实验结果分析

5.1　无障碍导航

为了评估算法在环境无障碍物时导航至目标点的能力，将行人从环境中移除，将训练好的网络权重加载到 LSTM-PPO 网络中，对模型进行无障碍导航性能测试。在此环境中，AGV 分别从(0,−2)，(0, 0)和(0, 2)这 3 个位置进行刷新，测试结果如图 8 所示。结果显示，在无障碍环境下，AGV 能够避免过多的绕路并成功导航至目标点位置。

5.2　人机共存场景下的导航

在人机共存的场景下进行了 4 个回合的测试。这 4 个回合中，行人分别被放置在(10, −2)，(10, −1)，(10, 1)，(10, 2)这 4 个位置上，并在该回合开始后向前匀速移动。仿真实验结果数据如表 4 所示，实验结果如图 9 所示。

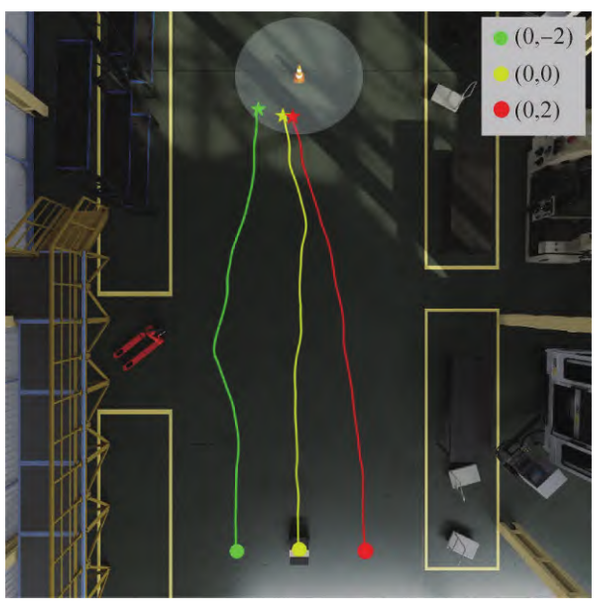


图 8　无障碍导航测试结果
Fig. 8　Obstacle-free navigation testing results

表 4　仿真实验结果列表
Table 4　Simulation experimental results list

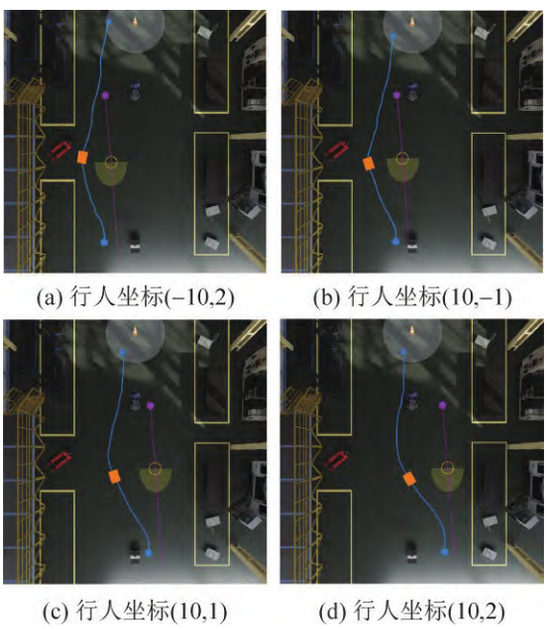
轮次	行人刷新位置	任务完成时间/s	最小距离值/m
1	(10, −2)	13.17	1.05
2	(10, −1)	13.24	1.44
3	(10, 1)	13.13	1.82
4	(10, 2)	14.02	1.70

在图 9 中，蓝色的曲线代表了 AGV 的前进路径，紫色的虚线则代表了行人的前进路径。AGV 的半径为 0.5 m，行人的半径为 0.3 m。橙色区域代表在避障过程中 AGV 与行人处于最小距离时的私人空间大小。实验结果表明：AGV 倾向于从左侧避开行人。当 AGV 检测到行人时，会开始向左转，并绕开一定的范围，以确保在躲避行人的过程中保持足够的距离，一旦 AGV 完成避障动作，它会迅速转向目标点方向，并朝目标点前进。

为了进一步验证该模型的避障效果，我们又进行了 30 个回合的实验以评估模型的避障成功

中国知网　https://www.cnki.net

率，行人的刷新点坐标设为$(x_r^{\mathrm{H}},y_r^{\mathrm{H}})$，其中$x_r^{\mathrm{H}}=10$，$y_r^{\mathrm{H}}\in[-2,2]$；AGV的刷新点坐标设为$(x_r^{\mathrm{A}},y_r^{\mathrm{A}})$，其中$x_r^{\mathrm{A}}=0$，$y_r^{\mathrm{A}}=y_r^{\mathrm{H}}+k$，$k\in[-1,1]$。评估结果如表5所示。



(a) 行人坐标(−10,2)　(b) 行人坐标(10,−1)

(c) 行人坐标(10,1)　(d) 行人坐标(10,2)

图9　人机共存导航测试结果

Fig. 9　Human-Aware Navigation Testing results

表5　评估结果列表

Table 5　Evaluation results list　m

轮次	距离	轮次	距离	轮次	距离
1	1.87	11	1.95	21	0
2	1.68	12	1.96	22	1.63
3	1.92	13	2.45	23	0.85
4	0.74	14	1.25	24	1.31
5	1.28	15	2.09	25	1.29
6	2.15	16	1.61	26	2.15
7	0.56	17	2.01	27	0.95
8	2.35	18	1.55	28	0.59
9	1.80	19	1.30	29	0.79
10	1.35	20	1.35	30	0.72

通过表5可知，30轮实验中行人与AGV交互过程中的最小距离，在这30轮实验中，有3轮实验判定为失败，在第7轮和第28轮实验中，指示函数$I(x_0,y_0)$判定AGV进入了行人的私人空间，会使行人感到不舒服，而在第21轮实验中，AGV则是与行人发生了碰撞。通过该实验验证了本文模型的避障效果，避障成功率在96.7%以上，在避障过程中能够保障行人安全舒适的成功率在90%以上。

6　结论

本文针对智能工厂环境下面对行人的避障问题进行了研究。将LSTM网络与PPO算法相结合，建立了一个基于深度强化学习的AGV控制器。

针对E2E方法中行人特征信息不足的问题，引入了YOLOv8目标检测算法提取行人的状态信息，并将行人状态信息与RGB图像、深度图像、AGV状态信息和目标点信息共同作为深度强化学习的状态输入。为使AGV在避障过程中能够保障行人安全舒适，融合个人空间理论设计了一个奖励函数以引导AGV实现该避障策略。搭建了仿真环境进行训练并测试，验证了该算法的有效性。仿真实验结果表明：本文方法避障成功率高达96.7%，在避障过程中能够保障行人舒适的成功率在90%以上。

本文方法能够控制AGV在避障过程中保障行人的舒适安全，但面对多个行人的情况下有可能导致碰撞的发生，存在局限性。在后续研究中，将对模型的泛化能力进行提升，通过设置不同数量及不同行为动作的行人以提高系统的泛化能力。

参考文献：

[1] Durrant-Whyte H, Bailey T. Simultaneous Localization and Mapping: Part I[J]. IEEE Robotics & Automation Magazine, 2006, 13(2): 99-110.

[2] LaValle S M. Planning Algorithms[M]. Cambridge: Cambridge University Press, 2006.

[3] Yi Guohong, Feng Zhili, Mei Tiancan, et al. Multi-AGVs Path Planning Based on Improved Ant Colony Algorithm [J]. The Journal of Supercomputing, 2019, 75(9): 5898-5913.

[4] Karlijn Fransen, Joost van Eekelena. Efficient Path Planning for Automated Guided Vehicles Using A* (Astar) Algorithm Incorporating Turning Costs in Search Heuristic[J]. International Journal of Production Research, 2023, 61(3): 707-725.

[5] Nwaonumah E, Samanta B. Deep Reinforcement

中国知网 https://www.cnki.net

Learning for Visual Navigation of Wheeled Mobile Robots[C]//2020 SoutheastCon. Piscataway: IEEE, 2020: 1-8.

[6] Zhu Yuke, Mottaghi R, Kolve E, et al. Target-driven Visual Navigation in Indoor Scenes Using Deep Reinforcement Learning[C]//2017 IEEE International Conference on Robotics and Automation (ICRA). Piscataway: IEEE, 2017: 3357-3364.

[7] Li Keyu, Xu Yangxin, Wang Jiankun, et al. SARL: Deep Reinforcement Learning Based Human-aware Navigation for Mobile Robot in Indoor Environments [C]//2019 IEEE International Conference on Robotics and Biomimetics (ROBIO). Piscataway: IEEE, 2019: 688-694.

[8] Lu Xiaojun, Hanwool Woo, Angela Faragasso, et al. Socially Aware Robot Navigation in Crowds via Deep Reinforcement Learning with Resilient Reward Functions [J]. Advanced Robotics, 2022, 36(8): 388-403.

[9] Wang S H, Wu Y H, Li T H S. Deep Reinforcement Learning with Pedestrian Trajectory Prediction Model for Service Robot Navigation in Crowded Environments[C]// 2023 International Conference on Advanced Robotics and Intelligent Systems (ARIS). Piscataway: IEEE, 2023: 1-6.

[10] Reinis Cimurs, Jin Han Lee, Il Hong Suh. Goal-oriented Obstacle Avoidance with Deep Reinforcement Learning in Continuous Action Space[J]. Electronics, 2020, 9 (3): 411.

[11] Lian Pengfei, Yuan Liang, Sun Lihui. Visual Navigation for Mobile Robots Based on Deep Reinforcement Learning[C]//2023 IEEE International Conference on Real-time Computing and Robotics (RCAR). Piscataway: IEEE, 2023: 650-656.

[12] Xue Honghu, Benedikt Hein, Mohamed Bakr, et al. Using Deep Reinforcement Learning with Automatic Curriculum Learning for Mapless Navigation in Intralogistics[J]. Applied Sciences, 2022, 12(6): 3153.

[13] Sunil Srivatsav Samsani, Husna Mutahira, Mannan Saeed Muhammad. Memory-based Crowd-aware Robot Navigation Using Deep Reinforcement Learning[J]. Complex & Intelligent Systems, 2023, 9(2): 2147-2158.

[14] 林俊强, 王红军, 邹湘军, 等. 基于DPPO的移动采摘机器人避障路径规划及仿真[J]. 系统仿真学报, 2023, 35 (8): 1692-1704.
Lin Junqiang, Wang Hongjun, Zou Xiangjun, et al. Obstacle Avoidance Path Planning and Simulation of Mobile Picking Robot Based on DPPO[J]. Journal of System Simulation, 2023, 35(8): 1692-1704.

[15] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms[EB/OL]. (2017-08-28) [2023-12-20]. https://arxiv.org/abs/1707.06347.

[16] Schulman J, Levine S, Abbeel P, et al. Trust Region Policy Optimization[C]//Proceedings of the 32nd International Conference on Machine Learning. Chia Laguna Resort: PMLR, 2015: 1889-1897.

[17] Mnih V, Adrià Puigdomènech Badia, Mirza M, et al. Asynchronous Methods for Deep Reinforcement Learning[C]//Proceedings of the 33rd International Conference on Machine Learning. Chia Laguna Resort: PMLR, 2016: 1928-1937.

[18] 夏家伟, 朱旭芳, 罗亚松, 等. 基于深度强化学习的无人艇轨迹跟踪算法研究[J]. 华中科技大学学报(自然科学版), 2023, 51(5): 74-80.
Xia Jiawei, Zhu Xufang, Luo Yasong, et al. Study on Trajectory Tracking Algorithm of Unmanned Surface Vehicle Based on Deep Reinforcement Learning[J]. Journal of Huazhong University of Science and Technology(Natural Science Edition), 2023, 51(5): 74-80.

[19] Xiao Xin, Feng Xinlong. Multi-object Pedestrian Tracking Using Improved YOLOv8 and OC-SORT[J]. Sensors, 2023, 23(20): 8439.

[20] Elena Pacchierotti, Henrik I Christensen, Patric Jensfelt. Evaluation of Passing Distance for Social Robots[C]// ROMAN 2006 - The 15th IEEE International Symposium on Robot and Human Interactive Communication. Piscataway: IEEE, 2006: 315-320.

[21] 孙立香, 孙晓娴, 刘成菊, 等. 人群环境中基于深度强化学习的移动机器人避障算法[J]. 信息与控制, 2022, 51 (1): 107-118.
Sun Lixiang, Sun Xiaoxian, Liu Chengju, et al. Obstacle Avoidance Algorithm for Mobile Robot Based on Deep Reinforcement Learning in Crowd Environment[J]. Information and Control, 2022, 51(1): 107-118.

中国知网 https://www.cnki.net