基于深度强化学习的改进RRT算法路径规划

梁秀满，刘子良*，刘振东
(华北理工大学 电气工程学院，河北 唐山 063210)

摘要：针对RRT算法在三维复杂场景中规划全局路径时存在规划效率低、安全性和实用性较差而无法满足无人机对飞行路径的安全需求，提出SAC深度强化学习算法与RRT算法融合的SAC-RRT算法。*设计基于SAC算法决策网络的目标点偏置策略和动态步长策略，降低RRT盲目性；设计随机点修正过程，根据决策网络输出动作优化随机点位置，改善路径安全性；设计精简步骤和平滑步骤，进一步提高路径安全性。*设计了不同复杂程度的三维场景，规划结果表明：SAC-RRT算法有效缩短了路径长度和规划时间，改善了路径的平滑性和安全性。

关键词：深度强化学习；SAC算法；RRT算法；无人机；三次B样条
中图分类号：TP18；TP391.9 文献标志码：A 文章编号：1004-731X(2025)10-2578-16
DOI: 10.16182/j.issn1004731x.joss.24-0494
引用格式: 梁秀满, 刘子良, 刘振东. 基于深度强化学习的改进RRT算法路径规划[J]. 系统仿真学报, 2025, 37(10): 2578-2593.
Reference format: Liang Xiuman, Liu Ziliang, Liu Zhendong. Path Planning of Improved RRT Algorithm Based on Deep Reinforcement Learning[J]. Journal of System Simulation, 2025, 37(10): 2578-2593.

Path Planning of Improved RRT Algorithm Based on Deep Reinforcement Learning

Liang Xiuman, *Liu Ziliang**, *Liu Zhendong*
(College of Electrical Engineering, North China University of Science and Technology, Tangshan 063210, China)

Abstract: To address the low planning efficiency, poor safety, and limited practicability of the RRT algorithm in global path planning within complex three-dimensional environments, which fail to meet the requirements of planning the safe flight path of UAVs, an improved SAC-RRT algorithm was proposed, which fused SAC deep reinforcement learning algorithm and RRT algorithm. *A target point bias strategy and a dynamic step size based on the SAC decision-making network were designed to reduce the blindness of RRT. A random point correction process was designed to optimize the position of random points based on actions from the decision network and improve the path safety. In addition, simplified and smooth steps were designed to further improve path safety.* Several 3D scenarios of varying complexity were designed, and the planning results show that the SAC-RRT algorithm reduces path length and planning time while improving path smoothness and safety.

Keywords: deep reinforcement learning; SAC algorithm; RRT algorithm; UAV; cubic B-spline

0 引言

无人机广泛应用于经济活动中，在物流运输、矿场勘探、灾害救援和视频摄影等应用场景中，通过安装对应机载设备可满足行业应用需求。不断拓宽的无人机用途对无人机的自主巡航能力有

收稿日期：2024-05-08 修回日期：2024-09-12
基金项目：河北省自然科学基金(F2018209289)
第一作者：梁秀满(1973-)，女，副教授，硕导，硕士，研究方向为机器学习、强化学习等。
通信作者：刘子良(1993-)，男，硕士生，研究方向为强化学习及应用等。

中国知网 https://www.cnki.net

了更高要求。无人机自主巡航需要规划安全可行的路径，按照规划范围不同，路径规划分为全局路径规划和局部路径规划。在大范围复杂场景中规划路径时场景范围大、规划耗时、障碍物密集，造成规划安全路径困难，对规划算法的规划效率和表现提出较高要求[1]。目前主流路径规划算法包括传统算法和启发式算法。传统算法中Dijkstra算法[2]结构简单，但规划效率低；A*算法[3]设计了启发函数，提高了搜索效率，但规划时计算量较大，规划复杂全局路径效率较差；概率路线图算法[4]结构简单且具有概率完备性，但规划合理路径需要大量搜索时间。启发式算法中GA[5]全局搜索能力强、鲁棒性好，但规划结果受早熟问题的严重影响；PSO[6]参数少、搜索速度快、鲁棒性强，但局部最优问题影响较大；AFP[7]结构简单、规划速度快，但容易陷入局部最小值陷阱。基于强化学习的智能规划算法通过训练学习决策策略，具有较高智能而受到极大关注。黄岩松等[8]针对自动引导小车的多起点多目标任务路径规划问题，基于DQN设计全局路径求解器，能够在设计的多种地图上得到较好的路径结果，且有较好地泛化能力。周治国等[9]提出了T-DQN算法，结合LSTM和DQN算法用于处理水面特殊环境的舰艇避障路径规划任务，强化学习算法规划结果的表现更为合理。目前，基于强化学习的路径规划算法面临动作与状态空间规模过大问题，往往采用地图栅格化处理，因此规划速率较低，同时路径平滑性差。RRT算法[10]结构简单、搜索速度快且具有概率完备性，无需对环境建模，适用于大范围复杂场景快速规划，但RRT算法基于随机均匀采样，有较强的盲目性，规划结果平滑性低，性能表现不稳定。相关研究针对RRT算法的缺陷做出改进。Kuffner等[11]对RRT算法的搜索维度作出拓展，提出双向扩展随机树算法(RRT-Connect)，以起点和目标点为搜索树根节点，进行双向搜索，提升了搜索速度，但规划结果有较多冗余节点，实用性较差；Karaman等[12]针对RRT算法结果非最优问题提出RRT*算法，采用依据评价函数来重构路径，使规划结果渐进最优，但寻优过程需要花费大量时间。上述改进算法从不同角度出发，较大提升了RRT算法规划性能。Klemm等[13]结合RRT*算法和RRT-Connect算法提出了RRT*-Connect算法，首先，吸收了RRT*算法的父节点重选和重新布线的寻优策略，然后，结合了RRT-Connect算法的双向搜索过程，改进算法能够快速搜索接近最优路径的结果。王冠强等[14]针对RRT-Connect盲目性问题，将RRT-Connect同人工势场法结合，利用人工势场引导采样点拓展方向，降低了盲目性，提升了复杂室内中的规划效率并缩短了路径长度。针对RRT盲目性问题和动力学效果差问题，Chiang等[15]结合RRT算法和强化学习理论提出RL-RRT算法，通过强化学习分别训练避障策略和时间预测策略，依据对避障规划路径和路径耗时的代价估计结果，对规划结果进行筛选，改善了RRT算法的规划效果。

上述研究从最优性和规划效率出发，对RRT算法做出改进，但用于无人机路径规划任务时，规划结果有冗余点较多、平滑性差、安全性低等不足。本文提出SAC-RRT算法，主要包括SAC算法[16]融合和改进RRT算法2部分。针对RRT算法缺陷，引入目标偏向拓展策略、动态步长策略和随机点修正过程的改进策略；通过训练SAC算法得到决策模型，用于自适应设定改进策略参数，提高改进RRT算法的灵活性；设计路径剪枝和平滑优化过程，提升路径安全性和实用性。

1 规划问题描述

1.1 约束条件

针对传统四旋翼无人机，需要考虑无人机的性能约束，本文主要考虑的约束因素：

(1) 最大续航里程约束。无人机一旦超过当前运行状态下所能允许的最大路程将无法返回，设定无人机最大路程为$\max L$。

中国知网 https://www.cnki.net

(2) 最小飞行距离约束。处于飞行状态的无人机需要一定飞行过程来实现姿态转换，将这个距离作为最小飞行距离 $\min L$。任意一段路径 L_i 的长度满足 $L_i \geqslant \min L$。

(3) 最大姿态角约束。无人机的姿态角包含俯仰角、偏航角和滚动角。设无人机允许的最大转弯角为 $\theta_{\max}$，三维空间坐标系中，路径点坐标为 (x_i, y_i, z_i)，路径段为 $\boldsymbol{\alpha}_i=(x_i-x_{i-1}, y_i-y_{i-1}, z_i-z_{i-1})$，此时无人机的最大姿态角约束关系为

$$\frac{\boldsymbol{\alpha}_i^{\mathrm{T}}\boldsymbol{\alpha}_{i+1}}{|\boldsymbol{\alpha}_i||\boldsymbol{\alpha}_{i+1}|} \geqslant \cos\theta_{\max},\quad i=1,2,\cdots,n \tag{1}$$

1.2 优化目标

本文主要考虑的优化目标：

(1) 成本消耗最小。无人机执行任务时需要消耗资源，例如，任务时间、燃料成本花费等。

(2) 收益优化。在单次无人机起降中，无人机能够完成更多任务时收益更高。

(3) 性能优化。规划结果符合无人机自身性能。

(4) 避障风险。无人机能躲避威胁区、障碍区。

2 理论介绍

2.1 快速搜索随机树

RRT 算法基于空间随机采样规划路径，具有概率完备性，算法简单，针对多障碍物场景可以快速规划可行路径，广泛应用于地面机器人、无人机的轨迹规划任务。

图 1 为 RRT 算法基本搜索过程：X_{init} 为随机搜索树的起始点，首先，在搜索空间中随机均匀采样得到随机点 X_{rand}，然后，在搜索随机树上查找距离 X_{rand} 最近节点 X_{nearest}，并将 X_{nearest} 和 X_{rand} 的连线方向作为树的拓展方向，拓展设定步长长度得到 X_{new}，如果 X_{new} 处于障碍物之外并且还未包含于随机树上，则加入随机树中。通过重复上述过程，当目标点 X_{goal} 存在于随机树中或 X_{new} 与 X_{goal} 之间的连线没有与障碍物等区域碰撞时，则得到了可行结果，此时路径规划完成。

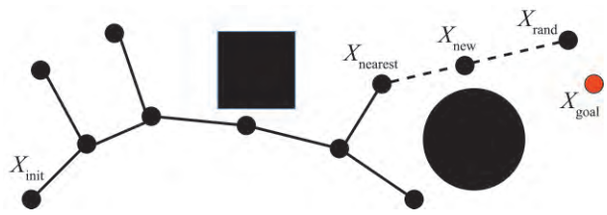


图 1 RRT 算法
Fig. 1 RRT algorithm

RRT 算法盲目性强，规划结果有冗余路径节点、路径平滑性差，无法满足无人机飞行需求。

2.2 深度强化学习

强化学习通过智能体与环境的交互过程训练策略网络，寻找决策策略，目的是使决策过程中的累计回报最大。智能体与环境交互过程可以用 MDP[17] 表示，描述为一组五元组 $\langle S, A, R, \pi, \gamma \rangle$，$S$ 为状态空间，表示智能体的状态集合；A 为动作空间，表示智能体的动作集合；R 为累计回报；π 为决策策略，用于输出智能体动作；γ 为折扣因子。对于具有复杂状态空间和动作空间学习任务，强化学习很难训练得到较好的决策策略。深度强化学习通过在原有的强化学习算法结构上引入神经网络结构，有效提升了对非线性奖励函数和非线性策略的拟合能力，能够处理连续型数值的状态动作问题。AC[18] 框架为深度强化学习理论中重要的算法结构，由 Actor 网络和 Critic 网络组成。Actor 网络用于接受状态信息、拟合强化学习的决策模型和输出决策动作；Critic 网络通过价值函数评估 Actor 网络的价值，用于训练网络过程。在此基础上，SAC 算法结合了最大熵模型、随机策略和离线训练过程，算法鲁棒性好，训练速度快，算法结构如图 2 所示[19]，具有 1 个 Actor 网络、2 个 Critic 网络和 2 个 Critic-Target 网络。Actor 根据输入状态输出动作分布，同时得到策略的熵，Critic 用于评估动作值，Critic-Target 网络用于评估当前状态值。

中国知网 https://www.cnki.net

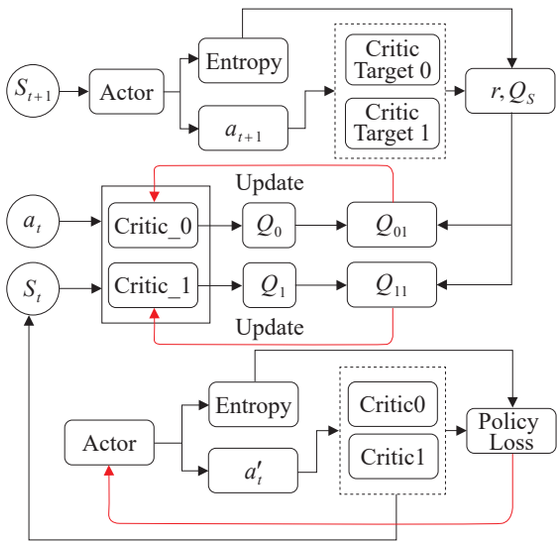


图2　SAC网络结构
Fig. 2　SAC network structure

SAC强化学习理论中，策略熵为

$$H(\pi(\cdot|S_t))=E_{x\sim P}[-\log p(\pi(\cdot S_t))] \tag{2}$$

式中：$\pi(\cdot|s_t)$为策略。引入策略熵后，SAC算法将强化学习问题转变为求解目标函数式(3)和目标策略式(4)的问题。

$$J(\pi)=\sum_{t=0}^{T}E_{(s_t,a_t)\sim\rho_\pi}[r(s_t,a_t)+\alpha H(\pi(\cdot|S_t))] \tag{3}$$

$$\pi^*_{\max}=\arg\max_{\pi}\sum_{t=0}^{T}E_{(s_t,a_t)\sim\rho_\pi}[r(s_t,a_t)+\alpha H(\pi(\cdot|S_t))] \tag{4}$$

式中：ρ_π为在策略π决策下，智能体可能处于的状态动作对所服从的分布；α为温度系数超参数，用于调整熵值比重。结合最大熵模型后，SAC算法在寻找最优策略的同时，可以兼顾寻找最大回报和最大熵2个目标，使Actor网络输出动作的分布更加均匀，同时鼓励搜索更多近优策略，因此，SAC算法在连续控制任务上有优秀表现。

3　SAC-RRT算法

文献[20]针对DWA提出了基于模糊控制决策的自适应改进方法，在不同场景中灵活设定DWA算法评价函数系数，提升算法整体表现。SAC-RRT算法通过将规划问题建模为强化学习问题，灵活设定RRT改进策略，提升算法的自适应能力。SAC-RRT算法框架如图3所示。决策模型用于处理采样点处观测数据；改进RRT算法负责接受决策动作和规划路径；优化步骤用于提升规划结果表现。

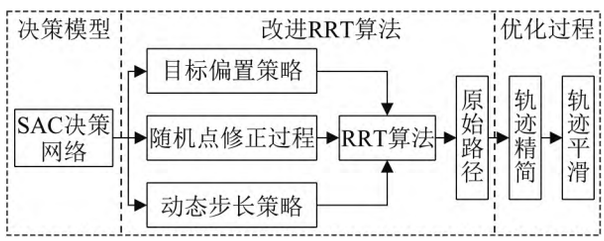
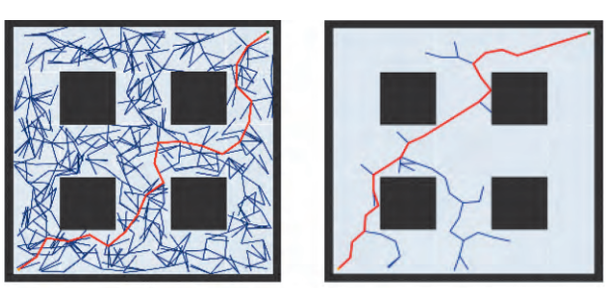


图3　SAC-RRT算法结构
Fig. 3　Structure of SAC-RRT algorithm

3.1　改进策略

针对RRT算法的缺陷，引入目标点偏置策略、随机点修正过程、动态步长策略的改进策略。

(1) 目标点偏置策略。由图4可以看出，RRT算法规划的路径曲折且有冗余，引入目标偏置后的规划结果大幅减少了冗余路径，同时平滑性有所提高。



(a) 无目标偏置　　(b) 引入目标偏置

图4　目标点偏置策略
Fig. 4　Target point bias strategy

目标点偏置策略操作过程为在拓展过程中，依据概率将目标点作为拓展方向。SAC-RRT算法通过随机均匀采样和依据目标点2种方式获得随机点。在复杂空间中搜索可行路径时，算法根据障碍物情况，将规划过程分为避障过程和指向目标点路径搜索过程，在不同搜索过程中，依据场景状态信息对偏置程度做出合理设定，实现更加

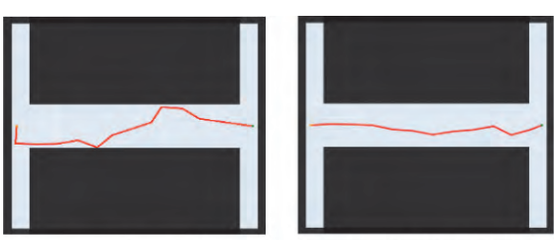
中国知网　https://www.cnki.net

灵活的避障和规划过程。结合构建强化学习框架需求，将当前采样点有限范围内的障碍物情况和采样点数作为状态空间元素，目标点偏置概率P_{sac}作为动作空间元素，生成随机点：

$$X_{rand}=\begin{cases}X_{goal}, & P_{rand}>P_{sac}\\ X_{rand}(), & P_{rand}\leqslant P_{sac}\end{cases} \tag{5}$$

式中：P_{rand}为随机概率，由系统随机生成；$X_{rand}()$为随机点生成函数；X_{rand}为随机点。

(2) 随机点修正过程。随机点生成后，与最近点有关的距离、角度等状态也随之确定。结合随机点有关状态信息，通过随机点修正过程对随机点的状态进行优化，可以改善规划表现。最近点处转角作为状态空间元素，输出修正距离r为动作空间元素。由图5可以看出，结合随机点修正过程后的规划结果更加平滑，同时与障碍物保持了较大的安全距离。



(a) 无修正过程　　(b) 引入修正过程

图5　随机点修正过程

Fig. 5　Random point correction process

根据修正距离r得到修正随机点的过程如图6所示，以随机点X_{rand1}为圆心，以r为半径构建空间并作为新的采样空间，在此空间中再次通过随机点生成函数生成候选随机点X_{rand2}。以是否能改善平滑性做出选择。选择函数为

$$X_{rand}=\begin{cases}X_{rand1}, & R_1\geqslant R_2\\ X_{rand2}, & R_1<R_2\end{cases} \tag{6}$$

式中：R_1和R_2为2个转角值，由$X_{nearest}$为顶点，X_{rand1}或X_{rand2}为连接点构成。图6中R_2角度数值大于R_1角度数值，以X_{rand2}为随机点时路径更加平滑。

(3) 动态步长。RRT算法的步长为固定值。由图7可以看出，采用较小步长规划的结果有较多采样点，平滑性一般，采用较大步长规划的结果平滑性差，同时采样失败次数增加。

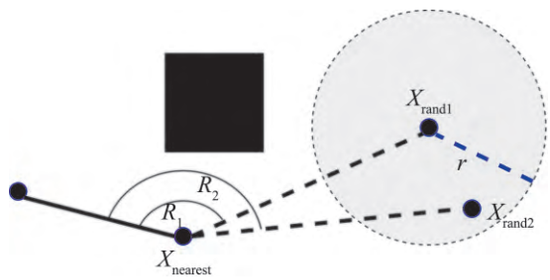
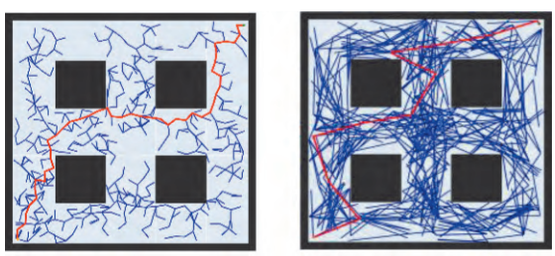


图6　修正随机点过程

Fig. 6　Random point correction process



(a) 步长过小　　(b) 步长过大

图7　动态步长

Fig. 7　Dynamic step

SAC-RRT算法根据场景属性灵活设定动态步长，更能提高规划表现。将采样点与最近障碍物之间距离矢量值、随机点与采样点之间距离矢量值作为状态空间元素。在训练决策模型过程中，当存在障碍物时，根据式(7)计算步长：

$$d_{step}=\begin{cases}L_{step}, & L_{obs}>L_{soft}\\ L_{soft}, & L_{obs}\leqslant L_{soft}\end{cases} \tag{7}$$

式中：d_{step}为采样步长；L_{step}为决策输出的动态步长；L_{obs}为当前采样点与最近障碍物最小距离；L_{soft}为最小安全距离。

在规划路径过程中，考虑有限观测范围内障碍物情况和最小安全距离，当不存在障碍物时，步长为最大观测半径O_r。

3.2　强化学习模型构建

图8为SAC-RRT算法训练流程。实际规划过程中，深度强化学习部分负责接受状态信息以及动作输出，结合改进策略的RRT规划算法负责接受

中国知网　https://www.cnki.net

动作和规划路径，决策模型的具体训练过程如下：

步骤1：初始化经验池、环境状态S、动作A、SAC策略网络和图2所示网络结构，随机赋值改进策略参数，复位规划环境。

步骤2：首先，SAC策略网络根据当前环境状态S_t输出当前决策动作A_t。然后，改进RRT算法接受动作A_t，依据式(5)计算随机点，依据式(6)修正随机点，依据式(7)决定新采样点位置，得到此次规划过程的路径。此时，环境状态进入S_{t+1}，在更新状态过程中，根据奖励函数计算决策动作A_t的奖励值，收集上述状态信息，组成经验(S_t, A_t, R_t, S_{t+1})，储存到经验池。

步骤3：通过重复执行步骤2填充经验池，收集经验过程中不会更新神经网络参数。

步骤4：当经验池里的样本达到设定阈值时，首先，从经验池随机抽取设定的批采样数量样本数，然后，通过损失函数计算误差，并在反向传播步骤中通过梯度下降过程更新神经网络参数。

步骤5：通过重复执行步骤2~4，实现训练策略网络的目的，当奖励最终收敛稳定时，SAC策略网络学习到了当前环境下最优决策策略。

SAC-RRT算法依据马尔可夫决策过程对规划问题建模。

(1) 状态S

状态空间是网络训练和决策的数据来源。根据设定和改进需要，状态空间为

$$S=\{P_{\text{goal}}, P_{\text{obs}}, P_{\text{r}}, D_{\text{obs}}, N_{\text{p}}, \theta\} \tag{8}$$

式中：P_{goal}为采样点到目标点距离矢量；P_{obs}为采样点到障碍物距离矢量；P_{r}为随机点与采样点之间距离矢量；D_{obs}为有限范围内障碍物状态；N_{p}为有限范围内采样点数；θ为采样点处角度信息。

(2) 动作空间A

智能体可选动作集合，决策模型输出动作用于参与改进RRT算法的规划过程，为连续型数值。动作空间为

$$A=\{P_{\text{sac}}, r, L_{\text{step}}\} \tag{9}$$

式中：P_{sac}设定范围为(0, 1)；r设定范围为$(0, O_{\text{r}})$；L_{step}设定范围为(5, 35)。

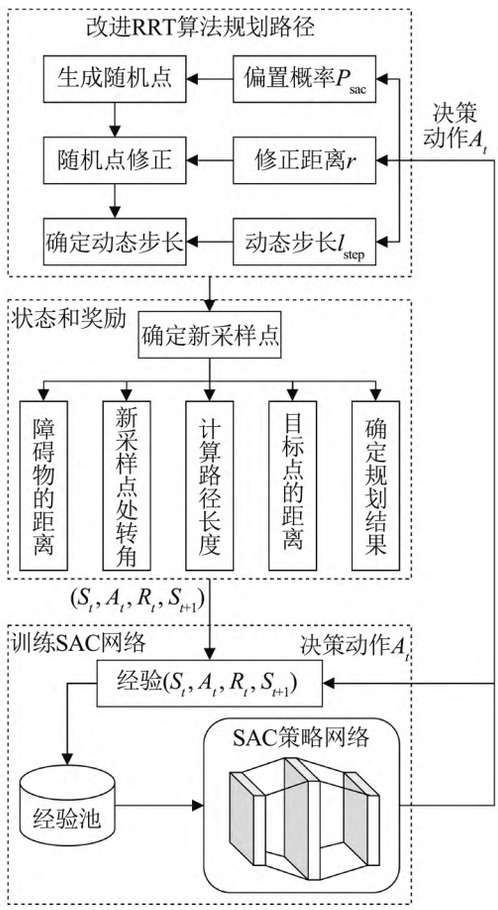


图8 训练过程
Fig. 8 Training process

(3) 奖励函数R

RRT算法的搜索过程为连续的采样规划过程，为避免因稀疏奖励造成训练困难，分别针对每次采样过程和最后的规划状态设定奖励函数。结合约束条件、优化目标和改进需求，具体奖励函数组成：

1) 避障奖励：可行的飞行路径需要与障碍物保持安全距离。

$$r_{\text{t}}=\begin{cases}0, & L_{\text{obs}}\geqslant L_{\text{soft}}\\ P^{\text{o}}_{\max}\dfrac{|L_{\text{soft}}-L_{\text{obs}}|}{|L_{\text{soft}}-L_{\text{w}}|}, & L_{\text{soft}}>L_{\text{obs}}>L_{\text{w}}\\ P^{\text{o}}_{\max}, & L_{\text{w}}\geqslant L_{\text{obs}}\end{cases} \tag{10}$$

式中：L_{w}为警告距离；$P^{\text{o}}_{\max}$为惩罚值。

2) 平滑奖励：对路径平滑程度做出评价。

中国知网 https://www.cnki.net

$$r_{\mathrm{m}}=\begin{cases}0, & \theta_{\mathrm{sta}}\geqslant\theta\\ P_{\max}^{\theta}\dfrac{|\theta-\theta_{\mathrm{sta}}|}{|\theta_{\max}-\theta_{\mathrm{sta}}|}, & \theta_{\max}>\theta>\theta_{\mathrm{sta}}\\ P_{\max}^{\theta}, & \theta\geqslant\theta_{\max}\end{cases}\tag{11}$$

式中：$\theta_{\max}$为最大转角；θ_{sta}为惩罚起始角度；$P_{\max}^{\theta}$为设定惩罚值，路径采样点的转角为θ。

3) 导航奖励：为避免训练为贪婪策略，将靠近时给予奖励转变为远离目标点时给予惩罚。

$$r_{\mathrm{g}}=\begin{cases}0, & L_{\mathrm{goal}}\geqslant L_{\mathrm{goal}}^{\mathrm{o}}\\ P_{\mathrm{goal}}, & L_{\mathrm{goal}}<L_{\mathrm{goal}}^{\mathrm{o}}\end{cases}\tag{12}$$

式中：L_{goal}为当前采样点到目标点的距离；$L_{\mathrm{goal}}^{\mathrm{o}}$为上一次测量的距离；$P_{\mathrm{goal}}$为惩罚值。

4) 路程奖励：根据规划结果情况，当规划失败时，路程奖励r_{l}取值为0；规划成功时，路程奖励函数为

$$r_{\mathrm{l}}=\begin{cases}P, & L<L_{\min}\\ 0, & L_{\min}\leqslant L\leqslant\max L\\ -P_{\mathrm{l}}, & \max L<L\end{cases}\tag{13}$$

式中：L为当前轨迹长度；$L_{\min}$为规划结果中目前最小路程；$\max L$为最大路程约束；P_{l}为奖励值。

5) 结果奖励：每次规划结束后根据是否得到可行路径计算。

$$r_{\mathrm{e}}=\begin{cases}P_{\mathrm{s}}, & \text{成功}\\ P_{\mathrm{f}}, & \text{失败}\end{cases}\tag{14}$$

式中：P_{s}为奖励值；P_{f}为惩罚值。

总奖励为

$$r_{\mathrm{all}}=r_{\mathrm{t}}+r_{\mathrm{g}}+r_{\mathrm{m}}+r_{\mathrm{l}}+r_{\mathrm{e}}\tag{15}$$

3.3 优化过程

(1) 轨迹精简

轨迹结果依然有冗余节点和尖锐转角，通过轨迹精简步骤去除冗余节点，使规划结果趋向于最优规划结果并减少平滑过程计算量，如图9所示。

步骤1：输入路径$path=[p_0,p_1,\cdots,p_n]$，$p_i$为轨迹第$i$个路径点，设定安全距离为$r_{\mathrm{soft}}$。

步骤2：输入路径点p_i与p_{i+1}，以(p_i,p_{i+1})作为起始搜索路径。

步骤3：以采样点p_{i+n}为待检测点p_{test}，其中$n-i>2$。

步骤4：检测$(p_{\mathrm{test}},p_{i+1})$与障碍物的距离$r_{\mathrm{o}}$，如果满足$r_{\mathrm{o}}>r_{\mathrm{soft}}$则进入下一步，否则执行步骤6。

步骤5：p_{i+n}通过检测，将p_{i+n+1}设定为待检测点，p_{i+n+1}为终点时执行步骤7，否则执行步骤4。

步骤6：路径点p_{i+n}没有通过检测将(p_{i+n-1},p_{i+n})记录到原精简路径，组成新精简路径$(p_1,p_2,\cdots,p_i,p_{i+1},\cdots,p_{i+n-1},p_{i+n})$，输入$p_{i+n-1}$与$p_{i+n}$，以$(p_{i+n-1},p_{i+n})$作为新搜索路径，将$p_{i+n+2}$设定为$p_{\mathrm{test}}$，如果$p_{i+n+2}$为终点则执行步骤7，否则执行步骤4。

步骤7：规划结束，输出精简路径。

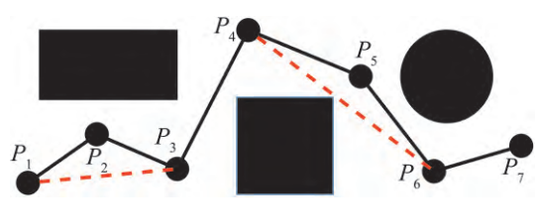


图9 路径精简
Fig. 9 Path refinement

(2) 轨迹平滑

路径的平滑程度影响无人机飞行安全。通过B样条[21]平滑轨迹的特点：①无需整体重规划即可改变局部轨迹；②B样条有良好的递推性质。k阶B样条计算式为

$$B_t=\sum_{i=0}^{n}P_iN_{i,k}(t)\tag{16}$$

式中：B_t为节点间曲线；k为B样条曲线阶数；P_i为此线段控制点；$N_{i,k}(t)$为此段对应基函数。对于三阶B样条，第i段路径的平滑曲线为

$$\boldsymbol{B}_t=1/6\,[t^3\ \ t^2\ \ t\ \ 1]\begin{bmatrix}-1 & 3 & -3 & 1\\ 3 & -6 & 3 & 0\\ -3 & 0 & 3 & 0\\ 1 & 4 & 1 & 0\end{bmatrix}\begin{bmatrix}P_i\\ P_{i+1}\\ P_{i+2}\\ P_{i+3}\end{bmatrix},1\geqslant t\geqslant 0\tag{17}$$

3.4 SAC-RRT 规划流程

图10为SAC-RRT算法流程。

中国知网 https://www.cnki.net

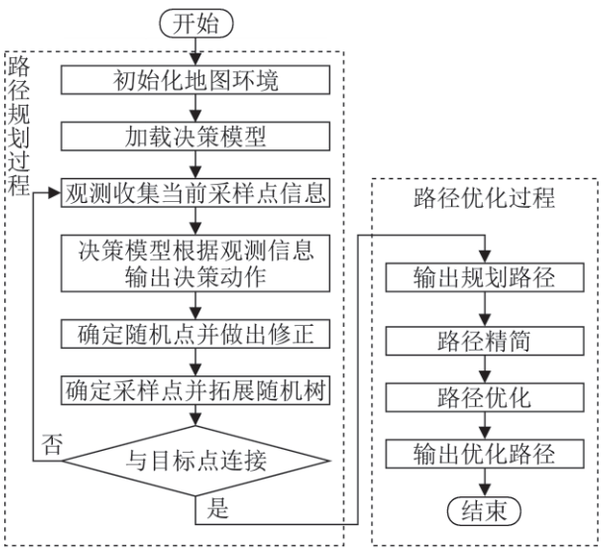


图10　规划流程
Fig. 10　Planning process

4　仿真验证

为验证算法的性能，设计三维场景，实验基于 Python 设计，处理器 AMD Ryzen™ 53600，RAM为16 GB。仿真中无人机表示为质点，无人机以匀速运动，设定最大采样数3 000，最大观测半径$O_r=10$。设计地图尺寸为(100, 100, 100)，不同障碍物数为n。

4.1 收敛性验证

各参数设定如表1~3所示。

表1　环境参数设定
Table 1　Environmental parameter setting

L_{max}	L_{min}	L_{soft}	L_w	θ_{max}/(°)	θ_{star}/(°)
300	1	5	2	65	45

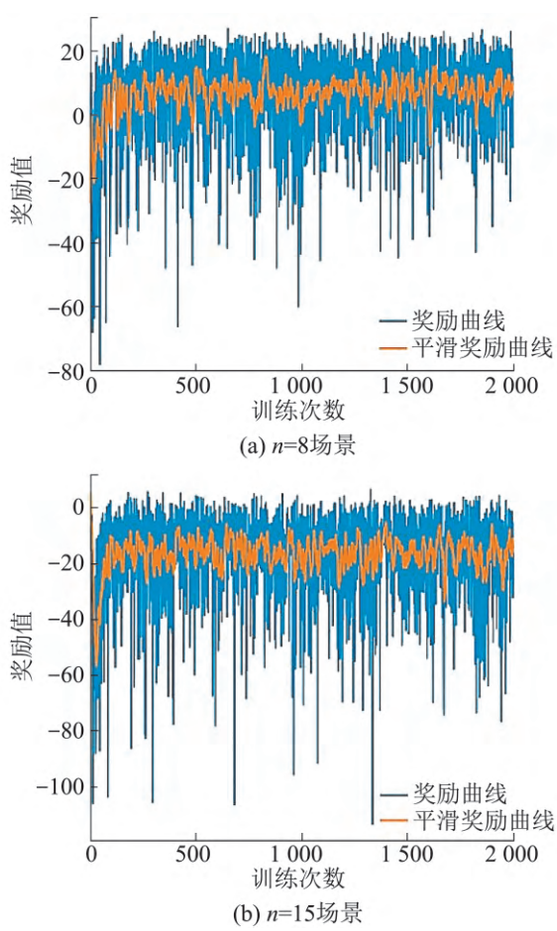
表2　SAC奖励参数
Table 2　SAC reward parameters

P_s	P_f	P_L	P_{max}^{θ}	P_{goal}	P_{max}^{o}
10	−20	5	−0.1	−0.1	−0.1

图11为SAC-RRT算法在障碍物数n=8和n=15场景中进行2 000次训练后奖励。以第200次训练作为分界线，之前部分为训练上升阶段，相较于上升阶段，之后的曲线数值维持在一定范围内波动，这部分曲线为相对平稳阶段。在上升阶段不同场景中，平滑奖励曲线均以较快速度达到某一数值并围绕其上下波动，在相对平稳阶段，平滑奖励曲线分别围绕不同数值保持在一定范围内上下波动，平滑奖励曲线结果证明了SAC-RRT算法在不同场景的收敛性并能够快速搜索到近优策略，达到平稳状态。

表3　SAC网络超参数
Table 3　SAC hyperparameters

参数名称	数值
演员网络学习率	0.003
评论家网络学习率	0.003
软更新参数	0.005
温度参数	0.8
折扣系数	0.97
每回合采样数量	128
训练最大回合数	3 000
经验池容量	100 000



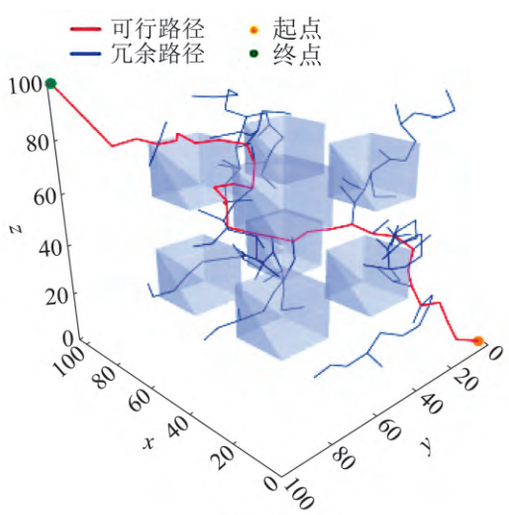
(a) n=8场景
(b) n=15场景

图11　训练奖励曲线
Fig. 11　Training reward curves

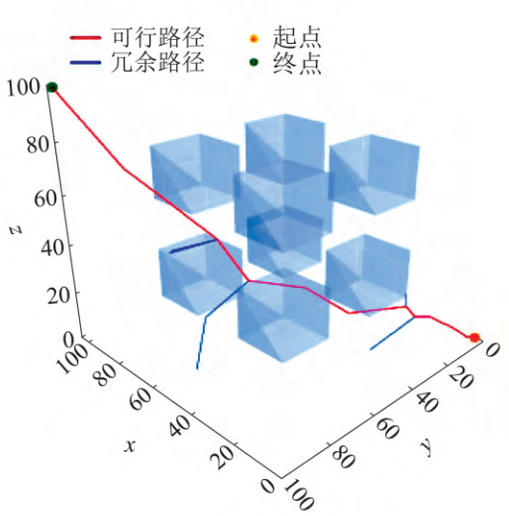
中国知网　https://www.cnki.net

4.2 规划性能验证

设计地图起始点为(5, 5, 5)，目标点为(95, 95, 95)。图 12 为不同算法的规划结果，表 4 为在 n=8 均匀分布场景中 50 次实验数据的均值。图 12(a)中有较多冗余路径和节点，RRT 算法由于随机采样过程需要对空间进行足够探索，因此路径平滑差，安全性低。图 12(b)规划结果冗余路径更少，平滑性更好。由表 4 可知，本文算法降低了规划时间，路径长度缩短了 5.8%，减少了路径点数和采样数，盲目性更低。



(a) RRT算法



(b) SAC-RRT算法

图 12　规划结果

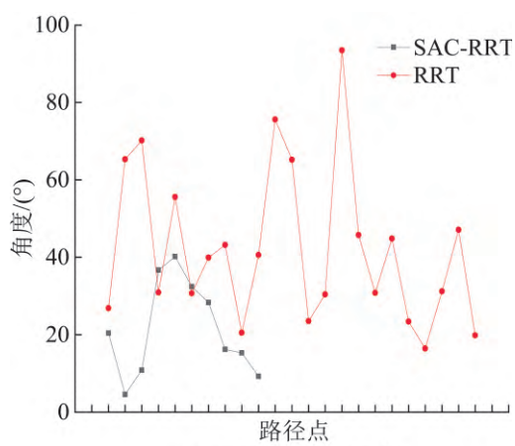
Fig. 12　Planning path results

表 4　数据对比

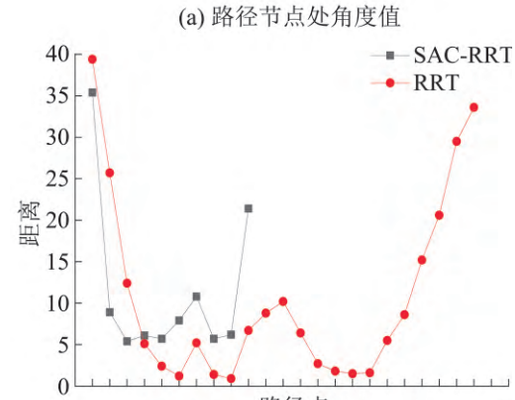
Table 4　Data comparison

算法	时间/s	长度	节点数	采样数
RRT	7.41	243.61	25	136
SAC-RRT	3.24	229.54	12	37

由图 13(a)和图 12(b)可知，SAC-RRT 算法规划结果更加平缓。由图 13(b)可知，SAC-RRT 算法路径最小距离为 5.1，而 RRT 算法结果最小距离为 0.4，改进算法保持更大的距离，安全性更好。



(a) 路径节点处角度值



(b) 路径节点与障碍物距离

图 13　n=8 场景中路径节点状态

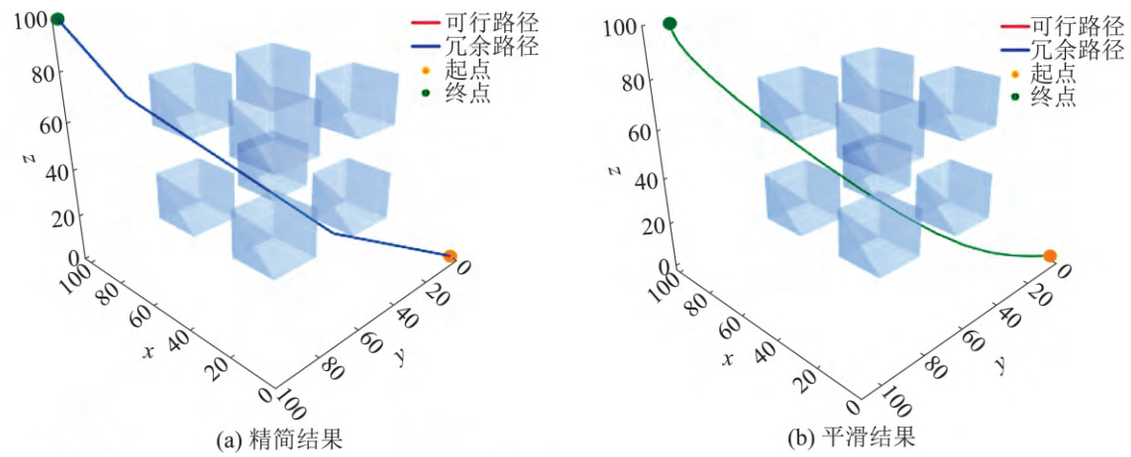
Fig. 13　Path node status in scenario with n = 8

图 14(a)为精简后的路径，路径长度缩短为 184.3，路径点数减小为 2，与 RRT 算法相比，路径长度缩短 19.7%，减少了路径点数。图 14(b)为经过平滑过程后路径，通过 B 样条对精简结果平滑处理，改进了路径平滑程度，提升了路径安全性。

中国知网　https://www.cnki.net

为进一步验证算法性能，分别在 n=8 和 n=15 场景中与 RRT、RRT-Connect 和 RRT*-Connect 仿真对比，并记录 50 次实验数据。

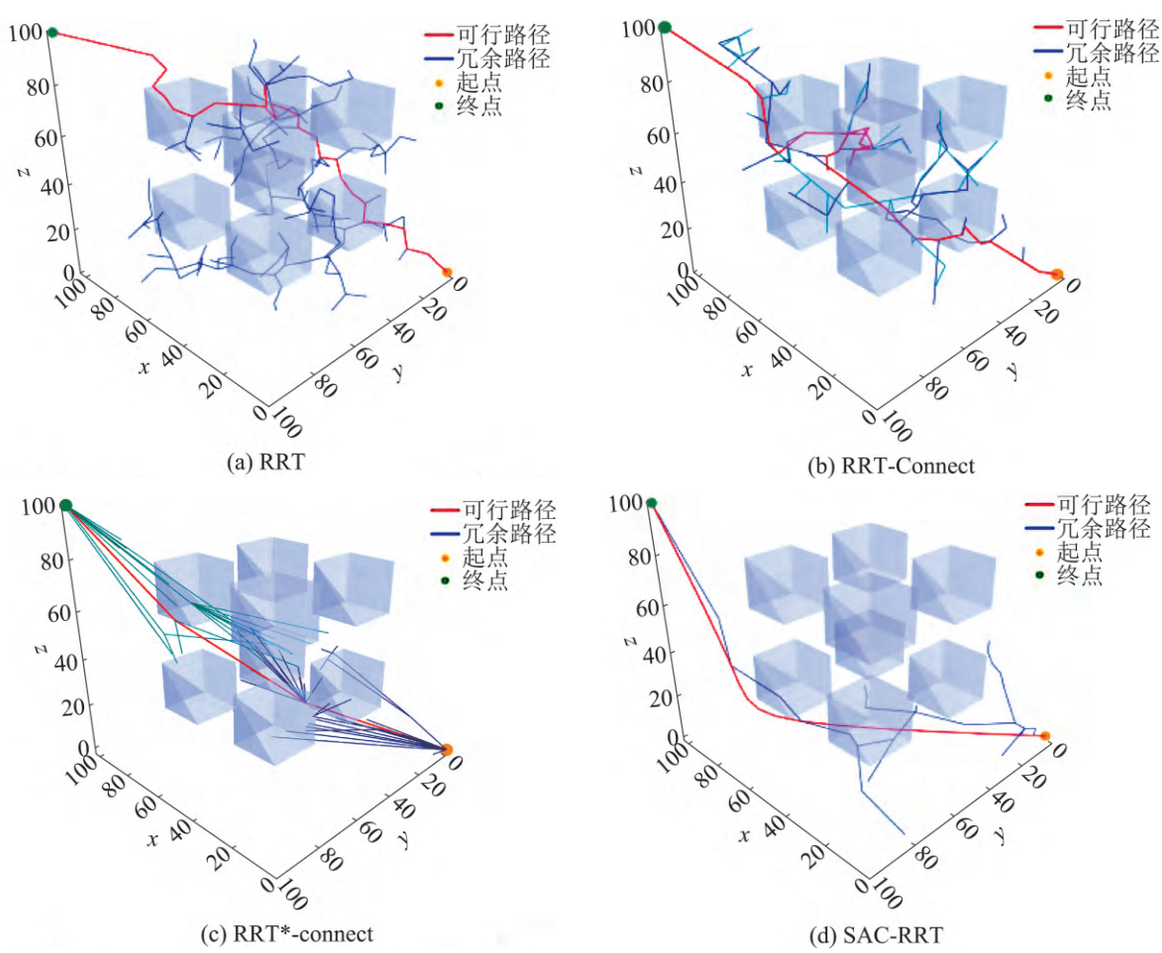
图 15 为在 n=8 简单场景中 SAC-RRT 算法和对比算法结果，本文算法的规划结果冗余路径更少，平滑性更高。各算法性能数据如表 5 所示。



(a) 精简结果　(b) 平滑结果

图 14　优化步骤

Fig. 14　Optimization steps



(a) RRT　(b) RRT-Connect

(c) RRT*-connect　(d) SAC-RRT

图 15　n=8 场景规划结果

Fig. 15　Planning results in scenario with n = 8

中国知网　https://www.cnki.net

表5　n=8场景数据对比

Table 5　Comparison of data in scenario with n = 8

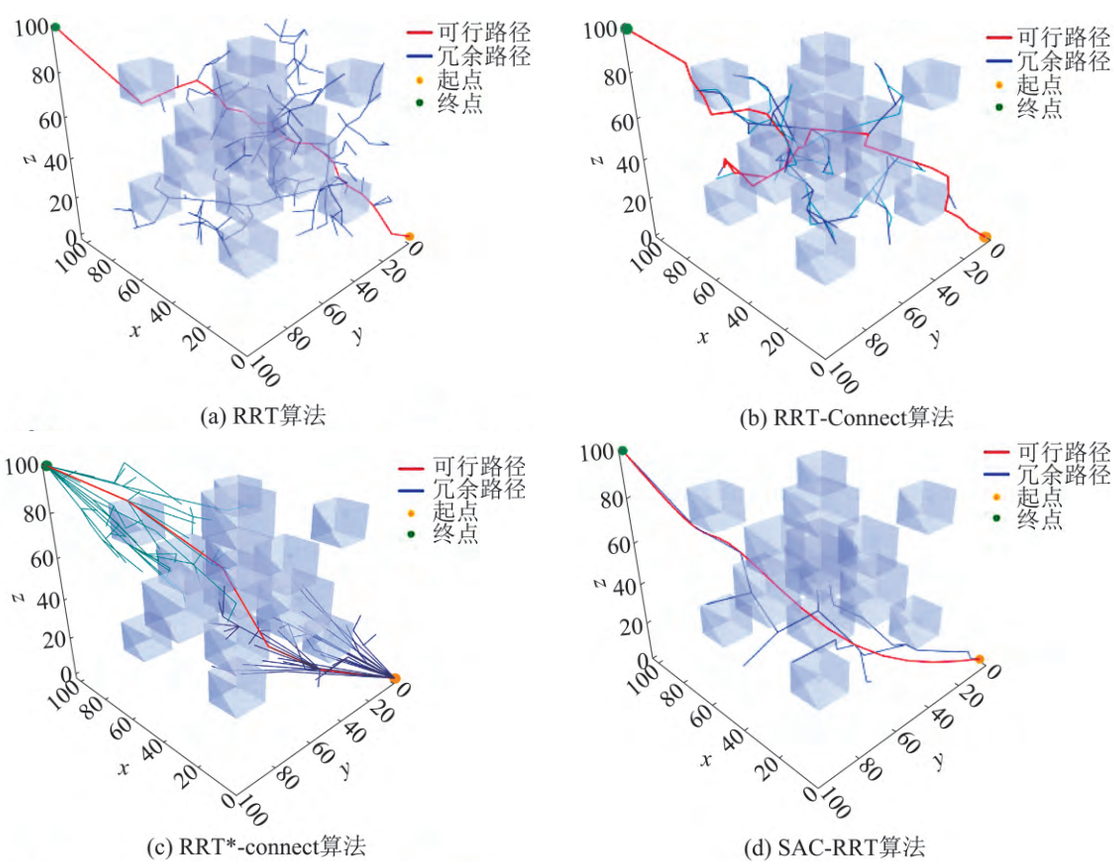
算法	时间/s	长度	节点数	采样数
RRT	7.81	237.01	25	136
RRT-Connect	4.96	262.25	33	46
RRT*-Connect	5.78	185.84	4	63
SAC-RRT	3.34	189.54	3	39

在规划时间上相较对比算法分别降低57.2%、32.7%、42.2%。在路径长度上比RRT和RRT-Connect各减少20%、27.7%，路径节点数减少。因为引入随机点修正策略，本文算法有更大概率规划远离障碍物路径，而非贴近障碍物的更短路径，路径长度相较RRT*-Connect变长，但因远离障碍物所以安全性高。

图16为SAC-RRT算法和对比算法在n=15复杂场景中的结果。SAC-RRT算法规划的结果冗余路径少，平滑性更高，证明在复杂场景中SAC-RRT算法盲目性低。各算法性能数据如表6所示。

SAC-RRT算法在规划时间上相较对比算法降低了63.3%、25.9%、42.4%，同时路径节点数更少，在路径长度方面，对比RRT和RRT-Connect各减少24.7%、30.2%。分析可知，在障碍物密集场景中，观测半径O_r内检测到障碍物的概略更大，对此情况，SAC-RRT算法更偏向于保守决策以满足安全需求，因此在路径长度上有所增加。

图17为不同n值实验算法性能数据。路径长度方面，对比RRT算法和RRT-Connect算法，本文算法稳定性更好且均值更低，与RRT*-Connect处于同一表现水平。规划时间方面，本文算法整体上要优于对比算法，规划时间更短。结果表明，SAC-RRT算法盲目性更低，规划效率更高，稳定性更好，能够在更少的时间内输出路径长度短、平滑安全的规划结果。



(a) RRT算法　(b) RRT-Connect算法

(c) RRT*-connect算法　(d) SAC-RRT算法

图16　n=15场景规划结果

Fig. 16　Planning results in scenario with n=15

中国知网　https://www.cnki.net

表6　n=15场景规划结果数据对比
Table 6　Comparison of planning result data in scenario with n=15

算法	时间/s	长度	节点数	采样数
RRT	10.63	256.69	45	234
RRT-Connect	5.26	276.96	32	69
RRT*-Connect	6.77	186.73	5	83
SAC-RRT	3.9	193.34	5	46

为进一步评估本文算法的鲁棒性，设计在(100, 100, 100)尺寸的三维空间中，生成有一定数量障碍物但位置随机的规划场景，并设计不同规划路径起点，用于测试起点对算法规划性能的影响程度。

图18中设定起点1坐标为(5, 5, 5)，起点2坐标为(45, 45, 45)。在不同随机障碍物场景中，SAC-RRT算法规划结果平滑性更好。由表7数据可知，在不同起始点和障碍物数量场景中，本文算法在规划时间上用时少，路径长度接近最短。

图19为以起点1为规划起点不同n值随机场景中规划结果。本文算法在连续多次规划过程中，在规划时间和路径长度较为稳定，性能表现接近最优。本文算法在动态随机地图中可以用更少的时间规划更优的结果且稳定性较好。

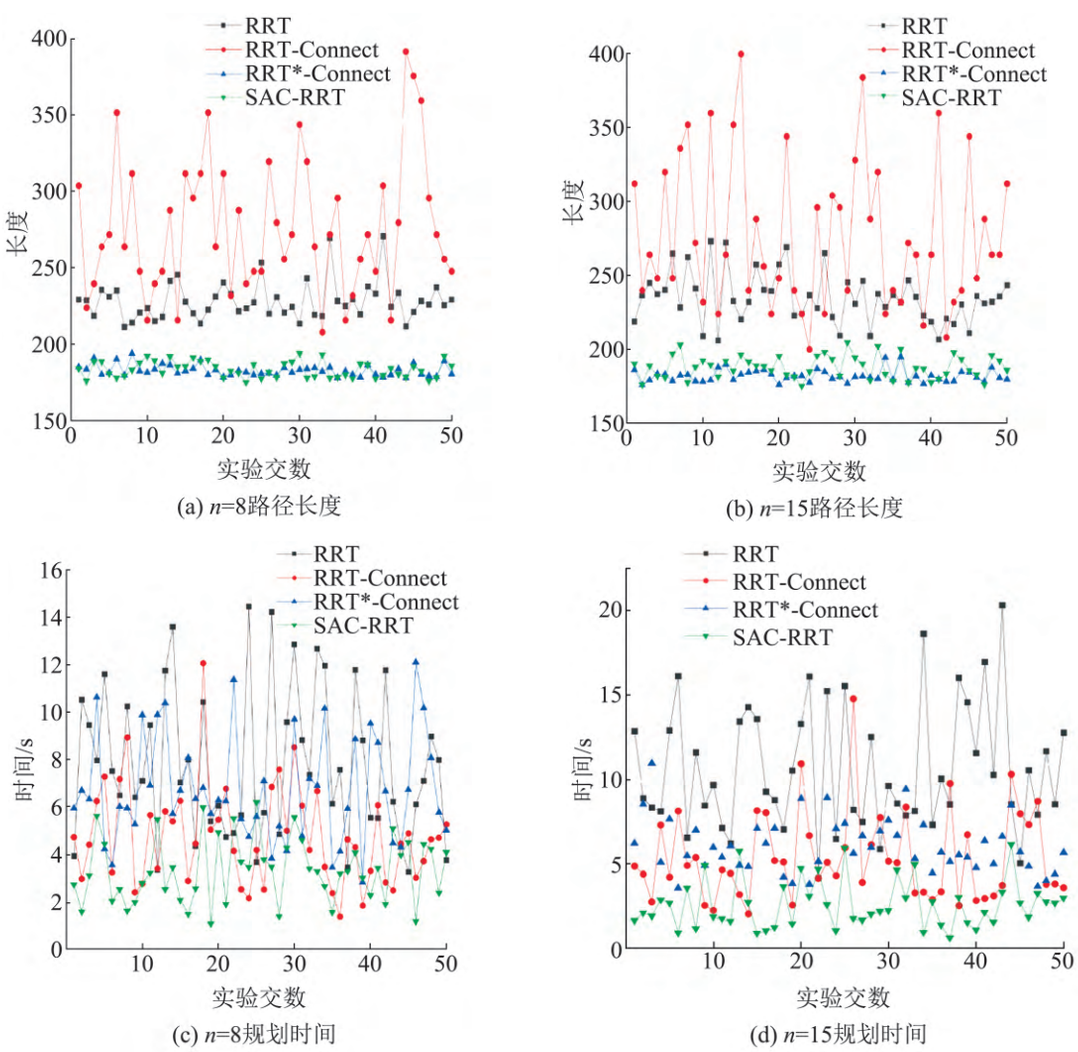
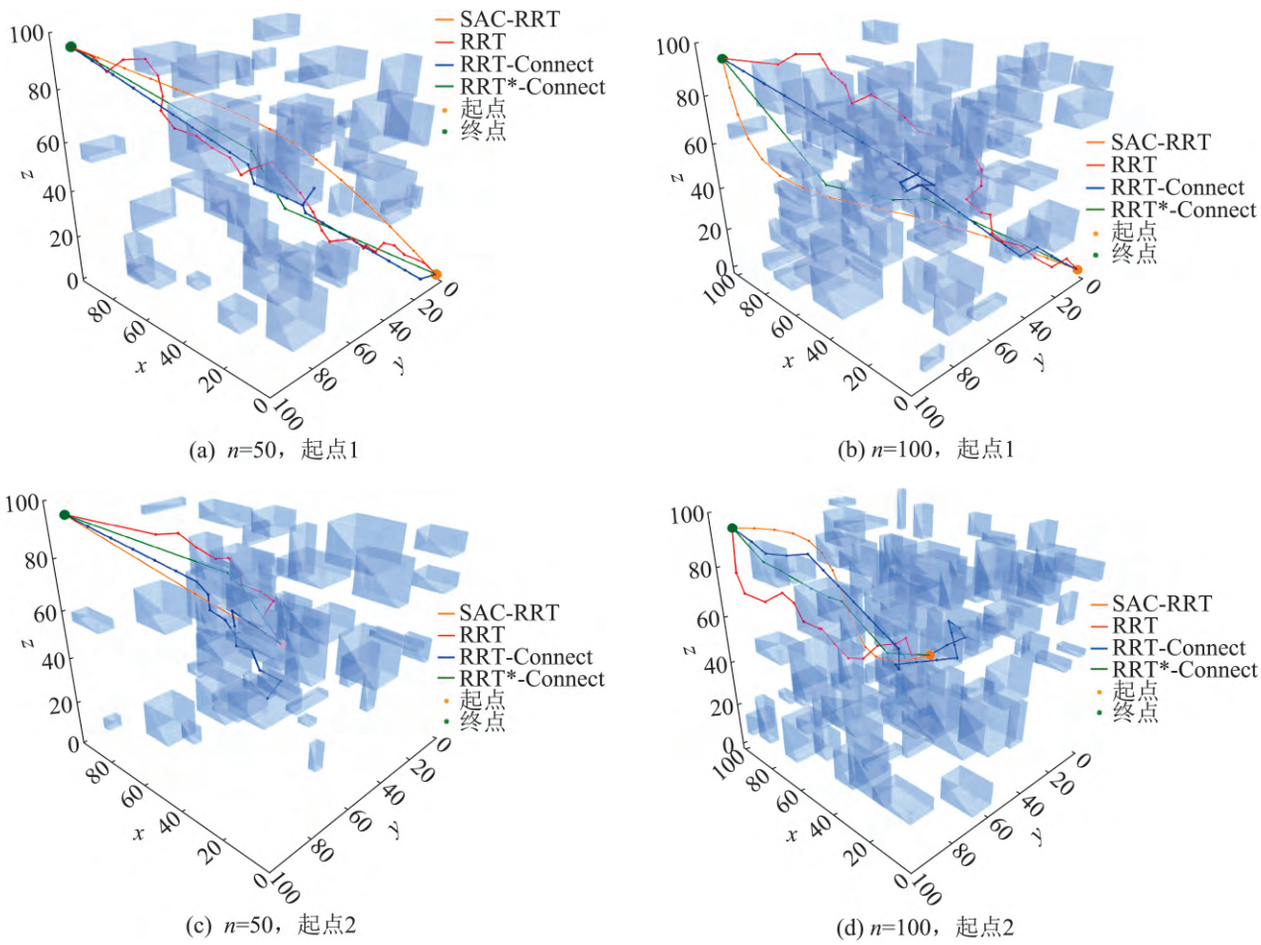


图17　不同n值场景算法结果对比
Fig. 17　Comparison of algorithm results in scenarios with different n values

中国知网　https://www.cnki.net



(a) n=50，起点1　(b) n=100，起点1

(c) n=50，起点2　(d) n=100，起点2

图18　不同n值随机场景规划结果

Fig. 18　Planning results in random scenarios with different n values

表7　随机场景规划结果数据

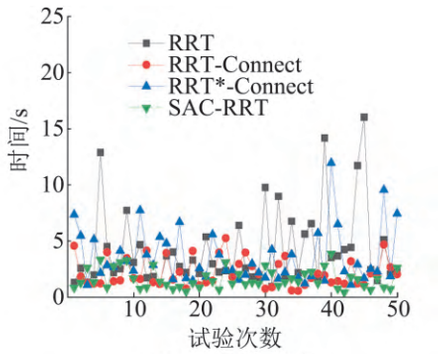
Table 7　Random scenario planning result data

算法	起点位置	时间/s		长度	
		n=50	n = 100	n = 50	n = 100
RRT	起点1	4.78	6.71	224.83	232.62
	起点2	4.54	6.05	128.55	130.64
RRT-Connect	起点1	2.16	2.33	241.87	248.48
	起点2	2.13	2.21	170.94	171.62
RRT*-Connect	起点1	3.19	3.88	169.1	171.76
	起点2	2.24	2.76	94.73	95.24
SAC-RRT	起点1	1.81	2.97	181.7	190.1
	起点2	1.71	2.27	103.19	110.2

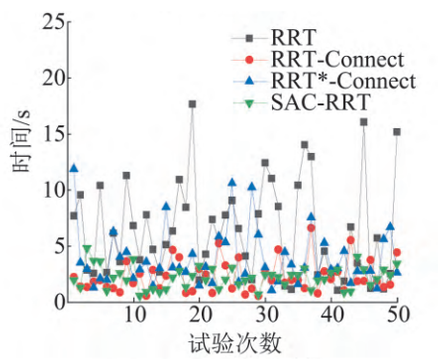
图20为以起点2为规划起点不同n值随机场景中规划结果。因为起点2更为接近目标点，所以规划路程更短，本文算法对环境变化更为敏感，稳定性变差。

综上，SAC-RRT算法在不同复杂程度的动态场景中性能整体表现较为稳定，虽然不同规划起点对算法稳定性有一定影响，但没有改变算法通过更少时间得到近优路径的结果，算法鲁棒性较好。

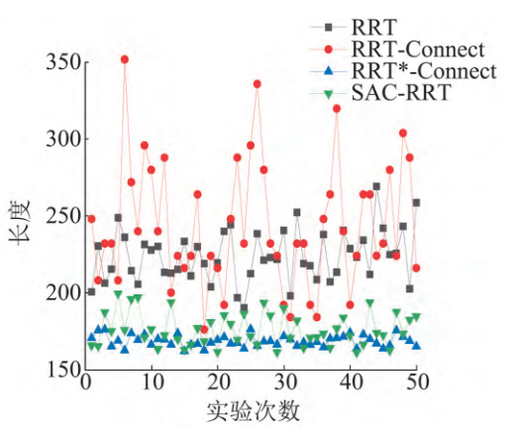
中国知网　https://www.cnki.net



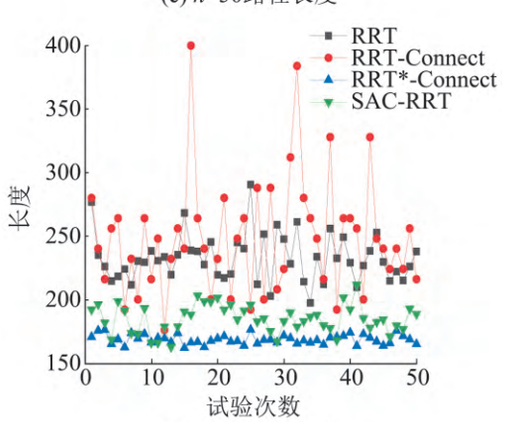
(a) n=50规划时间



(b) n=100规划时间



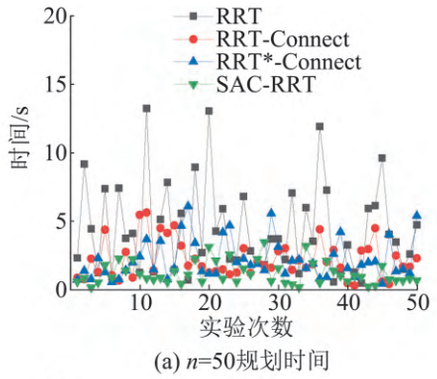
(c) n=50路径长度



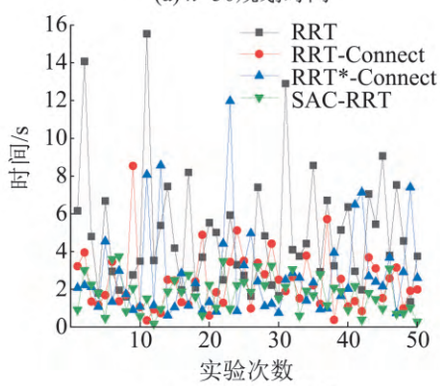
(d) n=100路径长度

图19　起点1规划结果对比

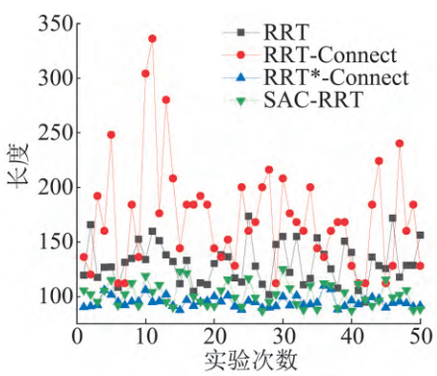
Fig. 19　Comparison of planning results for starting point 1



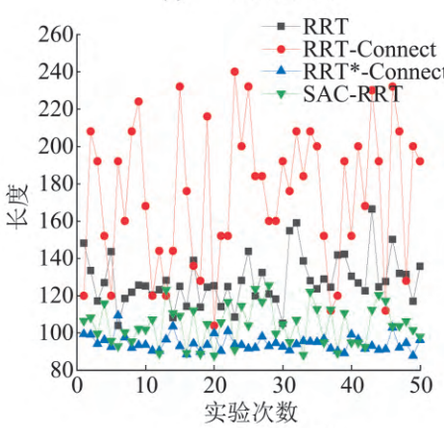
(a) n=50规划时间



(b) n=100规划时间



(c) n=50路径长度



(d) n=100路径长度

图20　起点2规划结果对比

Fig. 20　Comparison of planning results for Starting Point 2

中国知网　https://www.cnki.net

5 结论

针对传统RRT算法在规划无人机全局路径时规划效率低、平滑性差、实用性低的问题，提出了基于深度强化学习的改进RRT算法。结合RRT算法特性，避免了强化学习求解规划问题时需要栅格化地图步骤，结合强化学习的学习能力，提高了改进RRT算法的自适应能力。针对三维场景中规划无人机安全可行路径问题，首先，结合无人机的约束条件和优化目标，设计了强化学习模型和实验环境，得到了可行的决策策略。然后，引入基于决策策略的改进方法，通过对规划环境的观察，灵活设定了改进策略参数，优化了RRT算法的随机采样和拓展过程。仿真实验结果表明：本文算法的路径平滑性更好，规划时间和冗余路径进一步减少，盲目性更低，鲁棒性较好，规划路径基本满足了无人机安全飞行需求。但在性能表现上对比相关算法仍有不足，后续将进一步做出改进。

参考文献：

[1] 陈锦涛, 李鸿一, 任鸿儒, 等. 基于RRT森林算法的高层消防多无人机室内协同路径规划[J]. 自动化学报, 2023, 49(12): 2615-2626.
Chen Jintao, Li Hongyi, Ren Hongru, et al. Cooperative Indoor Path Planning of Multi-UAVs for High-rise Fire Fighting Based on RRT-forest Algorithm[J]. Acta Automatica Sinica, 2023, 49(12): 2615-2626.

[2] Sun Yinghui, Fang Ming, Su Yixin. AGV Path Planning Based on Improved Dijkstra Algorithm[J]. Journal of Physics: Conference Series, 2021, 1746(1): 012052.

[3] Zhang Jing, Wu Jun, Shen Xiao, et al. Autonomous Land Vehicle Path Planning Algorithm Based on Improved Heuristic Function of A-star[J]. International Journal of Advanced Robotic Systems, 2021, 2021(9): 17298814211042730.

[4] 李琼琼, 徐溢琪, 布升强, 等. 基于修正PRM算法的智能车辆路径规划研究[J]. 森林工程, 2022, 38(5): 179-186.
Li Qiongqiong, Xu Yiqi, Bu Shengqiang, et al. Smart Vehicle Path Planning Based on Modified PRM Algorithm[J]. Forest Engineering, 2022, 38(5): 179-186.

[5] Sourabh Katoch, Sumit Singh Chauhan, Vijay Kumar. A Review on Genetic Algorithm: Past, Present, and Future [J]. Multimedia Tools and Applications, 2021, 80(5): 8091-8126.

[6] 于力涵, 洪儒, 吴宇伦, 等. 基于IKGC-PSO算法的无人机三维路径规划系统[J]. 计算机测量与控制, 2023, 31(8): 259-266.
Yu Lihan, Hong Ru, Wu Yulun, et al. UAV 3D Path Planning System Based on IKGC-PSO Algorithm[J]. Computer Measurement & Control, 2023, 31(8): 259-266.

[7] Yuan Qingni, Yi Junhui, Sun Ruitong, et al. Path Planning of a Mechanical Arm Based on an Improved Artificial Potential Field and a Rapid Expansion Random Tree Hybrid Algorithm[J]. Algorithms, 2021, 14(11): 321.

[8] 黄岩松, 姚锡凡, 景轩, 等. 基于深度Q网络的多起点多终点AGV路径规划[J]. 计算机集成制造系统, 2023, 29(8): 2550-2562.
Huang Yansong, Yao Xifan, Jing Xuan, et al. DQN-based AGV Path Planning for Situations with Multi-starts and Multi-targets[J]. Computer Integrated Manufacturing Systems, 2023, 29(8): 2550-2562.

[9] 周治国, 余思雨, 于家宝, 等. 面向无人艇的T-DQN智能避障算法研究[J]. 自动化学报, 2023, 49(8): 1645-1655.
Zhou Zhiguo, Yu Siyu, Yu Jiabao, et al. Research on T-DQN Intelligent Obstacle Avoidance Algorithm of Unmanned Surface Vehicle[J]. Acta Automatica Sinica, 2023, 49(8): 1645-1655.

[10] Karaman S, Walter M R, Alejandro Perez, et al. Anytime Motion Planning Using the RRT*[C]//2011 IEEE International Conference on Robotics and Automation. Piscataway: IEEE, 2011: 1478-1483.

[11] Kuffner J J, LaValle S M. RRT-connect: An Efficient Approach to Single-query Path Planning[C]//Proceedings 2000 ICRA. Millennium Conference. IEEE International Conference on Robotics and Automation. Symposia Proceedings. Piscataway: IEEE, 2000: 995-1001.

[12] Karaman S, Frazzoli E. Sampling-based Algorithms for Optimal Motion Planning[J]. International Journal of Robotics Research, 2011, 30(7): 846-894.

[13] Sebastian Klemm, Jan Oberländer, Andreas Hermann, et al. RRT*-connect: Faster, Asymptotically Optimal Motion Planning[C]//2015 IEEE International Conference on Robotics and Biomimetics (ROBIO). Piscataway: IEEE, 2015: 1670-1677.

[14] 王冠强, 张驰洲, 陈明松, 等. 融合RRT-connect和DWA算法的室内移动机器人单目标点导航任务研究[J]. 中南大学学报(自然科学版), 2023, 54(11): 4326-4337.
Wang Guanqiang, Zhang Chizhou, Chen Mingsong, et al. Research on Single-target Point Navigation Task of Indoor Mobile Robot Integrating RRT-connect and DWA

中国知网 https://www.cnki.net

Algorithms[J]. Journal of Central South University (Science and Technology), 2023, 54(11): 4326-4337.

[15] Chiang H T L, Hsu J, Fiser M, et al. RL-RRT: Kinodynamic Motion Planning via Learning Reachability Estimators from RL Policies[J]. IEEE Robotics and Automation Letters, 2019, 4(4): 4298-4305.

[16] Haarnoja T, Zhou A, Abbeel P, et al. Soft Actor-critic: Off-policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor[C]//Proceedings of the 35th International Conference on Machine Learning. Chia Laguna Resort: PMLR, 2018: 1861-1870.

[17] Kurniawati H. Partially Observable Markov Decision Processes and Robotics[J]. Annual Review of Control, Robotics, and Autonomous Systems, 2022, 5: 253-277.

[18] Konda V R, Tsitsiklis J N. Actor-citic Agorithms[C]// Proceedings of the 13th International Conference on Neural Information Processing Systems. Cambridge: MIT Press, 1999: 1008-1014.

[19] 杨来义, 毕敬, 苑海涛. 基于SAC算法的移动机器人智能路径规划[J]. 系统仿真学报, 2023, 35(8): 1726-1736.
Yang Laiyi, Bi Jing, Yuan Haitao. Intelligent Path Planning for Mobile Robots Based on SAC Algorithm[J]. Journal of System Simulation, 2023, 35(8): 1726-1736.

[20] 罗征志, 韩怡可, 张鑫, 等. 改进RRT-connect与DWA算法的巡检机器人路径规划研究[J]. 计算机工程与应用, 2024, 60(15): 344-354.
Luo Zhengzhi, Han Yike, Zhang Xin, et al. Research on Path Planning of Inspection Robot with Improved RRT-connect and DWA Algorithm[J]. Computer Engineering and Applications, 2024, 60(15): 344-354.

[21] Prautzsch H, Boehm W, Paluszny M. Bézier and B-spline Techniques[M]. Berlin: Springer Science & Business Media, 2002.

中国知网 https://www.cnki.net