多约束条件下基于强化学习的无人机团队定向优化方法

杨灿，陈凯，朱峰*
(国防科技大学 系统工程学院，湖南 长沙 410073)

摘要：为解决多重复杂场景下传统优化方法难以高效求解，而现有强化学习方法存在求解质量不高、训练效率低的问题，提出了一种基于注意力机制的强化学习高效求解方法。*设计多信息融合的动态注意力策略网络以提升解的质量；结合可视图法简化威胁区约束，加快了训练收敛速度；解码阶段引入顺序重排机制，优化了解的性能。*仿真结果表明：该方法可在毫秒级时间内生成高质量解，其总奖励逼近甚至优于Ortools与PyVRP等传统求解器在数秒至数百秒内所得结果，训练效率大幅提升，单轮训练时间由数小时缩短至约30 min。

关键词：强化学习；团队定向问题；多无人机系统；注意力机制

中图分类号：TP391.9;TP181 文献标志码：A 文章编号：1004-731X(2026)02-0360-12

DOI: 10.16182/j.issn1004731x.joss.25-0595

引用格式: 杨灿, 陈凯, 朱峰. 多约束条件下基于强化学习的无人机团队定向优化方法[J]. 系统仿真学报, 2026, 38(2): 360-371.

Reference format: Yang Can, Chen Kai, Zhu Feng. Reinforcement Learning Based Method for UAV Team Orienteering Optimization under Multi-constraint Condition[J]. Journal of System Simulation, 2026, 38(2): 360-371.

Reinforcement Learning Based Method for UAV Team Orienteering Optimization under Multi-constraint Condition

*Yang Can, Chen Kai, Zhu Feng**

(College of Systems Engineering, National University of Defense Technology, Changsha 410073, China)

Abstract: Traditional optimization methods struggle with efficiency, while reinforcement learning approaches often yield low solution quality and high training costs. In response, this paper proposes an attention mechanism-based reinforcement learning method. *A dynamic attention strategy network with multi-information fusion is designed to improve solution quality. A visibility-graph approach is employed to simplify threat zone constraints and speed up convergence, and a decoding sequence reordering mechanism is introduced for further performance optimization of the solution.* The simulation results show that the method generates high-quality solutions within milliseconds, achieving total rewards that approach or even surpass those obtained by traditional solvers such as Ortools and PyVRP within several seconds to hundreds of seconds. The training efficiency is enhanced significantly, with the training time per epoch reducing from several hours to about 30 minutes.

Keywords: reinforcement learning; team orienteering problem; multi-UAV systems; attention mechanism

收稿日期：2025-06-24 修回日期：2025-09-07
基金项目：国家自然科学基金(61903368)
第一作者：杨灿(2000-)，男，硕士生，研究方向为智能行为建模。
通信作者：朱峰(1978-)，男，副教授，博士，研究方向为高性能仿真。

中国知网 https://www.cnki.net

0 引言

无人机系统因其部署灵活和功能多样，在军事侦察、低空突防等领域得到广泛应用。随着任务复杂度提升，实际场景常需多架无人机协同访问分布式任务点，这些任务点不仅价值不同，还伴随严格的时间窗约束。无人机执行任务时受限于最大航程，且需规避威胁区域以确保安全。同时，任务效果对飞行轨迹也提出更高要求，频繁急转弯可能导致传感器失效或成像模糊[1]，增加碰撞风险。因此，如何在多重约束下实现高效规划，成为无人机系统的关键问题[2]。

多约束多无人机团队定向问题[3]源于实际任务需求，其核心是在威胁区规避、转弯角度限制、时间窗和最大航程等约束下，为多架无人机协同规划路径，以最大化任务点总收益。尽管该问题可视为旅行商问题(TSP)、车辆路径规划(VRP)及其变体的扩展，已有启发式与强化学习方法[4]，但多集中于地面交通场景[5]，难以有效处理无人机特有的角度约束、威胁规避及多约束耦合优化。现有研究仍面临以下挑战：

(1) UAV-TOP 本质上属于 NP-hard 的组合优化问题，问题规模扩大和约束条件增多将显著加剧求解难度。传统的启发式和元启发式算法通常依赖人工设计复杂的启发式规则[6]和适应度函数[7]，其效果高度依赖于设计者的经验。当引入如飞行角度限制等无人机特有约束后，原有算法难以扩展或迁移。此外，已有的大多数路径规划方法主要针对 VRP 类问题构建，往往忽视飞行器在转弯半径、安全规避等方面的特殊需求，导致规划路径无法满足实际飞行安全要求。

(2) 策略网络模型难以有效融合多维约束和状态变化的信息，导致复杂约束下的求解质量不高[8]。大多数强化学习方法仅关注单一或简单组合的约束[9]，未能充分兼顾无人机任务中的飞行距离、时间窗、威胁区域、飞行角度等多重约束，规划结果与实际需求有较大差距。例如，当前基于注意力机制的策略网络[10]通常只将节点位置、时间窗、价值等静态信息一次性输入编码器，与环境的交互主要依靠解码器，而解码器设计简单，难以捕捉无人机任务中的动态信息，如剩余电量、实时路径角度、实际到达时间、剩余时间窗等。这些动态信息仅在与环境交互过程中逐步显现，解码器难以全面整合和利用这些关键变化的信息。

(3) 威胁区域约束难以高效融入强化学习，制约大规模训练。存在威胁区场景需要计算规避路径距离，而现有强化学习方法难以高效集成此类空间约束。常见做法是预计算任意 2 个任务点间的绕飞最短路径，用边编码方式进行建模，或者动态计算规避路径距离。但是由于强化学习在求解组合优化问题时，通常依赖大量训练样本，并以批次[11]在 GPU 上并行训练，当涉及威胁区域时，任意 2 个任务点之间的最短距离不再是固定的直线距离，而需通过 A*等路径搜索算法逐对计算[12]，绕过威胁区生成可行路径。计算规避路径距离高度依赖 CPU 串行计算，难以并行，无法利用 GPU 加速，导致每个训练样本的预处理时间、每一步距离的计算时长显著增加，使强化学习方法在该问题上的训练过程变得不可行。

针对上述挑战，本文设计了一种基于注意力机制的强化学习求解方法，用于解决多约束的无人机定向问题。

1 问题建模

1.1 数学模型

多约束下的多无人机团队定向问题是团队定向问题的关键变种。多架无人机从同一出发点起飞，在有限飞行距离和任务时间窗内，选择性访问区域内若干任务节点，以最大化整体任务奖励。每个节点具有固定服务时间和可用时间窗，且仅允许一架无人机访问。飞行过程中无人机需避开设定威胁区[12]，并满足最小转弯角等飞行安全约束[13-14]，如图 1 所示。

中国知网 https://www.cnki.net

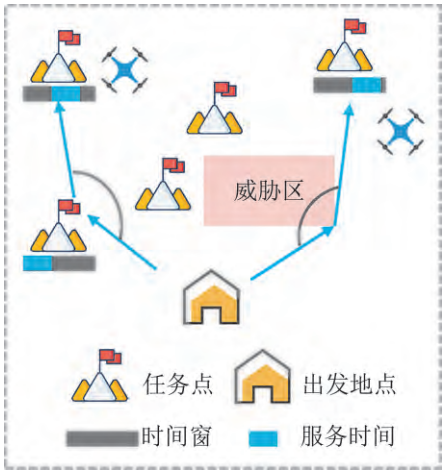


图1 多约束无人机定向问题示意图

Fig. 1 UAV orienteering problem under multi-constraint condition

(1) 数学模型符号

m：无人机数量；

N_{T}：任务节点数；

$x_{p,ij}$：第p架无人机是否从i到j；

$y_{p,j}$：第p架无人机是否访问任务节点j；

$t_{p,j}$：第p架无人机到达节点j的时间；

d_{ij}：节点i到j的距离；

s_j：节点j的服务时间；

$[e_j, l_j]$：节点j的时间窗；

p_j：任务节点j的奖励；

$d_{\max}$：最大飞行距离；

R_{ij}：节点i到j的可行性指示(威胁区)；

$\alpha_{\min}$：最小转弯角。

(2) 数学模型

目标为最大化所有无人机访问任务节点的奖励：

$$\max Z=\sum_{p=1}^{m}\sum_{j=1}^{N_{\mathrm{T}}}p_j y_{p,j} \tag{1}$$

式中：$y_{p,j}=\sum_{i=0}^{N}x_{p,ij}$，表示无人机$p$是否访问任务节点$j$。

每架无人机从仓库出发一次：

$$\sum_{j=1}^{N}x_{p,0j}=1,\ p=1,2,\cdots,m \tag{2}$$

保证中间节点进出次数平衡，路径连贯：

$$\sum_{i=0}^{N}x_{p,i,k}=\sum_{j=0}^{N}x_{p,k,j},\ p=1,2,\cdots,m,\ k=1,2,\cdots,N \tag{3}$$

每架无人机飞行距离不超$d_{\max}$：

$$\sum_{i=0}^{N}\sum_{j=0}^{N}d_{ij}x_{p,ij}\leqslant d_{\max},\ p=1,2,\cdots,m \tag{4}$$

满足节点服务的时间窗：

$$t_{p,j}\geqslant t_{p,i}+d_{ij}+s_i, e_j\leqslant t_{p,j}\leqslant l_j$$

$$\forall p,\ ij\ \text{ with }\ x_{p,ij}=1 \tag{5}$$

通过R_{ij}阻断跨威胁区飞行，它标志着所有节点，点与点之间的直接连线是否跨越威胁区：

$$x_{p,ij}\leqslant R_{ij}, R_{ij}=\begin{cases}1, & \text{不穿禁飞区},\\ 0, & \text{否则},\end{cases}\quad \forall p,i,j \tag{6}$$

三点夹角余弦$\cos\theta_{ijk}$，并要求其不小于$\cos\alpha_{\min}$，以保证转弯角度阈值：

$$\cos\theta_{ijk}=\frac{(j-i)(k-j)}{\|j-i\|\|k-j\|},$$

$$\cos\theta_{ijk}\geqslant\cos\alpha_{\min},\ \forall p,\ x_{p,ij}=x_{p,jk}=1 \tag{7}$$

每个任务点最多被一架无人机访问：

$$\sum_{p=1}^{m}y_{p,j}\leqslant 1,\ j=1,2,\cdots,N_{\mathrm{T}} \tag{8}$$

1.2 马尔可夫决策模型

强化学习解决多约束无人机团队定向问题形式化为顺序多智能体MDP[15]。策略网络视为单个智能体与环境的交互过程，策略网络输出的动作序列切分为多无人机的个体轨迹，现伪多智能体决策[16]。例如，策略网络输出序列{0,2,3,8,0,1,7}映射为2架无人机分别执行路径0→2→3→8与0→1→7。

状态s_t：包含当前无人机位置索引p_i、当前时间t_i、累计飞行距离d_i、已访问节点集合V_i、所有任务节点的静态信息，包括位置(x_j, y_j)、时间窗$[e_j, l_j]$、服务时间τ_j、任务奖励p_j，以及由可达性、时间窗、航程、航向角等约束共同确定的掩码action_mask_t。整体状态形式可表示为

中国知网 https://www.cnki.net

$$s_t=(\{p_i,t_i,d_i,V_i\}_{i=1}^{m},\{(x_j,y_j),[e_j,l_j],\tau_j,p_j\}_{j=1}^{N},\text{action mask}_t) \tag{9}$$

动作：动作空间被建模为离散动作空间，为所有可访问的任务节点，即每一步，智能体从候选任务节点集合中选择下一个访问节点，其中威胁区的顶点视为任务节点纳入同一动作空间。

$$\mathcal{A}=\mathcal{N}\cup\mathcal{V} \tag{10}$$

式中：$\mathcal{N}$为所有任务节点集合；$\mathcal{V}$为由威胁区边界顶点构成的可视图节点集合。动作需要满足多个约束条件，包括时间窗限制，即到达时间t_i+d_{ij}不超过上限l_j；航程限制，即累计飞行距离不超过最大值$d_{\max}$；可达性限制，即节点连线不穿越威胁区，满足$R_{ij}=1$；转向角限制，转角夹角需满足$\cos\theta_{ijk}\geqslant\cos\alpha_{\min}$；禁止连续原地选择，若无合法任务节点可选，则允许返回起点。最终可选动作通过环境自动更新，并以掩码形式传入策略网络，满足约束的节点可访问，不满足的被屏蔽。

状态转移：主要包括当前无人机位置p_i更新为目标节点j；时间更新为当前时间加上飞行时间、等待时间与服务时间，即$t_i\leftarrow t_i+d_{ij}+\max(0,e_j-(t_i+d_{ij}))+\tau_j$航程累积为$d_i\leftarrow d_i+d_{ij}$，节点$j$被标记为已访问，并重新计算动作掩码$\text{action mask}_{t+1}$，用于筛选下一个时间步的合法动作。

奖励：稀疏型奖励，若所选节点j为有效任务节点，则获得其对应奖励p_j，否则奖励为0。

$$\mathcal{R}(s_t,a_t)=\begin{cases}p_j, & \text{若}j\text{为合法任务节点}\\ 0, & \text{否则}\end{cases} \tag{11}$$

2 基于注意力机制的强化学习高效求解方法

2.1 算法框架

图2为本文方法整体框架。首先，任务区域中包含普通任务点与威胁区(红色多边形)，将威胁区域的边界顶点(虚线包围)视为可视图节点，与普通任务点统一作为输入节点处理。所有节点的静态信息，包括坐标、奖励值、时间窗等，被统一输入到策略网络中。策略网络由编码器和解码器两部分构成，编码器对静态节点信息进行一次性全图编码，提取每个节点的全局表示；解码器则在任务执行过程中与环境交互，根据当前无人机状态、剩余能量、时间窗、角度约束等动态信息，逐步选择下一个访问节点。完成初始路径规划后，进入解码顺序重排优化。依次固定每架无人机的路径，重新让模型规划剩余的无人机路径，得到多组方案。最终选择其中总奖励最大的解作为最终输出结果。

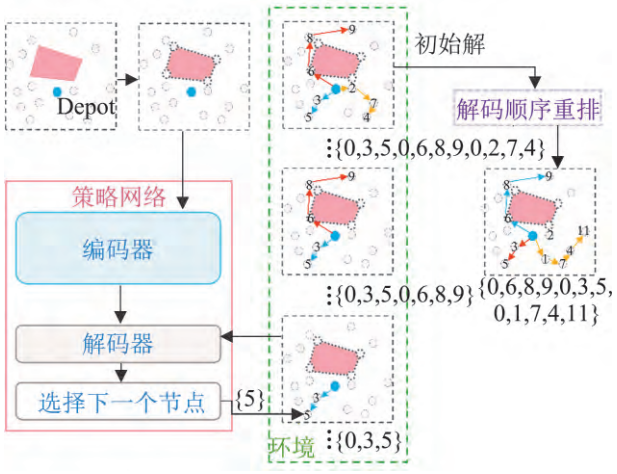


图2 基于注意力机制的RL求解方法框架

Fig. 2 Attention mechanism-based efficient RL framework

2.2 多信息融合动态注意力模型

本文设计了如图3所示的多信息融合动态注意力模型(multi-information fused dynamic attention model, MIFDAM)，用于融合节点的静态信息、动态信息、其他无人机信息，并对当前可行动作进行打分。该模型基于Transformer框架[17]，由编码器和解码器组成，编码器为静态信息的图编码器，结构与文献[5]的一致，解码器部分引入动态增量注入、角度偏置注意力和双视角信息融合3个关键机制，实现端到端的智能体协同调度。

中国知网 https://www.cnki.net

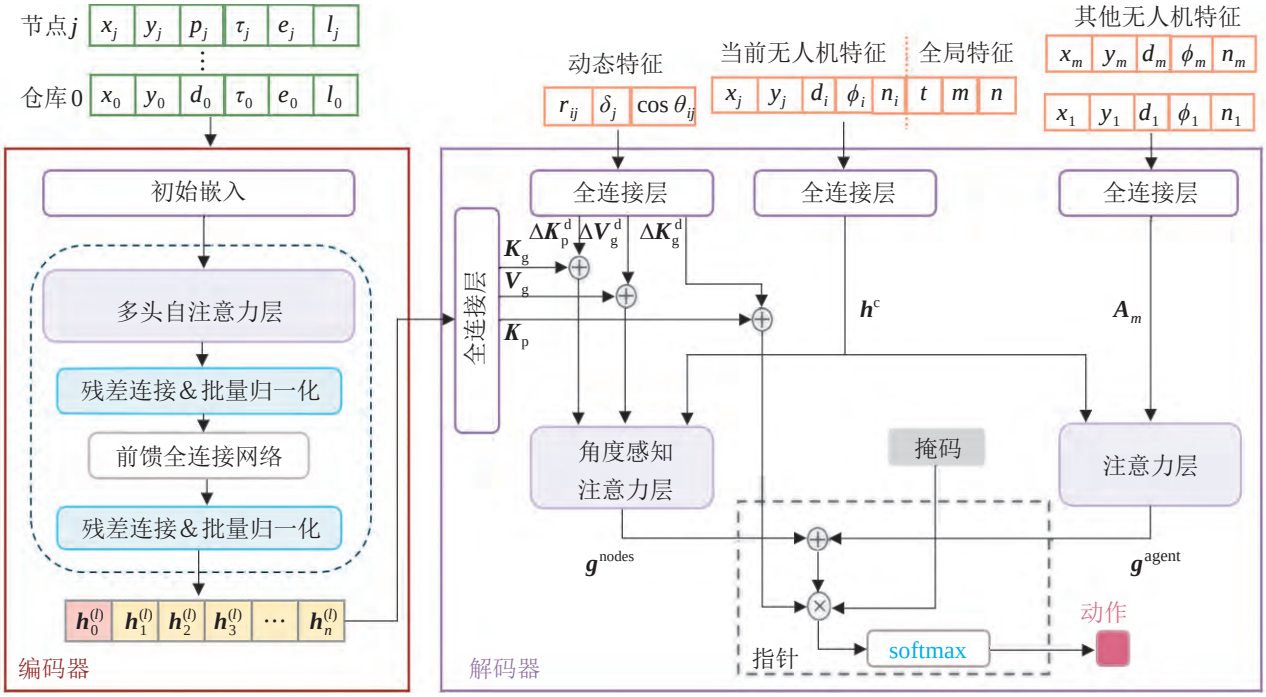


图3　多信息融合动态注意力模型

Fig. 3　MIFDAM

(1) 静态信息图编码器

每个任务节点 j 的静态特征表示为 $\boldsymbol{o}_j^{\mathrm{s}}=[x_j,y_j,p_j,\tau_j,e_j,l_j]$，该特征通过线性层嵌入到固定维度后，输入图结构编码器进行特征传播。使用 L 层图注意力网络(graph attention network, GAT)迭代更新节点表示：$\boldsymbol{h}_j^0=\mathrm{Linear}(\boldsymbol{o}_j^{\mathrm{s}})$，$\boldsymbol{h}_j^l=\mathrm{GAT}^l(\{\boldsymbol{h}_k^{l-1}\}_{k=1}^n),l=1,2,\cdots,L$

最终得到第 L 层输出作为节点表示 $\boldsymbol{h}_j^L$，并进一步映射为3类嵌入：指针键 $\boldsymbol{K}_{\mathrm{p}}^{\mathrm{s}}$、注意力键 $\boldsymbol{K}_{\mathrm{g}}^{\mathrm{s}}$、注意力值 $\boldsymbol{V}_{\mathrm{g}}^{\mathrm{s}}$，用于后续解码器计算，全程复用。

(2) 动态信息增量嵌入

在每个时间步 t，从当前无人机 i 的视角计算每个任务节点的动态特征：

$$\boldsymbol{o}_j^{\mathrm{d}}=[r_{ij},\delta_j,\cos\theta_{ij}] \tag{12}$$

式中：r_{ij} 为当前位置到节点 j 的飞行距离；$\delta_j=\max(0,l_j-t-\tau_j)$ 为节点剩余可服务时间；$\cos\theta_{ij}$ 为当前朝向与转向到 j 的夹角余弦，用于建模转弯限制。该特征不经过图结构传播，而是通过线性映射直接计算三组动态增量 $[\Delta\boldsymbol{K}_{\mathrm{p}}^{\mathrm{d}},\Delta\boldsymbol{K}_{\mathrm{g}}^{\mathrm{d}},\Delta\boldsymbol{V}_{\mathrm{g}}^{\mathrm{d}}]=\mathrm{Linear}(\boldsymbol{o}_j^{\mathrm{d}})$，最终与静态表示相加，得到时变节点表示 $\boldsymbol{K}_{\mathrm{p}}=\boldsymbol{K}_{\mathrm{p}}^{\mathrm{s}}+\Delta\boldsymbol{K}_{\mathrm{p}}^{\mathrm{d}},\boldsymbol{K}_{\mathrm{g}}=\boldsymbol{K}_{\mathrm{g}}^{\mathrm{s}}+\Delta\boldsymbol{K}_{\mathrm{g}}^{\mathrm{d}},\boldsymbol{V}_{\mathrm{g}}=\boldsymbol{V}_{\mathrm{g}}^{\mathrm{s}}+\Delta\boldsymbol{V}_{\mathrm{g}}^{\mathrm{d}}$。

(3) 双视角上下文融合

当前待调度的无人机状态 $\boldsymbol{o}^{\mathrm{agent}}$ 与全局任务状态 $\boldsymbol{o}^{\mathrm{global}}$ 拼接后，经过线性映射生成查询向量：

$$\boldsymbol{h}^{\mathrm{c}}=\mathrm{Linear}([\boldsymbol{o}^{\mathrm{agent}},\boldsymbol{o}^{\mathrm{global}}]) \tag{13}$$

式中：$\boldsymbol{o}^{\mathrm{agent}}=[x_i,y_i,d_i,\phi_i,n_i]$ 为当前位置、剩余航程、航向角、已服务节点数；$\boldsymbol{o}^{\mathrm{global}}=[t,m,n]$ 为全局时间步、剩余可调度无人机数量、剩余节点数。

分别计算2类注意力上下文。节点视角使用 $\boldsymbol{h}^{\mathrm{c}}$ 与节点注意力键 $\boldsymbol{K}_{\mathrm{g}}$ 和值 $\boldsymbol{V}_{\mathrm{g}}$ 执行加权计算，引入角度偏置打分：

$$\alpha_{ij}=\boldsymbol{h}^{\mathrm{cT}}\boldsymbol{K}_{\mathrm{g},j}+\boldsymbol{\omega}\cdot\cos\theta_{ij} \tag{14}$$

式中：$\boldsymbol{\omega}$ 为可学习权重。当转向角较小(即前后方向接近)时，$\cos\theta_{ij}\to1$，该项偏置值更大，从而提升该节点的被选择概率；反之，当需要大幅转向甚至掉头时，$\cos\theta_{ij}\to-1$，对应的注意力得分 α_{ij} 会自动下降。该机制以连续、可微的方式鼓励路径光滑、转向合理，避免飞行轨迹剧烈折返或不现实的航向跳变。

中国知网　https://www.cnki.net

最终节点视角上下文$\boldsymbol{g}^{\text{nodes}}=\sum_j \text{softmax}_j(\alpha_{ij})\cdot\boldsymbol{V}_{g,j}$，代理视角使用相同查询向量$\boldsymbol{h}^{\text{c}}$，首先将所有活跃无人机状态$\{\boldsymbol{o}_m^{\text{agent}}\}$通过共享嵌入层投影为agent表示$\boldsymbol{A}_m=\text{Linear}(\boldsymbol{o}_m^{\text{agent}})$，然后在该表示上执行多头注意力，得到代理上下文$\boldsymbol{g}^{\text{agents}}=\text{MHA}(\boldsymbol{h}^{\text{c}},\{\boldsymbol{A}_m\})$，最终将2个视角的上下文相加$\boldsymbol{g}=\boldsymbol{g}^{\text{nodes}}+\boldsymbol{g}^{\text{agents}}$。

(4) 指针解码与动作采样

解码器利用融合上下文$\boldsymbol{g}$与每个节点的指针键$\boldsymbol{K}_{\text{p}}$计算策略概率分布：

$$\pi(a_t=j\,|\,\boldsymbol{s}_t)=\text{softmax}_j(\boldsymbol{g}^{\text{T}}\boldsymbol{K}_{\text{p},j}+\text{mask}_j)$$

掩码mask_j用于排除不合法的动作，包括屏蔽已访问节点、威胁区域阻隔的节点或时间窗不满足的节点、角度太大的节点。

(5) 模型训练

模型将$\boldsymbol{g}=\boldsymbol{g}^{\text{nodes}}+\boldsymbol{g}^{\text{agents}}$的值经过线性层后作为状态值估计$\boldsymbol{V}(\boldsymbol{s}_t)$，用于强化学习中的优势评估与更新。本文采用强化学习解组合优化问题领域最常用的REINFORCE策略梯度结合Critic基线的优势估计方法[18]，通过从策略分布中采样轨迹进行策略更新。这一训练方法完全与文献[19]保持一致。

2.3 基于可视图的威胁区处理

将环境中各障碍物边界的顶点作为辅助节点引入图中[20]。如图4所示，本文将威胁区边界的顶点视为无奖励、无时间窗的辅助节点，可以重复访问，与任务节点统一编码，统一纳入动作空间，用以引导无人机智能绕飞威胁区，避免显式计算复杂的绕行路径。仅需用Liang-Barsky算法[21]预先计算可达性矩阵，计算开销极低，可轻松实现GPU并行加速，无需计算避障最短距离矩阵，或训练过程中动态计算避障最短路径，大幅减少训练时间。

2.4 解码顺序重排

强化学习模型一次性为多架无人机生成任务路径的过程中，每架无人机路径的解码顺序会影响最终任务的覆盖情况与总奖励值。这是因为先分配路径的无人机会对后续无人机的可选任务集合产生限制性影响，导致初始解的质量受限于解码顺序。为了解决这一问题，本文设计了一种后处理优化方法。如图5所示，首先，使用模型规划多架无人机的初始路径，并得到相应的初始解。随后，基于初始解，依次固定每架无人机的路径，将该无人机访问过的任务点从全局任务集合中移除，剩余任务点则交由剩余无人机重新规划。这种方式本质上是探索不同的解码顺序，利用不同顺序下无人机任务覆盖的互补性，提高整体解的质量。

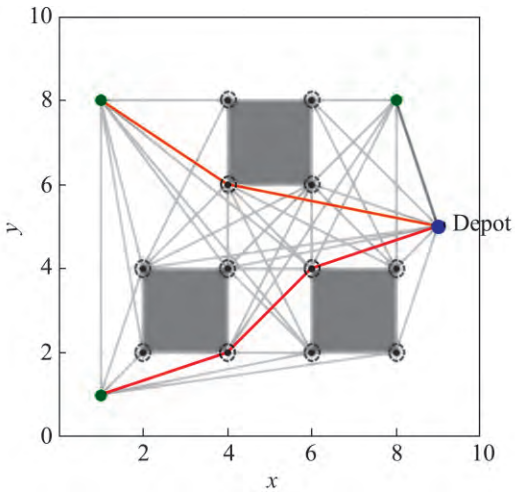


图4　基于可视图法的路径规划与威胁区规避示意图
Fig. 4　Path planning and threat zone avoidance based on visibility graph method

3　仿真实验

3.1 实验设置

为验证本文方法和模型的有效性进行了一系列实验。

本文模型的训练基于Actor-Critic强化学习框架。核心超参数方面，设置注意力层数为3层，编码器与解码器特征维数、学习率和Adam优化器的具体参数均遵循文献[6]AM模型的设定。训练过程使用了1.28亿个样本，训练100轮次，每轮次128万样本，批处理大小为512。其训练相关的超参数均与AM模型论文保持一致。实验中使用的场景实例生成：所有任务节点的地理位置坐

中国知网　https://www.cnki.net

标在单位正方形内通过均匀分布随机生成。各任务节点的时间窗、所需服务时间和访问价值(奖励，从[0,1]的均匀分布中随机抽取)的生成方式如表1所示，与文献[22-23]中的标准设置保持一致。

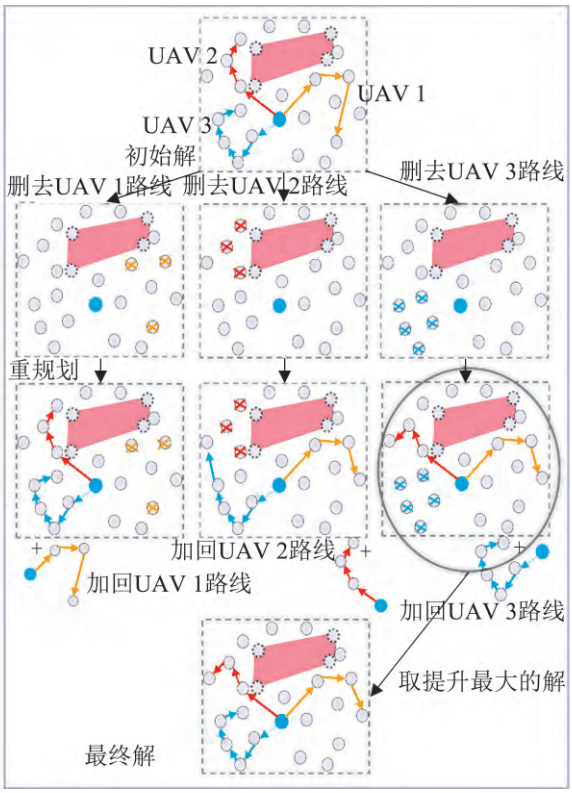


图5　解码顺序重排示意图

Fig. 5　Illustration of decoding sequence reordering

表1　模型训练超参数表

Table 1　Hyperparameter settings for model training

参数名称	取值
注意力层数	3
特征维数	128
批大小	512
训练样本总数	1.28亿
每轮次样本数	128万
轮次	100
优化器	Adam
学习率	0.000 1
策略	Sample

不同约束条件选择了不同的基准方法。有角度约束的场景下选用OR-Tools求解器与AM模型作为对比，其中，OR-Tools针对50-3实例设置计算时间上限为10 s，100-5实例为300 s，以保证其能在有限时间内输出可行解。无角度约束场景下对比方法为PyVRP[24]和OR-Tools[25]。

3.2 实验结果与分析

3.2.1 求解质量与速度

本节展示了本文方法与OR-Tools、启发式求解器PyVRP、AM模型在不同规模场景、不同威胁区数量，以及不同约束条件下测试500个随机生成样例的性能对比结果。本文模型和AM模型分别在有角度约束与无角度约束2种条件下、威胁区数量为3的50-3和100-5场景中进行训练，即对于每种角度约束条件下的每个规模，仅在威胁区数量为3的情况下训练模型。其他威胁区数量对应的测试结果均来自该模型的直接泛化测试，未进行额外训练。具体结果汇总于表2。

在考虑角度约束与威胁区域的复杂场景中，MIFDAM显示出显著的性能优势。传统求解器在角度约束作用下搜索空间激增，求解效率显著下降，甚至难以在规定时间内获得可行解[26]，限制了其实时应用。而MIFDAM依托多信息融合注意力机制与可视图建模策略，能够高效处理复杂约束，在保证解质量的同时大幅缩短求解时间，表现出优异的解空间探索能力。

在无角度约束的基础任务场景中，MIFDAM也保持了良好性能，尤其在任务点数量较大时更为明显。小规模下，其解质量与传统方法基本持平甚至略优；随着问题规模扩大，传统方法面临指数级复杂度增长，解质量与效率迅速下降，而MIFDAM凭借学习型策略持续输出高质量解，展现出更强的扩展性与稳定性。此外，针对不同算法的适用范围也有明显差异。传统启发式如PyVRP在含角度约束情形下难以应用，而MIFDAM能兼容多种约束，适应性更强。MIFDAM模型在不同任务规模下的原始解与应用后处理优化策略的结果如表3所示。

中国知网　https://www.cnki.net

表2　不同方法在多场景UAV-TOP问题中的性能对比
Table 2　Comparison among different methods on multi-scenario UAV-TOP problems

场景	角度约束	威胁区个数	MIFDAM模型	AM模型	OR-tools	PyVRP
50-3	有	3	**15.49** (<1 s)	14.63 (<1 s)	13.99 (10 s)	不适用
	有	4	**14.76** (<1 s)	13.80 (<1 s)	13.65 (10 s)	不适用
	有	5	**14.17** (<1 s)	13.33 (<1 s)	12.21 (10 s)	不适用
	无	3	**20.04** (<1 s)	19.48 (<1 s)	20.01 (1 s)	18.89 (1 s)
	无	4	19.51 (<1 s)	18.79(<1 s)	**19.92** (1 s)	18.73 (1 s)
	无	5	18.96 (<1 s)	18.03 (<1 s)	**19.86** (1 s)	18.50 (1 s)
100-5	有	3	**32.37** (<1 s)	30.17 (<1 s)	29.13 (200 s)	不适用
	有	4	**31.20** (<1 s)	28.90 (<1 s)	29.08 (200 s)	不适用
	有	5	**30.01** (<1 s)	28.62 (<1 s)	28.36 (200 s)	不适用
	无	3	**39.75** (<1 s)	38.41 (<1 s)	38.57 (1 s)	33.16 (1 s)
	无	4	**38.95** (<1 s)	37.76 (<1 s)	38.54 (1 s)	31.10 (1 s)
	无	5	38.27 (<1 s)	37.52 (<1 s)	**38.48** (1 s)	31.09 (1 s)

表3　解码顺序重排处理前后效果对比
Table 3　Performance comparison before and after decoding sequence reordering

序号	MIFDAM	解码顺序重排后
50-3	15.49	15.53
50-4	18.26	18.39
50-5	20.23	20.65
100-5	32.37	32.88
100-6	35.98	36.43
100-7	38.94	39.98

在所有测试场景中，引入解码顺序优化后整体任务收益均有提升，说明该策略对提升解的质量具有积极作用。这一提升源于强化学习模型在生成多无人机路径时，受初始状态影响较大。删去一些已经访问的节点，能让编码器更好地提取到剩余节点的特征。后处理优化策略通过打乱无人机的解码顺序，等价于从多个不同的“初始出发点”重新进行路径探索，有效增加了解空间的多样性。这种基于顺序的多样化解码相当于间接地对初始节点分布进行了干扰与重采样，进一步提升了解的全局质量。随着无人机数量的增加，解码顺序优化带来的收益提升更加明显。这是因为当无人机数量较多时，不同的解码顺序将带来更多组合的初次访问节点，扩大了解码过程中对任务空间的覆盖能力，因此，更有可能探索到更优的路径配置。

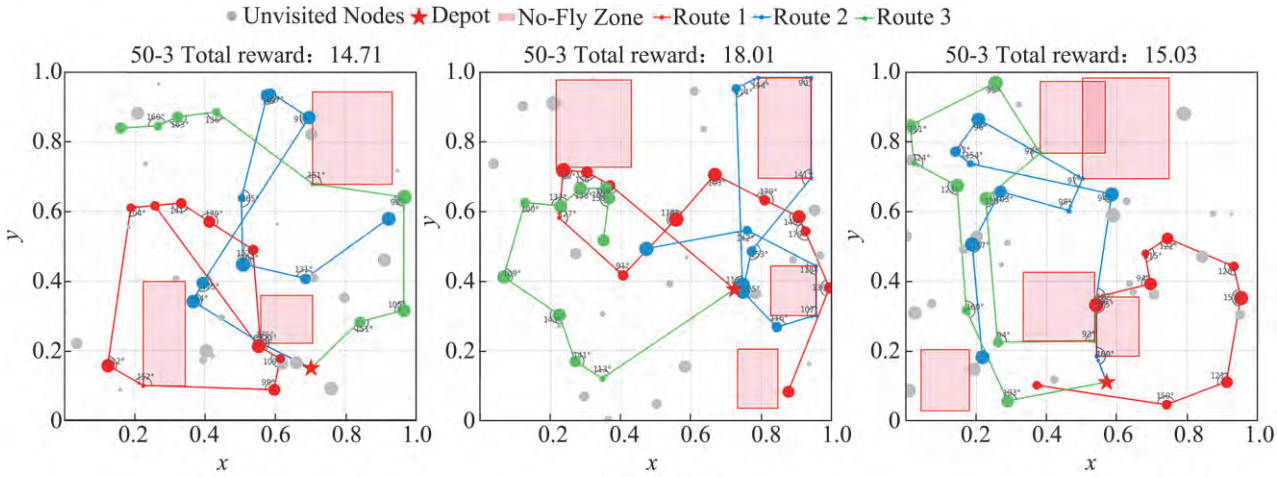
图6~7为在50-3和100-5任务场景下模型在不同威胁区数量及是否考虑角度约束条件下的路径规划结果。每张图中包含多架无人机的路径，红色方框代表威胁区域。角度约束对路径可行性与任务收益具有显著影响。在角度约束条件下的路径转角较为自然，能够避免急转弯，但这也可能导致某些高价值节点因角度限制无法访问，从而使总体收益略有下降。相比之下，未施加角度约束的路径更具灵活性，折返频繁，通常带来更高的收益。

3.2.2 训练耗时

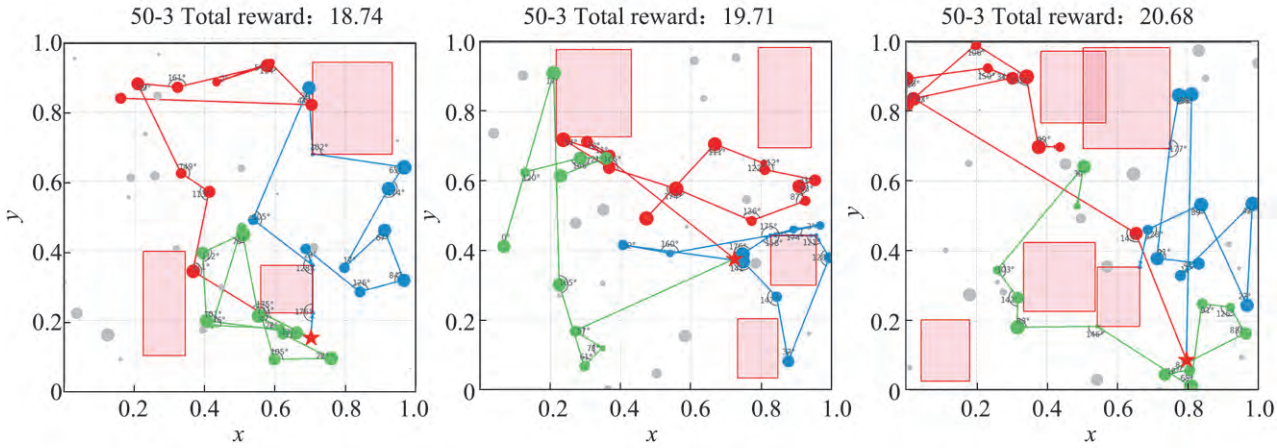
在存在威胁区约束的条件下，对比了2种威胁区处理方法在强化学习训练过程中每个轮次的耗时情况，如图8所示。不同处理方式在训练效率上的差异，为后续方法选择提供了参考依据。采用可视图建模策略的训练方式并不会显著增加训练时长，而基于A*计算绕飞距离几乎是不可行的，因为每一步都需要CPU计算当前节点到下一个节点的绕飞距离，导致每个轮次耗时长达数小时。可视图法通过构建任务图结构中的辅助节点，避免了显式计算绕飞距离，从而使训练可行。

图9为MIFDAM模型在不同场景下训练过程的收益变化曲线，反映了模型在各类设置中的收敛情况与性能上限。

中国知网　https://www.cnki.net



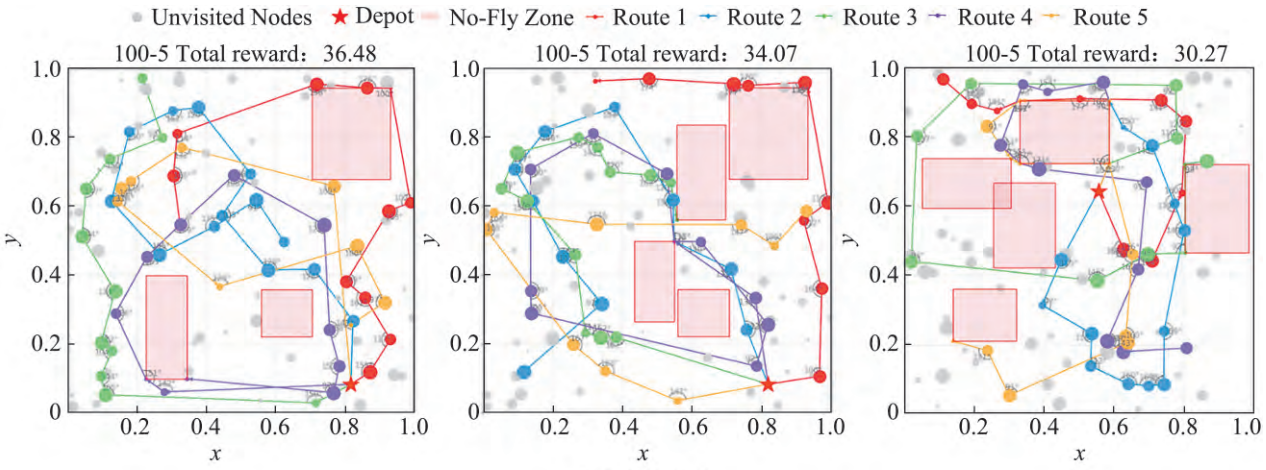
(a) 有角度约束



(b) 无角度约束

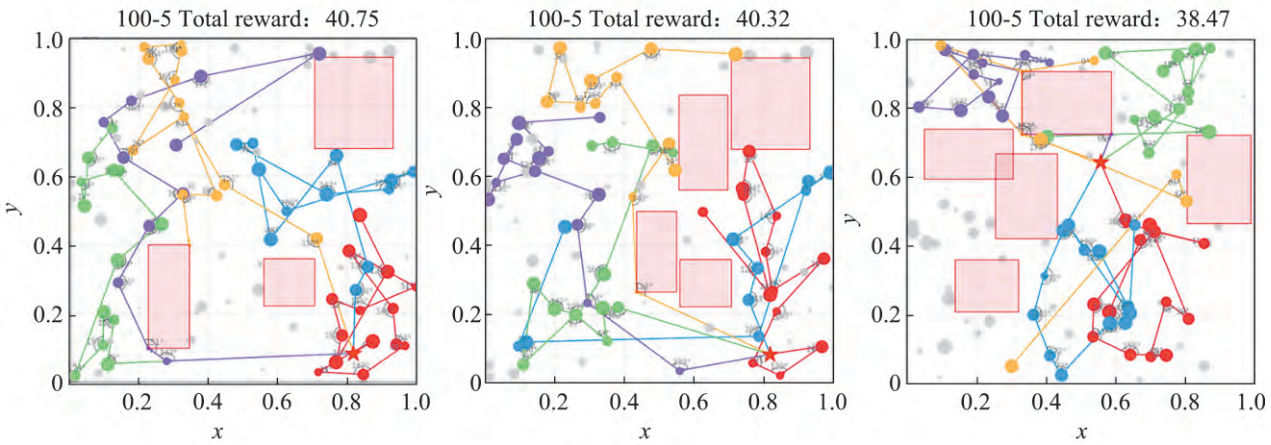
图6　在50-3场景中不同威胁区数量路径规划结果

Fig. 6　Path planning results for 50-3 scenario with varying numbers of threat zones



(a) 有角度约束

中国知网　https://www.cnki.net



(b) 无角度约束

图7　在100-5场景中不同威胁区数量路径规划结果

Fig. 7　Path planning results for 100-5 scenario with varying numbers of threat zones

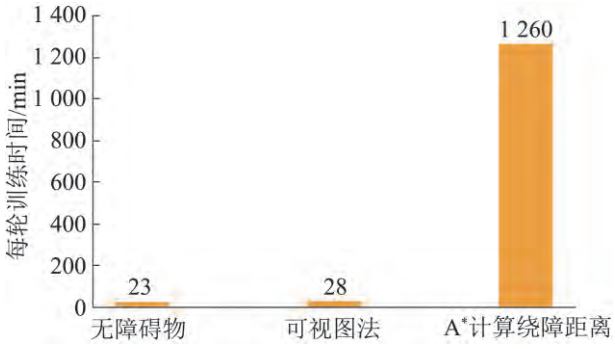


图8　不同威胁区处理方法下每个训练轮次的耗时比较

Fig. 8　Training time per epoch for different threat zone handling methods

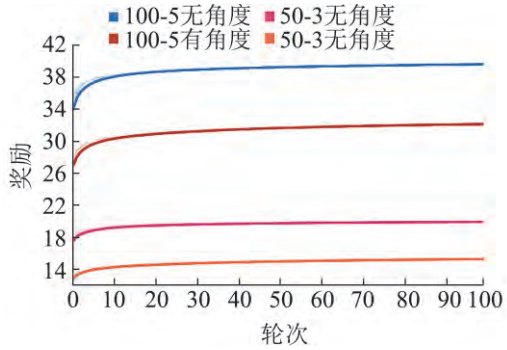


图9　不同场景下的训练收敛曲线

Fig. 9　Training convergence curves across different scenarios

4　结论

本文针对多约束无人机团队定向问题，提出了一种基于注意力机制的强化学习高效求解方法。设计了一种多信息融合的动态注意力策略网络，实现静态与动态等多维信息的深度融合，并提出解码顺序重排的后处理机制，提升了策略表达能力与求解质量；引入可视图法对威胁区进行几何建模，简化了环境表示并加快了训练收敛速度。实验结果表明：本文方法能够在极短的推理时间内生成高质量解，在解的总奖励上可达到甚至超过传统优化求解器的性能水平，并且训练效率极大提升，验证了在求解速度、质量、训练效率的综合优势。

未来，将进一步探索三维与动态场景。从“顶点”扩展至棱/面斯坦纳点集合，结合中轴结构生成稀疏关键点集，并考虑动态障碍物，以提升本文方法在复杂环境下的适用性与鲁棒性。

参考文献：

[1] Tordesillas J, How J P. PANTHER: Perception-aware Trajectory Planner in Dynamic Environments[J]. IEEE Access, 2022, 10: 22662-22677.

[2] 宁聪, 范菁, 孙书魁. 多无人机协同规划研究综述[J]. 计算机工程与应用, 2025, 61(1): 42-58.
Ning Cong, Fan Jing, Sun Shukui. Review of Multi-UAV Collaborative Planning Research[J]. Computer Engineering and Applications, 2025, 61(1): 42-58.

[3] Lorena S Reyes-Rubiano, Carlos F Ospina-Trujillo,

中国知网　https://www.cnki.net

Javier Faulin, et al. The Team Orienteering Problem with Stochastic Service Times and Driving-range Limitations: A Simheuristic Approach[C]//2018 Winter Simulation Conference (WSC). Piscataway: IEEE, 2018: 3025-3035.

[4] Chung K T, Lee C K M, Tsang Y P. Neural Combinatorial Optimization with Reinforcement Learning in Industrial Engineering: A Survey[J]. Artificial Intelligence Review, 2025, 58(5): 130.

[5] Jiang Mingyang, Li Yueyuan, Zhang Songan, et al. HOPE: A Reinforcement Learning-based Hybrid Policy Path Planner for Diverse Parking Scenarios[J]. IEEE Transactions on Intelligent Transportation Systems, 2025, 26(5): 6130-6141.

[6] Kool W, Van Hoof H, Welling M. Attention, Learn to Solve Routing Problems! [C]//International Conference on Learning Representations. New Orleans, LA, USA: OpenReview.net, 2019: 1-14.

[7] Kris Braekers, Katrien Ramaekers, Inneke Van Nieuwenhuyse. The Vehicle Routing Problem: State of the Art Classification and Review[J]. Computers & Industrial Engineering, 2016, 99: 300-313.

[8] Cai Junchuang, Zhang Xinzhi, Lin Qiuzhen, et al. Deep Reinforcement Learning for Solving the Vehicle Routing Problem in Practical Logistics[C]//2024 IEEE Congress on Evolutionary Computation (CEC). Piscataway: IEEE, 2024: 1-8.

[9] Kanchan Rajwar, Kusum Deep, Swagatam Das. An Exhaustive Review of the Metaheuristic Algorithms for Search and Optimization: Taxonomy, Applications, and Open Challenges[J]. Artificial Intelligence Review, 2023, 56(11): 13187-13257.

[10] Federico Berto, Hua Chuanbo, Junyoung Park, et al. RL4CO: An Extensive Reinforcement Learning for Combinatorial Optimization Benchmark[EB/OL]. (2023-06-29) [2025-06-01]. https://arxiv.org/abs/2306.17100v1.

[11] Nina Mazyavkina, Sergey Sviridov, Sergei Ivanov, et al. Reinforcement Learning for Combinatorial Optimization: A Survey[J]. Computers & Operations Research, 2021, 134: 105400.

[12] Fadi AlMahamid, Katarina Grolinger. Agile DQN: Adaptive Deep Recurrent Attention Reinforcement Learning for Autonomous UAV Obstacle Avoidance[J]. Scientific Reports, 2025, 15(1): 18043.

[13] He Yong, Hou Ticheng, Wang Mingran. A New Method for Unmanned Aerial Vehicle Path Planning in Complex Environments[J]. Scientific Reports, 2024, 14(1): 9257.

[14] Pieter Vansteenwegen, Wouter Souffriau, Dirk Van Oudheusden. The Orienteering Problem: A Survey[J]. European Journal of Operational Research, 2011, 209(1): 1-10.

[15] Darko Drakulic, Sofia Michel, Florian Mai, et al. BQ-NCO: Bisimulation Quotienting for Efficient Neural Combinatorial Optimization[C]//Proceedings of the 37th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2023: 77416-77429.

[16] Federico Berto, Hua Chuanbo, Laurin Luttmann, et al. PARCO: Learning Parallel Autoregressive Policies for Efficient Multi-agent Combinatorial Optimization[EB/OL]. (2024-09-05) [2025-06-01]. https://arxiv. org/abs/2409.03811v1.

[17] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 6000-6010.

[18] 王扬, 陈智斌, 吴兆蕊, 等. 强化学习求解组合最优化问题的研究综述[J]. 计算机科学与探索, 2022, 16(2): 261-279.
Wang Yang, Chen Zhibin, Wu Zhaorui, et al. Review of Reinforcement Learning for Combinatorial Optimization Problem[J]. Journal of Frontiers of Computer Science & Technology, 2022, 16(2): 261-279.

[19] Irwan Bello, Hieu Pham, Quoc V Le, et al. Neural Combinatorial Optimization with Reinforcement Learning[EB/OL]. (2016-11-29) [2025-06-01]. https://arxiv.org/abs/1611.09940v1.

[20] Márcio da Silva Arantes, Jesimar da Silva Arantes, Claudio Fabiano Motta Toledo, et al. A Hybrid Multi-population Genetic Algorithm for UAV Path Planning [C]//Proceedings of the Genetic and Evolutionary Computation Conference 2016. New York: ACM, 2016: 853-860.

[21] Jiří Bittner, Peter Wonka. Visibility in Computer Graphics [J]. Environment and Planning B: Planning and Design, 2003, 30(5): 729-755.

[22] Zhao Jiuxia, Mao Minjia, Zhao Xi, et al. A Hybrid of Deep Reinforcement Learning and Local Search for the Vehicle Routing Problems[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(11): 7208-7218.

[23] Pieter Vansteenwegen, Wouter Souffriau, Greet Vanden Berghe, et al. Iterated Local Search for the Team Orienteering Problem with Time Windows[J]. Computers & Operations Research, 2009, 36(12): 3281-3290.

[24] Wouda N A, Lan L, Kool W. PyVRP: : A High-performance VRP Solver Package[J]. Informs Journal on Computing, 2024, 36(4): 943-955.

[25] Saeid Nahavandi, Roohallah Alizadehsani, Darius

中国知网 https://www.cnki.net

Nahavandi, et al. A Comprehensive Review on Autonomous Navigation[J]. ACM Computing Surveys, 2025, 57(9): 234.

[26] Li Sirui, Yan Zhongxia, Wu C. Learning to Delegate for Large-scale Vehicle Routing[C]//Proceedings of the 35th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2021: 26198-26211.

中国知网 https://www.cnki.net