改进型深度确定性策略梯度的无人机路径规划

张森，代强强
(河南科技大学 信息工程学院，河南 洛阳 471023)

摘要：针对无人机在复杂环境下进行路径规划时，存在收敛性差和无效探索等问题，提出一种改进型深度确定性策略梯度(deep deterministic policy gradient，DDPG)算法。采用双经验池机制，分别存储成功经验和失败经验，算法能够利用成功经验强化策略优化，并从失败经验中学习避免错误路径；引入人工势场法为规划增加引导项，与随机采样过程中的探索噪声动作相结合，对所选动作进行动态整合；通过设计组合奖励函数，采用方向、距离、障碍躲避及时间奖励函数实现路径规划的多目标优化，并解决奖励稀疏问题。实验结果表明：该算法的奖励和成功率能够得到显著提高，且能够在更短的时间内达到收敛。

关键词：无人机；深度强化学习；路径规划；深度确定性策略梯度；人工势场法

中图分类号：TP273 文献标志码：A 文章编号：1004-731X(2025)04-0875-07

DOI: 10.16182/j.issn1004731x.joss.23-1524

引用格式: 张森, 代强强. 改进型深度确定性策略梯度的无人机路径规划[J]. 系统仿真学报, 2025, 37(4): 875-881.

Reference format: Zhang Sen, Dai Qiangqiang. UAV Path Planning Based on Improved Deep Deterministic Policy Gradients[J]. Journal of System Simulation, 2025, 37(4): 875-881.

UAV Path Planning Based on Improved Deep Deterministic Policy Gradients

Zhang Sen, Dai Qiangqiang

(College of Information Engineering, Henan University of Science and Technology, Luoyang 471023, China)

Abstract: Aiming at the problems of poor convergence and invalid exploration when UAVs perform path planning in complex environments, an improved deep deterministic policy gradient(DDPG) algorithm is proposed. *Using a dual experience pooling mechanism to store success and failure experiences separately, the algorithm is able to use the success experience to strengthen the strategy optimization and learn from the failure experience to avoid the wrong path; an APF method is introduced to add a bootstrap term to the planning, which is combined with the exploration of noisy actions in a randomized sampling process to dynamically integrate the selected actions; multi-objective optimization of path planning is achieved by designing combinatorial reward functions using direction, distance, obstacle avoidance and time reward functions and solving the reward sparsity problem.* Experiments show that the proposed algorithm can significantly improve the reward and success rate and reach convergence in a shorter time.

Keywords: UAV; DRL; path planning; deep deterministic policy gradient(DDPG); APF

0 引言

多旋翼无人机因其简单的机械结构、优秀的机动性，以及可在狭小杂乱的区域内进行垂直起飞、垂直降落、悬停或移动的能力而被应用于救援[1-2]、农业作业[3-4]、环境勘探[5]、物流[6-7]和工业

收稿日期：2023-12-13 修回日期：2024-01-17
基金项目：国家自然科学基金(62271193, 61304144)；河南省自然科学基金(222300420433)
第一作者：张森(1984-)，男，副教授，博士，研究方向为先进机器人与智能控制技术。

中国知网 https://www.cnki.net

检测[8-9]等领域。在这些应用中，无人机的路径规划成为工程实践中亟待解决的首要问题，受到国内外许多学者深入研究。

面对复杂和不确定的环境，研究者们已经提出了多种算法来解决无人机导航问题。Chai 等[10]提出了一种多策略融合差分进化算法，集成了多群体策略、自适应策略和交互式变异策略，以平衡开发和探索能力；采用多种群策略，将整个种群划分为3个指标子种群和1个奖励子种群，以保持整个种群的多样性，使算法能够在复杂环境中快速收敛，并保持稳定运行。Yan 等[11]提出了一种可靠的人工势场模型，用于多无人机系统在复杂环境下的路径规划，提供了一种无人机节能的方法以及解决无人机局部最小化问题的求解方法。Zu 等[12]将猎食者优化算法与任务分配机制相结合，将路径规划问题转化为多约束优化问题，实现了多无人机针对复杂任务的协同路径规划，能保证在复杂环境下无人机路径规划的实时灵活性和鲁棒性。然而，在实际工程中，由于模型不匹配、测量手段不充分、精确成本高，以及模型迁移等因素的限制，精确获取无人机动力学模型变得十分困难。所以，这些基于模型的策略在实践中很难应用于复杂的不确定环境。

DRL 不依赖于环境模型和先验知识，可有效解决未知环境下的无人机路径规划问题。它摆脱了对精确环境模型或预先获得的知识的依赖，在处理无人机导航时具有显著的优势，能够更灵活地适应各种未知和动态的环境条件。Xue 等[13]将无人机的感知约束导航建模为部分可观测马尔可夫决策过程，并设计了一种基于 actor-critic 框架的快速循环随机值梯度算法用于在线求解，能够使无人机在未知的杂乱环境中安全导航。Zhao 等[14]提出了一种结合状态分裂和最优状态的双 DQN 状态分裂 Q 网络算法，通过将多维状态信息进行分类存储，并通过有针对性的训练获取最优路径信息。Zhang 等[15]提出了一种新的目标更新算法，通过自适应确定待到达的航点，将 HL-DRL 训练模块与全局规划模块相结合，使无人机能够在较短的重新规划时间内快速适应环境变化。然而，在复杂环境下，仍然存在收敛速度慢和奖励稀疏的问题。

本文提出了一种改进型 DDPG 算法，首先，引入了双经验池来存储数据，有助于提高经验数据的可学习性，增加数据质量，加快算法的收敛速度。其次，通过结合 APF 法改善动态动作选择策略，并设计组合奖励函数来解决奖励稀疏的问题。

1 无人机路径规划模型构建

1.1 状态空间设定

无人机的状态空间代表了在做出决策之前无人机可以获得的有价值信息，可帮助无人机评估当前的情况[16]。为了训练跟踪决策模型，无人机状态空间为

$$S_t=[P_{\mathrm{u}},P_{\mathrm{o}},P_{\mathrm{g}},\boldsymbol{v}_t,d_{\mathrm{r}},d_{\mathrm{ug}}] \tag{1}$$

式中：P_{u}为无人机的位置；P_{o}为障碍物的位置；P_{g}为目标点的位置；$\boldsymbol{v}_t$为无人机的速度；d_{r}为无人机和障碍物的距离；d_{ug}为无人机和目标点的距离。

1.2 动作选取策略设计

在复杂未知的环境中进行路径规划时，如果在初始阶段采用随机的动作选择策略来训练智能体，那么该智能体很容易陷入大量无效的探索，导致奖励稀疏问题，从而难以有效收敛。为了应对这一问题，本文提出了一种动态动作选择策略。使用 APF 法计算出一个指导轨迹Δr，将其作为引导项，为无人机提供一个参考的动作探索方向。将引导项与随机采样的带有 DRL 算法探索噪声的动作项相结合，对所选动作进行动态整合。这种动态组合后的新动作可以表述为

$$\beta=e^{-\eta E_{\mathrm{cur}}} \tag{2}$$

$$a_{t+1}=(1-\beta)a_t+\beta\Delta r \tag{3}$$

式中：β为比例因子；E_{cur}为当前训练集数；

中国知网 https://www.cnki.net

$\eta\in(0,1)$为常数且满足；a_t为t状态下带噪音的动作。

新的动作选择策略使无人机在初始训练阶段能够更有针对性地选择动作，从而避免了无效探索，解决了奖励稀疏性问题。随着训练集数量的增加，比例因子的值逐渐减小，导致引导项在动态动作中所占比例逐渐减小，而随机采样动作所占比例逐渐增大，无人机的动作选择逐渐随机化。

1.3 奖励函数设计

为了应对在复杂环境下进行轨迹规划时的奖励稀疏问题[17]，本文提出了一种结合APF思想的组合奖励函数。组合奖励函数由3个标量函数组成：

$$R=R_{\mathrm{g}}+R_{\mathrm{o}}+R_{\mathrm{t}} \tag{4}$$

式中：R_{g}为目标吸引奖励函数；R_{o}为障碍拒绝奖励函数；R_{t}为时间奖励函数。

1.3.1 目标吸引奖励函数

传统APF引导机器人到达目标位置并避免障碍物，本文通过引力势场的概念来设计目标吸引奖励函数：

$$R_{\mathrm{g}}=R_{\mathrm{dis}}+R_{\mathrm{dir}} \tag{5}$$

式中：R_{dis}为距离奖励函数；R_{dir}为方向奖励函数。

为了确保无人机在路径规划过程中持续向目标前进，引入R_{dir}。首先，计算无人机当前位置和目标点的直线方向向量$\boldsymbol{v}_1$，再求出无人机运动方向的方向向量$\boldsymbol{v}_2$。计算当前时刻下$\boldsymbol{v}_1$和$\boldsymbol{v}_2$的夹角ω_t，将ω_t和下一时刻夹角ω_{t+1}比较。

$$\cos(\omega_t)=\frac{\boldsymbol{v}_1\cdot\boldsymbol{v}_2}{\|\boldsymbol{v}_1\|\cdot\|\boldsymbol{v}_2\|} \tag{6}$$

$$\omega_t=\arccos\left(\frac{\boldsymbol{v}_1\cdot\boldsymbol{v}_2}{\|\boldsymbol{v}_1\|\cdot\|\boldsymbol{v}_2\|}\right) \tag{7}$$

$$\Delta\omega=\omega_{t+1}-\omega_t \tag{8}$$

若$\Delta\omega<0$，说明无人机在当前状态下选取的动作策略是正确的，系统将会给予小额奖励。若$\Delta\omega=0$，说明无人机运动方向是当前状态下最优的，系统将给予较大奖励。若$\Delta\omega>0$，说明无人机正在偏离正确航向，系统将给予小额惩罚。

$$R_{\mathrm{dir}}=\begin{cases}-k_1\Delta\omega, & \Delta\omega>0\\ k_2, & \Delta\omega=0\\ -k_3\Delta\omega, & \Delta\omega<0\end{cases} \tag{9}$$

式中：$k_1,k_2,k_3>0$为方向奖励系数。

方向奖励函数确保无人机的方向不偏离，而距离奖励函数R_{dis}则确保无人机可以成功到达目标点。无人机距离目标点位越近，奖励越高；当达到终点时，将获得最大奖励。

$$R_{\mathrm{dis}}=d_0/(d_0+d_{\mathrm{c}})k_4 \tag{10}$$

式中：d_0为初始状态下无人机到达目的地位置所需的距离；d_{c}为当前状态下无人机到达目的地所需的距离；$k_4>0$为距离奖励系数。

1.3.2 障碍奖励函数

在没有障碍的情况下，无人机的最优路径通常沿着起始点直线向目标点移动。然而，在实际飞行中会面临许多阻碍飞行的因素。因此，本文引入障碍奖励函数R_{o}，以确保无人机在保持最短路径的同时能够避开障碍物，安全到达目标点。设置无人机的位置$P_{\mathrm{u}}=(x_{\mathrm{u}},y_{\mathrm{u}},z_{\mathrm{u}})$，障碍物的位置为$P_{\mathrm{o}}=(x_{\mathrm{o}},y_{\mathrm{o}},z_{\mathrm{o}})$，即可求出当前无人机到障碍物的距离$d_{\mathrm{r}}$。障碍物斥力场的作用范围并非无限远，而是有一个最大影响距离$d_{\max}$，超出这个范围，障碍物对无人机无影响。当无人机进入斥力场时，为了防止碰撞，系统会施加惩罚。若无人机不慎碰撞到障碍物，系统将施加较大的惩罚，将其视为任务失败。

$$d_{\mathrm{r}}=\sqrt{(x_{\mathrm{u}}-x_{\mathrm{o}})^2+(y_{\mathrm{u}}-y_{\mathrm{o}})^2+(z_{\mathrm{u}}-z_{\mathrm{o}})^2} \tag{11}$$

$$R_{\mathrm{o}}=\begin{cases}0, & d_{\mathrm{r}}>d_{\max}\\ -k_5e^{-d_{\mathrm{r}}}, & d_{\min}\leqslant d_{\mathrm{r}}\leqslant d_{\max}\\ -k_6, & d_{\mathrm{r}}<d_{\min}\end{cases} \tag{12}$$

式中：$d_{\min}$为最小安全距离；$k_5>0$为障碍奖励系数；k_6为大于0的常数。

1.3.3 时间奖励函数

时间奖励函数的设定旨在确保无人机能够在最短时间内完成任务，提高其效率。为此，在系统中，随着时间的推移会施加一定的惩罚，时间

中国知网 https://www.cnki.net

奖励函数为

$$R_t=-k_7 t_{\mathrm{u}} \tag{13}$$

式中：t_{u}为无人机路径规划所用时间；$k_7>0$为时间奖励系数。

2 双池DDPG算法描述

在无人机进行路径规划时，生成路径容易陷入局部最优，并且单个经验池中的数据对于无人机的学习效果不够显著。使用双经验池替代单一经验池，将经验数据分别存储，有助于提高算法的收敛速度，保证数据的质量。该算法包含2个经验池：失败经验池和成功经验池。失败经验池用于存储无人机路径规划失败的经验数据，其容量设置为M_{d}；成功经验池用于存储无人机路径规划成功的经验数据或者无人机成功躲避障碍的经验数据，容量设置为M_{s}。为了判断任务是否成功，设置了一个判断环节：如果即时奖励大于0，则任务被视为成功，将经验存入成功经验池，否则将其移至失败经验池。双池DDPG算法结构框图如图1所示。

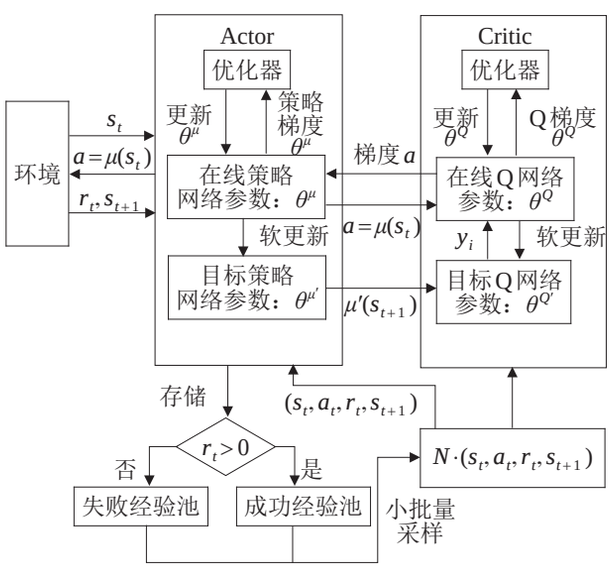


图1 双池DDPG算法结构框图

Fig. 1 Block diagram of structure of dual-pool DDPG algorithm

在进行小批量采样时，按照一定比例从2个经验池中采样，即使在路径规划过程中陷入局部最优，系统仍然能够从成功经验池中获取成功的经验数据进行学习，有助于迅速脱离局部最优。算法的流程如算法1所示。

算法1 双池DDPG伪代码

使用权重θ^{Q}和θ^{μ}随机初始化Critic网络$Q(s,a|\theta^{Q})$和Actor网络$\mu(s|\theta^{\mu})$。使用权重$\theta^{Q'}\leftarrow\theta^{Q}$，$\theta^{\mu'}\leftarrow\theta^{\mu}$初始化目标网络$Q'$和$\mu'$。初始化失败经验池$P_{\mathrm{d}}$和成功经验池$P_{\mathrm{s}}$

for episode =1 ~ M do

为行动探索初始化一个随机进程N

得到初始观测状态s_1

for t = 1, T do

根据当前策略、引导项和添加探索噪音来选择动作

$$a_t=\mu(s_t|\theta^{\mu})+N_t$$

满足$a_{t+1}=(1-\beta)a_t+\beta\Delta r$

执行动作a_t，获取即时奖励r_t，然后观测新状态s_{t+1}

if $r_t\geqslant 0$ then

将经验(s_t, a_t, r_t, s_{t+1})存储在P_{s}

else

将经验(s_t, a_t, r_t, s_{t+1})存储在P_{d}

按比例β随机从经验池P_{s}和P_{d}中进行小批量采样

$$y_i=r_i+\gamma Q'(s_{i+1},\mu'(s_{i+1}|\theta^{\mu'})|\theta^{Q'})$$

使用最小化损失函数来更新批评网络

$$L=\frac{1}{N}\sum_i(y_i-Q(s_i,a_i|\theta^{Q}))^2$$

利用取样策略梯度更新行动者策略

$$\nabla_{\theta^{\mu}}J\approx\frac{1}{N}\sum_i\nabla_a Q(s,a|\theta^{Q})|_{s=s_i,a=\mu(s_i)}\nabla_{\theta^{\mu}}\mu(s|\theta^{\mu})|_{s_i}$$

更新目标网络

$$\theta^{Q'}\leftarrow\tau\theta^{Q}+(1-\tau)\theta^{Q'}$$

$$\theta^{\mu'}\leftarrow\tau\theta^{\mu}+(1-\tau)\theta^{\mu'}$$

end for

end for

中国知网 https://www.cnki.net

假设采样比例为γ，采取经验总量为S，则对失败经验池和成功经验池采样的数据量为

$$\begin{cases} s_1=\gamma S \\ s_2=S-s_1 \end{cases} \tag{14}$$

式中：s_1为从成功经验池采取的数据；s_2为从失败经验池采取的数据。

3 无人机路径规划仿真验证

本文算法是基于 Python 环境、使用 PyTorch 2.0 和 CUDA 11.1 框架构建的。在训练过程中，采用 Adam 优化器来更新 Actor-Critic 网络的参数，具体的训练参数如表 1 所示。设置最大训练轮数为$E_{\max}$，小批量采样容量为 100。为验证本文算法的可行性和有效性，设计实验验证。通过与原 DDPG 算法同时进行实验，测得平均奖励(一个训练集中所有步骤的平均奖励)和成功率(最近 50 次到达终点的概率)，再设置新的障碍环境测试算法的泛化性。为了简化建模，将工厂复杂环境中的各个障碍物替换为圆柱体、球和长方体。在环境设置时，将会随机生成起始点、目标点和障碍物的个数和位置，环境空间为 100 m×100 m×100 m。分别使用本文算法和原 DDPG 算法进行测试，测试结果如图 2~3 所示。

表 1　训练参数设置

Table 1　Training parameter settings

参数	数值	参数	数值
学习率	0.001	k_1	0.3
折扣因子	0.9	k_2	10
$E_{\max}$	1 000	k_3	0.3
最大步长	500	k_4	15
P_s	100 000	k_5	5
P_d	100 000	k_6	50
η	0.02	k_7	1

由图 2 可知，在训练完成后，本文算法的平均奖励达到了 65.7，而原始 DDPG 算法的平均奖励仅为 60.8。这表明，在相同的环境下进行路径规划时，原 DDPG 算法的奖励直到 300 轮后才收敛到最大值，收敛速度较低，而且在前期探索过程，奖励曲线有一段下降，说明奖励稀疏，无人机很难选取到有价值的动作；而本文提出的算法能够获得更高的奖励，并且更快地找到最优动作。

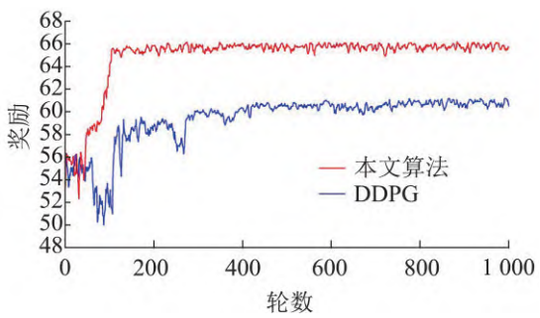


图 2　两种算法所获得的奖励

Fig. 2　Rewards obtained by two algorithms

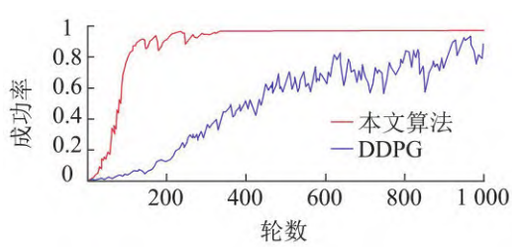


图 3　两种算法训练时的成功率

Fig. 3　Success rate of both algorithms during training

值得注意的是，在训练 100 到 200 轮数时，原 DDPG 算法一直收敛到一个相对较小的值，即在训练过程中陷入了局部最优，影响了算法的收敛速度，而改进型 DDPG 算法在达到最优前，一直处于上升状态，并未陷入局部最优。动作选择具有一定的探索性随机性，导致无人机在前期经历较大波动。然而，通过持续的训练和学习，系统逐渐学会了谨慎，使得在收敛后趋于稳定。

为验证训练后的无人机在新环境中是否具备环境泛化能力，将之前训练的无人机应用到一个更具挑战性的环境中进行测试，该环境中障碍物更加密集，避障更加困难。

图 4 和图 5 分别为在新复杂环境下 2 种算法经过测试后的奖励和成功率。由图 4 可知，本文算法最终获得了 59.8 的奖励，而原始 DDPG 算法仅

中国知网 https://www.cnki.net

获得了56.1。从图5可以看出，本文算法表现出更高且更稳定的成功率。图6为路径规划的测试图。结果表明：本文算法和原始DDPG算法都具有良好的环境泛化能力，但本文算法效果更佳，在实际验证时，可以获得更好的结果。

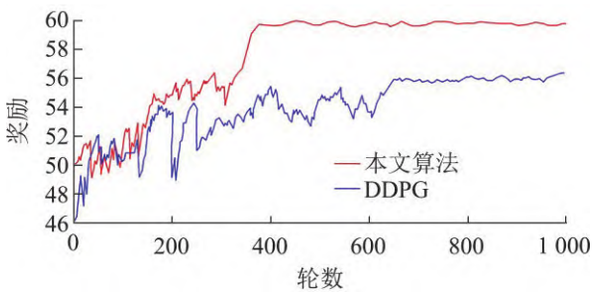


图4　新环境下两种算法获得的奖励

Fig. 4　Rewards obtained by two algorithms in new environment

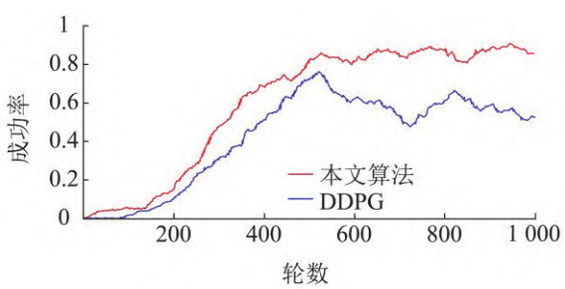


图5　新环境下两种算法的成功率

Fig. 5　Success rate of two algorithms in new environment

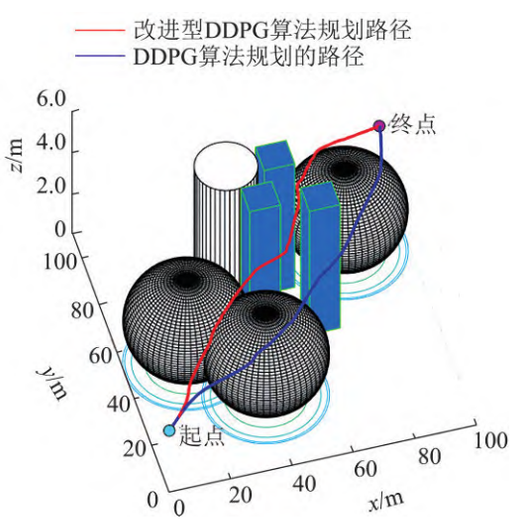


图6　路径规划

Fig. 6　Path planning

4　结论

本文提出了一种改进型DDPG算法，旨在应对无人机在复杂未知环境下路径规划时出现的收敛性差、无效探索和奖励稀疏的问题。通过成功经验池和失败经验池分别存储经验，确保了经验的质量，提高了可学习性，加速了算法的收敛速度。为解决无效探索和奖励稀疏问题，引入了人工势场法。使用人工势场法计算出一个指导轨迹，将动作选取结果作为引导项，为无人机提供一个参考的动作探索方向。将引导项与随机采样的带有深度强化学习算法探索噪声的动作项相结合，以改进动作选择策略。采用人工势场思想设计了组合奖励函数，包括目标吸引奖励函数、障碍奖励函数和时间奖励函数，有效解决了奖励稀疏的问题。实验证明了算法的可行性。

参考文献：

[1] Zhang Ming, Li Wei, Wang Mengmeng, et al. Helicopter-UAVs Search and Rescue Task Allocation Considering UAVs Operating Environment and Performance[J]. Computers & Industrial Engineering, 2022, 167: 107994.

[2] Xing Linjie, Fan Xiaoyan, Dong Yaxin, et al. Multi-UAV Cooperative System for Search and Rescue Based on YOLOv5[J]. International Journal of Disaster Risk Reduction, 2022, 76: 102972.

[3] Emmanuel K Raptis, Marios Krestenitis, Konstantinos Egglezos, et al. End-to-end Precision Agriculture UAV-based Functionalities Tailored to Field Characteristics[J]. Journal of Intelligent & Robotic Systems, 2023, 107 (2): 23.

[4] Zhou Maowu, Chen Hongbin, Shu Lei, et al. UAV-assisted Sleep Scheduling Algorithm for Energy-efficient Data Collection in Agricultural Internet of Things[J]. IEEE Internet of Things Journal, 2022, 9(13): 11043-11056.

[5] Saeid Asadzadeh, Wilson José de Oliveira, Carlos Roberto de Souza Filho. UAV-based Remote Sensing for the Petroleum Industry and Environmental Monitoring: State-of-the-art and Perspectives[J]. Journal of Petroleum Science and Engineering, 2022, 208, Part D: 109633.

[6] Lee H W. Research on Multi-functional Logistics Intelligent Unmanned Aerial Vehicle[J]. Engineering Applications of Artificial Intelligence, 2022, 116: 105341.

中国知网　https://www.cnki.net

[7] Lu Ziyi, Yu Na, Wang Xuehe. Incentive Mechanism and Path Planning for Unmanned Aerial Vehicle (UAV) Hitching over Traffic Networks[J]. Future Generation Computer Systems, 2023, 145: 521-535.

[8] Vincenzo Lippiello, Jonathan Cacace. Robust Visual Localization of a UAV over a Pipe-rack Based on the Lie Group SE(3)[J]. IEEE Robotics and Automation Letters, 2022, 7(1): 295-302.

[9] Liu Kangcheng, Chen B M. Industrial UAV-based Unsupervised Domain Adaptive Crack Recognitions: From Database Towards Real-site Infrastructural Inspections[J]. IEEE Transactions on Industrial Electronics, 2023, 70(9): 9410-9420.

[10] Chai Xuzhao, Zheng Zhishuai, Xiao Junming, et al. Multi-strategy Fusion Differential Evolution Algorithm for UAV Path Planning in Complex Environment[J]. Aerospace Science and Technology, 2022, 121: 107287.

[11] Yan Yuehao, Lü Zhiying, Yuan Jinbiao, et al. Obstacle Avoidance for Multi-UAV System with Optimized Artificial Potential Field Algorithm[J]. International Journal of Robotics and Automation, 2021, 36: 1-7.

[12] Zu Linan, Wang Zhipeng, Liu Cong, et al. Research on UAV Path Planning Method Based on Improved HPO Algorithm in Multitask Environment[J]. IEEE Sensors Journal, 2023, 23(17): 19881-19893.

[13] Xue Yuntao, Chen Weisheng. A UAV Navigation Approach Based on Deep Reinforcement Learning in Large Cluttered 3D Environments[J]. IEEE Transactions on Vehicular Technology, 2023, 72(3): 3001-3014.

[14] Zhao Jinduo, Gan Zhigao, Liang Jiakai, et al. Path Planning Research of a UAV Base Station Searching for Disaster Victims' Location Information Based on Deep Reinforcement Learning[J]. Entropy, 2022, 24(12): 1767.

[15] Zhang Sitong, Li Yibing, Ye Fang, et al. A Hybrid Human-in-the-loop Deep Reinforcement Learning Method for UAV Motion Planning for Long Trajectories with Unpredictable Obstacles[J]. Drones, 2023, 7(5): 311.

[16] 张云燕, 魏瑶, 刘昊, 等. 基于深度强化学习的端到端无人机避障决策[J]. 西北工业大学学报, 2022, 40(5): 1055-1064.
Zhang Yunyan, Wei Yao, Liu Hao, et al. End-to-end UAV Obstacle Avoidance Decision Based on Deep Reinforcement Learning[J]. Journal of Northwestern Polytechnical University, 2022, 40(5): 1055-1064.

[17] 文超, 董文瀚, 解武杰, 等. 基于解耦型MADDPG的无人机集群自主跟踪与避障[J]. 飞行力学, 2022, 40(6): 24-31.
Wen Chao, Dong Wenhan, Xie Wujie, et al. Autonomous Tracking and Obstacle Avoidance of UAV Swarms Based on Decomposed MADDPG[J]. Flight Dynamics, 2022, 40(6): 24-31.

中国知网 https://www.cnki.net